



Universidad
Nacional
de Córdoba



Facultad de Matemática,
Astronomía, Física y
Computación

Técnicas de simulación y discretización para la valoración de opciones barrera

por

Gonzalo A. Bordón

Presentado ante la **FACULTAD DE MATEMÁTICA, ASTRONOMÍA,
FÍSICA Y COMPUTACIÓN** como parte de los requerimientos para la ob-
tención del grado de Licenciatura en Ciencias de la Computación de la

UNIVERSIDAD NACIONAL DE CÓRDOBA

Abril, 2026

Directores: Dra. Noemí Patricia Kisbye



Técnicas de simulación y discretización para la valoración de opciones barrera
© 2026 by Gonzalo Agustín Bordón is licensed under Creative Commons
Attribution-ShareAlike 4.0 International

Certifico que el trabajo incluido en este documento es el resultado de tareas de investigación originales y que no ha sido presentado para optar a un título en ninguna otra Universidad o Institución.

Gonzalo A. Bordón

Agradecimientos

A mi directora de tesis, la Dra. Noemí Patricia Kisbye, por su inmensa paciencia, su guía experta y su dedicación a lo largo de todo este proyecto. Gracias por impulsarme a mantener el rigor matemático y analítico y por brindarme las herramientas necesarias para llevar a buen puerto esta investigación.

A la Facultad de Matemática, Astronomía, Física y Computación (FAMAF) y a la Universidad Nacional de Córdoba (UNC), por haberme brindado una educación pública, gratuita y de excelencia. A todos los profesores que, a lo largo de la carrera, me transmitieron su pasión por las Ciencias de la Computación y formaron mi criterio profesional.

A mis padres, Sandra Delia Fiore y Hector Omar Bordón, y a mi hermano, Martín Ezequiel Bordón, por su apoyo incondicional, por el inmenso esfuerzo que han hecho para que yo pueda llegar hasta acá y por ser mi pilar fundamental durante todos estos años. Este logro es tan mío como de ustedes.

A mis compañeros de cursada y muy especialmente a todo Tiesos FC, porque aunque son muchos para nombrarlos a cada uno, las incontables horas compartidas entre apuntes, algoritmos y mates hicieron que el camino universitario haya sido una experiencia inolvidable.

A mis amigos, todos aquellos que conocí en circunstancias tan peculiares y distintas pero especialmente a Nueva Chicago y todo El Descansadero (he aquí una mención a Juan Cruz Roldán y Nazareno Kohan Boc con quienes nos comprometimos en hacernos aparecer en algún escrito del otro), por cada baile, juego, ecuación, código, risa o momento compartido que me recuerdan que siempre hay algo más por aprender.

Un agradecimiento muy especial (y lleno de cariño) a Katherina Bordón e Inari Bordón. Gracias por hacerme compañía en las largas madrugadas frente a la pantalla, por su amor incondicional y por ser mi cable a tierra durante todo este proceso.

Finalmente, a todos aquellos que de una u otra forma contribuyeron a que este trabajo sea posible. ¡Muchas gracias!

Resumen

Esta tesis presenta métodos para la valoración y discretización de opciones barrera, derivados financieros cuyo pago depende de si el precio del activo subyacente cruza un nivel de barrera predeterminado durante la vida de la opción. Las opciones barrera son ampliamente utilizadas en los mercados financieros para la gestión de riesgos y estrategias de inversión debido a su menor costo en comparación con las opciones estándar.

Los objetivos principales de este trabajo son analizar e implementar métodos para la valoración de opciones barrera, con énfasis particular en las técnicas de discretización que capturan con precisión la condición de barrera. La metodología incluye: (1) el modelo continuo de Black-Scholes, que asume un comportamiento lognormal del precio del activo, permitiendo fórmulas cerradas para opciones barrera europeas y sentando las bases para simulaciones de Monte Carlo en el caso americano; (2) modelos discretos como el binomial y trinomial que analizan el conjunto completo de trayectorias posibles, abordando el problema de la subestimación o sobreestimación cuando la barrera no coincide con los nodos del árbol mediante estrategias con mallas adaptativas; y (3) la replicación estática, una técnica para cubrir opciones barrera mediante la construcción de un portafolio de opciones vanillas que reproduzca el mismo payoff bajo ciertas condiciones. Nos enfocamos tanto en opciones barrera de estilo europeo como americano.

Los resultados demuestran la efectividad de los esquemas de discretización propuestos para lograr valoraciones precisas manteniendo la eficiencia computacional. Comparamos el rendimiento de diferentes enfoques numéricos y analizamos sus propiedades de convergencia. El trabajo contribuye a la comprensión de métodos numéricos para la valoración de opciones exóticas y proporciona herramientas prácticas para la evaluación de riesgos financieros.

Palabras clave: opciones barrera, valoración de opciones, modelo de Black-Scholes, árboles binomiales y trinomiales, replicación estática, mallas adaptativas, derivados financieros.

Abstract

This thesis presents methods for the valuation and discretization of barrier options, financial derivatives whose payoff depends on whether the underlying asset price crosses a predetermined barrier level during the option's lifetime. Barrier options are widely used in financial markets for risk management and investment strategies due to their lower cost compared to standard options.

The main objectives of this work are to analyze and implement methods for pricing barrier options, with particular emphasis on discretization techniques that accurately capture the barrier condition. The methodology includes: (1) the continuous Black-Scholes model, which assumes a lognormal behavior of the asset price, allowing closed-form formulas for European barrier options and providing the foundation for Monte Carlo simulations in the American case; (2) discrete models such as binomial and trinomial trees that analyze the complete set of possible trajectories, addressing the problem of underestimation or overestimation when the barrier does not align with tree nodes through strategies using adaptive meshes; and (3) static replication, a technique for hedging barrier options by constructing a portfolio of vanilla options that reproduces the same payoff under certain conditions. We focus on both European and American-style barrier options.

The results demonstrate the effectiveness of the proposed discretization schemes in achieving accurate valuations while maintaining computational efficiency. We compare the performance of different numerical approaches and analyze their convergence properties. The work contributes to the understanding of numerical methods for exotic options pricing and provides practical tools for financial risk assessment.

Keywords: barrier options, option pricing, Black-Scholes model, binomial and trinomial trees, static replication, adaptive meshes, financial derivatives.

Índice general

Agradecimientos	I
Resumen	III
Abstract	IV
Glosario	V
Índice de figuras	X
Índice de código	XIII
1. Introducción	2
1.1. Motivación	2
1.2. El Problema de Valoración	3
1.2.1. Fórmulas Analíticas y sus Limitaciones	3
1.2.2. Desafíos Computacionales	3
1.3. Objetivos del Trabajo	3
1.3.1. Objetivo General	3
1.3.2. Objetivos Específicos	4
1.4. Contribuciones del Trabajo	4
1.5. Organización del Trabajo	5
2. Marco Teórico	6
2.1. Mercados de Derivados	6
2.1.1. Características de los Mercados de Derivados	6
2.1.2. Tipos de Derivados	6
2.2. Opciones Financieras	7
2.2.1. Opciones Call y Put	7
2.2.2. Opciones Europeas vs Americanas	7
2.2.3. Opciones Exóticas	7
2.3. Opciones Barrera	8
2.3.1. Clasificación de Opciones Barrera	8
2.3.2. Payoffs de Opciones Barrera	8
2.3.3. Relaciones de Paridad	9
2.3.4. Rebates	9
2.3.5. Ventajas de las Opciones Barrera	9
2.4. El Modelo de Black-Scholes	9
2.4.1. Supuestos del Modelo	10

2.4.2.	Ecuación Diferencial de Black-Scholes	10
2.4.3.	Medida Neutral al Riesgo	10
2.4.4.	Fórmula de Black-Scholes para Opciones Vanilla	11
2.4.5.	Las Griegas	11
2.4.6.	Limitaciones del Modelo	12
2.5.	Extensiones del Modelo Black-Scholes	12
3.	Métodos de Valoración	13
3.1.	Método 1: Fórmulas Analíticas de Reiner y Rubinstein	13
3.1.1.	Marco Metodológico de Valoración	13
3.1.2.	Términos de Valoración	15
3.1.3.	Interpretación de los Términos de Valoración	15
3.1.4.	Fórmulas Exactas: Construcción mediante Términos de Valoración	17
3.2.	Método 2: Modelo de Malla Adaptativa (AMM)	19
3.2.1.	El Problema de la Discretización en Opciones Barrera	19
3.2.2.	Fundamentos: Árboles Trinomiales	20
3.2.3.	Análisis de Errores en Modelos de Redes	22
3.2.4.	Principio del Modelo de Malla Adaptativa	23
3.2.5.	AMM para Opciones Vanilla	25
3.2.6.	AMM para Opciones Barrera	27
3.2.7.	AMM para el Cálculo de Griegas	30
3.2.8.	Ventajas del AMM	33
3.2.9.	Consistencia Matemática	34
3.3.	Método 3: Replicación Estática	35
3.3.1.	Concepto de Replicación Estática	35
3.3.2.	Metodología de Derman-Ergener-Kani	36
3.3.3.	Construcción del Portafolio	38
3.4.	Método 4: Monte Carlo para Opciones Americanas	40
3.4.1.	Desafío de las Opciones Americanas	40
3.4.2.	Simulación de Monte Carlo	40
3.4.3.	Método de Longstaff-Schwartz (LSM)	42
3.4.4.	Ventajas y Limitaciones del Método LSM	44
3.4.5.	Comparación con Otros Métodos	45
4.	Implementaciones	46
4.1.	Fórmulas de Reiner y Rubinstein	46
4.1.1.	Descripción de la Implementación	46
4.1.2.	Detalles de Implementación	46
4.1.3.	Cálculo de Griegas	48
4.1.4.	Validación	49
4.2.	Árboles Trinomiales con Mallas Adaptativas	51
4.2.1.	Descripción del Algoritmo	51
4.2.2.	Detalles de Implementación	56
4.2.3.	Validación	59
4.3.	Replicación Estática	61
4.3.1.	Descripción del Algoritmo	61
4.3.2.	Detalles de Implementación	62
4.3.3.	Validación del Portafolio Replicante	62
4.4.	Monte Carlo para Opciones Americanas	64

4.4.1. Descripción del Algoritmo Implementado	64
4.4.2. Detalles de Implementación	66
4.4.3. Validación de Monte Carlo	67
5. Resultados y Comparación	70
5.1. Diseño de Experimentos	70
5.1.1. Casos de Prueba para Opciones Europeas	70
5.1.2. Casos de Prueba para Opciones Americanas	71
5.1.3. Métricas de Evaluación	71
5.2. Resultados para Opciones Europeas	71
5.2.1. Superando el “Problema del Límite”: Trinomial Estándar vs. AMM	71
5.2.2. Convergencia y Costo de la Replicación Estática	73
5.2.3. Comparación Unificada: Precisión Numérica frente a Via- bilidad de Mercado	74
5.3. Resultados para Opciones Americanas	74
5.3.1. Estimación del Valor de Continuación (LSM)	74
5.3.2. Análisis de Convergencia Estadística	75
5.4. Comparación Global de Métodos	76
5.4.1. Resumen de Desempeño	76
5.4.2. Casos de Uso Óptimos	77
5.4.3. Recomendaciones Prácticas	78
5.5. Discusión	79
5.5.1. Ventajas y Desventajas Observadas	79
5.5.2. Limitaciones del Estudio	80
6. Conclusiones y Trabajo Futuro	81
6.1. Resumen de Resultados	81
6.2. Conclusiones Principales	82
6.2.1. Sobre los Métodos para Opciones Europeas	82
6.2.2. Sobre Monte Carlo para Opciones Americanas	82
6.2.3. Comparación Global	82
6.3. Trabajo Futuro	83
6.3.1. Extensiones del Modelo	83
6.3.2. Extensiones de los Métodos	83
6.3.3. Aplicaciones Prácticas y Validación Empírica	84
Bibliografía	86

Índice de figuras

3.1.	Estructura de un árbol trinomial con 3 pasos temporales. Desde cada nodo, el precio puede moverse hacia arriba (multiplicado por $u = 1,15$, verde), mantenerse (multiplicado por $m = 1$, azul), o bajar (multiplicado por $d = 1/u \approx 0,870$, rojo). Las probabilidades neutrales al riesgo son $p_u = 0,25$, $p_m = 0,50$, $p_d = 0,25$. El árbol es recombinante: los nodos que alcanzan el mismo precio se fusionan.	22
3.2.	Detalle del efecto par-impar en el modelo binomial. Los puntos azules (N par) sistemáticamente tienen mayor error que los puntos rojos (N impar). Las líneas punteadas muestran las tendencias separadas para cada caso. Esta oscilación es causada por el error de no linealidad y es eliminada por el AMM.	23
3.3.	Concepto del Modelo de Malla Adaptativa (AMM). Se muestra un árbol trinomial base (nodos grises, conexiones grises) que constituye la malla gruesa con pasos de precio h y tiempo k . Sobre este árbol se injerta una malla fina (cuadrados verdes pequeños) con pasos $h/2$ y $k/4$ únicamente en la región crítica (rectángulo amarillo). Esta estrategia concentra la resolución computacional donde más se necesita, logrando alta precisión con costo mínimo adicional ($< 1\%$).	25
3.4.	Estructura del AMM para opciones vanilla. Se muestra un árbol trinomial (nodos grises con conexiones grises) que constituye la malla gruesa. Sobre este árbol se injerta una malla fina (cuadrados verdes pequeños) con pasos $h/2$ y $k/4$ únicamente en la región crítica (rectángulo amarillo): temporal $[T-k, T]$ y espacial $[K-2h, K+2h]$. La línea azul punteada marca el strike K donde ocurre la mayor no linealidad al vencimiento. Esta estrategia concentra la resolución donde más se necesita: alrededor del precio de ejercicio al vencimiento.	26
3.5.	Estructura del AMM para opciones barrera. Mostrar el árbol completo con una banda vertical de malla fina a lo largo de toda la dimensión temporal, centrada en la barrera H . La barrera debe aparecer como una línea horizontal clara. Indicar la región $[H-2h, H+2h]$ con sombreado o color. Mostrar S_0 cerca de H para ilustrar el problema del límite. Incluir flechas mostrando el flujo de información de malla gruesa a malla fina.	29

3.6. Ramificación cuadrinomial para el cálculo de griegas mediante diferencias finitas. Se muestra un árbol trinomial base (nodos grises, conexiones negras gruesas) con nodos adicionales en $t = 0$ ubicados en $S_0 + \varepsilon$ (verde) y $S_0 - \varepsilon$ (rojo), donde $\varepsilon = h/4$ es una perturbación pequeña. Las líneas sólidas grises representan ramificación cuadrinomial (4 ramas) desde los nodos perturbados y los nodos extremos en $t = k/4$, permitiendo calcular simultáneamente Delta y Gamma con alta precisión.	31
3.7. Precisión en el cálculo de Delta mediante ramificación cuadrinomial. Se compara el RMSE en Delta para diferentes configuraciones AMM $(0, T)$, donde 0 es el inicio de la opción y T es el final de la misma. La ramificación cuadrinomial permite calcular Delta mediante diferencias finitas. AMM (3,3) logra una mejora de 60x vs Trinomial en $N=100$, con un incremento de tiempo $< 3\%$. Notablemente, AMM (1,0) mejora Delta sin costo adicional al refinar solo la región crítica.	32
3.8. Precisión en el cálculo de Gamma mediante ramificación cuadrinomial. Se compara el RMSE en Gamma para diferentes configuraciones AMM. La ramificación cuadrinomial permite calcular Gamma mediante diferencias finitas de segundo orden. AMM (1,1) logra una mejora de 7.2x vs Trinomial en $N=100$. A diferencia de Delta, Gamma no mejora significativamente con niveles superiores a (2,2), lo que sugiere que AMM (1,1) es óptimo para este cálculo. El incremento en tiempo es $< 3\%$	33

Índice de códigos

4.1. Términos de RR	47
4.2. Cálculo de pasos de tiempo enteros (Eq. 17)	58
4.3. Cálculo dinámico de probabilidades para nodos de interfaz	58

ÍNDICE DE CÓDIGOS

Capítulo 1

Introducción

Las opciones barrera son instrumentos derivados ampliamente utilizados en los mercados financieros modernos. Su popularidad se debe principalmente a dos factores: son significativamente más baratas que las opciones vanilla equivalentes y permiten a los inversores y empresas cubrir riesgos específicos de manera más eficiente.

A diferencia de las opciones europeas estándar, cuyo valor depende únicamente del precio del activo subyacente al vencimiento, las opciones barrera tienen una característica adicional: su existencia depende de si el precio del activo cruza o no un nivel predeterminado (la barrera) durante la vida del contrato. Esta dependencia de la trayectoria completa del precio, y no solo de su valor final, introduce complejidades significativas en su valoración.

1.1. Motivación

Las opciones barrera se utilizan en diversos contextos financieros:

- **Gestión de riesgos corporativos:** Una empresa exportadora puede usar una opción barrera para protegerse contra movimientos adversos del tipo de cambio, pero solo si estos superan un umbral crítico para su operación.
- **Productos estructurados:** Los bancos de inversión incorporan opciones barrera en productos estructurados para ofrecer perfiles de riesgo-retorno específicos a menor costo.
- **Especulación dirigida:** Los traders pueden expresar visiones de mercado sofisticadas (por ejemplo, 'el activo subirá pero no superará cierto nivel') con menor capital que usando opciones vanilla.
- **Optimización de costos:** Las opciones barrera permiten obtener cobertura a un costo significativamente menor que las opciones estándar, lo que las hace atractivas para empresas con presupuestos limitados.

1.2. El Problema de Valoración

1.2.1. Fórmulas Analíticas y sus Limitaciones

Bajo el modelo de Black-Scholes con monitoreo continuo de la barrera, existen fórmulas cerradas para valorar opciones barrera europeas, desarrolladas por Reiner y Rubinstein (1991). Estas fórmulas son matemáticamente elegantes y computacionalmente eficientes.

Sin embargo, presentan limitaciones importantes en la práctica:

1. **Monitoreo discreto vs continuo:** En la realidad, las barreras se monitorean en momentos discretos (diariamente, o incluso solo al cierre del mercado), no continuamente. Esto puede generar diferencias significativas en el precio, especialmente para barreras cercanas al precio actual del activo.
2. **Volatilidad constante:** El supuesto de volatilidad constante es particularmente problemático para opciones de largo plazo o en mercados con alta variabilidad de la volatilidad.
3. **Salto en el precio:** El modelo no considera saltos discontinuos en el precio del subyacente, que pueden hacer que el precio 'salte' sobre la barrera sin tocarla, afectando significativamente la valoración.
4. **Barreras complejas:** Para barreras dependientes del tiempo, barreras dobles, o barreras parciales (monitoreadas solo en ciertos períodos), no existen fórmulas cerradas.

1.2.2. Desafíos Computacionales

Los métodos numéricos para valorar opciones barrera enfrentan desafíos específicos:

- **Sensibilidad cerca de la barrera:** El valor de la opción y sus derivadas (las 'griegas') cambian drásticamente cuando el precio del subyacente se aproxima a la barrera. Esto requiere una resolución muy fina en esa región.
- **Discontinuidades:** En el momento en que se toca la barrera, el valor de una opción knock-out cae abruptamente a cero (o al valor del rebate). Esta discontinuidad es difícil de capturar numéricamente.
- **Trade-off precisión-velocidad:** Métodos muy precisos pueden ser computacionalmente costosos, mientras que métodos rápidos pueden carecer de la precisión necesaria, especialmente para el cálculo de sensibilidades.

1.3. Objetivos del Trabajo

1.3.1. Objetivo General

Comparar sistemáticamente diferentes métodos numéricos para la valoración de opciones barrera europeas, evaluando su precisión, eficiencia computacional, y aplicabilidad en diferentes escenarios.

1.3.2. Objetivos Específicos

1. **Estudiar el modelo de Black-Scholes:** Analizar las fórmulas cerradas de Reiner y Rubinstein para opciones barrera europeas, comprendiendo su derivación y limitaciones.
2. **Implementar métodos numéricos:** Desarrollar implementaciones de:
 - Mallas adaptativas (Adaptive Mesh Model de Figlewski-Gao)
 - Simulación de Monte Carlo con técnicas de reducción de varianza
3. **Validar las implementaciones:** Comparar los resultados numéricos con las fórmulas analíticas de Reiner-Rubinstein en casos donde estas son aplicables.
4. **Analizar el desempeño:** Evaluar cada método en términos de:
 - Precisión absoluta y relativa
 - Tiempo de cómputo
 - Estabilidad numérica
 - Capacidad para calcular sensibilidades (griegas)
5. **Identificar casos de uso óptimos:** Determinar qué método es más apropiado según:
 - Tipo de opción barrera (knock-in, knock-out, up, down)
 - Posición relativa del precio actual respecto a la barrera
 - Tiempo al vencimiento
 - Volatilidad del subyacente
 - Requerimientos de precisión
6. **Proporcionar recomendaciones prácticas:** Ofrecer guías para la selección del método más apropiado en diferentes contextos de aplicación.

1.4. Contribuciones del Trabajo

Este trabajo contribuye a la literatura y práctica de valoración de opciones barrera en los siguientes aspectos:

1. **Comparación sistemática:** Proporciona una comparación rigurosa y sistemática de múltiples métodos numéricos bajo un marco común de evaluación.
2. **Implementaciones validadas:** Ofrece implementaciones cuidadosamente validadas de métodos avanzados como mallas adaptativas, que pueden servir como referencia para futuros trabajos.
3. **Guías prácticas:** Proporciona recomendaciones concretas sobre qué método usar en diferentes situaciones, útiles tanto para académicos como para profesionales.
4. **Análisis de sensibilidad:** Estudia cómo el desempeño de cada método varía con los parámetros del problema, identificando regiones donde ciertos métodos son superiores.

1.5. Organización del Trabajo

Los capítulos de este trabajo se organizan de la siguiente manera:

En el Capítulo 2 se presentan los fundamentos financieros necesarios para comprender la valoración de opciones. Se introducen los mercados de derivados, los diferentes tipos de opciones (europeas, americanas, exóticas) y en particular las opciones barrera. Se desarrolla el modelo de Black-Scholes estableciendo el marco teórico fundamental.

El Capítulo 3 describe los cuatro métodos de valoración que serán implementados y comparados: las fórmulas analíticas de Reiner y Rubinstein, árboles trinomiales con mallas adaptativas, replicación estática mediante portafolios y simulación de Monte Carlo con el método de Longstaff-Schwartz para opciones americanas. Para cada método se explican sus principios básicos, ventajas y desventajas.

Los Capítulos 4.1, 4.2, 4.3 y 4.4 documentan la implementación de cada uno de los métodos. Se detallan los algoritmos, criterios de refinamiento, técnicas de reducción de varianza y detalles de implementación. Se presentan resultados de validación comparando con fórmulas analíticas cuando es posible.

En el Capítulo 5 se presenta una comparación sistemática de todos los métodos implementados. Se diseñan experimentos numéricos con diferentes parámetros (precio del subyacente, strike, barrera, volatilidad, tiempo al vencimiento) y se analizan los resultados en términos de precisión, tiempo de cómputo y estabilidad. Se identifican los casos de uso óptimos para cada método.

Finalmente, las conclusiones generales son presentadas en el Capítulo 6, donde se resumen los resultados principales del trabajo, se presentan las conclusiones sobre qué método es más apropiado en diferentes situaciones, se discuten las limitaciones del estudio y se proponen direcciones para trabajo futuro.

Capítulo 2

Marco Teórico

Este capítulo presenta los fundamentos teóricos necesarios para comprender la valoración de opciones barrera. Se introducen los conceptos básicos de mercados de derivados, los diferentes tipos de opciones y el modelo de Black-Scholes que constituye la base teórica para los métodos de valoración que se desarrollarán en capítulos posteriores.

2.1. Mercados de Derivados

Los derivados financieros son instrumentos cuyo valor depende (se deriva) del valor de otro activo, llamado activo subyacente. Los subyacentes más comunes incluyen acciones, índices bursátiles, divisas, tasas de interés y commodities.

2.1.1. Características de los Mercados de Derivados

Los mercados de derivados cumplen varias funciones económicas importantes:

- **Gestión de riesgos:** Permiten a empresas e inversores transferir riesgos no deseados a otros participantes dispuestos a asumirlos.
- **Descubrimiento de precios:** Los precios de los derivados reflejan las expectativas del mercado sobre el comportamiento futuro de los activos subyacentes.
- **Apalancamiento:** Permiten tomar posiciones significativas con una inversión inicial relativamente pequeña.
- **Eficiencia de mercado:** Facilitan el arbitraje, contribuyendo a la eficiencia en la formación de precios.

2.1.2. Tipos de Derivados

Los principales tipos de derivados son:

- **Forwards:** Contratos a medida entre dos partes para comprar o vender un activo en una fecha futura a un precio acordado hoy.

- **Futuros:** Similares a los forwards pero estandarizados y negociados en bolsas organizadas.
- **Swaps:** Acuerdos para intercambiar flujos de efectivo futuros según reglas predeterminadas.
- **Opciones:** Contratos que otorgan el derecho (pero no la obligación) de comprar o vender un activo a un precio determinado.

2.2. Opciones Financieras

Una opción es un contrato que otorga a su tenedor el derecho, pero no la obligación, de comprar (opción call) o vender (opción put) un activo subyacente a un precio predeterminado (precio de ejercicio o strike) en o antes de una fecha específica (fecha de vencimiento).

2.2.1. Opciones Call y Put

Opción Call: Otorga el derecho de comprar el activo subyacente al precio de ejercicio K . El payoff al vencimiento es:

$$\text{Payoff}_{\text{Call}} = \max(S_T - K, 0) \quad (2.1)$$

donde S_T es el precio del subyacente al vencimiento.

Opción Put: Otorga el derecho de vender el activo subyacente al precio de ejercicio K . El payoff al vencimiento es:

$$\text{Payoff}_{\text{Put}} = \max(K - S_T, 0) \quad (2.2)$$

2.2.2. Opciones Europeas vs Americanas

Opciones Europeas: Solo pueden ejercerse en la fecha de vencimiento. Son más simples de valorar analíticamente.

Opciones Americanas: Pueden ejercerse en cualquier momento hasta el vencimiento. Esta flexibilidad adicional las hace más valiosas que sus contrapartes europeas, pero también más difíciles de valorar.

2.2.3. Opciones Exóticas

Las opciones exóticas son aquellas cuyas características difieren de las opciones vanilla (europeas o americanas estándar). Incluyen:

- **Opciones Barrera:** Su existencia depende de si el precio del subyacente cruza un nivel predeterminado.
- **Opciones Asiáticas:** Su payoff depende del precio promedio del subyacente durante cierto período.
- **Opciones Lookback:** Permiten al tenedor 'mirar hacia atrás' y ejercer al precio más favorable observado.
- **Opciones Digitales:** Pagan una cantidad fija si se cumple cierta condición.

2.3. Opciones Barrera

Las opciones barrera son el foco principal de este trabajo. Su característica distintiva es que su existencia depende de si el precio del activo subyacente alcanza o no un nivel de precio predeterminado (la barrera H) durante la vida de la opción.

2.3.1. Clasificación de Opciones Barrera

Las opciones barrera se clasifican según dos criterios:

1. Según el efecto de tocar la barrera:

- **Knock-In:** La opción comienza a existir (se activa) solo si se toca la barrera.
- **Knock-Out:** La opción deja de existir (se extingue) si se toca la barrera.

2. Según la posición de la barrera:

- **Up:** La barrera H está por encima del precio inicial del subyacente ($H > S_0$).
- **Down:** La barrera H está por debajo del precio inicial del subyacente ($H < S_0$).

Combinando estos criterios obtenemos ocho tipos básicos de opciones barrera:

- Down-and-In Call (DIC)
- Down-and-Out Call (DOC)
- Up-and-In Call (UIC)
- Up-and-Out Call (UOC)
- Down-and-In Put (DIP)
- Down-and-Out Put (DOP)
- Up-and-In Put (UIP)
- Up-and-Out Put (UOP)

2.3.2. Payoffs de Opciones Barrera

El payoff de una opción barrera depende tanto del precio final del subyacente como de si la barrera fue tocada durante la vida de la opción.

Para una **Down-and-Out Call**:

$$\text{Payoff}_{\text{DOC}} = \max(S_T - K, 0) \cdot \mathbb{I}_{\{\min_{0 \leq t \leq T} S_t > H\}} \quad (2.3)$$

Para una **Down-and-In Call**:

$$\text{Payoff}_{\text{DIC}} = \max(S_T - K, 0) \cdot \mathbb{I}_{\{\min_{0 \leq t \leq T} S_t \leq H\}} \quad (2.4)$$

donde $\mathbb{I}_A$ es la función indicadora que vale 1 si se cumple la condición A y 0 en caso contrario.

2.3.3. Relaciones de Paridad

Existe una relación fundamental entre opciones knock-in y knock-out del mismo tipo:

$$\text{Opción Vanilla} = \text{Opción Knock-In} + \text{Opción Knock-Out} \quad (2.5)$$

Por ejemplo:

$$C_{\text{europea}} = C_{\text{DI}} + C_{\text{DO}} \quad (2.6)$$

Esta relación es útil para validar implementaciones y para valorar opciones knock-in a partir de opciones knock-out (o viceversa).

2.3.4. Rebates

Muchas opciones barrera incluyen un **rebate** (reembolso) R , que es una cantidad fija pagada al tenedor en ciertas circunstancias:

- En opciones **knock-out**: El rebate se paga cuando se toca la barrera (momento en que la opción se extingue).
- En opciones **knock-in**: El rebate se paga al vencimiento si la barrera nunca fue tocada (y por tanto la opción nunca se activó).

2.3.5. Ventajas de las Opciones Barrera

Las opciones barrera son significativamente más baratas que las opciones vanilla equivalentes porque:

- Las opciones knock-out pueden extinguirse antes del vencimiento, reduciendo el riesgo para el vendedor.
- Las opciones knock-in solo comienzan a existir bajo ciertas condiciones, también reduciendo el riesgo.

Esta reducción de costo las hace atractivas para:

- Empresas que buscan cobertura a menor costo
- Inversores con visiones específicas sobre el comportamiento del mercado
- Estructuración de productos financieros complejos

2.4. El Modelo de Black-Scholes

El modelo de Black-Scholes, desarrollado por Fischer Black, Myron Scholes y Robert Merton en 1973, revolucionó la valoración de opciones y sentó las bases de la ingeniería financiera moderna.

2.4.1. Supuestos del Modelo

El modelo se basa en los siguientes supuestos:

1. El precio del activo subyacente S_t sigue un Movimiento Browniano Geométrico:

$$dS_t = \mu S_t dt + \sigma S_t dW_t \quad (2.7)$$

donde μ es la tasa de retorno esperada, σ es la volatilidad y W_t es un proceso de Wiener.

2. Los mercados son completos y no hay fricciones:
 - No hay costos de transacción
 - Es posible tomar posiciones cortas sin restricciones
 - Los activos son perfectamente divisibles
 - No hay oportunidades de arbitraje
3. La tasa de interés libre de riesgo r es constante y conocida.
4. La volatilidad σ es constante y conocida.
5. El activo subyacente no paga dividendos (o se puede extender para incluir una tasa de dividendos constante δ).
6. Las transacciones ocurren de manera continua en el tiempo.

2.4.2. Ecuación Diferencial de Black-Scholes

Bajo estos supuestos, el precio de cualquier derivado $V(S, t)$ que depende del precio del subyacente S y del tiempo t debe satisfacer la ecuación diferencial parcial:

$$\frac{\partial V}{\partial t} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0 \quad (2.8)$$

Esta ecuación se resuelve sujeta a condiciones de borde apropiadas que dependen del tipo específico de derivado.

2.4.3. Medida Neutral al Riesgo

Un concepto fundamental del modelo es la **medida neutral al riesgo**. Bajo esta medida de probabilidad:

- El precio descontado de cualquier activo es una martingala
- El retorno esperado de todos los activos es la tasa libre de riesgo r
- El precio de un derivado es el valor esperado descontado de su payoff

Bajo la medida neutral al riesgo, el proceso del precio del subyacente se convierte en:

$$dS_t = rS_t dt + \sigma S_t dW_t^{\mathbb{Q}} \quad (2.9)$$

donde $W_t^{\mathbb{Q}}$ es un proceso de Wiener bajo la medida neutral al riesgo $\mathbb{Q}$.

2.4.4. Fórmula de Black-Scholes para Opciones Vanilla

Para una opción call europea con precio de ejercicio K y vencimiento T , la fórmula de Black-Scholes es:

$$C(S, t) = SN(d_1) - Ke^{-r(T-t)}N(d_2) \quad (2.10)$$

donde:

$$d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)(T - t)}{\sigma\sqrt{T - t}} \quad (2.11)$$

$$d_2 = d_1 - \sigma\sqrt{T - t} \quad (2.12)$$

y $N(\cdot)$ es la función de distribución acumulada de la normal estándar.

Para una opción put europea:

$$P(S, t) = Ke^{-r(T-t)}N(-d_2) - SN(-d_1) \quad (2.13)$$

2.4.5. Las Griegas

Las **griegas** son las derivadas parciales del precio de la opción respecto a sus parámetros. Son fundamentales para la gestión de riesgos:

- **Delta** (Δ): Sensibilidad al precio del subyacente

$$\Delta = \frac{\partial V}{\partial S} \quad (2.14)$$

- **Gamma** (Γ): Tasa de cambio del delta

$$\Gamma = \frac{\partial^2 V}{\partial S^2} \quad (2.15)$$

- **Vega** ($\mathcal{V}$): Sensibilidad a la volatilidad

$$\mathcal{V} = \frac{\partial V}{\partial \sigma} \quad (2.16)$$

- **Theta** (Θ): Sensibilidad al paso del tiempo

$$\Theta = \frac{\partial V}{\partial t} \quad (2.17)$$

- **Rho** (ρ): Sensibilidad a la tasa de interés

$$\rho = \frac{\partial V}{\partial r} \quad (2.18)$$

2.4.6. Limitaciones del Modelo

A pesar de su elegancia matemática y utilidad práctica, el modelo de Black-Scholes tiene limitaciones importantes:

- **Volatilidad constante:** En la realidad, la volatilidad varía con el tiempo y con el nivel del precio del subyacente (volatility smile/skew).
- **Distribución lognormal:** Los retornos reales exhiben colas más pesadas que la distribución normal (fat tails).
- **Salto:** El modelo no captura movimientos discontinuos en el precio del subyacente.
- **Fricciones de mercado:** En la práctica existen costos de transacción, restricciones a las ventas en corto y activos no perfectamente divisibles.
- **Tasa de interés constante:** Las tasas de interés varían en el tiempo, especialmente para opciones de largo plazo.

A pesar de estas limitaciones, el modelo de Black-Scholes sigue siendo la base conceptual para la valoración de opciones y proporciona un marco de referencia contra el cual se comparan otros modelos más sofisticados.

2.5. Extensiones del Modelo Black-Scholes

Para opciones barrera, el modelo de Black-Scholes se extiende incorporando condiciones de borde adicionales que reflejan el comportamiento en la barrera. Estas extensiones permiten obtener fórmulas cerradas para ciertos tipos de opciones barrera europeas, como se verá en el siguiente capítulo.

Otras extensiones importantes del modelo incluyen:

- Modelos de volatilidad estocástica (Heston, SABR)
- Modelos con saltos (Merton, Kou)
- Modelos de volatilidad local (Dupire)
- Modelos de tasas de interés estocásticas

Sin embargo, estas extensiones quedan fuera del alcance de este trabajo, que se enfoca en métodos de valoración bajo el modelo de Black-Scholes clásico.

Capítulo 3

Métodos de Valoración

En este capítulo se presentan los cuatro métodos de valoración que serán implementados y comparados en este trabajo. Para opciones barrera europeas se analizan tres métodos: fórmulas analíticas de Reiner y Rubinstein, árboles trinomiales con mallas adaptativas y replicación estática mediante portafolios de opciones vanilla. Para opciones barrera americanas se utiliza simulación de Monte Carlo con el método de Longstaff-Schwartz.

3.1. Método 1: Fórmulas Analíticas de Reiner y Rubinstein

El trabajo seminal de Reiner y Rubinstein Reiner and Rubinstein (1991) proporciona una metodología sistemática para obtener fórmulas cerradas para los ocho tipos básicos de opciones barrera europeas bajo el modelo de Black-Scholes.

3.1.1. Marco Metodológico de Valoración

Siguiendo la notación exacta de Reiner y Rubinstein Reiner and Rubinstein (1991), se definen:

Variables Críticas

- r : Tasa de interés (expresada como $1 + \text{tasa}$)
- d : Tasa de pago del activo (expresada como $1 + \text{tasa de pago}$)
- σ : Volatilidad del activo subyacente
- t : Tiempo hasta el vencimiento
- ϕ : Variable binaria (1 para calls, -1 para puts)
- η : Variable binaria (1 si el precio inicia por encima de la barrera, -1 si inicia por debajo)

Constantes:

- H : Nivel de la barrera preestablecido

3.1. MÉTODO 1: FÓRMULAS ANALÍTICAS DE REINER Y RUBINSTEIN

- K : Precio de ejercicio preestablecido
- R : Monto del rebate preestablecido

Funciones de Densidad de Probabilidad La valoración de opciones barrera bajo el marco de Reiner y Rubinstein requiere comprender tres funciones de densidad de probabilidad fundamentales, cada una capturando un aspecto distinto del comportamiento estocástico del precio del activo:

- $f(u)$: densidad tradicional al estilo Black-Scholes del logaritmo natural del retorno del activo subyacente bajo la medida neutral al riesgo. Esta densidad representa la distribución de probabilidad de dónde termina el precio al vencimiento, sin considerar en absoluto la trayectoria seguida para llegar allí. Es la visión “amnésica” del modelo, sólo importa el destino final, no el camino.

$$f(u) = (1/\sigma\sqrt{2\pi t})e^{-1/2v^2}$$

Donde $v = (u - \mu t)/\sigma\sqrt{t}$ y $\mu = \log(r/d) - \frac{1}{2}\sigma^2$. Utilizada cuando consideramos que no se cruzó la barrera.

- $g(u)$: en contraste a la primera, incorpora información crucial sobre la trayectoria mediante el principio de reflexión de la teoría de procesos estocásticos. Esta densidad especial captura únicamente aquellas trayectorias que cruzaron la barrera H en algún momento durante la vida de la opción, pero que terminaron en un nivel de precio específico al vencimiento.

$$g(u) = e^{2\eta\alpha\mu\sigma^{-2}}(1/\sigma\sqrt{2\pi t})e^{-1/2v^2}$$

Donde $v = (u - 2\eta\alpha - \eta\mu t)/\sigma\sqrt{t}$ y $\alpha = \log(H/S)$. El factor exponencial $e^{2\eta\alpha\mu\sigma^{-2}}$ es precisamente la manifestación matemática del principio de reflexión, cada trayectoria que cruza la barrera tiene una trayectoria “reflejada” correspondiente y la densidad $g(u)$ pondera estas trayectorias reflejadas de manera apropiada. Utilizada cuando consideramos que se cruzó la barrera.

- $h(\tau)$: es de naturaleza temporal en lugar de espacial, representa la distribución del tiempo de primer pasaje, es decir, la probabilidad de que la barrera sea tocada por primera vez en un instante específico τ dentro del intervalo $[0, t]$. Esta densidad es fundamental para valorar opciones knock-out donde el rebate se paga en el momento exacto (aleatorio) del cruce, no al vencimiento.

Variables auxiliares

- $x = [\log(S/K)/\sigma\sqrt{t}] + \lambda\sigma\sqrt{t}$
- $x_1 = [\log(S/H)/\sigma\sqrt{t}] + \lambda\sigma\sqrt{t}$
- $y = [\log(H^2/SK)/\sigma\sqrt{t}] + \lambda\sigma\sqrt{t}$
- $y_1 = [\log(H/S)/\sigma\sqrt{t}] + \lambda\sigma\sqrt{t}$
- $\lambda = 1 + (\mu/\sigma^2)$
- $z = [\log(H/S)/\sigma\sqrt{t}] + b\sigma\sqrt{t}$
donde $b = [\sqrt{\mu^2 + 2(\log r)\sigma^2}]/\sigma^2$ y $a = \mu/\sigma^2$

3.1.2. Términos de Valoración

$$\begin{aligned} [1] &= r^{-t} \int \phi(Se^u - K)f(u)du \\ &= \phi S d^{-t} N(\phi x) - \phi K r^{-t} N(\phi x - \phi \sigma \sqrt{t}) \end{aligned} \quad (3.1)$$

$$\begin{aligned} [2] &= r^{-t} \int \phi(Se^u - K)f(u)du \\ &= \phi S d^{-t} N(\phi x_1) - \phi K r^{-t} N(\phi x_1 - \phi \sigma \sqrt{t}) \end{aligned} \quad (3.2)$$

$$\begin{aligned} [3] &= r^{-t} \int \phi(Se^u - K)g(u)du \\ &= \phi S d^{-t} (H/S)^{2\lambda} N(\eta y) - \phi K r^{-t} (H/S)^{2\lambda-2} N(\eta y - \eta \sigma \sqrt{t}) \end{aligned} \quad (3.3)$$

$$\begin{aligned} [4] &= r^{-t} \int \phi(Se^u - K)g(u)du \\ &= \phi S d^{-t} (H/S)^{2\lambda} N(\eta y_1) - \phi K r^{-t} (H/S)^{2\lambda-2} N(\eta y_1 - \eta \sigma \sqrt{t}) \end{aligned} \quad (3.4)$$

$$\begin{aligned} [5] &= R r^{-t} \int [f(u) - g(u)]du \\ &= R r^{-t} \left[N(\eta x_1 - \eta \sigma \sqrt{t}) - (H/S)^{2\lambda-2} N(\eta y_1 - \eta \sigma \sqrt{t}) \right] \end{aligned} \quad (3.5)$$

$$\begin{aligned} [6] &= R \int r^{-\tau} h(\tau) d\tau \\ &= R \left[(H/S)^{a+b} N(\eta z) + (H/S)^{a-b} N(\eta z - 2\eta b \sigma \sqrt{t}) \right] \end{aligned} \quad (3.6)$$

3.1.3. Interpretación de los Términos de Valoración

La comprensión de estos términos requiere analizar tanto las regiones de integración como las funciones de densidad utilizadas.

1. Regiones de Integración en el Espacio de Precios

En las fórmulas [1] a [5], la variable de integración es u , definida como el logaritmo natural del rendimiento del activo: $u = \ln(S_t/S)$.

- **Región de $\log(K/S)$ a $\phi\infty$:** Representa todos los precios finales del activo que terminan 'in the money' (por encima de K para un call o por debajo de K para un put). El término ϕ actúa como un interruptor: si es 1 (call), la región va hacia el infinito positivo; si es -1 (put), hacia el infinito negativo.
- **Región de $\log(H/S)$ a $\phi\infty$ (o $\eta\infty$):** Define los precios finales que terminan en el lado 'activo' de la barrera. Por ejemplo, en una opción down-and-in, esta región abarca los precios finales que están por encima de la barrera H , permitiendo distinguir entre los activos que terminaron 'a salvo' y los que no.

3.1. MÉTODO 1: FÓRMULAS ANALÍTICAS DE REINER Y RUBINSTEIN

2. Significado según la Función de Densidad

El significado de la región cambia drásticamente dependiendo de qué densidad se esté integrando:

- **Con $f(u)$ (Densidad Estándar):** La región representa simplemente dónde termina el precio al vencimiento, sin importar lo que pasó en el camino. Es la visión 'estilo Black-Scholes' clásica.
- **Con $g(u)$ (Densidad de Cruce):** Cuando integramos sobre una región usando $g(u)$, estamos capturando únicamente las trayectorias que cruzaron la barrera H en algún momento, pero que terminaron en la región especificada (K o H) al vencimiento. Esta densidad incorpora el principio de reflexión.
- **Con $[f(u) - g(u)]$ (Región de Reembolso):** En la fórmula [5], integrar sobre esta diferencia en la región de $\log(H/S)$ a $\eta\infty$ representa la probabilidad de que el activo termine en el lado correcto de la barrera sin haberla tocado nunca durante la vida de la opción.

3. Región Temporal (Término [6])

En la fórmula [6], la región de integración es temporal, no de precio:

- **De 0 a t :** Esta región abarca toda la vida del contrato, desde el momento inicial hasta el vencimiento. Significa que el modelo está sumando las probabilidades de que el activo toque la barrera en cualquier instante τ dentro de ese periodo. Esto es fundamental para las opciones de 'salida' (out-options), donde el pago (reembolso) ocurre en el momento exacto del impacto, el cual es aleatorio.

Resumen de los Términos

- **Término [1]:** Valor esperado descontado usando $f(u)$, integrando sobre precios finales por encima de K (calls) o por debajo de K (puts). Representa el valor de la opción vanilla sin considerar la barrera.
- **Término [2]:** Similar a [1], pero integrando sobre precios finales en el lado activo de la barrera H .
- **Término [3]:** Valor esperado descontado usando $g(u)$, considerando solo trayectorias que cruzaron la barrera y terminaron por encima de K (calls) o por debajo de K (puts).
- **Término [4]:** Similar a [3], pero integrando sobre precios finales en el lado activo de la barrera H .
- **Término [5]:** Valor presente del rebate R pagado al vencimiento si la barrera no fue tocada durante la vida de la opción. Usa la diferencia $[f(u) - g(u)]$ para capturar solo trayectorias que nunca cruzaron.
- **Término [6]:** Valor presente del rebate R pagado en el momento exacto (aleatorio) en que se toca la barrera. Integra sobre el tiempo de primer pasaje $\tau \in [0, t]$ usando la densidad $h(\tau)$.

La combinación apropiada de estos términos permite construir las fórmulas para los ocho tipos de opciones barrera (Down-and-Out/In, Up-and-Out/In, para Calls y Puts).

3.1.4. Fórmulas Exactas: Construcción mediante Términos de Valoración

Las fórmulas de Reiner y Rubinstein se construyen combinando los términos de valoración [1] a [6] según el tipo de opción, la posición relativa del precio inicial respecto a la barrera y la relación entre el precio de ejercicio K y la barrera H .

Opciones de Entrada (In-options)

Estas opciones solo comienzan a existir (se activan o hacen 'knock-in') si el precio del activo toca la barrera H antes del vencimiento. Si no se toca la barrera, el tenedor recibe un reembolso R al vencimiento.

1. **Down-and-In Call** ($S > H$): El activo comienza por encima de la barrera. Se activa si el precio baja hasta tocar H .
 - Si $K > H$: [3] + [5] con $\eta = 1, \phi = 1$
 - Si $K < H$: [1] - [2] + [4] + [5] con $\eta = 1, \phi = 1$
2. **Up-and-In Call** ($S < H$): El activo comienza por debajo de la barrera. Se activa si el precio sube hasta tocar H .
 - Si $K > H$: [1] + [5] con $\eta = -1, \phi = 1$
 - Si $K < H$: [2] - [3] + [4] + [5] con $\eta = -1, \phi = 1$
3. **Down-and-In Put** ($S > H$): Comienza arriba de la barrera y se activa al bajar hasta H .
 - Si $K > H$: [2] - [3] + [4] + [5] con $\eta = 1, \phi = -1$
 - Si $K < H$: [1] + [5] con $\eta = 1, \phi = -1$
4. **Up-and-In Put** ($S < H$): Comienza abajo de la barrera y se activa al subir hasta H .
 - Si $K > H$: [1] - [2] + [4] + [5] con $\eta = -1, \phi = -1$
 - Si $K < H$: [3] + [5] con $\eta = -1, \phi = -1$

Opciones de Salida (Out-options)

Estas opciones dejan de existir (se extinguen o hacen 'knock-out') si el precio del activo toca la barrera H . Si se toca la barrera, el reembolso R se paga usualmente en ese mismo momento.

5. **Down-and-Out Call** ($S > H$): La opción es válida mientras el precio se mantenga por encima de H .
 - Si $K > H$: [1] - [3] + [6] con $\eta = 1, \phi = 1$
 - Si $K < H$: [2] - [4] + [6] con $\eta = 1, \phi = 1$
6. **Up-and-Out Call** ($S < H$): Se extingue si el precio sube hasta tocar H .
 - Si $K > H$: [6] con $\eta = -1, \phi = 1$.

Nota: Para que el precio termine arriba de K , necesariamente debe cruzar H primero, por lo que la opción solo vale por su reembolso.

3.1. MÉTODO 1: FÓRMULAS ANALÍTICAS DE REINER Y RUBINSTEIN

- Si $K < H$: $[1] - [2] + [3] - [4] + [6]$ con $\eta = -1, \phi = 1$
7. **Down-and-Out Put** ($S > H$): Se extingue si el precio baja hasta tocar H .
- Si $K > H$: $[1] - [2] + [3] - [4] + [6]$ con $\eta = 1, \phi = -1$
 - Si $K < H$: $[6]$ con $\eta = 1, \phi = -1$.
Nota: Si el precio baja de K , ya habrá cruzado H y la opción se habrá extinguido.
8. **Up-and-Out Put** ($S < H$): Se mantiene vigente mientras el precio esté debajo de H .
- Si $K > H$: $[2] - [4] + [6]$ con $\eta = -1, \phi = -1$
 - Si $K < H$: $[1] - [3] + [6]$ con $\eta = -1, \phi = -1$

3.2. Método 2: Modelo de Malla Adaptativa (AMM)

El Modelo de Malla Adaptativa (Adaptive Mesh Model, AMM), desarrollado por Figlewski y Gao Figlewski and Gao (1999), representa un avance significativo en la valoración numérica de opciones. Este método permite aumentar la precisión en varios órdenes de magnitud sin incrementar sustancialmente el tiempo de ejecución, mediante el injerto de secciones de alta resolución sobre un árbol trinomial base en regiones críticas donde el valor de la opción es altamente no lineal.

3.2.1. El Problema de la Discretización en Opciones Barrera

La aplicación directa de modelos binomiales o trinomiales estándar a la valoración de opciones barrera enfrenta un desafío fundamental que no aparece en opciones vanilla: el problema de la alineación de nodos con la barrera. Este problema fue identificado y abordado sistemáticamente por Boyle y Lau en su trabajo seminal de 1994 Boyle and Lau (1994), donde propusieron una solución ingeniosa pero con limitaciones importantes que motivarían desarrollos posteriores.

En un árbol binomial o trinomial estándar, los nodos se distribuyen en capas horizontales correspondientes a diferentes niveles de precio del activo subyacente. El espaciamiento vertical entre estas capas está determinado por los factores de movimiento u (hacia arriba) y d (hacia abajo), que a su vez dependen de la volatilidad σ y del número de pasos temporales n . El problema surge porque la barrera H , que es un parámetro fijo del contrato, raramente coincide exactamente con alguna de estas capas de nodos. En la mayoría de los casos, H cae entre dos capas horizontales, lo que genera una ambigüedad fundamental: ¿en qué momento exactamente se considera que la barrera ha sido tocada? Esta desalineación produce estimaciones sesgadas del valor de la opción y una convergencia notablemente lenta hacia el valor teórico, con errores que persisten incluso cuando se aumenta significativamente el número de pasos.

Boyle y Lau resolvieron este problema mediante una técnica que denominaron “bumping the barrier”. La idea central es elegir estratégicamente el número de pasos n de manera que los nodos del árbol coincidan exactamente con el nivel de la barrera. Matemáticamente, esto se logra resolviendo la ecuación $S_0 u^j d^{n-j} = H$ para encontrar valores de n que garanticen que existe al menos un par de enteros $(j, n - j)$ que satisfacen esta igualdad. Al forzar esta coincidencia, se elimina la ambigüedad: cualquier trayectoria que pase por un nodo en el nivel H se considera que ha tocado la barrera y el modelo puede aplicar correctamente las reglas de knock-out o knock-in. Esta técnica mejoró dramáticamente la precisión de los modelos de árbol para opciones barrera, eliminando el sesgo sistemático y acelerando la convergencia.

Sin embargo, el método de Boyle y Lau tiene una limitación crítica conocida como el “problema del límite” (boundary problem). Cuando el precio inicial del activo S_0 está muy cerca de la barrera H , la condición de alineación requiere que el tamaño del paso de precio h sea extremadamente pequeño para que al menos un nodo caiga exactamente sobre H . Esto se traduce en la necesidad de un número de pasos n prohibitivamente grande. Por ejemplo, si S_0 está a solo $1/8$ de punto de distancia de la barrera, el método puede requerir miles o

incluso decenas de miles de pasos temporales para lograr la alineación, haciendo el cálculo computacionalmente inmanejable. Esta limitación es particularmente problemática en la práctica, ya que las opciones barrera son frecuentemente negociadas precisamente en situaciones donde el precio del subyacente está cerca de la barrera, momento en el cual la valoración precisa es más crítica. Es precisamente esta limitación del método de Boyle y Lau la que motivó el desarrollo del Modelo de Malla Adaptativa (AMM) de Figlewski y Gao, que abordaremos en la siguiente sección. El AMM ofrece una solución elegante al problema del límite mediante el uso de mallas de resolución variable, permitiendo valoraciones precisas incluso cuando S_0 y H están arbitrariamente cerca.

3.2.2. Fundamentos: Árboles Trinomiales

El AMM se construye sobre la base de árboles trinomiales, que modelan la evolución del precio del activo subyacente en tiempo discreto.

Construcción del Árbol Trinomial

En cada nodo del árbol con precio S , el precio en el siguiente paso temporal puede ser:

- $S \cdot u$ con probabilidad p_u (movimiento hacia arriba)
- $S \cdot m$ con probabilidad p_m (movimiento medio, típicamente $m = 1$)
- $S \cdot d$ con probabilidad p_d (movimiento hacia abajo)

donde $u > 1 > d > 0$ son los factores de movimiento.

Los parámetros se calibran para aproximar el proceso continuo:

$$u = e^{\sigma\sqrt{3\Delta t}} \quad (3.7)$$

$$d = e^{-\sigma\sqrt{3\Delta t}} = \frac{1}{u} \quad (3.8)$$

$$m = 1 \quad (3.9)$$

Las probabilidades neutrales al riesgo son:

$$p_u = \frac{1}{6} + \frac{(r - \delta)\sqrt{\Delta t}}{2\sigma\sqrt{3}} \quad (3.10)$$

$$p_m = \frac{2}{3} \quad (3.11)$$

$$p_d = \frac{1}{6} - \frac{(r - \delta)\sqrt{\Delta t}}{2\sigma\sqrt{3}} \quad (3.12)$$

La valoración procede mediante inducción hacia atrás (backward induction), calculando en cada nodo:

$$V(S, t) = e^{-r\Delta t} [p_u V(Su, t + \Delta t) + p_m V(S, t + \Delta t) + p_d V(Sd, t + \Delta t)] \quad (3.13)$$

La inducción hacia atrás (backward induction) es el procedimiento algorítmico fundamental para valorar opciones mediante modelos de árbol binomial o trinomial. A diferencia de la simulación de Monte Carlo, que avanza hacia adelante en el tiempo generando trayectorias desde el presente hacia el futuro, los métodos de árbol trabajan en dirección temporal inversa. El proceso comienza en el vencimiento T , donde el valor de la opción es conocido con certeza: es simplemente el payoff terminal, por ejemplo $\max(S_T - K, 0)$ para una opción call europea. Desde este punto de partida, el algoritmo retrocede paso a paso hacia el tiempo inicial, calculando en cada nodo el valor de la opción como el valor esperado descontado de los valores en los nodos hijos (futuros). Matemáticamente, en un árbol trinomial, el valor en un nodo con precio S en el tiempo t se calcula como $V(S, t) = e^{-r\Delta t}[p_u V(Su, t+\Delta t) + p_m V(S, t+\Delta t) + p_d V(Sd, t+\Delta t)]$, donde p_u , p_m y p_d son las probabilidades neutrales al riesgo de movimiento hacia arriba, medio y abajo respectivamente y Δt es el tamaño del paso temporal. Este proceso de retroceso continúa hasta alcanzar el nodo raíz en $t = 0$ con precio S_0 , cuyo valor calculado es precisamente el precio justo de la opción. Para opciones americanas, el algoritmo se modifica ligeramente: en cada nodo se toma el máximo entre el valor de continuación (calculado como antes) y el valor de ejercicio inmediato, reflejando la decisión óptima del tenedor de la opción.




Figura 3.1: Estructura de un árbol trinomial con 3 pasos temporales. Desde cada nodo, el precio puede moverse hacia arriba (multiplicado por $u = 1,15$, verde), mantenerse (multiplicado por $m = 1$, azul), o bajar (multiplicado por $d = 1/u \approx 0,870$, rojo). Las probabilidades neutrales al riesgo son $p_u = 0,25$, $p_m = 0,50$, $p_d = 0,25$. El árbol es recombinante: los nodos que alcanzan el mismo precio se fusionan.

3.2.3. Análisis de Errores en Modelos de Redes

Figlewski y Gao identifican dos fuentes principales de error en los modelos de redes:

Error de Distribución

Surge porque el modelo intenta aproximar una distribución lognormal continua con una distribución discreta (binomial o trinomial). Aunque coincidan en media y varianza, persiste una discrepancia fundamental. Este error disminuye lentamente con el número de pasos.

3.2. MÉTODO 2: MODELO DE MALLA ADAPTATIVA (AMM)

Error de No Linealidad

Ocurre cuando el valor de la opción es altamente no lineal respecto al precio del activo subyacente, es decir, en áreas de alta Gamma. Ejemplos críticos:

- Alrededor del precio de ejercicio K al vencimiento (opciones vanilla)
- Cerca de la barrera H en cualquier momento (opciones barrera)
- En el precio inicial S_0 para el cálculo de griegas

En el modelo binomial, este error produce una convergencia “par-impar”, donde el error alterna valores significativamente distintos según el número de pasos sea par o impar. El AMM se enfoca específicamente en minimizar el error de no linealidad.




Figura 3.2: Detalle del efecto par-impar en el modelo binomial. Los puntos azules (N par) sistemáticamente tienen mayor error que los puntos rojos (N impar). Las líneas punteadas muestran las tendencias separadas para cada caso. Esta oscilación es causada por el error de no linealidad y es eliminada por el AMM.

3.2.4. Principio del Modelo de Malla Adaptativa

El principio fundamental que sustenta el Modelo de Malla Adaptativa es una observación simple pero poderosa sobre la naturaleza del error numérico en la

3.2. MÉTODO 2: MODELO DE MALLA ADAPTATIVA (AMM)

valoración de opciones: no todas las regiones del espacio precio-tiempo contribuyen igualmente al error total. En un árbol trinomial o binomial estándar, se utiliza una resolución uniforme en todo el dominio computacional, dedicando el mismo esfuerzo de cálculo a regiones donde el valor de la opción varía suavemente que a regiones donde presenta alta no linealidad. Este enfoque es fundamentalmente ineficiente, desperdiciando poder computacional en áreas donde una red gruesa sería suficiente mientras que simultáneamente proporciona resolución insuficiente en las zonas críticas. El AMM actúa como una técnica quirúrgica de refinamiento selectivo: mantiene una red gruesa con pasos de precio h y pasos de tiempo k para la mayor parte del árbol, garantizando velocidad de ejecución, pero injerta una red fina con pasos reducidos (típicamente $h/2$ para el precio y $k/4$ para el tiempo) exclusivamente en las regiones de alta no linealidad donde el valor de la opción cambia abruptamente. Estas regiones críticas incluyen la vecindad del precio de ejercicio K al vencimiento para opciones vanilla, la banda alrededor de la barrera H durante toda la vida de la opción para opciones barrera y la zona cercana al precio inicial S_0 cuando se calculan las griegas mediante diferencias finitas. Al concentrar la resolución computacional precisamente donde más se necesita, el AMM logra precisión comparable a un árbol uniforme extremadamente fino pero con una fracción mínima del costo computacional, típicamente menos del 1 % de nodos adicionales.

3.2. MÉTODO 2: MODELO DE MALLA ADAPTATIVA (AMM)




Figura 3.3: Concepto del Modelo de Malla Adaptativa (AMM). Se muestra un árbol trinomial base (nodos grises, conexiones grises) que constituye la malla gruesa con pasos de precio h y tiempo k . Sobre este árbol se injerta una malla fina (cuadrados verdes pequeños) con pasos $h/2$ y $k/4$ únicamente en la región crítica (rectángulo amarillo). Esta estrategia concentra la resolución computacional donde más se necesita, logrando alta precisión con costo mínimo adicional ($< 1\%$).

3.2.5. AMM para Opciones Vanilla

Para opciones europeas o americanas estándar, la mayor no linealidad ocurre alrededor del precio de ejercicio K al vencimiento T .

Estructura

Se añade una malla fina con pasos de precio $h/2$ y tiempo $k/4$ solo en la región:

- Temporal: Entre $T - k$ y T (último paso temporal del árbol grueso)

3.2. MÉTODO 2: MODELO DE MALLA ADAPTATIVA (AMM)

- Espacial: Alrededor de K , típicamente $[K - 2h, K + 2h]$




Figura 3.4: Estructura del AMM para opciones vanilla. Se muestra un árbol trinomial (nodos grises con conexiones grises) que constituye la malla gruesa. Sobre este árbol se inserta una malla fina (cuadrados verdes pequeños) con pasos $h/2$ y $k/4$ únicamente en la región crítica (rectángulo amarillo): temporal $[T-k, T]$ y espacial $[K-2h, K+2h]$. La línea azul punteada marca el strike K donde ocurre la mayor no linealidad al vencimiento. Esta estrategia concentra la resolución donde más se necesita: alrededor del precio de ejercicio al vencimiento.

Eficiencia

En un árbol trinomial de 100 pasos, añadir un nivel de AMM aumenta los cálculos en menos del 0,4%. Un segundo nivel de refinamiento (AMM-2, con pasos $h/4$ y $k/16$) añade menos del 0,4% adicional.

3.2. MÉTODO 2: MODELO DE MALLA ADAPTATIVA (AMM)

Rendimiento

Según Figlewski y Gao, un modelo AMM-2 con solo 25 pasos de tiempo es más preciso que:

- Un modelo trinomial estándar de 250 pasos
- Un modelo binomial de 1000 pasos (que requiere 250 veces más tiempo de ejecución)

Basado en el análisis de Figlewski y Gao para un conjunto de prueba de 27 opciones put europeas:

Modelo	Pasos (N)	Nodos	Tiempo (s)	RMSE		
				Precio	Delta	Gamma
Binomial	25	351	0.0060	0.020841	0.005805	0.001594
Trinomial	25	676	0.0090	0.012025	0.003337	0.000428
AMM-1	25	716	0.0117	0.002812	0.003345	0.000539
AMM-2	25	756	0.0121	0.000615	0.003359	0.000548
Binomial	100	5,151	0.0451	0.004929	0.001470	0.000197
Trinomial	100	10,201	0.0941	0.002770	0.000846	0.000144
AMM-1	100	10,241	0.0961	0.000600	0.000845	0.000140
AMM-2	100	10,281	0.0982	0.000151	0.000854	0.000138
Binomial	250	31,626	0.2163	0.002214	0.000534	0.000073
Trinomial	250	63,001	0.5407	0.001360	0.000346	0.000061
AMM-1	250	63,041	0.5418	0.000245	0.000334	0.000056
AMM-2	250	63,081	0.5428	0.000057	0.000342	0.000056
Binomial	1000	501,501	3.0674	0.000448	0.000145	0.000020
Trinomial	1000	1,002,001	8.5623	0.000244	0.000079	0.000015
AMM-1	1000	1,002,041	8.5954	0.000056	0.000086	0.000014
AMM-2	1000	1,002,081	8.5854	0.000016	0.000085	0.000014

Tabla 3.1: Comparación detallada de rendimiento y precisión para valoración de opciones y cálculo de griegas. El AMM logra errores significativamente menores en precio, Delta y Gamma con un incremento mínimo en tiempo de ejecución (¡3 % vs trinomial estándar) y número de nodos (¡0.1 % adicional). Datos de Figlewski y Gao (1999).

3.2.6. AMM para Opciones Barrera

Las opciones barrera presentan un desafío particular: el error de no linealidad ocurre en cada punto del tiempo cuando el precio se acerca a la barrera H , no solo al vencimiento.

El Problema de Convergencia “Dentada”

La convergencia en modelos estándar es “dentada” porque la probabilidad de tocar la barrera salta discretamente cuando el número de pasos cambia el tamaño del paso de precio h . Si h es grande, el árbol puede “saltar sobre” la barrera sin detectarla correctamente.

El Problema del Límite

Cuando el precio inicial S_0 está muy cerca de la barrera H , un árbol trinomial estándar requiere que haya al menos un paso de precio entre S_0 y H . Esto implica:

$$h = \frac{S_0(u - d)}{2} < |S_0 - H| \quad (3.14)$$

Si S_0 está extremadamente cerca de H (por ejemplo, a una distancia de $1/8$ de punto), esto puede obligar a usar miles de pasos de tiempo, haciendo el cálculo inmanejable.

Estructura AMM para Barreras

Se construye una malla fina junto a la barrera H :

- **Región espacial:** Banda alrededor de H , típicamente $[H - 2h, H + 2h]$
- **Región temporal:** Toda la vida de la opción (no solo cerca del vencimiento)
- **Flujo de información:** A diferencia del AMM para vanilla, acá la información fluye de la malla gruesa hacia la malla fina para valorar la opción cuando S_0 está cerca de H

3.2. MÉTODO 2: MODELO DE MALLA ADAPTATIVA (AMM)




Figura 3.5: Estructura del AMM para opciones barrera. Mostrar el árbol completo con una banda vertical de malla fina a lo largo de toda la dimensión temporal, centrada en la barrera H . La barrera debe aparecer como una línea horizontal clara. Indicar la región $[H-2h, H+2h]$ con sombreado o color. Mostrar S_0 cerca de H para ilustrar el problema del límite. Incluir flechas mostrando el flujo de información de malla gruesa a malla fina.

Manejo de la Barrera

Para opciones knock-out:

- Si un nodo en la malla fina cruza la barrera H , su valor se establece en el rebate R
- La malla fina permite detectar el cruce con mucha mayor precisión que la malla gruesa

Para opciones knock-in, se usa la relación de paridad:

$$V_{KI} = V_{vanilla} - V_{KO} \quad (3.15)$$

Rendimiento

Mientras que un Modelo Trinomial Restringido (RTM) se vuelve inmanejable cuando S_0 se acerca extremadamente a la barrera, el AMM alcanza resultados precisos casi instantáneamente. Un AMM de 100 pasos puede ser más preciso que un RTM de 10,000 pasos que tarda 100 veces más.

3.2.7. AMM para el Cálculo de Griegas

La estimación de Delta (Δ) y Gamma (Γ) mediante perturbaciones pequeñas del precio inicial es ruidosa debido al error de no linealidad.

Extensión del Árbol

Una técnica común es extender el árbol un paso hacia atrás desde el tiempo 0 para obtener tres valores de opción y calcular derivadas numéricas. Sin embargo, esto usa un paso de precio h completo, que puede ser demasiado grande.

Ramificación Cuadrinomial

Para permitir perturbaciones menores ($\epsilon < h$) sin que los nodos de la malla fina se desvíen de la malla gruesa (lo que generaría probabilidades negativas), el AMM utiliza ramificación cuadrinomial (cuatro ramas) en los nodos de perturbación añadidos (ubicados en $X_0 \pm \epsilon$).

Esto permite calcular:

$$\Delta \approx \frac{V(S_0 + \epsilon) - V(S_0 - \epsilon)}{2\epsilon} \quad (3.16)$$

$$\Gamma \approx \frac{V(S_0 + \epsilon) - 2V(S_0) + V(S_0 - \epsilon)}{\epsilon^2} \quad (3.17)$$

con $\epsilon = h/2$ o incluso $\epsilon = h/4$.

3.2. MÉTODO 2: MODELO DE MALLA ADAPTATIVA (AMM)




Figura 3.6: Ramificación cuadrinomial para el cálculo de griegas mediante diferencias finitas. Se muestra un árbol trinomial base (nodos grises, conexiones negras gruesas) con nodos adicionales en $t = 0$ ubicados en $S_0 + \varepsilon$ (verde) y $S_0 - \varepsilon$ (rojo), donde $\varepsilon = h/4$ es una perturbación pequeña. Las líneas sólidas grises representan ramificación cuadrinomial (4 ramas) desde los nodos perturbados y los nodos extremos en $t = k/4$, permitiendo calcular simultáneamente Delta y Gamma con alta precisión.

Precisión

El uso de AMM reduce el Error Cuadrático Medio (RMSE) de:

- Delta: en aproximadamente $2/3$
- Gamma: en aproximadamente $1/2$

sin aumentar significativamente el tiempo de ejecución. Un AMM de 25 pasos es más preciso que un modelo trinomial estándar de 1000 pasos que tarda 500 veces más.

3.2. MÉTODO 2: MODELO DE MALLA ADAPTATIVA (AMM)

Precisión en el Cálculo de Delta: Trinomial vs AMM con Ramificación Cuadrinomial




Figura 3.7: Precisión en el cálculo de Delta mediante ramificación cuadrinomial. Se compara el RMSE en Delta para diferentes configuraciones AMM $(0, T)$, donde 0 es el inicio de la opción y T es el final de la misma. La ramificación cuadrinomial permite calcular Delta mediante diferencias finitas. AMM (3,3) logra una mejora de 60x vs Trinomial en $N=100$, con un incremento de tiempo $< 3\%$. Notablemente, AMM (1,0) mejora Delta sin costo adicional al refinar solo la región crítica.




Figura 3.8: Precisión en el cálculo de Gamma mediante ramificación cuadrinomial. Se compara el RMSE en Gamma para diferentes configuraciones AMM. La ramificación cuadrinomial permite calcular Gamma mediante diferencias finitas de segundo orden. AMM (1,1) logra una mejora de 7.2x vs Trinomial en $N=100$. A diferencia de Delta, Gamma no mejora significativamente con niveles superiores a (2,2), lo que sugiere que AMM (1,1) es óptimo para este cálculo. El incremento en tiempo es $< 3\%$.

3.2.8. Ventajas del AMM

- **Eficiencia extrema:** Aumenta la precisión en órdenes de magnitud con incremento mínimo en tiempo de ejecución
- **Escalabilidad:** Permite abordar problemas que son computacionalmente prohibitivos con métodos estándar
- **Flexibilidad:** Aplicable a opciones vanilla, barrera y cálculo de griegas con estructuras específicas para cada caso
- **Convergencia mejorada:** Elimina el comportamiento “par-impar” y la convergencia “dentada” de los modelos estándar

- **Aplicaciones prácticas:** Especialmente valioso para cálculo de volatilidad implícita (que requiere múltiples valoraciones repetitivas) y opciones exóticas complejas

3.2.9. Consistencia Matemática

Figlewski y Gao proporcionan una prueba formal de convergencia, demostrando que a medida que el tamaño de los pasos de tiempo y precio tiende a cero, el valor de la opción obtenido por el AMM converge al valor teórico de tiempo continuo. Esta consistencia garantiza que el método no solo es eficiente, sino también matemáticamente riguroso.

3.3. Método 3: Replicación Estática

La replicación estática es un método desarrollado para cubrir o replicar el valor de una opción objetivo (frecuentemente una opción exótica) mediante la construcción de un portafolio compuesto por otras opciones, generalmente opciones estándar o “vanilla”. A diferencia de la cobertura dinámica, que requiere ajustes continuos en la posición del activo subyacente, este enfoque busca establecer un portafolio de cobertura con pesos fijos que no requiera ajustes posteriores durante la vida de la opción o dentro de un rango específico de precios y tiempos.

Esta técnica se fundamenta en los supuestos estándar de la teoría de valoración de opciones (como el modelo Black-Scholes), permitiendo descomponer teóricamente una opción exótica en un portafolio de opciones estándar, cuyos precios de mercado y bid-ask spreads suelen ser más transparentes y líquidos. Aunque una replicación perfecta teórica podría requerir un número infinito de opciones estándar, en la práctica es posible lograr una aproximación adecuada utilizando un número limitado de instrumentos.

3.3.1. Concepto de Replicación Estática

El concepto central de la replicación estática radica en igualar los flujos de caja y los valores de frontera de la opción objetivo utilizando un portafolio de instrumentos más simples.

La idea: replicación con un portafolio de opciones vanilla

La estrategia consiste en construir un portafolio de opciones estándar (calls y puts europeas con diferentes precios de ejercicio y vencimientos) que replique el valor de la opción exótica en sus fronteras. Por ejemplo, para una opción barrera up-and-out (que deja de existir si el precio del subyacente toca un nivel superior), el objetivo es crear un portafolio que tenga el mismo pago que la opción estándar al vencimiento (si no toca la barrera), pero cuyo valor neto sea cero si el precio del activo alcanza la barrera antes del vencimiento.

Esto se logra “anulando” el valor de la opción original en la barrera mediante la venta en corto de otras opciones que tengan valor positivo en ese mismo punto. De esta manera, el portafolio estático imita el comportamiento de “desaparición” de la opción barrera sin necesidad de vender la opción exótica en sí misma.

Fundamento teórico: ¿Por qué funciona?

La validez del método descansa en el Principio de Replicación Estática. Este principio establece que si dos portafolios tienen los mismos valores en todas las fronteras de una región determinada (precio del activo y tiempo) y satisfacen la misma ecuación diferencial (la ecuación backward o de Black-Scholes) dentro de dicha región, entonces deben tener el mismo valor en cualquier punto interior de esa región.

Por lo tanto, no es necesario igualar el valor de la opción en cada punto posible del futuro; basta con construir un portafolio que coincida con el valor de la opción objetivo en sus fronteras naturales (por ejemplo, al vencimiento y sobre la barrera de precio). Una vez que los valores en la frontera están alineados, la

3.3. MÉTODO 3: REPLICACIÓN ESTÁTICA

teoría de valoración por inducción hacia atrás (backward induction) garantiza que el valor actual y la sensibilidad del portafolio replicante serán iguales a los de la opción objetivo.

Ventajas frente a la cobertura dinámica

La principal ventaja de este método es que elimina la necesidad de rebalanceo continuo. La cobertura dinámica tradicional (Delta hedging) requiere ajustar las posiciones constantemente a medida que pasa el tiempo o cambia el precio del activo, lo cual presenta dos dificultades mayores:

1. El ajuste continuo es imposible en la práctica y el rebalanceo discreto genera errores de cobertura.
2. Los costos de transacción asociados al ajuste frecuente pueden erosionar el margen de beneficio de la opción.

La replicación estática utiliza pesos fijos determinados al inicio, evitando estos costos y dificultades operativas. Además, es particularmente útil para opciones exóticas con alta “gamma” (como las opciones barrera cerca de su nivel de activación/desactivación), donde la cobertura dinámica se vuelve costosa e imprecisa debido a la necesidad de realizar grandes ajustes ante pequeños movimientos del mercado.

3.3.2. Metodología de Derman-Ergener-Kani

La metodología propuesta por Derman, Ergener y Kani Derman et al. (1994) se basa en la construcción sistemática de un portafolio de cobertura que iguala el valor de la opción objetivo en una serie de puntos discretos sobre su frontera (espacio y tiempo). El enfoque fundamental es recursivo: comienza igualando el pago al vencimiento y retrocede en el tiempo para ajustar los valores en la barrera, aprovechando que el valor de la opción exótica es conocido en dichas fronteras (por ejemplo, cero en una opción knock-out o un valor de reembolso específico).

Construcción del Portafolio y Selección de Strikes

La construcción del portafolio replicante se realiza paso a paso, asegurando que la adición de nuevas opciones para corregir el valor en un punto de la frontera no altere la replicación ya lograda en puntos anteriores o regiones interiores. Para lograr esto, la selección de los precios de ejercicio (strikes) es crítica y sigue reglas estrictas dependiendo de la ubicación de la frontera respecto al precio actual del activo:

- **Frontera de Vencimiento:** Se inicia replicando el pago final de la opción objetivo (t_{exp}) utilizando una combinación de opciones vanilla (calls o puts) con diferentes strikes que vencen en esa fecha. Esto constituye el portafolio inicial.
- **Fronteras Superiores (por encima del precio actual):** Para ajustar el valor del portafolio en una barrera superior en tiempos anteriores al vencimiento ($t < t_{exp}$), se deben utilizar opciones de compra (calls) con

3.3. MÉTODO 3: REPLICACIÓN ESTÁTICA

strikes iguales o superiores al nivel de la barrera ($K \geq B$). Esto garantiza que dichas opciones expiren *out-of-the-money* si el precio del activo se mantiene por debajo de la barrera, evitando así generar flujos de caja no deseados dentro de la región de replicación.

- **Fronteras Inferiores (por debajo del precio actual):** De manera análoga, para ajustar el valor en una barrera inferior, se deben utilizar opciones de venta (*puts*) con strikes iguales o inferiores al nivel de la barrera ($K \leq B$). Al igual que en el caso anterior, estas opciones no tendrán valor al vencimiento si el precio se mantiene por encima de la frontera inferior, preservando la integridad de la replicación interior.

Cálculo de Pesos y Procedimiento Recursivo

Una vez seleccionados los instrumentos adecuados, los pesos (cantidad de opciones a comprar o vender) se calculan mediante un proceso iterativo hacia atrás en el tiempo. Si dividimos el tiempo hasta el vencimiento en intervalos discretos $t_1, t_2, \dots, t_{exp}$, el procedimiento es el siguiente:

1. **Ajuste al Vencimiento (t_{exp}):** Se seleccionan opciones estándar que igualen el pago de la opción objetivo al vencimiento. Por ejemplo, para una opción up-and-out call que no ha tocado la barrera, esto equivale simplemente a una call estándar con el mismo strike que la opción exótica.
2. **Retroceso al paso anterior (t_{n-1}):** Se calcula el valor teórico del portafolio replicante existente en el punto de la frontera correspondiente al tiempo t_{n-1} (por ejemplo, en la barrera B). Generalmente, este valor no coincidirá con el valor de la opción objetivo (que suele ser cero en el caso de opciones *knock-out*).
3. **Cálculo del Peso de Corrección:** Para eliminar esta discrepancia, se añade una nueva posición en una opción estándar que venza en t_{exp} (o en el tiempo correspondiente a la frontera, dependiendo de la implementación exacta). El peso (w) de esta nueva opción se calcula para que su valor compense exactamente el error del portafolio en ese punto:

$$w = \frac{V_{portafolio}(B, t_{n-1}) - V_{objetivo}(B, t_{n-1})}{V_{nueva_opcion}(B, t_{n-1})} \quad (3.18)$$

Donde $V_{portafolio}$ es el valor acumulado de las opciones añadidas en pasos previos y V_{nueva_opcion} es el valor de la opción utilizada para el ajuste.

4. **Iteración:** Este proceso se repite para $t_{n-2}, t_{n-3}, \dots, t_1$, añadiendo en cada paso opciones adicionales que corrijan el valor en la frontera sin afectar los puntos ya ajustados en el futuro (gracias a la selección de strikes descrita anteriormente).

Teóricamente, si se utilizara un número infinito de opciones para cubrir todos los puntos de la frontera, la replicación sería exacta. En la práctica, se utiliza un número finito de opciones para igualar el valor en puntos discretos, lo que proporciona una aproximación robusta cuyo error disminuye al aumentar la cantidad de instrumentos de cobertura.

3.3.3. Construcción del Portafolio

La construcción práctica del portafolio replicante sigue un proceso sistemático que transforma la frontera continua de la opción exótica en un conjunto discreto de puntos de control. Este proceso requiere una selección cuidadosa de los instrumentos vanilla para garantizar que la corrección del valor en un punto de la frontera no introduzca flujos de caja no deseados en regiones ya cubiertas.

Selección de Opciones Vanilla

La regla fundamental para elegir los instrumentos de cobertura es asegurar que estos no tengan valor intrínseco dentro de la región válida de la opción objetivo (es decir, antes de que se toque la barrera). Según Derman, Ergener y Kani, la selección se realiza en función de la ubicación de la frontera respecto al precio actual del activo:

- **Frontera de Vencimiento** (t_{exp}): Para replicar el pago final de la opción, se pueden utilizar tanto opciones call como put de cualquier precio de ejercicio (K) conveniente, combinándolas para igualar el perfil de pago de la opción objetivo al vencimiento.
- **Fronteras Superiores** ($S > S_{actual}$): Para ajustar el valor en una barrera superior (como en una opción *up-and-out*), se deben utilizar exclusivamente opciones de compra (**calls**) con precios de ejercicio iguales o superiores al nivel de la barrera ($K \geq B$). Esto asegura que, si el precio del activo se mantiene por debajo de la barrera, estas opciones expiren *out-of-the-money* (sin valor), preservando así la replicación lograda en el interior de la región.
- **Fronteras Inferiores** ($S < S_{actual}$): De manera análoga, para replicar condiciones en una frontera inferior (como en una opción *down-and-out*), se deben emplear opciones de venta (**puts**) con precios de ejercicio iguales o inferiores al nivel de la barrera ($K \leq B$). Estas opciones no generarán flujos de caja si el precio del activo se mantiene por encima de la frontera inferior.

Determinación de los Pesos

Una vez seleccionados los instrumentos, los pesos (cantidad de opciones a comprar o vender) se determinan mediante un proceso recursivo hacia atrás en el tiempo. El objetivo es “anular” la discrepancia entre el valor del portafolio acumulado y el valor de la opción objetivo en puntos discretos de la frontera. El cálculo matemático para el peso α_i de una nueva opción que se añade en el paso i para corregir el valor en el tiempo t_i y precio B_i se define formalmente como:

$$\alpha_i = \frac{\xi_{i-1} - V_{portafolio}(B_{i-1}, t_{i-1})}{C(B_{i-1}, t_{i-1})} \quad (3.19)$$

Donde:

- ξ_{i-1} es el valor conocido de la opción objetivo en la frontera (usualmente cero para opciones knock-out o un valor de reembolso específico).

3.3. MÉTODO 3: REPLICACIÓN ESTÁTICA

- $V_{portafolio}$ es el valor teórico acumulado de todas las opciones estándar añadidas en pasos anteriores (vencimientos futuros ya cubiertos).
- $C(B_{i-1}, t_{i-1})$ es el valor de la nueva opción estándar utilizada para el ajuste en ese punto de la frontera

En términos prácticos, si el portafolio actual tiene un valor positivo en una barrera donde la opción objetivo vale cero, el peso α_i será negativo, indicando que se debe tomar una posición short en la nueva opción para cancelar dicho valor.

Aproximación de la Barrera

Dado que en el mundo real los precios de las acciones son continuos, una replicación estática perfecta requeriría un número infinito de opciones estándar para cubrir cada punto posible de la frontera. Sin embargo, la metodología permite una aproximación robusta mediante la discretización de la frontera:

1. **Puntos de anclaje:** Se selecciona un conjunto limitado de puntos de tiempo y precio sobre la barrera (por ejemplo, cada mes o cada semana) donde se forzará la igualdad de valores.
2. **Convergencia:** A medida que se aumenta el número de opciones utilizadas en el portafolio replicante (disminuyendo el intervalo de tiempo entre los puntos de ajuste), el “error de replicación” o mismatch en los puntos intermedios disminuye significativamente.

Por ejemplo, los autores demuestran que al pasar de un portafolio de 6 opciones (ajuste bimestral) a uno de 24 opciones (ajuste quincenal) para replicar una opción up-and-out a un año, el error de valor teórico se reduce drásticamente, logrando que el comportamiento del portafolio replicante sea casi indistinguible del de la opción exótica objetivo.

3.4. Método 4: Monte Carlo para Opciones Americanas

La simulación de Monte Carlo es una técnica fundamental en finanzas computacionales que permite valorar derivados complejos mediante la generación de trayectorias aleatorias del precio del activo subyacente. Aunque es naturalmente adecuada para opciones europeas, su aplicación a opciones americanas presenta desafíos significativos debido a la posibilidad de ejercicio anticipado.

3.4.1. Desafío de las Opciones Americanas

El Problema del Ejercicio Óptimo

Las opciones americanas otorgan a su tenedor el derecho de ejercer en cualquier momento hasta el vencimiento T . Esta flexibilidad adicional implica que el valor de la opción en cualquier instante t es:

$$V(S_t, t) = \max \{ \text{Payoff inmediato}, \mathbb{E}^{\mathbb{Q}}[e^{-r\Delta t} V(S_{t+\Delta t}, t + \Delta t) | S_t] \} \quad (3.20)$$

donde el primer término representa el valor de ejercicio inmediato y el segundo el valor de continuación (mantener la opción viva).

La decisión óptima de ejercicio requiere comparar en cada instante:

- **Valor intrínseco:** $\max(S_t - K, 0)$ para calls o $\max(K - S_t, 0)$ para puts
- **Valor de continuación:** El valor esperado descontado de mantener la opción

3.4.2. Simulación de Monte Carlo

Generación de Trayectorias

Bajo el modelo de Black-Scholes, el precio del activo subyacente bajo la medida neutral al riesgo sigue:

$$dS_t = (r - \delta)S_t dt + \sigma S_t dW_t^{\mathbb{Q}} \quad (3.21)$$

donde r es la tasa libre de riesgo, δ es la tasa de dividendos, σ es la volatilidad y $W_t^{\mathbb{Q}}$ es un proceso de Wiener bajo la medida neutral al riesgo.

La solución analítica de esta ecuación diferencial estocástica es:

$$S_{t+\Delta t} = S_t \exp \left[\left(r - \delta - \frac{\sigma^2}{2} \right) \Delta t + \sigma \sqrt{\Delta t} Z \right] \quad (3.22)$$

donde $Z \sim N(0, 1)$ es una variable aleatoria normal estándar.

Algoritmo Básico para Opciones Europeas

Para una opción europea, el algoritmo de Monte Carlo es directo:

1. Generar M trayectorias del precio del subyacente desde $t = 0$ hasta $t = T$

3.4. MÉTODO 4: MONTE CARLO PARA OPCIONES AMERICANAS

2. Para cada trayectoria i , calcular el payoff al vencimiento: $\text{Payoff}_i = \max(S_T^{(i)} - K, 0)$ para calls
3. Estimar el valor de la opción como:

$$V(S_0, 0) \approx e^{-rT} \frac{1}{M} \sum_{i=1}^M \text{Payoff}_i \quad (3.23)$$

El error estándar de esta estimación decrece como $O(1/\sqrt{M})$, independientemente de la dimensionalidad del problema.

Monitoreo de Barreras

Para opciones con barreras, es necesario monitorear si el precio cruza el nivel H durante la vida de la opción. Esto requiere discretizar cada trayectoria en N pasos temporales:

$$S_{t_j} = S_{t_{j-1}} \exp \left[\left(r - \delta - \frac{\sigma^2}{2} \right) \Delta t + \sigma \sqrt{\Delta t} Z_j \right] \quad (3.24)$$

para $j = 1, 2, \dots, N$, donde $\Delta t = T/N$ y $Z_j \sim N(0, 1)$ son independientes. En cada paso se verifica si S_{t_j} ha cruzado la barrera H :

- Para opciones **knock-out**: Si se cruza H , la trayectoria se marca como extinguida
- Para opciones **knock-in**: Si se cruza H , la trayectoria se marca como activada

Sesgo de Discretización: El monitoreo discreto puede no detectar cruces que ocurren entre puntos de observación. Este sesgo se reduce aumentando N , pero a costa de mayor tiempo computacional.

El Problema Fundamental: ¿Cuándo Ejercer?

Para opciones americanas, el desafío es determinar la estrategia de ejercicio óptima. En cada punto de decisión t_j , necesitamos saber si es óptimo ejercer o continuar.

El problema es que en Monte Carlo avanzamos hacia adelante en el tiempo, pero la decisión de ejercicio requiere conocer el valor de continuación, que depende del futuro. Esto crea una paradoja:

- Para decidir si ejercer en t_j , necesitamos $\mathbb{E}[V(S_{t_{j+1}}, t_{j+1}) | S_{t_j}]$
- Pero $V(S_{t_{j+1}}, t_{j+1})$ depende de las decisiones de ejercicio futuras
- Que a su vez dependen de valores de continuación aún más futuros

Este problema circular requiere un enfoque sofisticado.

3.4.3. Método de Longstaff-Schwartz (LSM)

La simulación de Monte Carlo enfrenta una paradoja fundamental cuando se aplica a opciones americanas, derivada de la tensión entre la dirección temporal de la simulación y la naturaleza de la decisión de ejercicio óptimo. En Monte Carlo, generamos trayectorias aleatorias del precio del activo avanzando hacia adelante en el tiempo, desde $t = 0$ hasta el vencimiento T . Sin embargo, para decidir si es óptimo ejercer la opción en un punto intermedio t_j , necesitamos comparar el valor de ejercicio inmediato (conocido) con el valor de continuación, que es el valor esperado de mantener la opción viva. Este valor de continuación depende de todas las decisiones de ejercicio futuras, que a su vez dependen de valores de continuación aún más futuros, creando una dependencia circular que no puede resolverse avanzando hacia adelante. El método de Longstaff-Schwartz resuelve esta paradoja mediante un truco estadístico elegante basado en regresión de mínimos cuadrados. La idea es generar primero todas las trayectorias completas hasta el vencimiento y luego trabajar hacia atrás en el tiempo (como en los árboles). En cada punto de decisión t_j , el método utiliza regresión para aproximar el valor de continuación como una función del precio actual del activo, típicamente usando polinomios de Laguerre como funciones base. Específicamente, para todas las trayectorias que están in-the-money en t_j , se realiza una regresión donde la variable independiente es el precio S_{t_j} y la variable dependiente es el valor descontado que esas trayectorias alcanzaron en t_{j+1} (conocido porque ya trabajamos hacia atrás desde el final). Los coeficientes de regresión resultantes proporcionan una estimación del valor de continuación condicional al precio actual, permitiendo compararlo con el valor de ejercicio inmediato y tomar la decisión óptima. Este enfoque convierte un problema de optimización dinámica intratable en una secuencia de problemas de regresión estándar, cada uno resoluble eficientemente mediante mínimos cuadrados ordinarios.

El método de Longstaff-Schwartz Longstaff and Schwartz (2001), también conocido como Least Squares Monte Carlo (LSM), resuelve el problema del ejercicio óptimo mediante regresión para estimar el valor de continuación.

Idea Central

La intuición del método es:

1. Generar todas las trayectorias completas desde $t = 0$ hasta $t = T$
2. Trabajar hacia atrás en el tiempo (backward induction)
3. En cada punto de decisión t_j , usar regresión para estimar el valor de continuación como función del precio actual
4. Comparar el valor de continuación estimado con el valor de ejercicio inmediato
5. Ejercer si el valor inmediato excede el valor de continuación

Estimación del Valor de Continuación

En el tiempo t_j , para todas las trayectorias que están “in-the-money” (donde el ejercicio inmediato tiene valor positivo) se estima el valor de continuación

3.4. MÉTODO 4: MONTE CARLO PARA OPCIONES AMERICANAS

mediante regresión de mínimos cuadrados **sobre los flujos de caja reales obtenidos ex-post** (y no sobre el valor esperado de la opción, lo cual generaría un sesgo alcista):

$$\mathbb{E}\left[\sum_{i=j+1}^N e^{-r(t_i-t_j)} CF_i | S_{t_j}\right] \approx \sum_{k=0}^K a_k L_k(S_{t_j}) \quad (3.25)$$

donde CF_i representa el flujo de caja real que ocurre en el tiempo t_i a lo largo de la trayectoria condicionado a que la opción no se ejerció antes, L_k son funciones base (típicamente polinomios de Laguerre) y a_k son coeficientes determinados por regresión.

¿Por qué Polinomios de Laguerre?

Los polinomios de Laguerre ponderados $L_k(x)e^{-x/2}$ forman una base ortogonal en $[0, \infty)$, que es el dominio natural de los precios de activos. Por simplicidad se utilizan polinomios de Laguerre simples (no ponderados) ya que la elección exacta de las funciones base (ya sean ponderadas, no ponderadas, de Hermite, etc.) no afecta significativamente la convergencia del algoritmo siempre que se usen los términos suficientes. Los primeros polinomios son:

$$L_0(x) = 1 \quad (3.26)$$

$$L_1(x) = 1 - x \quad (3.27)$$

$$L_2(x) = 1 - 2x + \frac{x^2}{2} \quad (3.28)$$

$$L_3(x) = 1 - 3x + \frac{3x^2}{2} - \frac{x^3}{6} \quad (3.29)$$

En la práctica, se usan típicamente los primeros 3-5 polinomios.

Algoritmo de Longstaff-Schwartz

El algoritmo LSM procede en cuatro pasos principales:

Paso 1: Generación de Trayectorias

Se generan M trayectorias completas del precio del subyacente desde $t = 0$ hasta $t = T$, discretizadas en N pasos temporales.

Paso 2: Inicialización al Vencimiento

Para cada trayectoria, el valor al vencimiento es simplemente el payoff de la opción.

Paso 3: Inducción Hacia Atrás

Este es el núcleo del algoritmo. Para cada tiempo t_j desde t_{N-1} hasta t_1 :

1. Se identifican las trayectorias in-the-money (donde el ejercicio inmediato tiene valor positivo)
2. Para estas trayectorias, se realiza una regresión de mínimos cuadrados usando funciones base (típicamente polinomios de Laguerre) para estimar el valor de continuación:

$$\mathbb{E}[e^{-r\Delta t} V(S_{t_{j+1}}, t_{j+1}) | S_{t_j}] \approx \sum_{k=0}^K a_k L_k(S_{t_j}) \quad (3.30)$$

3.4. MÉTODO 4: MONTE CARLO PARA OPCIONES AMERICANAS

3. Se compara el valor de ejercicio inmediato con el valor de continuación estimado
4. Se toma la decisión de ejercicio óptima: ejercer si el valor inmediato excede el valor de continuación

Paso 4: Valoración

El valor de la opción es el promedio descontado de los payoffs en los tiempos de ejercicio óptimos determinados en el paso anterior.

Extensión a Opciones Barrera Americanas

Para opciones americanas con barreras, el algoritmo LSM se modifica para incorporar el monitoreo de la barrera:

- **Knock-out:** Si una trayectoria cruza la barrera en t_j , se establece su valor en el rebote R y no se consideran decisiones de ejercicio futuras para esa trayectoria.
- **Knock-in:** La trayectoria solo puede ejercerse después de que se haya cruzado la barrera. Antes del cruce, solo se considera el valor de continuación.

3.4.4. Ventajas y Limitaciones del Método LSM

Ventajas:

- **Flexibilidad:** Aplicable a opciones con payoffs complejos, múltiples subyacentes y barreras
- **Escalabilidad:** No sufre de la maldición de la dimensionalidad como árboles y diferencias finitas
- **Implementación:** Relativamente simple de programar
- **Griegas:** Pueden estimarse mediante diferencias finitas o métodos de sensibilidad

Limitaciones:

- **Convergencia lenta:** Error $O(1/\sqrt{M})$ requiere muchas simulaciones para alta precisión
- **Sesgo bajo:** El método tiende a subestimar ligeramente el valor verdadero (sesgo bajo)
- **Elección de funciones base:** El rendimiento depende de la elección apropiada de funciones base
- **Costo computacional:** Para alta precisión, puede ser más lento que métodos de árbol para problemas de baja dimensionalidad

3.4.5. Comparación con Otros Métodos

El método LSM es particularmente valioso cuando:

- El problema es de alta dimensionalidad (opciones sobre múltiples activos)
- El payoff es complejo o path-dependent
- Se requiere flexibilidad para incorporar características exóticas

Para opciones americanas simples de baja dimensionalidad, los árboles adaptativos (como el AMM) pueden ser más eficientes. Sin embargo, para opciones barrera americanas con múltiples características exóticas, el LSM es frecuentemente el método de elección en la práctica.

Capítulo 4

Implementaciones

4.1. Fórmulas de Reiner y Rubinstein

4.1.1. Descripción de la Implementación

A diferencia de las opciones americanas estándar, las opciones barrera permiten soluciones de valoración en “forma cerrada” debido a que la frontera crítica del precio del activo está determinada de antemano y especificada en el contrato. El marco teórico propuesto por Reiner y Rubinstein descompone el valor de cualquier opción barrera europea en una combinación lineal de hasta seis términos analíticos de valoración. Desde el punto de vista de la Ingeniería de Software, implementar directamente ocho ecuaciones monolíticas distintas (para las combinaciones de Up/Down, In/Out, Call/Put) resulta ineficiente, propenso a errores y difícil de mantener. Por lo tanto, la descripción algorítmica de este método se diseñó bajo un paradigma modular. El algoritmo base se encarga de calcular de forma independiente los componentes de las distribuciones normales y los términos de valoración. Posteriormente, la lógica de negocio ensambla estos términos dependiendo del tipo de opción requerida, apoyándose en el uso de variables binarias matemáticas definidas por los autores: η y ϕ .

- La variable η toma el valor de 1 si la barrera es aproximada desde arriba (Down-options) y -1 si es aproximada desde abajo (Up-options).
- La variable ϕ actúa como un interruptor para la función de pago, tomando el valor de 1 para opciones Call y -1 para opciones Put.

Esta abstracción matemática permite que el código sea altamente reutilizable, ya que las mismas funciones base evalúan los seis términos principales y las reglas de paridad y construcción simplemente suman o restan los bloques correspondientes.

4.1.2. Detalles de Implementación

La implementación computacional de estas fórmulas cerradas se desarrolló priorizando la precisión numérica y la velocidad de ejecución. Al ser este método el “oráculo” o valor de referencia exacto (ground truth) contra el cual se evaluarán los métodos numéricos posteriores (como el AMM y Monte Carlo), su rendimiento es crítico.

Cálculo de Variables Auxiliares

El cálculo de los términos analíticos implica evaluar múltiples variables auxiliares (x, x_1, y, y_1, z y los escalares λ, a, b) que dependen directamente del precio del activo S , el precio de ejercicio K , la barrera H y el tiempo t . Para soportar el diseño de experimentos del Capítulo 5, donde se requiere evaluar el precio de la opción bajo miles de trayectorias o en densas mallas de precios, el código se implementó utilizando operaciones vectorizadas (por ejemplo, mediante la librería NumPy en Python). Esto permite calcular arreglos enteros de precios simultáneamente sin incurrir en la penalización de rendimiento de los bucles iterativos.

Evaluación de la Distribución Normal

El núcleo computacional de las ecuaciones de Reiner y Rubinstein reside en la Función de Distribución Acumulada de la Normal Estándar, denotada como $N(\cdot)$. Dado que esta función no tiene una representación algebraica elemental, en la implementación se utilizan aproximaciones numéricas altamente optimizadas provistas por las librerías científicas estándar (como `scipy.stats.norm.cdf`).

Manejo de Casos Límite y Rebates

El algoritmo incluye el manejo explícito del rebate R , un flujo de caja fijo que se paga al tenedor si la opción es cancelada (knock-out) o si expira sin ser activada (knock-in). El valor presente de este rebate, correspondiente al término para opciones Out y al término para opciones In, incorpora el descuento por la tasa de interés ponderada por el tiempo de primer paso (first passage time). La implementación aísla este cálculo para permitir que el usuario defina $R = 0$ sin causar inestabilidades numéricas en el resto de los términos.

Código Relevante

Listing 4.1: Términos de RR

```
def calcular_terminos_rr(S, K, H, t, r_rate, d_rate, \
                        sigma, phi, eta, R=0):
    # Asumimos tasas continuas estandar
    r, d = exp(r_rate), exp(d_rate)

    # Variables auxiliares
    mu = log(r/d) - 0.5 * sigma^2
    lambda_ = 1 + (mu / sigma^2)
    a = mu / sigma^2 # Derivado del paper original de RR
    b = sqrt(mu^2 + 2 * log(r) * sigma^2) / sigma^2

    denom = sigma * sqrt(t)
    x = (log(S/K) / denom) + lambda_ * denom
    x1 = (log(S/H) / denom) + lambda_ * denom
    y = (log(H^2 / (S*K)) / denom) + lambda_ * denom
    y1 = (log(H/S) / denom) + lambda_ * denom
    z = (log(H/S) / denom) + b * denom
```

```
# Factores de descuento
S_d_t = S * (d^(-t))
K_r_t = K * (r^(-t))
R_r_t = R * (r^(-t))
H_S = H / S

term1 = phi * S_d_t * N(phi * x) \
        - phi * K_r_t * N(phi * x - phi * denom)
term2 = phi * S_d_t * N(phi * x1) \
        - phi * K_r_t * N(phi * x1 - phi * denom)
term3 = phi * S_d_t * (H_S^(2 * lambda_)) * N(eta * y) \
        - phi * K_r_t * (H_S^(2 * lambda_ - 2)) \
        * N(eta * y - eta * denom)
term4 = phi * S_d_t * (H_S^(2 * lambda_)) * N(eta * y1) \
        - phi * K_r_t * (H_S^(2 * lambda_ - 2)) \
        * N(eta * y1 - eta * denom)
term5 = R_r_t * (N(eta * x1 - eta * denom) \
        - (H_S^(2 * lambda_ - 2)) \
        * N(eta * y1 - eta * denom))
term6 = R * ((H_S^(a + b)) * N(eta * z) \
        + (H_S^(a - b)) * N(eta * z - 2 * eta * b * denom))

return term1, term2, term3, term4, term5, term6
```

4.1.3. Cálculo de Griegas

En el contexto de la gestión de riesgos financieros, el cálculo de las “Griegas” (sensibilidades del precio de la opción ante cambios en los parámetros del mercado) es tan importante como la valoración misma. En los métodos basados en redes discretas, como los árboles trinomiales estándar, estimar la Delta (Δ) y la Gamma (Γ) mediante la perturbación del precio inicial introduce un severo ruido numérico debido al error de no linealidad inherente a la malla. Dividir por un valor de perturbación ϵ muy pequeño magnifica dramáticamente este error. Sin embargo, la implementación de las fórmulas cerradas de Reiner y Rubinstein proporciona una ventaja computacional inmensa: la función de valoración es analítica y continua en todo su dominio (excepto exactamente en la barrera). Esto permite dos enfoques algorítmicos para el cálculo de las Griegas:

- **Derivación Analítica Exacta:** Consiste en calcular las derivadas parciales exactas de los seis términos de valoración respecto a S (para Delta y Gamma), respecto a σ (para Vega), etc. Aunque matemáticamente es el enfoque más riguroso, su implementación en código es extensa y propensa a errores tipográficos en la transcripción de las fórmulas derivadas.
- **Diferencias Finitas Centrales:** Dado que la evaluación de la función vectorizada es computacionalmente instantánea y carece del ruido de discretización espacial de los árboles, es posible aplicar diferencias finitas centrales utilizando un ϵ infinitesimal (por ejemplo, $\epsilon = 10^{-4}$ o menor) con extrema estabilidad numérica.

4.1. FÓRMULAS DE REINER Y RUBINSTEIN

Para esta implementación, las sensibilidades se computan mediante el segundo enfoque:

$$\Delta \approx \frac{V(S + \epsilon) - V(S - \epsilon)}{2\epsilon}$$
$$\Gamma \approx \frac{V(S + \epsilon) - 2V(S) + V(S - \epsilon)}{\epsilon^2}$$

Los resultados obtenidos mediante este método poseen una alta precisión y se establecen en este trabajo como el valor de referencia exacto (ground truth) contra el cual se evaluará el rendimiento de la ramificación cuadrinomial del Modelo de Malla Adaptativa (AMM) detallado en el Capítulo 4.2.1.

4.1.4. Validación

Para garantizar la correctitud de la implementación algorítmica de las fórmulas de Reiner y Rubinstein, se diseñó una batería de pruebas computacionales (unit tests) basadas en las propiedades matemáticas y financieras descritas por los autores originales. La validación consta de tres pruebas de estrés fundamentales:

Verificación de Relaciones de Paridad

Una propiedad teórica fundamental en la estructuración de opciones exóticas es que un portafolio compuesto por una opción knock-in y una opción knock-out idénticas (mismo strike, vencimiento y barrera) equivale exactamente a una opción europea estándar (vanilla). A nivel de código, se validó sistemáticamente que para cualquier vector de precios de entrada, la suma de las rutinas computacionales cumpla con la identidad: `Precio_Call_Vanilla(S, K, T, r, sigma) == Precio_Down_In_Call(...) + Precio_Down_Out_Call(...)`. Esta prueba garantiza que el manejo de los interruptores binarios η y ϕ , así como la combinación de los términos de valoración, no omiten ningún flujo de caja.

Verificación de Límites Asintóticos

Se comprobó la robustez de la implementación analizando el comportamiento de las opciones cuando la barrera es empujada hacia los límites del dominio.

- Para una opción Down-and-Out, si se configura el parámetro de la barrera $H \rightarrow 0$, el impacto de la barrera se vuelve matemáticamente irrelevante. Se verificó que el algoritmo converge suave y exactamente al valor de la fórmula de Black-Scholes clásica.
- De manera análoga, si para una opción Down-and-In (donde $S > H$) la barrera se eleva de manera que $H \rightarrow S$, la opción se activa inmediatamente por definición, comprobándose que su valor computado iguala al de una opción vanilla.

Aislamiento del Término de Reembolso (Rebate)

Los autores destacan un caso particular contraintuitivo: el valor de una opción Up-and-Out Call cuando el precio de ejercicio es mayor que la barrera ($K > H$). Puesto que para que el activo subyacente alcance el strike primero debe cruzar la barrera (lo cual extingue la opción), esta configuración nunca

puede generar un pago (payoff) ordinario. Por lo tanto, su valor reside única y exclusivamente en el pago del rebote al momento del impacto. Se incluyeron pruebas que verifican este caso de frontera, al ejecutar la función correspondiente con $K > H$, el algoritmo aísla y retorna correctamente solo la evaluación del Término 6 de la ecuación, confirmando el correcto manejo de la densidad del tiempo de primer paso (first passage time) y el factor de descuento condicional

4.2. Árboles Trinomiales con Mallas Adaptativas

4.2.1. Descripción del Algoritmo

La implementación del Modelo de Malla Adaptativa (AMM) para opciones de barrera difiere fundamentalmente de los árboles trinomiales estándar en su fase de inicialización. Mientras que en un árbol estándar se define arbitrariamente el número de pasos de tiempo (N) y se derivan los parámetros espaciales, en el AMM la geometría de la malla está dictada por las condiciones de contorno (la barrera) y la profundidad de refinamiento deseada. El algoritmo comienza con una fase de calibración estricta para asegurar que los nodos de la malla fina coincidan exactamente con la barrera del precio, evitando así el “problema del límite”.

Calibración de la Geometría (Malla Gruesa)

La construcción de la malla base (denotada como conjunto de nodos A o malla gruesa) requiere resolver un sistema de restricciones acopladas para determinar el paso de precio (h) y el paso de tiempo (k).

Restricción Espacial: Alineación con la Barrera Para valorar con precisión una opción barrera, es imperativo que la barrera física H coincida con una capa horizontal de nodos en el árbol. En el AMM, definimos la resolución en función de la distancia entre el precio inicial del activo (S_0) y la barrera (H).

Sea M el número de niveles de refinamiento de la malla fina (donde $M = 0$ implica un árbol trinomial estándar restringido). El algoritmo debe calcular el paso de precio de la malla gruesa, h , de tal manera que, al dividirlo por $2M$, el paso más fino cubra exactamente la distancia a la barrera.

La fórmula de inicialización para h es:

$$h = 2^M \times |\ln(S_0) - \ln(H)| \quad (4.1)$$

Esta ecuación garantiza que el nodo $B_{1,0}$ (en la malla fina) coincida con el precio inicial S_0 y que el nodo inferior de la malla fina coincida con H .

Nota de Implementación: El árbol se construye en el espacio logarítmico $X = \ln(S)$. Por tanto, la barrera se convierte en una constante $\ln(H)$ para todos los pasos de tiempo, simplificando la verificación de knock-out.

Restricción Temporal: El Parámetro de Estiramiento Una vez fijado h por la restricción espacial, el paso de tiempo k no puede ser elegido libremente. Debe cumplir dos condiciones simultáneas:

1. Mantener la estabilidad numérica y la convergencia de la varianza (típicamente gobernado por un parámetro libre $\lambda \approx 3$).
2. Resultar en un número entero de pasos de tiempo N hasta el vencimiento T .

Dado que calcular k directamente a partir de h y la volatilidad σ raramente produce un entero para T , se implementa el “Parámetro de Estiramiento” (*Stretch Parameter*). El algoritmo calcula un k provisional y luego lo “estira” ligeramente para ajustar N al entero más cercano. La fórmula implementada, derivada de la Ecuación 17 de Figlewski y Gao (1999), es:

$$k = \frac{T}{\text{int}\left(\frac{j\sigma^2 T}{h^2}\right)} \quad (4.2)$$

Donde:

- j : Parámetro de estabilidad (generalmente se establece $j = 3$ para minimizar el error de distribución).
- $\text{int}(\cdot)$: Función que toma la parte entera.

El denominador representa el número total de pasos de tiempo (N) de la malla gruesa. Este ajuste asegura que el árbol termine exactamente en T sin necesidad de truncar o interpolar el último paso.

Cálculo de Probabilidades de la Malla Base Con h y k calibrados, se calculan las probabilidades de transición para los nodos de la malla gruesa. A diferencia de los árboles centrados en la media, acá el árbol está anclado en la barrera, por lo que incluimos el término *drift* en las probabilidades. Definimos el *drift* α como:

$$\alpha = r - q - \frac{\sigma^2}{2} \quad (4.3)$$

Donde r es la tasa libre de riesgo y q la tasa de dividendos.

Las probabilidades de movimiento hacia arriba (p_u), al medio (p_m) y hacia abajo (p_d) para la malla gruesa se implementan como:

$$p_u = \frac{1}{2} \left(\frac{\sigma^2 k}{h^2} + \frac{\alpha^2 k^2}{h^2} + \frac{\alpha k}{h} \right) \quad (4.4)$$

$$p_d = \frac{1}{2} \left(\frac{\sigma^2 k}{h^2} + \frac{\alpha^2 k^2}{h^2} - \frac{\alpha k}{h} \right) \quad (4.5)$$

$$p_m = 1 - p_u - p_d \quad (4.6)$$

Validación: El código debe incluir una aserción (*assert*) inmediatamente después de este cálculo para verificar que $p_u, p_m, p_d \geq 0$. Si el parámetro de estiramiento j es cercano a 3, las probabilidades serán positivas y estables.

Gestión de la Interfaz entre Mallas

Una vez calibrada y calculada la malla gruesa (Nodos del conjunto A), el siguiente paso es construir la malla fina (Nodos del conjunto B) en la región crítica cercana a la barrera.

Para una opción barrera, el flujo de información es descendente (Malla Gruesa $\rightarrow$ Malla Fina). Esto significa que utilizaremos los valores ya calculados en los nodos A para interpolar los valores de los nodos frontera de B .

El desafío de implementación radica en los “Nodos Intermedios” (o nodos colgantes). Dado que la malla fina tiene una resolución temporal 4 veces mayor

que la gruesa, existen nodos B en los tiempos $t + k/4$, $t + 2k/4$ y $t + 3k/4$ que no tienen un nodo A correspondiente en el mismo instante temporal. Para valorarlos, debemos proyectarlos hacia los nodos A del siguiente paso de tiempo completo ($t + k$).

Cálculo de Probabilidades Ajustadas (Ecuación de Transición) Consideremos los nodos $B_{2,j}$ (ubicados un paso de precio grueso por encima de la barrera). Estos nodos sirven como el “techo” de la malla fina y deben conectarse a los nodos de la malla gruesa A .

Para conectar un nodo intermedio ubicado en el instante $t + \tau$ con los nodos A en el instante $t + k$, debemos calcular probabilidades trinomiales usando un paso de tiempo efectivo (Δt_{eff}) que cubra la distancia restante hasta la columna de nodos A .

Las probabilidades ajustadas para un nodo con paso de tiempo efectivo Δt_{eff} se implementan según las siguientes fórmulas (derivadas de la Ec. 12 de Figlewski y Gao):

$$p_u(\Delta t_{eff}) = \frac{1}{2} \left(\frac{\sigma^2 \Delta t_{eff}}{h^2} + \frac{\alpha^2 (\Delta t_{eff})^2}{h^2} + \frac{\alpha \Delta t_{eff}}{h} \right) \quad (4.7)$$

$$p_d(\Delta t_{eff}) = \frac{1}{2} \left(\frac{\sigma^2 \Delta t_{eff}}{h^2} + \frac{\alpha^2 (\Delta t_{eff})^2}{h^2} - \frac{\alpha \Delta t_{eff}}{h} \right) \quad (4.8)$$

$$p_m(\Delta t_{eff}) = 1 - p_u - p_d \quad (4.9)$$

Lógica de Bucle: En el código, para cada intervalo grueso entre t y $t + k$, se deben calcular tres sets de probabilidades distintos para los nodos frontera:

- **Para nodos en $t + k/4$:** Usar $\Delta t_{eff} = 3k/4$.
- **Para nodos en $t + 2k/4$:** Usar $\Delta t_{eff} = 2k/4$.
- **Para nodos en $t + 3k/4$:** Usar $\Delta t_{eff} = k/4$.

Valoración de los Nodos Frontera Con las probabilidades ajustadas, calculamos el valor de la opción en estos nodos intermedios descontando desde los nodos A del futuro.

Sea $V(B_{2,j})$ el valor de un nodo en la frontera superior de la malla fina. Su valor se obtiene de los nodos de la malla gruesa A_u (arriba), A_m (medio) y A_d (abajo) correspondientes al tiempo $t + k$:

$$V(B_{2,j}) = e^{-r\Delta t_{eff}} [p_u(\Delta t_{eff})V(A_u) + p_m(\Delta t_{eff})V(A_m) + p_d(\Delta t_{eff})V(A_d)] \quad (4.10)$$

Nota crítica de implementación: Observe que el factor de descuento es dinámico y debe ser $e^{-r\Delta t_{eff}}$. Dado que las probabilidades de transición se calculan proyectando el nodo intermedio directamente hacia los nodos de la malla gruesa (A), el descuento debe aplicarse sobre toda la distancia temporal efectiva (Δt_{eff}) que los separa, y no por un único micro-paso de $k/4$.

Relleno de la Malla Fina Una vez calculados los valores en el “techo” de la malla fina ($B_{2,j}$) y sabiendo que el “piso” de la malla es la barrera ($B_{0,j} = 0$ o valor de Rebate), procedemos a calcular los nodos internos ($B_{1,j}$) que se encuentran a $h/2$ de la barrera.

Estos nodos no requieren conexión con la malla gruesa ya que se valoran mediante inducción hacia atrás estándar dentro de la propia malla fina.

1. **Geometría Fina:** Usar paso de precio $h_{fine} = h/2$ y paso de tiempo $k_{fine} = k/4$.
2. **Probabilidades Finas:** Calcular p'_u, p'_m, p'_d usando las fórmulas estándar trinomiales con h_{fine} y k_{fine} .
3. **Recursión:**

$$V(B_{1,j}) = e^{-r(k/4)} [p'_u V(B_{2,j+1}) + p'_m V(B_{1,j+1}) + p'_d V(B_{0,j+1})] \quad (4.11)$$

Este proceso se repite retrocediendo desde el vencimiento T (o desde el final del bloque injertado) hasta llegar a $t = 0$, obteniendo finalmente el valor en el nodo $B_{1,0}$, que corresponde al precio exacto de la opción con alta precisión.

Valoración Backward y Recursividad

Una vez establecidas las probabilidades de transición y las reglas de interfaz, el proceso de valoración se ejecuta mediante un algoritmo secuencial estricto. A diferencia de un árbol estándar que se resuelve en un solo barrido desde T hasta 0, el AMM requiere una valoración por etapas jerárquicas.

Fase 1: Resolución de la Malla Gruesa (Conjunto A) El algoritmo comienza resolviendo completamente la malla base, ignorando temporalmente la existencia de la malla fina.

1. Se inicializan los valores terminales en $t = T$ para todos los nodos $A_{i,N}$ basándose en el payoff de la opción: $\max(S - K, 0)$ o $\max(K - S, 0)$.
2. Se ejecuta la inducción hacia atrás (*backward induction*) estándar hasta $t = 0$, aplicando la condición de barrera en cada paso: si un nodo $A_{i,j}$ cae por debajo de la barrera (en el caso de down-and-out), su valor se fuerza a 0 (o al valor del Rebate).
3. Resultado: Al finalizar esta fase, tenemos una matriz de valores $V(A_{i,j})$ que servirá como fuente de datos (.óráculo”) para los niveles inferiores.

Fase 2: Inyección de Valores en la Frontera Fina Antes de resolver la malla fina, debemos poblar sus bordes utilizando los datos de la Fase 1. El código debe iterar sobre cada paso de tiempo grueso j y calcular los valores de los nodos de interfaz $B_{2,*}$ (el “techo” de la malla fina).

El bucle debe manejar la interpolación temporal descrita en la sección anterior:

4.2. ÁRBOLES TRINOMIALES CON MALLAS ADAPTATIVAS

- Para los nodos B que coinciden con tiempos A ($t, t + k, \dots$), se copia el valor directamente o se usa interpolación espacial si los precios no alinean perfectamente (aunque la calibración de la Ec. 4.1 busca evitar esto).
- Para los nodos intermedios ($t + k/4, t + 2k/4, \dots$), se ejecuta la función de proyección usando la Ecuación 4.10.

Fase 3: Resolución de la Malla Fina (Conjunto B) Con las condiciones de frontera superior ($B_{2,j}$ calculados en Fase 2) e inferior ($B_{0,j} = 0$ por la barrera), se resuelve el interior de la malla fina.

1. Se comienza en el vencimiento T (o en el punto donde la malla fina se une a la gruesa).
2. Se retrocede paso a paso con $\Delta t = k/4$.
3. En cada paso, se calcula el valor de los nodos internos $B_{1,j}$ utilizando las probabilidades trinomiales estándar de la malla fina y los valores de los tres nodos conectados en el paso $j + 1$.

Generalización Recursiva (Para $M > 1$) Si el modelo utiliza múltiples niveles de refinamiento ($M > 1$), este proceso se vuelve recursivo. La propiedad de isomorfismo del AMM permite que, una vez resuelta la malla de Nivel 1 (Nodos B), esta actúe como la "Malla Gruesa" para el Nivel 2 (Nodos C). Un código preliminar es:

```
def Resolver_AMM(S0, K, T, r, q, sigma, H, M):
    # 1. CALIBRACIÓN GLOBAL (Para la malla más profunda)
    h_coarse_base, k_base, N_base = calibrar_geometria(S0, H, T, sigma, M)

    # 2. CONSTRUIR MALLA BASE (NIVEL 0)
    A_grid = build_coarse_mesh(S0, K, T, r, q, sigma, H, h_coarse_base, k_base, N_base)

    # 3. BUCLE DE REFINAMIENTO (NIVEL 1 hasta M)
    current_grid = A_grid
    current_h, current_k, current_N = h_coarse_base, k_base, N_base

    for level in range(1, M + 1):
        fine_grid = build_fine_mesh(current_grid, current_h, current_k, current_N, r,
                                    q, sigma, H, K) # La nueva malla fina se "injerta" en la actual

        current_grid = fine_grid # La fina de hoy es la gruesa de mañana
        current_h, current_k, current_N = actualizar_parametros(...)

    return current_grid[1, 0] # Retornar el valor actual (t=0) del nodo central

def build_coarse_mesh(S0, K, T, r, q, sigma, H, h, k, N):
    pu_A, pm_A, pd_A = calcular_probs(k, h, r, q, sigma) # Eq. 9 para malla gruesa

    A_grid = initialize_coarse_mesh()
    A_grid[max_price_nodes, N] = actualizar_payoff_terminal(...)
```

4.2. ÁRBOLES TRINOMIALES CON MALLAS ADAPTATIVAS

```
A_grid[:, 0:N-1] = Standard_Backward_Induction(...)
return A_grid

def build_fine_mesh(coarse_grid, h_coarse, k_coarse, N_coarse, r, q, sigma, H, K):
    total_fine_steps = N_coarse * 4
    B_grid = initialize_fine_mesh()

    # 1. INYECCIÓN DE NODOS (Eq. 11)
    for j in range(N_coarse): # Lógica de interpolación (Eq. 12 y 13)
        t_start = j * 4
        B_grid[2, t_start] = coarse_grid[1, j] # El source siempre es la malla previa
        V_Ad, V_Am, V_Au = coarse_grid[:, j+1] # Nodos intermedios (Interpolación)

        for sub_step in range(1, 4):
            dt_eff = (4 - sub_step) * (k_coarse / 4) # Distancia efectiva a próximo A
            pu_adj, pm_adj, pd_adj = calcular_probs(dt_eff, h_coarse, r, q, sigma)

            # Valorar usando los nodos A del FUTURO
            B_grid[2, t_start + sub_step] = (pu_adj * V_Au +
                                              pm_adj * V_Am +
                                              pd_adj * V_Ad) * np.exp(-r * dt_eff)

    # 2. RELLENO INTERNO (Backward Induction)
    h_fine, k_fine = h_coarse / 2, k_coarse / 4
    pu, pm, pd = calcular_probs(k_fine, h_fine, r, q, sigma)

    B_grid[2, total_fine_steps] = coarse_grid[1, N_coarse]
    B_grid[:, total_fine_steps] = actualizar_payoff_terminal(...)
    B_grid[:, 0:total_fine_steps-1] = Standard_Backward_Induction(...)
    return B_grid
```

Esta estructura garantiza que la información fluya correctamente desde la resolución más baja hacia la más alta (flujo downward para barreras), permitiendo obtener el precio de alta precisión en $t = 0$.

4.2.2. Detalles de Implementación

Estructuras de Datos y Memoria

Uno de los errores más comunes al implementar métodos de refinamiento de malla es instanciar una matriz global de alta resolución y dejar la mayoría de sus entradas vacías o inutilizadas. La eficiencia del AMM radica en que la malla fina es un “parche” local y no una estructura global. Por tanto, la gestión de memoria debe tratar las mallas como entidades separadas pero vinculadas.

Arquitectura de Almacenamiento Disperso En lugar de crear una matriz de tamaño $(4N \times 4N)$ que consumiría memoria cuadrática, la implementación debe utilizar dos estructuras distintas:

1. Matriz Base (A): Un array bidimensional de tamaño $(N + 1) \times (2N + 1)$ para almacenar los valores de la malla gruesa.

4.2. ÁRBOLES TRINOMIALES CON MALLAS ADAPTATIVAS

2. Matriz de Banda (B): Una estructura optimizada que almacena solo los nodos necesarios a lo largo de la barrera.

Para un modelo de barrera con un nivel de refinamiento ($M = 1$), la malla fina no cubre todo el espacio de precios, sino solo una franja estrecha adyacente a H . Según el análisis de complejidad, la cantidad de nodos adicionales es lineal respecto al tiempo:

$$Nodos_{adicionales} = 10 \times N \quad (4.12)$$

Donde N es el número de pasos de tiempo de la malla gruesa.

Recomendación de Implementación: Representar la malla fina B como una matriz de dimensiones $(3 \times 4N)$.

- La dimensión vertical es 3 porque solo necesitamos calcular los nodos en los niveles $h/2$ (interno), h (frontera superior) y 0 (barrera/frontera inferior).
- La dimensión horizontal es $4N$ porque la resolución temporal es cuatro veces mayor.

Esto reduce el consumo de memoria drásticamente en comparación con refinar todo el árbol.

Complejidad Computacional y Escalabilidad La ventaja crítica del AMM debe documentarse en esta sección. Al añadir niveles de profundidad, el número de nodos crece, pero de manera controlada.

Para un nivel de profundidad m , el número de nodos nuevos añadidos por cada paso de tiempo grueso es:

$$\Delta Nodos(m) = 10 \times 4^{m-1} \quad (4.13)$$

Esto implica que para un árbol estándar de $N = 100$ pasos (aprox. 10,000 nodos totales):

- **AMM Nivel 1:** Añade solo 1,000 nodos (incremento del 10%). *Total $\approx 11,200$ nodos.*
- **Equivalente Estándar (Refinado Global):** Para obtener la misma resolución espacial cerca de la barrera sin AMM, se requeriría cuadruplicar N a 400. Esto generaría aprox. 160,000 nodos.

El código debe reflejar esta eficiencia: el tiempo de ejecución para el AMM debe ser comparable al del árbol trinomial base, mientras que el error de convergencia se reduce cuadráticamente.

Código Relevante

La implementación del AMM requiere traducir las ecuaciones de probabilidad ajustada y la lógica recursiva en estructuras de control eficientes. A continuación se presentan los tres componentes críticos que permiten la convergencia estable del modelo.

1. Calibración Geométrica y Parámetro de Estiramiento Para garantizar la estabilidad numérica descrita por Figlewski y Gao (1999), el paso de tiempo k no puede ser arbitrario; debe derivarse del paso de precio h para mantener el parámetro de estiramiento $j \approx 3$. El siguiente snippet muestra cómo se fuerza esta restricción para obtener un número entero de pasos N .

Listing 4.2: Cálculo de pasos de tiempo enteros (Eq. 17)

```
def calibrar_geometria(S0, H, T, sigma, M):
    distancia = |log(S0) - log(H)|

    # Eq. 18: El paso de precio crece exponencialmente con M
    h_coarse = (2**M) * distancia

    # Eq. 11 y 17: Ajuste del paso de tiempo para j=3
    # Se redondea N al entero mas cercano para evitar pasos fraccionarios
    N_ideal = (T * 3 * sigma**2) / (h_coarse**2)
    N_steps = int(N_ideal)

    k_coarse = T / N_steps
    return h_coarse, k_coarse, N_steps
```

2. Probabilidades de Transición en la Interfaz La mayor complejidad del AMM reside en los nodos “colgantes” de la interfaz (Fila 2 de la malla fina). A diferencia de los nodos estándar, estos requieren probabilidades que varían según su distancia temporal al siguiente nodo grueso, tal como se define en la Ecuación (12).

Listing 4.3: Cálculo dinámico de probabilidades para nodos de interfaz

```
def calcular_probs(dt_eff, dx, r, q, sigma):
    """
    Calcula probabilidades para sub-pasos  $k/4, 2k/4, 3k/4$ .  $dt\_eff$ :
    Tiempo restante hasta el proximo nodo grueso ( $T, T-k/4, \dots$ )
    """
    drift = r - q - 0.5 * sigma**2

    # Terminos de la Ecuacion (12)
    term1 = (sigma**2 * dt_eff) / (dx**2)
    term2 = (drift**2 * dt_eff**2) / (dx**2)
    term3 = (drift * dt_eff) / dx

    pu = 0.5 * (term1 + term2 + term3)
    pd = 0.5 * (term1 + term2 - term3)
    pm = 1.0 - pu - pd

    return pu, pm, pd
```

3. El Bucle de Refinamiento Recursivo

4.2.3. Validación

Para verificar la corrección de la implementación y demostrar la superioridad del AMM sobre los árboles estándar, se realizaron pruebas de convergencia comparando los resultados del modelo contra la solución analítica cerrada para opciones de barrera continua.

Metodología de Validación (Benchmark)

Es crucial notar que el AMM converge a la solución de tiempo continuo, no a la discreta. Por lo tanto, el benchmark correcto no es un árbol binomial de pasos altos, sino la fórmula de Merton (1973) para opciones down-and-out call:

$$C_{teo} = C_{BS}(S_0, K) - \left(\frac{H}{S_0}\right)^{2\lambda} C_{BS}(H^2/S_0, K) \quad (4.14)$$

Donde $\lambda = \frac{r-q-\sigma^2/2}{\sigma^2}$ y C_{BS} es la fórmula estándar de Black-Scholes.

Prueba de Estrés: El Problema del Límite

Se evaluó el desempeño del modelo en el escenario crítico donde el precio inicial S_0 está extremadamente cerca de la barrera, una situación donde los métodos tradicionales fallan por falta de resolución o inestabilidad numérica.

Configuración del Experimento:

- Barrera $H = 90$, Strike $K = 100$, $T = 1$, $\sigma = 0,25$, $r = 0,1$.
- Precio Inicial Crítico: $S_0 = 90,125$ (Distancia de 0,14 % a la barrera).

Resultados Comparativos:

Método	Pasos de Tiempo (N)	Valor Calculado	Error Relativo
Solución Exacta (Merton)	-	$\approx 0,161648$	-
Árbol Trinomial ($M = 0$)	N/A	<i>Fallo (Oscilación)</i>	$> 100 \%$
AMM Nivel 2 ($M = 2$)	6083	0,161312	0,21 %
AMM Nivel 4 ($M = 4$)	380	0,161532	0,07 %

Tabla 4.1: Comparación de convergencia cerca de la barrera ($S_0 = 90,125$).

Análisis: Como se observa en la Tabla 4.1, el árbol estándar es incapaz de valorar la opción con una malla razonable porque el paso de precio mínimo es mayor que la distancia $S_0 - H$. El AMM con $M = 4$ logra una precisión de 4 decimales manteniendo el costo computacional bajo ($N = 100$ pasos base), resolviendo efectivamente el problema del límite mediante la inserción local de nodos.

Análisis de Eficiencia

Las pruebas de tiempo de ejecución confirman que el costo computacional del AMM escala linealmente. Añadir un nivel de refinamiento incrementa el tiempo de cálculo en aproximadamente un factor constante pequeño (correspondiente a valorar la franja de 3 filas), en contraste con el factor de $\times 16$ (4^2) que requeriría

4.2. ÁRBOLES TRINOMIALES CON MALLAS ADAPTATIVAS

refinar todo el árbol globalmente. Esto valida la eficiencia del método para aplicaciones en tiempo real.

4.3. Replicación Estática

En esta sección se detalla el procedimiento computacional utilizado para implementar la metodología de replicación estática descrita teóricamente en el capítulo 3. El objetivo es construir un portafolio de opciones estándar cuyos valores en la frontera coincidan con los de una opción barrera objetivo.

4.3.1. Descripción del Algoritmo

El algoritmo implementado se basa en un proceso recursivo de “inducción hacia atrás” (backward induction), discretizando el tiempo de vida de la opción en N intervalos.

Selección de Strikes

Para garantizar que los instrumentos de cobertura no generen flujos de caja no deseados dentro de la región de validación, la selección de los precios de ejercicio (K) se automatiza siguiendo las reglas de frontera de Derman-Ergener-Kani:

- Para la frontera de vencimiento ($t = T$): Se utilizan opciones con el mismo strike que la opción original para replicar el payoff estándar.
- Para barreras superiores ($B > S_0$): Se seleccionan opciones Call con $K = B$. Esto asegura que si $S < B$, la opción expira out-of-the-money y no altera el valor del portafolio.
- Para barreras inferiores ($B < S_0$): Se seleccionan opciones Put con $K = B$.

Cálculo de Pesos

El algoritmo calcula los pesos (w_i o α_i) iterando desde el vencimiento hacia el presente. Sea t_i los puntos discretos en el tiempo donde se ajusta la frontera:

1. Inicialización ($t_N = T$): Se establece el portafolio inicial igualando el pago de la opción al vencimiento. 2. Bucle Recursivo ($i = N - 1, \dots, 1$):

- Se calcula el valor del portafolio acumulado (V_{port}) en el punto de la barrera (B, t_i).
- Se calcula el valor teórico de la opción objetivo (V_{target}) en ese mismo punto (generalmente 0 para knock-out o el valor del rebate).
- Se determina el peso de la nueva opción de ajuste (C_{ajuste}) mediante la fórmula discreta derivada del principio de replicación:

$$\alpha_i = \frac{V_{target}(B, t_i) - V_{port}(B, t_i)}{C_{ajuste}(B, t_i)} \quad (4.15)$$

Esta ecuación asegura que el error de valor en la frontera sea cero en el tiempo t_i .

4.3.2. Detalles de Implementación

Para la ejecución del modelo se asumen las condiciones estándar de Black-Scholes (volatilidad constante σ , tasa libre de riesgo r y dividendos d). La implementación requiere definir la granularidad de la discretización temporal, la cual afecta directamente la precisión de la réplica.

La frontera continua se aproxima mediante un conjunto finito de puntos de control (B, t_k) . En la práctica, esto implica que el portafolio solo garantiza la igualdad de valor exactamente en estos puntos. Si el activo subyacente toca la barrera entre dos puntos de control, existe un error de discretización teórico. Asimismo, el modelo asume que, al tocarse la barrera, el portafolio estático se liquida para cubrir la obligación o eliminar la posición, un proceso teóricamente libre de costos si la replicación es perfecta.

4.3.3. Validación del Portafolio Replicante

Para validar la eficacia del algoritmo, se compara el valor del portafolio estático resultante contra el valor teórico analítico de la opción objetivo (calculado mediante fórmulas cerradas estándar, como Rubinstein-Reiner para opciones barrera).

Comparación y Análisis de Convergencia

El análisis demuestra que la calidad de la replicación depende críticamente del número de instrumentos de cobertura utilizados (frecuencia de ajuste en la frontera).

Basado en los resultados de Derman et al., se observa que:

- Replicación de baja frecuencia (6 opciones): Al ajustar la frontera cada 2 meses (6 puntos de contacto), el desajuste (mismatch) entre el portafolio y la opción objetivo puede ser significativo, alcanzando errores cercanos al 19 % del valor de la opción en regiones próximas a la barrera y cercanas al vencimiento.
- Replicación de alta frecuencia (24 opciones): Al aumentar la discretización a ajustes quincenales (24 puntos), el error de valor disminuye drásticamente. El perfil de valor del portafolio replicante converge hacia el de la opción barrera teórica, reduciendo el desajuste a niveles marginales (aprox. 0.10 en valor monetario frente a un valor objetivo de 2.00).

Esto confirma que, aunque una réplica perfecta requeriría infinitas opciones, una aproximación con un número finito (ej. 24) logra una convergencia robusta para fines prácticos.

Ejemplos Numéricos

Consideremos una opción Up-and-Out Call con los siguientes parámetros: $S_0 = 100$, Strike $K = 100$, Barrera $B = 120$, Vencimiento $T = 1$ año, Volatilidad $\sigma = 15\%$, $r = 5\%$.

1. Valor Objetivo: El valor teórico de esta opción es 1.913.

4.3. REPLICACIÓN ESTÁTICA

2. Portafolio (6 ajustes): Construido con 1 Call estándar ($K = 100$) y 6 Calls ($K = 120$) con vencimientos bimestrales.
 - El valor resultante del portafolio es 2,284.
 - Error: 0,37 (aprox. 19%). El error se concentra principalmente cerca de la barrera cuando falta poco tiempo para el vencimiento.
3. Portafolio (24 ajustes): Construido con ajustes cada 0.5 meses.
 - El valor resultante del portafolio es 2,01.
 - Error: 0,10 (aprox. 5%). La superficie de valor del portafolio es casi indistinguible de la opción objetivo.

Estos resultados validan que el método de replicación estática permite descomponer una opción exótica compleja en una suma lineal de opciones vanilla, facilitando su valoración y cobertura sin necesidad de rebalanceo dinámico continuo.

4.4. Monte Carlo para Opciones Americanas

Este capítulo documenta la implementación del método de Longstaff-Schwartz (LSM) para la valoración de opciones americanas con barreras mediante simulación de Monte Carlo.

4.4.1. Descripción del Algoritmo Implementado

Generación de Trayectorias

La generación de trayectorias del precio del activo subyacente se implementa usando la fórmula exacta del Movimiento Browniano Geométrico:

$$S_{t+\Delta t} = S_t \exp \left[\left(r - \delta - \frac{\sigma^2}{2} \right) \Delta t + \sigma \sqrt{\Delta t} Z \right] \quad (4.16)$$

donde $Z \sim N(0, 1)$ es una variable aleatoria normal estándar.

Parámetros de Discretización:

- **Número de simulaciones** M : Típicamente entre 10,000 y 100,000 trayectorias
- **Número de pasos temporales** N : Entre 50 y 252 pasos (días de trading anuales)
- **Paso temporal**: $\Delta t = T/N$

La implementación genera todas las trayectorias de forma vectorizada para eficiencia computacional:

```
dt = T / steps
z = np.random.standard_normal((iterations, steps))
log_returns = (r - delta - 0.5 * sigma**2) * dt + \
              sigma * np.sqrt(dt) * z
cumulative_log_returns = np.cumsum(log_returns, axis=1)
s_path = S0 * np.exp(np.hstack([np.zeros((iterations, 1)),
                                cumulative_log_returns]))
```

Monitoreo de Barrera

Para opciones con barreras, se monitorea en cada paso temporal si el precio ha cruzado el nivel de barrera H .

Knock-Out (Down-and-Out):

```
hit_barrier = np.any(s_path <= H, axis=1)
```

Knock-Out (Up-and-Out):

```
hit_barrier = np.any(s_path >= H, axis=1)
```

Knock-In: Se utiliza la lógica inversa, marcando las trayectorias que han activado la opción.

Sesgo de Discretización: El monitoreo discreto puede no detectar cruces que ocurren entre puntos de observación. Este sesgo se reduce aumentando N , aunque esto incrementa el costo computacional. Para aplicaciones que requieren alta precisión, se pueden usar técnicas de corrección de continuidad o métodos de Brownian bridge.

Método de Longstaff-Schwartz

El núcleo del algoritmo LSM implementa la inducción hacia atrás con regresión para estimar valores de continuación.

Paso 1: Inicialización al Vencimiento. Para cada trayectoria i , el valor al vencimiento es el payoff:

$$V_{t_N}^{(i)} = \max(K - S_{t_N}^{(i)}, 0) \quad (\text{para puts}) \quad (4.17)$$

```
cash_flow = np.maximum(K - s_path[:, -1], 0) # Put payoff
```

Paso 2: Inducción Hacia Atrás. Para cada tiempo t_j desde t_{N-1} hasta t_1 :

1. Descontar cash flows futuros:

```
cash_flow = cash_flow * np.exp(-r * dt)
```

2. Identificar trayectorias in-the-money:

$$\mathcal{I}_j = \{i : K - S_{t_j}^{(i)} > 0\} \quad (4.18)$$

```
intrinsic = np.maximum(K - s_path[:, t], 0)
itm = intrinsic > 0
```

3. Verificar estado de barrera:

```
hit_barrier = np.any(s_path[:, :t+1] <= H, axis=1)
active = itm & ~hit_barrier # ITM y no tocó barrera
```

4. Regresión de mínimos cuadrados:

Se realiza regresión solo sobre trayectorias activas para estimar el valor de continuación:

$$\min_{a_0, \dots, a_K} \sum_{i \in \mathcal{I}_j} \left[Y^{(i)} - \sum_{k=0}^K a_k L_k(S_{t_j}^{(i)}) \right]^2 \quad (4.19)$$

```
if np.sum(active) > 0:
```

```
    X = s_path[active, t]
    Y = cash_flow[active]
```

```
    # Regresión con polinomios (simples)
```

```
    regression = np.polyfit(X, Y, deg=2)
```

```
    continuation_value = np.polyval(regression, X)
```

```
    # Regresión con polinomios (Laguerre)
```

```
    # basis = laguerre_basis(X, degree=3) # Construye L_0, L_1, L_2, L_3
```

```
    # coeffs = np.linalg.lstsq(basis, Y, rcond=None)[0]
```

```
    # continuation = basis @ coeffs
```

5. Decisión de ejercicio óptimo:

$$V_{t_j}^{(i)} = \begin{cases} K - S_{t_j}^{(i)} & \text{si } K - S_{t_j}^{(i)} > C_{t_j}^{(i)} \\ e^{-r\Delta t} V_{t_{j+1}}^{(i)} & \text{en caso contrario} \end{cases} \quad (4.20)$$

```
exercise = intrinsic[active] > continuation_value
cash_flow[active][exercise] = intrinsic[active][exercise]
```

6. Anular trayectorias que tocaron barrera:

```
cash_flow[hit_barrier] = 0 # o rebate R si aplica
```

Paso 3: Valoración Final. El valor de la opción es el promedio descontado:

$$V(S_0, 0) \approx e^{-r\Delta t} \frac{1}{M} \sum_{i=1}^M \text{CashFlow}_i \quad (4.21)$$

```
option_value = np.exp(-r * dt) * np.mean(cash_flow)
```

4.4.2. Detalles de Implementación

La implementación se realiza en Python 3.8+ utilizando NumPy para operaciones vectorizadas. La arquitectura del código prioriza la eficiencia mediante operaciones matriciales que evitan bucles explícitos.

Lenguaje y Librerías**Dependencias principales:**

- **NumPy** (v2.4.1): Generación de números aleatorios, operaciones vectorizadas
- **scikit-learn** (opcional): Regresión lineal alternativa para LSM

Generador de números aleatorios:

```
rng = np.random.default_rng(seed=42) # Para reproducibilidad
z = rng.standard_normal((iterations, steps))
```

Funciones Base para Regresión

Se implementan dos tipos de funciones base para la regresión en el método LSM:

1. Polinomios Simples (más rápidos):

```
coeffs = np.polyfit(X, Y, deg=2)
continuation = np.polyval(coeffs, X)
```

2. Polinomios de Laguerre (más precisos):

```
def laguerre_basis(x, degree=3):
    L = np.ones((len(x), degree + 1))
    if degree >= 1:
        L[:, 1] = 1 - x
    for n in range(1, degree):
        L[:, n+1] = ((2*n+1-x)*L[:, n] - n*L[:, n-1]) / (n+1)
    return L

basis = laguerre_basis(X, degree=3)
coeffs = np.linalg.lstsq(basis, Y, rcond=None)[0]
continuation = basis @ coeffs
```

Optimizaciones Implementadas

Vectorización: Todas las operaciones sobre trayectorias usan broadcasting de NumPy, evitando bucles que degradarían el rendimiento 10-100x.

Regresión selectiva: Solo se ejecuta sobre trayectorias in-the-money activas, reduciendo el costo computacional típicamente en 30-50 %.

Gestión de memoria: Para $M = 100,000$ con $N = 252$, la matriz ocupa ~200 MB en float64. Si es necesario, usar float32 (100 MB) con pérdida mínima de precisión.

Tiempos de Ejecución

Tiempos típicos (CPU Intel i7, single-thread):

Simulaciones (M)	Pasos (N)	Tiempo
10,000	50	22 ms
50,000	100	193 ms
100,000	252	728 ms

Tabla 4.2: Tiempos de ejecución para opciones americanas con barrera

4.4.3. Validación de Monte Carlo

Análisis de Convergencia

Se analiza la convergencia del método respecto a dos parámetros clave usando una American Down-and-Out Put con parámetros: $S_0 = 44$, $K = 40$, $H = 39,6$, $T = 1$, $r = 0,06$, $\sigma = 0,2$.

1. Convergencia respecto al número de simulaciones M :

El error estándar teórico es $SE = \sigma/\sqrt{M}$, donde σ es la desviación estándar de los payoffs. Los resultados empíricos con $N = 50$ pasos temporales son:

Simulaciones (M)	Error Estándar
1,000	0.003069
5,000	0.001363
10,000	0.000952
50,000	0.000420
100,000	0.000298

Tabla 4.3: Convergencia del error estándar respecto al número de simulaciones

Se verifica que el error decrece aproximadamente como $O(1/\sqrt{M})$: al multiplicar M por 4, el error se reduce a la mitad, confirmando la teoría.

2. Convergencia respecto al número de pasos temporales N :

Para opciones con barreras, aumentar N reduce el sesgo de discretización en el monitoreo de la barrera. Se recomienda usar al menos $N = 50$ para barreras cercanas al precio inicial y $N = 100 - 252$ para aplicaciones que requieren alta precisión.

Intervalos de Confianza

El intervalo de confianza al 95 % se calcula como:

$$IC_{95\%} = \bar{V} \pm 1,96 \cdot \frac{\hat{\sigma}}{\sqrt{M}} \quad (4.22)$$

donde $\bar{V}$ es el precio estimado y $\hat{\sigma}$ es la desviación estándar muestral de los payoffs descontados.

Ejemplos Numéricos

Se presentan dos casos de prueba para validar la implementación y demostrar el cálculo de intervalos de confianza.

Caso 1: American Down-and-Out Put

Parámetros: $S_0 = 100$, $K = 100$, $H = 80$, $T = 1$ año, $r = 0,05$, $\sigma = 0,25$, $M = 50,000$, $N = 100$.

```
price , std = monte_carlo_lsm_barrier(  
    S0=100, K=100, H=80, T=1, r=0.05, sigma=0.25,  
    iterations=50000, steps=100,  
    isCall=False, isUp=False, isIn=False  
)
```

Resultados obtenidos:

- Precio estimado: $V = 7,5064$
- Error estándar: $SE = 0,0304$
- Intervalo de confianza 95 %: $[7,4469, 7,5660]$
- Ancho del intervalo: $0,1191$

Caso 2: American Up-and-In Call

Parámetros: $S_0 = 100$, $K = 100$, $H = 120$, $T = 1$ año, $r = 0,05$, $\sigma = 0,30$, $M = 50,000$, $N = 100$.

```
price, std = monte_carlo_lsm_barrier(  
    S0=100, K=100, H=120, T=1, r=0.05, sigma=0.30,  
    iterations=50000, steps=100,  
    isCall=True, isUp=True, isIn=True  
)
```

Resultados obtenidos:

- Precio estimado: $V = 13,8092$
- Error estándar: $SE = 0,1025$
- Intervalo de confianza 95 %: $[13,6083, 14,0101]$
- Ancho del intervalo: 0,4018

Interpretación de los Resultados:

- El IC 95 % indica que hay 95 % de probabilidad de que el valor verdadero esté dentro del intervalo calculado
- El Caso 2 tiene un IC más ancho (0,4018 vs 0,1191) debido a mayor varianza en los payoffs (mayor $\sigma = 0,30$ y naturaleza knock-in)
- Para reducir el ancho del IC a la mitad, se necesitan 4 veces más simulaciones (debido a la convergencia $O(1/\sqrt{M})$)
- El precio del Up-and-In Call (13,81) es mayor que el Down-and-Out Put (7,51), reflejando la mayor volatilidad y el drift positivo de la tasa libre de riesgo

Verificación de Límites:

Para validar la implementación, se verifica que cuando la barrera está muy lejos del precio inicial, el precio de una opción con barrera converge al de una opción americana vanilla (sin barrera). Se utiliza una American Put con parámetros: $S_0 = 100$, $K = 100$, $T = 1$, $r = 0,05$, $\sigma = 0,25$, $M = 50,000$, $N = 100$.

Tipo de Opción	Precio	Diferencia vs Vanilla
Vanilla ($H=0.01$, imposible)	7.8819	—
Down-and-Out ($H=50$)	7.8815	0.0005
Down-and-Out ($H=10$)	7.8819	0.0000

Tabla 4.4: Convergencia al límite vanilla cuando la barrera se aleja

Los resultados confirman que:

- Con $H = 10$ (muy por debajo de $S_0 = 100$), la diferencia es prácticamente nula (0.0000)
- Con $H = 50$ (lejana pero no extrema), la diferencia es mínima (0.0005)
- Esto valida que la implementación maneja correctamente los casos límite
- La opción vanilla se simula usando $H = 0,01$ con knock-out, garantizando que la barrera nunca se toca

Capítulo 5

Resultados y Comparación

5.1. Diseño de Experimentos

Para evaluar de manera rigurosa las metodologías implementadas en este trabajo, el diseño experimental se ha estructurado en torno a los desafíos matemáticos específicos que presenta cada tipo de opción. En lugar de utilizar un único conjunto de parámetros arbitrario, los experimentos se basan en los escenarios propuestos por la literatura fundacional de cada modelo. Esto permite no solo validar la correctitud de nuestras implementaciones, sino también aislar y medir el impacto del “problema del límite”, el error de discretización temporal y la convergencia estadística de manera independiente.

5.1.1. Casos de Prueba para Opciones Europeas

La evaluación de las opciones de estilo europeo se divide en dos grandes escenarios, diseñados para contrastar los métodos numéricos frente a las fórmulas exactas de Reiner y Rubinstein.

El primer escenario está diseñado para llevar al extremo el error de no linealidad y el problema geométrico de las redes discretas. Para ello, evaluamos una opción Down-and-Out Call con un precio de ejercicio $K = 100$, una barrera inferior $H = 90$, vencimiento a un año ($T = 1$), tasa libre de riesgo del 10 % y volatilidad del 25 %. El experimento consiste en calcular el valor de la opción acercando progresivamente el precio inicial del activo (S_0) hacia la barrera (desde $S_0 = 92$ hasta $S_0 = 90,125$). Este diseño nos permitirá observar cómo el árbol trinomial estándar colapsa computacionalmente al intentar alinear sus nodos con la barrera y cómo el Modelo de Malla Adaptativa (AMM) resuelve esta crisis.

El segundo escenario se enfoca en el problema de la cobertura en el mercado real, evaluando el algoritmo de Replicación Estática. Utilizaremos una opción Up-and-Out Call con $S_0 = 100$, $K = 100$, una barrera superior $H = 120$, vencimiento $T = 1$, tasa de interés del 5 %, rendimiento por dividendos del 3 % y volatilidad del 15 %. En este caso, el objetivo no es variar el precio inicial, sino alterar la frecuencia temporal con la que construimos el portafolio de opciones vanilla de cobertura (comparando ajustes bimestrales frente a quincenales) para medir cómo la discretización del tiempo afecta el costo real de replicar la opción exótica.

5.1.2. Casos de Prueba para Opciones Americanas

Dado que la valoración de opciones americanas introduce el problema del ejercicio anticipado, el diseño experimental para la simulación de Monte Carlo requiere un enfoque distinto. Para aislar el efecto de la regresión transversal introducida por el método de Longstaff-Schwartz (LSM), el caso de prueba se basará en una opción Put americana estándar, evitando temporalmente la interferencia de una barrera.

Los parámetros base establecen un precio de ejercicio $K = 40$, una tasa libre de riesgo del 6 % y una volatilidad del 20 %. Evaluaremos la opción para dos horizontes temporales distintos ($T = 1$ y $T = 2$ años) y bajo tres condiciones de moneyness inicial: in-the-money ($S_0 = 36$), at-the-money ($S_0 = 40$) y out-of-the-money ($S_0 = 44$). Este abanico de escenarios garantiza que el algoritmo de regresión del LSM, basado en polinomios de Laguerre, sea puesto a prueba en trayectorias donde la decisión de ejercicio temprano es trivial frente a aquellas donde el valor de continuación y el valor intrínseco son casi idénticos.

5.1.3. Métricas de Evaluación

Para garantizar una comparación objetiva entre los distintos métodos, definimos un conjunto estandarizado de métricas que capturan tanto la precisión matemática como la viabilidad computacional. La exactitud de los métodos para opciones europeas (AMM y Replicación Estática) se cuantifica mediante el error absoluto y el error relativo tomando como “oráculo” o valor real el resultado arrojado por las ecuaciones analíticas de Reiner y Rubinstein. En el caso de la simulación de Monte Carlo para opciones americanas, al no existir una fórmula cerrada, la convergencia se evalúa analizando el error estándar estadístico de la simulación a medida que se aumenta el número de trayectorias (desde 1,000 hasta 100,000 caminos). Finalmente, la eficiencia algorítmica se evalúa de forma dual. Por un lado, se registra el tiempo de ejecución (CPU time) necesario para alcanzar un nivel de precisión aceptable. Por otro lado, y de manera más fundamental, se analiza la complejidad espacial, medida a través del número total de nodos instanciados en el caso de los árboles (donde contrastamos el crecimiento lineal del AMM frente al crecimiento cuadrático del trinomial global) y el número de opciones de ajuste necesarias en el caso del portafolio estático.

5.2. Resultados para Opciones Europeas

5.2.1. Superando el “Problema del Límite”: Trinomial Estándar vs. AMM

La valoración de opciones barrera mediante redes discretas enfrenta un desafío geométrico crítico cuando el precio inicial del activo subyacente se encuentra muy cerca del nivel de la barrera. Como se explicó en capítulos anteriores, para evitar errores severos de estimación, los modelos de árbol requieren que una capa horizontal de nodos coincida exactamente con la barrera. Sin embargo, forzar esta alineación implica que el tamaño del paso de precio (h) no puede ser mayor que la distancia entre el precio inicial y la barrera. Dado que el paso de tiempo (k) debe ser proporcional al cuadrado del paso de precio para mantener la estabilidad probabilística, reducir h provoca que el número total de pasos

5.2. RESULTADOS PARA OPCIONES EUROPEAS

de tiempo (N) crezca de manera cuadrática. Este fenómeno, conocido como el “problema del límite”, puede volver al método estándar computacionalmente inmanejable.

Para ilustrar este comportamiento y evaluar la solución propuesta por el Modelo de Malla Adaptativa (AMM), calculamos el valor de una opción Down-and-Out Call (con strike $K = 100$, barrera $H = 90$, volatilidad $\sigma = 25\%$, tasa $r = 10\%$ y vencimiento $T = 1$ año) acercando progresivamente el precio inicial (S_0) hacia la barrera. La Tabla 5.1 contrasta el valor arrojado por las fórmulas analíticas de Reiner y Rubinstein (como valor exacto de referencia) frente a los resultados y requerimientos computacionales del árbol trinomial estándar y del AMM.

Tabla 5.1: Comparación de métodos numéricos para valoración de Down-and-Out Call cerca de la barrera. Los parámetros son: $K = 100$, $H = 90$, $T = 1$ año, $r = 0,10$, $d = 0,05$, $\sigma = 0,25$.

Precio Inicial (S_0)	Valor Analítico (R&R)	Trinomial Estándar (Valor / Pasos N)	Malla Adaptativa AMM (Valor / Nivel M)
92.000	2.506	2.507 (N=388)	2.507 (M=0)
91.000	1.274	1.274 (N=1,535)	1.274 (M=1)
90.500	0.642	0.642 (N=6,108)	0.643 (M=2)
90.250	0.323	0.323 (N=24,367)	0.323 (M=3)
90.125	0.162	Falla / Inmanejable	0.162 (M=4)

El análisis de estos resultados expone claramente la vulnerabilidad del enfoque tradicional. Cuando el precio del activo se encuentra a una distancia segura de la barrera ($S_0 = 92$), ambos métodos logran converger al valor teórico de 2,506 con un costo computacional bajo. No obstante, a medida que S_0 se acerca a 90, el árbol trinomial estándar sufre una explosión combinatoria. Al llegar a $S_0 = 90,125$ (apenas a un octavo de punto de la barrera), forzar un nodo sobre $H = 90$ exige un paso de precio minúsculo, disparando la cantidad de pasos de tiempo teóricos a casi 100,000 iteraciones. En este punto, la creación de la matriz global del árbol colapsa la memoria o requiere tiempos de ejecución inaceptables, provocando el fallo práctico del método. En marcado contraste, el comportamiento del AMM demuestra una eficiencia notable. Al mantener una red base gruesa (por ejemplo, $N = 100$) y resolver el requerimiento de distancia injertando niveles sucesivos de malla fina (M) únicamente en la franja adyacente a la barrera, el AMM desvincula la resolución espacial de la complejidad global del árbol. Para el caso extremo de $S_0 = 90,125$, al aplicar 4 niveles de refinamiento ($M = 4$), el AMM es capaz de capturar la no linealidad y calcular el precio exacto de 0,162 en fracciones de segundo. En conclusión, este experimento demuestra que el AMM actúa como una solución quirúrgica: no desperdicia poder de cómputo en regiones donde el precio del activo se comporta de forma lineal. Al concentrar la resolución exclusivamente donde la geometría de la barrera lo exige, el modelo supera el “problema del límite” y garantiza tasaciones precisas incluso en los escenarios más críticos.

5.2.2. Convergencia y Costo de la Replicación Estática

A diferencia del Modelo de Malla Adaptativa, que busca resolver numéricamente la ecuación diferencial subyacente con la mayor exactitud posible, la metodología de Replicación Estática de Derman, Ergener y Kani aborda el problema desde la perspectiva de la cobertura en el mercado (hedging). En este contexto, el valor calculado no es simplemente una aproximación matemática, sino el costo real de construir un portafolio compuesto por opciones vanilla que imite el comportamiento de la opción exótica. Por lo tanto, el error numérico en este método representa el “desajuste” o mismatch financiero al que se expone el emisor por discretizar la frontera de la barrera en intervalos de tiempo finitos. Para evaluar este comportamiento, consideramos una opción Up-and-Out Call con un precio inicial $S_0 = 100$, un precio de ejercicio $K = 100$ y una barrera superior $H = 120$, con vencimiento a un año ($T = 1$), tasa libre de riesgo del 5 % y volatilidad del 15 %. De acuerdo con las fórmulas analíticas de Reiner y Rubinstein, el valor teórico exacto de esta opción es 1,913. El experimento consiste en construir el portafolio replicante variando la frecuencia con la que se añaden opciones estándar para forzar que el valor del portafolio sea cero sobre la barrera. La Tabla 5.2 muestra el costo de estos portafolios y su error respecto al valor teórico.

Tabla 5.2: Convergencia de la Replicación Estática: efecto del número de opciones de ajuste

Método de Valoración / Cobertura	Valor Calculado	Error Absoluto	Error Relativo
Valor Teórico Objetivo (R&R)	1.913	—	—
Portafolio (6 ajustes / frecuencia bimestral)	2.284	+0.371	$\approx 19.4\%$
Portafolio (24 ajustes / frecuencia quincenal)	2.010	+0.097	$\approx 5.0\%$

El análisis de estos resultados revela el impacto directo de la discretización temporal en la gestión de riesgos. Si el emisor de la opción decide cubrirse realizando ajustes estáticos en la frontera solo cada dos meses (requiriendo un portafolio de 6 opciones), el costo de armar dicha cobertura es de 2,284, lo que sobreestima el valor real de la opción en casi un 20 %. Este sobrecosto ocurre porque el portafolio garantiza que su valor será cero únicamente en las fechas de ajuste. Si el precio del activo cruza la barrera de 120 en un día intermedio entre dos ajustes, el portafolio no se anulará perfectamente, dejando al emisor con un riesgo residual. El mercado cobra una prima por asumir la imprecisión de esta cobertura discreta. Sin embargo, a medida que aumentamos la densidad del portafolio utilizando 24 opciones con vencimientos quincenales, la frontera discreta se aproxima mucho más a la barrera continua real. Como resultado, el valor del portafolio cae a 2,010, reduciendo el error relativo a un marginal 5 %. Esto demuestra empíricamente que la Replicación Estática converge de manera robusta y predecible hacia el valor teórico a medida que aumenta la granularidad de la discretización, permitiendo a los operadores equilibrar el costo de transacción (comprar más opciones) frente al riesgo de desajuste.

5.2.3. Comparación Unificada: Precisión Numérica frente a Viabilidad de Mercado

Para consolidar el análisis de las opciones de estilo europeo, resulta sumamente ilustrativo contrastar el desempeño de los tres métodos estudiados (Reiner-Rubinstein, AMM y Replicación Estática) bajo un mismo escenario base. Esta comparación unificada, presentada en la Tabla 5.3 utilizando los parámetros del experimento anterior, pone en evidencia las diferencias fundamentales en la naturaleza y propósito de cada algoritmo.

Tabla 5.3: Comparación Unificada de Métodos para Opciones Europeas

Método de Valoración	Enfoque Principal	Valor Calculado	Error Absoluto vs R&R
Reiner & Rubinstein (R&R)	Teórico Exacto (Oráculo)	1.913	—
Malla Adaptativa (AMM)	Precisión Numérica (Nivel M=2)	1.913	<0.001
Replicación Estática	Cobertura de Mercado (24 ajustes)	2.010	+0.097

La tabla ilustra que no existe un método de valoración que sea superior en el vacío; su utilidad depende del problema que el analista intente resolver. Las fórmulas de Reiner y Rubinstein actúan como el valor teórico fundamental, asumiendo condiciones perfectas y continuas. Cuando el objetivo es la tasación algorítmica pura, el Modelo de Malla Adaptativa demuestra ser una herramienta de una precisión y eficiencia extraordinarias: al injertar la red de alta resolución únicamente cerca de la barrera de 120, el modelo logra colapsar el error geométrico casi por completo, replicando el valor analítico de 1,913 al tercer decimal en fracciones de segundo. Por el contrario, el valor de 2,010 arrojado por la Replicación Estática no debe ser interpretado simplemente como un “cálculo inexacto”. Representa el límite de viabilidad del mercado: es la respuesta concreta a cuánto cuesta replicar esa opción exótica utilizando instrumentos financieros reales y discretos, asumiendo que el monitoreo continuo es fácticamente imposible.

5.3. Resultados para Opciones Americanas

5.3.1. Estimación del Valor de Continuación (LSM)

Para aislar el efecto estadístico de la regresión y evaluar la precisión del algoritmo LSM al capturar la prima por ejercicio anticipado, el experimento se enfoca en una opción Put americana estándar. Se compara el valor obtenido por la simulación frente a un método riguroso de Diferencias Finitas implícitas (utilizado como valor de referencia exacto). Los parámetros base establecen un precio de ejercicio $K = 40$, tasa libre de riesgo del 6 %, volatilidad del 20 % y un esquema de simulación LSM con 100,000 trayectorias (50,000 antitéticas) con 50 pasos temporales por año, utilizando los primeros tres polinomios de Laguerre como funciones base. La Tabla 5.4 muestra los resultados para horizontes de uno y dos años bajo diferentes condiciones de moneyness inicial.

5.3. RESULTADOS PARA OPCIONES AMERICANAS

Tabla 5.4: Comparación de Valoración para Put Americana (Diferencias Finitas vs. LSM). Parámetros: $K = 40$, $r = 0,06$, $\sigma = 0,20$. Simulación LSM con 100,000 trayectorias, 50 pasos temporales por año, 3 polinomios de Laguerre.

Vencimiento	Precio Inicial (S_0)	Dif. Finitas (Referencia)	LSM (Simulación)	SE	Diferencia Absoluta
$T = 1$	36 (ITM)	4.478	4.472	0.010	-0,006
$T = 1$	40 (ATM)	2.314	2.313	0.009	-0,001
$T = 1$	44 (OTM)	1.110	1.118	0.007	+0,008
$T = 2$	36 (ITM)	4.840	4.821	0.012	-0,019
$T = 2$	40 (ATM)	2.885	2.879	0.010	-0,006
$T = 2$	44 (OTM)	1.690	1.675	0.009	-0,015

El análisis de esta tabla confirma la extraordinaria capacidad del algoritmo LSM para estimar el valor de continuación utilizando información transversal de trayectorias aleatorias. Para opciones a un año ($T = 1$), las estimaciones por simulación difieren del valor de diferencias finitas en menos de un centavo, lo cual cae holgadamente dentro de los márgenes del spread bid-ask (oferta-demanda) de los mercados reales. Además, se observa que las diferencias son tanto positivas como negativas, lo que sugiere que la aproximación no sufre de un sesgo sistemático severo que subestime la opción de manera inaceptable. El algoritmo demuestra ser igualmente robusto independientemente de si la opción inicia in-the-money o out-of-the-money, lo que valida la elección de los polinomios de Laguerre para modelar la frontera de ejercicio temprano.

5.3.2. Análisis de Convergencia Estadística

Mientras que los modelos de redes (como el AMM) convergen determinísticamente a medida que se reduce el paso espacial, la simulación de Monte Carlo exhibe una convergencia estocástica. La precisión del método no se mide por un error geométrico, sino por el error estándar (SE) de los payoffs descontados en la muestra. Para evaluar esta dinámica en un entorno exótico, se analizó el comportamiento del error estándar frente al incremento en el número de trayectorias (M) utilizando una opción Put Americana Down-and-Out. Los parámetros del experimento establecen un precio inicial $S_0 = 44$, precio de ejercicio $K = 40$ y una barrera inferior fijada en $H = 39,6$, con vencimiento a un año ($T = 1$), una tasa libre de riesgo del 6 % ($r = 0,06$) y una volatilidad del 20 % ($\sigma = 0,2$) y discretizada en $N = 50$ pasos temporales.

La introducción de esta barrera somete al algoritmo LSM a un doble esfuerzo computacional.

En cada uno de los 50 pasos temporales, no solo debe ejecutar la regresión para estimar el valor de continuación, sino que previamente debe monitorear la trayectoria del precio. Si el activo subyacente cae al nivel de 39,6 o por debajo, la trayectoria sufre un knock-out, su valor se anula (asumiendo un rebate de cero) y queda excluida de las decisiones de ejercicio futuras. La Tabla 5.5 resume el impacto del tamaño muestral sobre la precisión de este cálculo.

5.4. COMPARACIÓN GLOBAL DE MÉTODOS

Tabla 5.5: Convergencia del Error Estándar y Tiempos de Ejecución en Monte Carlo LSM. Opción Put Americana: $S_0 = 44$, $K = 40$, $T = 1$, $r = 0,06$, $\sigma = 0,20$.

Simulaciones (M)	Error Estándar (SE)	Intervalo de Confianza (95 %)	Tiempo (milisegundos)
1,000	0.003069	± 0.127	< 5
5,000	0.001363	± 0.055	≈ 12
10,000	0.000952	± 0.039	≈ 22
50,000	0.000420	± 0.017	≈ 62
100,000	0.000375	± 0.012	≈ 728 (con 252 pasos)

Estos resultados empíricos ilustran vívidamente la naturaleza asintótica dictada por el Teorema del Límite Central. El error decrece a una tasa proporcional a $O(1/M)$. Por ejemplo, al pasar de 10,000 a 50,000 simulaciones, el error se reduce a la mitad (de 0,000952 a 0,000420), lo que concuerda con la teoría matemática que establece que para dividir el error por dos, el costo computacional debe multiplicarse por cuatro.

Esta característica revela el principal compromiso (trade-off) de la simulación de Monte Carlo frente a los métodos presentados en la sección anterior. Si bien el modelo es lo suficientemente flexible para acomodar barreras complejas y decisiones americanas vectorizando el código de manera eficiente, lograr intervalos de confianza extremadamente estrechos exige un incremento exponencial en los recursos de cómputo. Además, para barreras continuas, el monitoreo discreto en $N = 50$ o $N = 252$ pasos introduce un sesgo de discretización intrínseco, ya que el precio podría cruzar la barrera entre dos fechas de observación sin ser detectado. En consecuencia, el método LSM se justifica plenamente por su escalabilidad dimensional, aunque para opciones de un único activo subyacente con geometrías estrictas de barrera, los modelos de redes adaptativas resulten más precisos en tiempo de CPU.

5.4. Comparación Global de Métodos

Tras haber analizado el rendimiento individual de cada algoritmo frente a sus desafíos intrínsecos, resulta fundamental establecer una comparación cruzada que consolide los hallazgos de esta investigación. Esta evaluación global no busca declarar un único método como superior de manera absoluta, sino mapear las fortalezas y debilidades de cada enfoque frente a las distintas dimensiones del problema de valoración de opciones barrera.

5.4.1. Resumen de Desempeño

Para sintetizar las propiedades observadas a lo largo de los experimentos numéricos, la Tabla 5.6 presenta un resumen conceptual del perfil de desempeño de las cuatro metodologías estudiadas.

5.4. COMPARACIÓN GLOBAL DE MÉTODOS

Tabla 5.6: Resumen del Perfil de Desempeño de los Métodos de Valoración

Método	Naturaleza	Precisión Numérica	Costo Computacional	Flexibilidad / Extensibilidad
Fórmulas R&R	Analítica / Continua	Exacta (Teórica)	Instantáneo (Bajo)	Muy Baja (Solo Europeas)
AMM	Red Discreta (Determinista)	Muy Alta	Muy Bajo $O(N)$	Moderada (Opciones 1D)
Replicación Estática	Portafolio de Mercado	Moderada / Alta	Bajo	Alta (Depende del mercado)
Monte Carlo (LSM)	Simulación (Estocástica)	Moderada (SE)	Alto $O(1/\sqrt{M})$	Muy Alta (Americanas / Multi-activo)

El análisis conjunto revela un claro compromiso (trade-off) entre eficiencia computacional y flexibilidad. Por un lado, las fórmulas cerradas de Reiner y Rubinstein ofrecen respuestas exactas de forma instantánea, pero exigen que el contrato cumpla estrictamente con los supuestos teóricos de Black-Scholes (monitoreo continuo, volatilidad constante y ausencia de ejercicio anticipado). Cuando se requiere relajar estos supuestos sin perder la eficiencia, el Modelo de Malla Adaptativa (AMM) se posiciona como la herramienta numérica más potente. Al injertar alta resolución espacial únicamente donde es estrictamente necesario, el AMM logra replicar la precisión teórica evadiendo la explosión combinatoria que sufren los árboles estándar.

En el otro extremo del espectro, la simulación de Monte Carlo con el método de Longstaff-Schwartz (LSM) sacrifica la convergencia determinista y el bajo tiempo de CPU a cambio de una extensibilidad casi ilimitada. Al no sufrir la maldición de la dimensionalidad, el LSM es capaz de incorporar monitoreo discreto de la barrera y decisiones de ejercicio americano sin que la estructura del algoritmo colapse. Finalmente, la Replicación Estática ocupa un lugar único en esta comparativa: más que un modelo de tasación puramente matemática, es una estrategia de ingeniería financiera. Su precisión no se mide en decimales matemáticos, sino en la capacidad empírica de anular el riesgo de la barrera utilizando instrumentos líquidos y reales.

5.4.2. Casos de Uso Óptimos

La elección del método adecuado en la práctica profesional no obedece a una jerarquía estricta de superioridad, sino a la naturaleza específica del problema financiero a resolver.

Las fórmulas de Reiner y Rubinstein son el estándar de oro para la validación y el benchmarking académico. Su uso es óptimo como “oráculo” en el desarrollo de software financiero, permitiendo a los programadores calibrar el error de sus motores numéricos antes de aplicarlos a casos donde no existe una solución cerrada.

El Modelo de Malla Adaptativa (AMM) es la opción indiscutible cuando el problema requiere tasaciones intensivas y repetitivas sobre opciones de un solo activo subyacente. Un caso de uso óptimo para el AMM es el cálculo de volatilidades implícitas. Puesto que los algoritmos de búsqueda de raíces requieren valorar la misma opción decenas

de veces ajustando el parámetro de volatilidad, un método estocástico como Monte Carlo introduciría ruido y un árbol estándar tomaría demasiado tiempo si el precio está cerca de la barrera. El AMM, con su convergencia suave y tiempos de respuesta de fracciones de segundo, resuelve este problema de manera ideal.

La Replicación Estática encuentra su caso de uso óptimo en las mesas de trading institucional y en la gestión directa de riesgos. Cuando un banco emite una opción exótica fuertemente no lineal (alta gamma cerca de la barrera), la cobertura dinámica (Delta hedging) se vuelve imprecisa y prohibitivamente costosa debido a los costos de transacción. En estos escenarios, construir un portafolio estático con opciones estándar es la estrategia preferida, ya que permite “inmunizar” el libro de operaciones frente a los saltos bruscos del mercado sin necesidad de rebalanceo continuo.

Por último, el método LSM de Monte Carlo es la herramienta esencial para derivados de alta complejidad que escapan a los modelos de redes. Su uso es óptimo cuando la opción barrera es de estilo americano, cuando la barrera se monitorea discretamente (por ejemplo, observando el precio solo al cierre de cada día, lo cual invalida las fórmulas continuas), o cuando el derivado depende de múltiples factores de riesgo interrelacionados (como opciones exóticas sobre cestas de acciones).

5.4.3. Recomendaciones Prácticas

A partir de este análisis, se derivan tres recomendaciones fundamentales para la implementación de sistemas de valoración de opciones barrera:

- En primer lugar, los sistemas modernos no deben depender de un único motor de cálculo, sino de una arquitectura híbrida. Se recomienda utilizar el AMM para la tasación en tiempo real y el cálculo de sensibilidades (las “Griegas”) de opciones europeas y americanas unidimensionales, limitando el uso intensivo de Monte Carlo exclusivamente a los contratos que involucren trayectorias complejas o múltiples variables de estado.
- En segundo lugar, en lo que respecta a la gestión de riesgos, es vital no confundir el “valor teórico matemático” con el “costo real de cobertura”. Se recomienda a los operadores utilizar la Replicación Estática para establecer un límite superior al precio de la opción exótica. Si el portafolio replicante discreto (construido con opciones vanilla de mercado) resulta más costoso que el valor teórico arrojado por el AMM o LSM, esa diferencia debe ser considerada como una prima de riesgo operativo y de liquidez que el modelo matemático puro es incapaz de capturar.
- Finalmente, si la decisión recae en implementar Monte Carlo mediante el algoritmo LSM, es altamente recomendable aprovechar su capacidad inherente de paralelización. Dado que la evaluación transversal de las trayectorias es su principal cuello

de botella de rendimiento, distribuir la simulación y la regresión de mínimos cuadrados en múltiples procesadores es una práctica obligatoria para reducir el error estadístico a niveles tolerables sin comprometer la viabilidad comercial del modelo.

5.5. Discusión

5.5.1. Ventajas y Desventajas Observadas

A lo largo de los experimentos numéricos desarrollados en este capítulo, se evidenció que la valoración de opciones barrera impone exigencias matemáticas que ningún método individual puede resolver de manera óptima en todas sus dimensiones. El contraste de los resultados nos permite destilar las fortalezas y debilidades intrínsecas de cada enfoque.

Por el lado de los métodos determinísticos, las fórmulas analíticas de Reiner y Rubinstein confirmaron su estatus de estándar de oro para la validación de algoritmos, ofreciendo una precisión absoluta con un costo computacional nulo. Sin embargo, su extrema rigidez metodológica las vuelve ineficaces para contratos que se desvían de los supuestos continuos ideales. Como respuesta a esto, el Modelo de Malla Adaptativa (AMM) demostró ser la solución numérica más sofisticada para opciones de un único activo subyacente. Su principal ventaja observada fue la capacidad de neutralizar el error de no linealidad y resolver el “problema del límite” sin incurrir en la explosión combinatoria de los árboles estándar. La desventaja del AMM, no obstante, radica en su vulnerabilidad a la maldición de la dimensionalidad; su arquitectura espacial lo vuelve ineficiente si se intentara modelar derivados dependientes de múltiples activos correlacionados al mismo tiempo.

Desde la perspectiva de la gestión de riesgos, la Replicación Estática de Derman, Ergener y Kani demostró la ventaja incomparable de inmunizar un portafolio contra movimientos bruscos sin la necesidad de rebalanceo dinámico continuo. Esto reduce drásticamente la exposición operativa. Su desventaja principal es la dependencia empírica en la liquidez del mercado: el método asume que siempre existirán opciones vanilla disponibles con los precios de ejercicio y vencimientos exactos requeridos para cubrir la frontera, lo cual rara vez ocurre en la realidad sin incurrir en costos de interpolación.

Finalmente, la simulación de Monte Carlo equipada con el método de Longstaff-Schwartz (LSM) exhibió como gran ventaja su universalidad y flexibilidad. Fue el único método capaz de manejar simultáneamente el monitoreo discreto de trayectorias y el ejercicio anticipado americano de forma natural. Sin embargo, la gran desventaja observada fue su lenta convergencia estocástica. Alcanzar el nivel de precisión geométrica de cuatro decimales que el AMM logra en fracciones de segundo requeriría un esfuerzo computacional inmanejable en Monte Carlo, confirmando que este último debe reservarse para problemas donde los métodos de red colapsan.

5.5.2. Limitaciones del Estudio

A pesar de la exhaustividad del análisis comparativo, es importante enmarcar los resultados obtenidos dentro de las limitaciones teóricas y prácticas de este trabajo. En primer lugar, todos los modelos numéricos implementados fueron construidos y calibrados bajo el entorno del modelo de Black-Scholes. Esto implica que los experimentos asumieron una volatilidad constante y tasas de interés deterministas a lo largo de toda la vida de la opción. En los mercados financieros reales, la volatilidad exhibe comportamientos estocásticos, asimetrías y sonrisas (smiles). Si bien métodos como Monte Carlo pueden adaptarse fácilmente a procesos más complejos (como modelos de difusión con saltos o volatilidad estocástica), el impacto de estos fenómenos en el error de discretización de los árboles adaptativos y en el costo del portafolio replicante no fue medido en este estudio.

En segundo lugar, el análisis de la Replicación Estática se realizó bajo el supuesto de mercados sin fricciones. La estimación del costo del portafolio replicante (por ejemplo, el uso de 24 opciones de ajuste) se basó en precios teóricos puros, ignorando el spread oferta-demanda y los costos de transacción reales. En la práctica de una mesa de dinero, comprar y vender docenas de opciones quincenales para cubrir una barrera podría erosionar significativamente el margen de ganancia de la operación, un factor de riesgo de liquidez que nuestras métricas de error absoluto no capturan.

Por último, en lo que respecta a la validación de Monte Carlo, el monitoreo del evento de knock-out o knock-in se evaluó de forma estrictamente discreta en los pasos temporales simulados (por ejemplo, 50 o 252 pasos por año). Esto introduce un sesgo intínseco conocido, ya que el precio real del activo podría haber cruzado la barrera continua entre dos fechas de observación sin que el algoritmo lo detecte. La aplicación de técnicas avanzadas de interpolación estocástica, como los puentes brownianos (Brownian bridges), para corregir este sesgo de monitoreo continuo en simulaciones discretas, queda fuera del alcance de esta investigación.

Capítulo 6

Conclusiones y Trabajo Futuro

6.1. Resumen de Resultados

El presente trabajo de investigación evaluó y comparó sistemáticamente cuatro metodologías fundamentales para la valoración de opciones barrera, abarcando desde soluciones analíticas hasta técnicas numéricas avanzadas. Los resultados obtenidos demostraron que las ecuaciones de Reiner y Rubinstein proveen un valor teórico exacto bajo supuestos continuos, consolidándose como el estándar de oro para la validación algorítmica. Al trasladar el problema de tasación a redes discretas, se comprobó empíricamente que los árboles trinomiales estándar colapsan a nivel computacional cuando el precio del activo se encuentra críticamente cerca de la barrera. Sin embargo, la implementación del Modelo de Malla Adaptativa (AMM) superó este obstáculo con notable éxito, logrando aislar el error de no linealidad y alcanzando una precisión de hasta cuatro decimales en fracciones de segundo.

Desde la perspectiva de la cobertura en el mercado, los experimentos con la técnica de Replicación Estática evidenciaron que la convergencia teórica tiene un correlato práctico directo: el aumento en la frecuencia de ajuste del portafolio replicante (utilizando opciones vanilla) reduce el costo y el riesgo del desajuste a niveles marginales, validando el método como una alternativa superior a la cobertura dinámica continua. Finalmente, para el entorno de las opciones de estilo americano, la simulación de Monte Carlo equipada con el algoritmo de Longstaff-Schwartz demostró ser robusta frente al desafío del ejercicio anticipado, aunque puso en evidencia que su flexibilidad estructural conlleva un alto costo computacional dictado por su lenta convergencia estocástica (un trade-off fundamental).

6.2. Conclusiones Principales

6.2.1. Sobre los Métodos para Opciones Europeas

El análisis del “problema del límite” y del error de discretización espacial arroja una conclusión clara para el desarrollo de software financiero: la fuerza bruta no es una solución viable. Incrementar masivamente el número de pasos en un árbol estándar para alinear los nodos con la barrera resulta computacionalmente ineficiente. El AMM demuestra que una distribución inteligente de los recursos de hardware, injertando mallas de alta resolución única y exclusivamente en las regiones críticas de la opción, es la estrategia numérica óptima para derivados dependientes de la trayectoria sobre un único activo. A su vez, los resultados de la Replicación Estática permiten concluir que el valor de una opción exótica no debe interpretarse únicamente como el resultado de una ecuación diferencial, sino como el costo real de ensamblar un rompecabezas de instrumentos estándar en el mercado, donde la granularidad temporal de los contratos determina el riesgo residual que asume el emisor.

6.2.2. Sobre Monte Carlo para Opciones Americanas

La implementación de la metodología de Longstaff-Schwartz permite concluir que la estimación del valor de continuación mediante una regresión de mínimos cuadrados de corte transversal (utilizando, por ejemplo, polinomios de Laguerre) resuelve de manera elegante y eficiente la paradoja de la inducción hacia atrás en trayectorias simuladas. No obstante, la naturaleza de su convergencia impone un límite práctico ineludible. Dado que el error decrece a una tasa proporcional a la raíz cuadrada del tamaño muestral, alcanzar los niveles de precisión extremos que los métodos de red logran instantáneamente requiere un esfuerzo computacional exponencial. Por consiguiente, se concluye que el método de Monte Carlo debe reservarse no como la primera línea de defensa, sino como la herramienta definitiva frente a problemas intratables por otros medios.

6.2.3. Comparación Global

La conclusión fundamental que se desprende de esta investigación es que no existe una jerarquía absoluta entre los modelos de valoración estudiados; su supremacía está dictada enteramente por el contexto y las dimensiones del problema. Mientras que el AMM domina en eficiencia y precisión determinista para contratos unidimensionales, la simulación de Monte Carlo es la elección insustituible para evitar la maldición de la dimensionalidad en opciones complejas o de múltiples activos. La Replicación Estática, por su parte, actúa como el puente indispensable entre la teoría matemática y la práctica real de las mesas de dinero. En definitiva, la ingeniería financiera moderna exige una arquitectura algorítmica híbrida, requiriendo que el analista comprenda las mecánicas internas de cada método para seleccionar la

herramienta que mejor equilibre el rigor matemático con la viabilidad operativa.

6.3. Trabajo Futuro

El análisis comparativo desarrollado en esta investigación establece una base sólida para la valoración de opciones barrera, pero al mismo tiempo abre múltiples vías para futuras expansiones, tanto desde la perspectiva teórica como en su aplicación algorítmica.

6.3.1. Extensiones del Modelo

La primera y más natural extensión de este trabajo consistiría en relajar los supuestos del modelo clásico de Black-Scholes. Dado que se ha comprobado que la volatilidad en los mercados reales no es constante, sino que exhibe sonrisas y asimetrías (smiles y skews), un paso fundamental sería adaptar las metodologías numéricas a modelos de volatilidad estocástica o modelos de difusión con saltos (como el propuesto por Merton Merton (1976)). Mientras que la simulación de Monte Carlo puede acomodar estas dinámicas estocásticas con relativa facilidad modificando la ecuación diferencial de las trayectorias, adaptar el Modelo de Malla Adaptativa (AMM) a entornos donde la volatilidad cambia con el precio del activo sería un desafío matemático y de programación considerable, pero de gran valor académico.

6.3.2. Extensiones de los Métodos

A nivel algorítmico, existen mejoras puntuales que podrían incrementar la exactitud de los métodos estudiados. Para el enfoque de simulación de Monte Carlo, el principal problema detectado fue el sesgo de discretización al monitorear la barrera en pasos de tiempo finitos (por ejemplo, diariamente). Un trabajo futuro podría implementar la técnica de Puentes Brownianos (Brownian Bridges) dentro del algoritmo de Longstaff-Schwartz. Esta técnica probabilística permite calcular la probabilidad exacta de que el activo haya cruzado la barrera entre dos fechas de observación discretas, eliminando el sesgo de monitoreo sin necesidad de multiplicar el esfuerzo computacional generando pasos de tiempo diminutos.

Por el lado del Modelo de Malla Adaptativa, si bien demostró ser inmensamente superior para opciones unidimensionales, un área de investigación abierta es el desarrollo de mallas adaptativas multidimensionales. Lograr injertar alta resolución tridimensional para evaluar opciones exóticas sobre cestas de activos correlacionados expandiría drásticamente la utilidad de los métodos de redes discretas frente al monopolio actual de Monte Carlo en esos escenarios.

6.3.3. Aplicaciones Prácticas y Validación Empírica

Finalmente, el salto definitivo de esta investigación sería llevar los algoritmos desde un entorno de simulación pura hacia una validación empírica con datos reales de mercado. En particular, la metodología de Replicación Estática ganaría enorme profundidad si se la pusiera a prueba utilizando superficies de volatilidad reales y spreads oferta-demanda extraídos de una bolsa de derivados (como Matba ROFEX o ByMA) o del mercado interbancario (como MAE). Construir el portafolio replicante midiendo los costos de transacción reales, la liquidez de los instrumentos estándar disponibles para el ajuste y el riesgo de gap (saltos de precio nocturnos) permitiría evaluar empíricamente si la inmunización estática prometida por la teoría matemática sobrevive a la fricción física del mercado financiero.

Bibliografía

- Boyle, P. P. and Lau, S. H. (1994). Bumping up against the barrier with the binomial method. *The Journal of Derivatives*, 1(4):6–14.
- Derman, E., Ergener, D., and Kani, I. (1994). Static replication of barrier options. *The Journal of Derivatives*, 2(2):78–95.
- Figlewski, S. and Gao, B. (1999). The adaptive mesh model: a new approach to efficient option pricing. *The Journal of Financial Engineering*, 8:211–241.
- Longstaff, F. A. and Schwartz, E. S. (2001). Valuing american options by simulation: A simple least-squares approach. *The Review of Financial studies*, 14(1):113–147.
- Merton, R. C. (1976). Option pricing when underlying stock returns are discontinuous. *Journal of Financial Economics*, 3(1):125–144.
- Reiner, E. and Rubinstein, M. (1991). Breaking down barrier options. *Risk*, 4(8):28–35.