



Universidad
Nacional
de Córdoba



Facultad de Matemática,
Astronomía, Física y
Computación

Técnicas de simulación y discretización para la valoración de opciones barrera

por

Gonzalo A. Bordón

Presentado ante la **FACULTAD DE MATEMÁTICA, ASTRONOMÍA,
FÍSICA Y COMPUTACIÓN** como parte de los requerimientos para la ob-
tención del grado de Licenciatura en Ciencias de la Computación de la

UNIVERSIDAD NACIONAL DE CÓRDOBA

Mayo, 2026

Directores: Dra. Noemí Patricia Kisbye



Técnicas de simulación y discretización para la valoración de opciones barrera
© 2026 by Gonzalo Agustín Bordón is licensed under Creative Commons
Attribution-ShareAlike 4.0 International

Certifico que el trabajo incluido en este documento es el resultado de tareas de investigación originales y que no ha sido presentado para optar a un título en ninguna otra Universidad o Institución.

Gonzalo A. Bordón

Agradecimientos

A mi directora de tesis, la Dra. Noemí Patricia Kisbye, por su inmensa paciencia, su guía experta y su dedicación a lo largo de todo este proyecto. Gracias por impulsarme a mantener el rigor matemático y analítico y por brindarme las herramientas necesarias para llevar a buen puerto esta investigación.

A la Facultad de Matemática, Astronomía, Física y Computación (FAMAF) y a la Universidad Nacional de Córdoba (UNC), por haberme brindado una educación pública, gratuita y de excelencia. A todos los profesores que, a lo largo de la carrera, me transmitieron su pasión por las Ciencias de la Computación y formaron mi criterio profesional.

A mis padres, Sandra Delia Fiore y Hector Omar Bordón, y a mi hermano, Martín Ezequiel Bordón, por su apoyo incondicional, por el inmenso esfuerzo que han hecho para que yo pueda llegar hasta acá y por ser mi pilar fundamental durante todos estos años. Este logro es tan mío como de ustedes.

A mis compañeros de cursada y muy especialmente a todo Tiesos FC, porque aunque son muchos para nombrarlos a cada uno, las incontables horas compartidas entre apuntes, algoritmos y mates hicieron que el camino universitario haya sido una experiencia inolvidable.

A mis amigos, todos aquellos que conocí en circunstancias tan peculiares y distintas pero especialmente a Nueva Chicago y todo El Descansadero (he aquí una mención a Juan Cruz Roldán y Nazareno Kohan Boc con quienes nos comprometimos en hacernos aparecer en algún escrito del otro), por cada baile, juego, ecuación, código, risa o momento compartido que me recuerdan que siempre hay algo más por aprender.

Un agradecimiento muy especial (y lleno de cariño) a Katherina Bordón e Inari Bordón. Gracias por hacerme compañía en las largas madrugadas frente a la pantalla, por su amor incondicional y por ser mi cable a tierra durante todo este proceso.

Finalmente, a todos aquellos que de una u otra forma contribuyeron a que este trabajo sea posible. ¡Muchas gracias!

Resumen

Esta tesis presenta métodos para la valoración y discretización de opciones barrera, derivados financieros cuyo pago depende de si el precio del activo subyacente cruza un nivel de barrera predeterminado durante la vida de la opción. Las opciones barrera son ampliamente utilizadas en los mercados financieros para la gestión de riesgos y estrategias de inversión debido a su menor costo en comparación con las opciones estándar.

Los objetivos principales de este trabajo son analizar e implementar métodos para la valoración de opciones barrera, con énfasis particular en las técnicas de discretización que capturan con precisión la condición de barrera. La metodología incluye cuatro enfoques principales: (1) fórmulas analíticas bajo el modelo de Black-Scholes, que asumen un comportamiento lognormal del precio del activo y permiten obtener soluciones cerradas exactas para opciones europeas; (2) simulación de Monte Carlo, un método computacional robusto para aproximar el valor mediante la generación estocástica de múltiples trayectorias posibles; (3) modelos discretos avanzados, específicamente el Método de Malla Adaptativa (AMM), que soluciona el problema de sobreestimación o subestimación cuando la barrera no coincide con los nodos de un árbol tradicional; y (4) la replicación estática, una técnica para cubrir opciones barrera mediante la construcción de un portafolio de opciones *vanilla* que reproduzca el mismo *payoff* bajo ciertas condiciones. Nos enfocamos tanto en opciones barrera de estilo europeo como americano.

Los resultados demuestran la efectividad de los esquemas de discretización propuestos para lograr valoraciones precisas manteniendo la eficiencia computacional. Comparamos el rendimiento de diferentes enfoques numéricos y analizamos sus propiedades de convergencia. El trabajo contribuye a la comprensión de métodos numéricos para la valoración de opciones exóticas y proporciona herramientas prácticas para la evaluación de riesgos financieros.

Palabras clave: opciones barrera, valoración de opciones, modelo de Black-Scholes, simulación de Monte Carlo, árboles binomiales y trinomiales, replicación estática, mallas adaptativas, derivados financieros.

Abstract

This thesis presents methods for the valuation and discretization of barrier options, financial derivatives whose payoff depends on whether the underlying asset price crosses a predetermined barrier level during the option's lifetime. Barrier options are widely used in financial markets for risk management and investment strategies due to their lower cost compared to standard options.

The main objectives of this work are to analyze and implement methods for pricing barrier options, with particular emphasis on discretization techniques that accurately capture the barrier condition. The methodology includes four main approaches: (1) analytical formulas under the Black-Scholes model, which assume a lognormal behavior of the asset price and provide exact closed-form solutions for European options; (2) Monte Carlo simulation, a versatile and robust computational method to approximate the value by generating multiple random price trajectories; (3) advanced discrete models, specifically the Adaptive Mesh Model (AMM), which addresses the positioning error problem when the barrier does not align with standard tree nodes; and (4) static replication, a technique for hedging barrier options by constructing a portfolio of vanilla options that reproduces the same payoff under certain conditions. We focus on both European and American-style barrier options.

The results demonstrate the effectiveness of the proposed discretization schemes in achieving accurate valuations while maintaining computational efficiency. We compare the performance of different numerical approaches and analyze their convergence properties. The work contributes to the understanding of numerical methods for exotic options pricing and provides practical tools for financial risk assessment.

Keywords: barrier options, option pricing, Black-Scholes model, Monte Carlo simulation, binomial and trinomial trees, static replication, adaptive meshes, financial derivatives.

Índice general

Agradecimientos	I
Resumen	III
Abstract	IV
Índice de figuras	XI
Índice de código	XIV
1. Introducción	2
1.1. ¿Qué es una Opción Financiera?	2
1.1.1. Componentes de una Opción	2
1.1.2. Motivación y Usos Prácticos de las Opciones	3
1.2. Opciones Barrera	3
1.2.1. Motivación de las Opciones Barrera	3
1.3. El Problema de Valoración	4
1.3.1. ¿Qué significa “Valorar” una Opción?	4
1.3.2. Fórmulas Analíticas y sus Limitaciones	5
1.3.3. Desafíos Computacionales	5
1.4. Objetivos del Trabajo	5
1.4.1. Objetivo General	5
1.4.2. Objetivos Específicos	6
1.5. Contribuciones del Trabajo	6
1.6. Organización del Trabajo	7
1.7. Repositorio de Código	7
2. Marco Teórico	8
2.1. Mercados de Derivados	8
2.1.1. Características de los Mercados de Derivados	8
2.1.2. Tipos de Derivados	8
2.2. Opciones Financieras	9
2.2.1. Opciones Call y Put	9
2.2.2. Opciones Europeas vs Americanas	10
2.2.3. Opciones Exóticas	10
2.3. Opciones Barrera	10
2.3.1. Clasificación de Opciones Barrera	11
2.3.2. Payoffs de Opciones Barrera	12
2.3.3. Relaciones de Paridad	12

2.3.4.	Rebates	13
2.3.5.	Ventajas de las Opciones Barrera	13
2.4.	El Modelo de Black-Scholes	13
2.4.1.	Supuestos del Modelo	14
2.4.2.	Ecuación Diferencial de Black-Scholes	15
2.4.3.	Medida Neutral al Riesgo	15
2.4.4.	Fórmula de Black-Scholes para Opciones Vanilla	16
2.4.5.	Las Griegas	16
2.4.6.	Limitaciones del Modelo	17
2.5.	Extensiones del Modelo Black-Scholes	17
3.	Método 1: Fórmulas Analíticas de Reiner y Rubinstein	19
3.1.	Intuición Matemática del Método	19
3.2.	Marco Metodológico de Valoración	20
3.3.	Desarrollo para una Opción Call Down-and-In	21
3.3.1.	Trayectorias sin cruce de barrera	21
3.3.2.	Términos de Valoración Adicionales para la Call Down-and-In	22
3.3.3.	Ensamblando la Opción Call Down-and-In	23
3.3.4.	El Término Temporal: Rebate al momento de cruce	23
3.4.	Catálogo de Fórmulas Exactas	24
3.4.1.	Opciones Call	24
3.4.2.	Opciones Put	26
3.5.	Generalización del Modelo	27
3.5.1.	Términos Generalizados	28
3.5.2.	Catálogo Simplificado	28
4.	Método 2: Modelo de Malla Adaptativa (AMM)	30
4.1.	El Problema de la Discretización en Opciones Barrera	30
4.2.	Fundamentos: Árboles Binomiales y Trinomiales	31
4.2.1.	Árbol Binomial	32
4.2.2.	Árbol Trinomial	32
4.3.	Análisis de Errores en Árboles Trinomiales	34
4.3.1.	Error de Distribución	34
4.3.2.	Error de No Linealidad	35
4.4.	Principio del Modelo de Malla Adaptativa	36
4.4.1.	Arquitectura en el Espacio de Logaritmos	37
4.4.2.	Operación y Valoración sobre la Malla Adaptativa	37
4.5.	AMM para Opciones Barrera	39
4.5.1.	El Problema de Convergencia “Dentada”	39
4.5.2.	El Problema del Límite	39
4.5.3.	Estructura AMM para Barreras	39
4.5.4.	Manejo de la Barrera	41
4.5.5.	Eficiencia Computacional	42
4.6.	AMM para Opciones Vanilla	43
4.6.1.	Estructura	43
4.6.2.	Eficiencia	44
4.6.3.	Rendimiento	44
4.7.	AMM para el Cálculo de Griegas	45
4.7.1.	Extensión del Árbol	46

4.7.2.	Ramificación Cuadrinomial	46
4.7.3.	Precisión	48
4.8.	Ventajas del AMM	50
4.9.	Consistencia Matemática	51
5.	Método 3: Replicación Estática	52
5.1.	Concepto de Replicación Estática	52
5.2.	Metodología de Derman-Ergener-Kani	54
5.2.1.	Construcción del Portafolio y Selección de Strikes	54
5.2.2.	Cálculo de Pesos y Procedimiento Recursivo	54
5.3.	Construcción del Portafolio	55
5.3.1.	Selección de Opciones Vanilla	55
5.3.2.	Determinación de los Pesos	56
5.3.3.	Aproximación de la Barrera	57
6.	Método 4: Monte Carlo para Opciones Americanas	58
6.1.	Desafío de las Opciones Americanas	58
6.1.1.	El Problema del Ejercicio Óptimo	58
6.2.	Simulación de Monte Carlo	58
6.2.1.	Generación de Trayectorias	58
6.2.2.	Algoritmo Básico para Opciones Europeas	59
6.2.3.	Monitoreo de Barreras	59
6.2.4.	El Problema Fundamental: ¿Cuándo Ejercer?	60
6.3.	Método de Longstaff-Schwartz (LSM)	60
6.3.1.	Idea Central	60
6.3.2.	Estimación del Valor de Continuación	61
6.3.3.	Algoritmo de Longstaff-Schwartz	61
6.3.4.	Extensión a Opciones Barrera Americanas	62
6.3.5.	Ventajas y Limitaciones del Método LSM	62
6.3.6.	Comparación con Otros Métodos	63
7.	Implementaciones	64
7.1.	Fórmulas de Reiner y Rubinstein	64
7.1.1.	Descripción de la Implementación	64
7.1.2.	Detalles de Implementación	64
7.1.3.	Cálculo de Griegas	66
7.1.4.	Validación	67
7.2.	Árboles Trinomiales con Mallas Adaptativas	69
7.2.1.	Descripción del Algoritmo	69
7.2.2.	Detalles de Implementación	73
7.2.3.	Validación	77
7.3.	Replicación Estática	79
7.3.1.	Descripción del Algoritmo	79
7.3.2.	Detalles de Implementación	80
7.3.3.	Validación del Portafolio Replicante	80
7.4.	Monte Carlo para Opciones Americanas	82
7.4.1.	Descripción del Algoritmo Implementado	82
7.4.2.	Detalles de Implementación	84
7.4.3.	Validación de Monte Carlo	85

8. Resultados y Comparación	88
8.1. Diseño de Experimentos	88
8.1.1. Casos de Prueba para Opciones Europeas	88
8.1.2. Casos de Prueba para Opciones Americanas	89
8.1.3. Métricas de Evaluación	89
8.2. Resultados para Opciones Europeas	89
8.2.1. Superando el “Problema del Límite”: AMM vs. Trinomial Estándar	89
8.2.2. Convergencia y Costo de la Replicación Estática	91
8.2.3. Comparación Unificada: Precisión Numérica frente a Via- bilidad de Mercado	92
8.3. Resultados para Opciones Americanas	92
8.3.1. Estimación del Valor de Continuación (LSM)	92
8.3.2. Análisis de Convergencia Estadística	93
8.4. Comparación Global de Métodos	94
8.4.1. Resumen de Desempeño	94
8.4.2. Casos de Uso Óptimos	95
8.4.3. Recomendaciones Prácticas	96
8.5. Discusión	97
8.5.1. Ventajas y Desventajas Observadas	97
8.5.2. Limitaciones del Estudio	97
9. Conclusiones y Trabajo Futuro	99
9.1. Resumen de Resultados	99
9.2. Conclusiones Principales	99
9.2.1. Sobre los Métodos para Opciones Europeas	99
9.2.2. Sobre Monte Carlo para Opciones Americanas	100
9.2.3. Comparación Global	100
9.3. Trabajo Futuro	100
9.3.1. Extensiones del Modelo	101
9.3.2. Extensiones de los Métodos	101
9.3.3. Aplicaciones Prácticas y Validación Empírica	101
Bibliografía	103

Índice de figuras

4.1.	Estructura de un árbol trinomial con 3 pasos temporales. Desde cada nodo, el precio puede moverse hacia arriba (multiplicado por $u = 1,15$, verde), mantenerse (multiplicado por $m = 1$, azul), o bajar (multiplicado por $d = 1/u \approx 0,870$, rojo). Las probabilidades neutrales al riesgo son $p_u = 0,25$, $p_m = 0,50$, $p_d = 0,25$. El árbol es recombinante: los nodos que alcanzan el mismo precio se fusionan.	34
4.2.	Ejemplo de convergencia inestable causada por el error de no linealidad. Históricamente, el efecto “par-impar” en modelos binomiales demostraba cómo la falta de alineación de los nodos finales generaba oscilaciones. El AMM elimina completamente estos problemas de no linealidad en las estructuras trinomiales.	36
4.3.	Concepto del Modelo de Malla Adaptativa (AMM). Se muestra un árbol trinomial base (nodos grises) que constituye la malla gruesa. Sobre este se injerta una malla fina (cuadrados verdes) con pasos reducidos en la región crítica. La operación transfiere los valores del árbol grueso hacia los bordes del árbol fino, para luego resolver la valoración internamente.	38
4.4.	Estructura del AMM para opciones barrera. Se ilustra el árbol trinomial base con una banda vertical de malla fina a lo largo de toda la dimensión temporal. La malla fina se construye exclusivamente del lado activo de la barrera: para una opción down-and-out, la banda de refinamiento cubre el intervalo $[\ln(H), \ln(H)+h]$ en el espacio logarítmico, es decir, desde la barrera H hasta el primer nodo grueso por encima de ella. Se muestra el precio inicial S_0 cerca de H para evidenciar la solución al problema del límite. Las flechas indican el flujo de información (condiciones de borde) que se transfiere desde la malla gruesa hacia la malla fina para la valoración.	41
4.5.	Estructura del AMM para opciones vanilla. Se muestra un árbol trinomial (nodos grises con conexiones grises) que constituye la malla gruesa. Sobre este árbol se injerta una malla fina (cuadrados verdes pequeños) con pasos $h/2$ y $k/4$ únicamente en la región crítica (rectángulo amarillo): temporal $[T-k, T]$ y espacial $[K-2h, K+2h]$. La línea azul punteada marca el strike K donde ocurre la mayor no linealidad al vencimiento. Esta estrategia concentra la resolución donde más se necesita: alrededor del precio de ejercicio al vencimiento.	44

4.6.	Ramificación cuadrinomial para el cálculo de griegas mediante diferencias finitas. Se muestra un árbol trinomial base (nodos grises, conexiones negras gruesas) con nodos adicionales en $t = 0$ ubicados en $S_0 + \varepsilon$ (verde) y $S_0 - \varepsilon$ (rojo), donde $\varepsilon = h/4$ es una perturbación pequeña. Las líneas sólidas grises representan ramificación cuadrinomial (4 ramas) desde los nodos perturbados y los nodos extremos en $t = k/4$, permitiendo calcular simultáneamente Delta y Gamma con alta precisión.	47
4.7.	Precisión en el cálculo de Delta mediante ramificación cuadrinomial. Se compara el RMSE en Delta para diferentes configuraciones AMM $(0, T)$, donde 0 es el inicio de la opción y T es el final de la misma. La ramificación cuadrinomial permite calcular Delta mediante diferencias finitas. AMM (3,3) logra una mejora de 60x vs Trinomial en $N=100$, con un incremento de tiempo $< 3\%$. Notablemente, AMM (1,0) mejora Delta sin costo adicional al refinar solo la región crítica.	49
4.8.	Precisión en el cálculo de Gamma mediante ramificación cuadrinomial. Se compara el RMSE en Gamma para diferentes configuraciones AMM. La ramificación cuadrinomial permite calcular Gamma mediante diferencias finitas de segundo orden. AMM (1,1) logra una mejora de 7.2x vs Trinomial en $N=100$. A diferencia de Delta, Gamma no mejora significativamente con niveles superiores a (2,2), lo que sugiere que AMM (1,1) es óptimo para este cálculo. El incremento en tiempo es $< 3\%$	50

Índice de códigos

7.1. Términos de RR	65
7.2. Cálculo de pasos de tiempo enteros (Eq. 17)	74
7.3. Cálculo dinámico de probabilidades para nodos de interfaz	75
7.4. Generalización recursiva y bucle de refinamiento	75

Capítulo 1

Introducción

1.1. ¿Qué es una Opción Financiera?

Antes de profundizar en las opciones barrera, que son el foco principal de este trabajo, es fundamental establecer qué es una opción financiera básica (a menudo denominada opción *vanilla*). En el ámbito de las finanzas, una opción es un contrato derivado, lo que significa que su valor depende o se deriva del precio de otro activo, conocido como **activo subyacente**.

En términos simples, una opción otorga a su comprador el derecho, pero no la obligación, de comprar o vender el activo subyacente a un precio fijo en o antes de una fecha determinada. A cambio de adquirir este derecho, el comprador paga un monto inicial al vendedor (o emisor) de la opción. El vendedor, por su parte, recibe este dinero y asume la obligación de cumplir con el contrato si el comprador decide hacer valer (ejercer) su derecho.

1.1.1. Componentes de una Opción

Todo contrato de opción estándar está definido por los siguientes elementos esenciales:

- **Activo Subyacente (Underlying Asset):** El activo de referencia (como acciones, divisas, índices bursátiles, materias primas o tasas de interés) sobre el cual se basa el contrato.
- **Precio de Ejercicio (Strike Price):** El precio predeterminado al cual se podrá comprar o vender el activo subyacente si la opción es ejercida.
- **Fecha de Vencimiento (Maturity Date):** La fecha límite en la cual la opción puede ser ejercida. Pasada esta fecha, la opción expira y pierde su validez.
- **Prima (Premium):** El precio o costo que paga el comprador al vendedor por adquirir los derechos que otorga el contrato.
- **Tipo de Opción:**
 - **Opción de Compra (Call):** Otorga al comprador el derecho de *comprar* el activo subyacente al precio de ejercicio.

- **Opción de Venta (Put):** Otorga al comprador el derecho de *vender* el activo subyacente al precio de ejercicio.

1.1.2. Motivación y Usos Prácticos de las Opciones

Las opciones son herramientas muy versátiles en el mundo financiero, y su utilización suele estar motivada por tres razones principales:

1. **Cobertura (Hedging):** Las opciones se utilizan frecuentemente como un seguro financiero para mitigar riesgos. Por ejemplo, una empresa agrícola podría comprar opciones put sobre el trigo para asegurarse un precio mínimo de venta para su cosecha, protegiéndose de posibles caídas en el mercado. De manera similar, un inversor puede proteger su portafolio de acciones comprando opciones de venta frente a una eventual recesión.
2. **Especulación:** Los participantes del mercado pueden usar opciones para intentar beneficiarse de los movimientos direccionales esperados en los precios de los activos. Si un inversor cree que las acciones de una compañía van a subir, puede comprar una opción call en lugar de comprar las acciones directamente, limitando su riesgo máximo a la prima pagada.
3. **Apalancamiento (Leverage):** Las opciones permiten a los inversores controlar una gran cantidad de activos subyacentes con una inversión inicial relativamente pequeña (la prima). Esto proporciona apalancamiento, lo que significa que un pequeño cambio en el precio del activo subyacente puede resultar en un cambio porcentual mucho mayor en el valor de la opción, amplificando tanto las ganancias como las posibles pérdidas sobre la inversión inicial.

1.2. Opciones Barrera

Habiendo establecido el funcionamiento de las opciones estándar, podemos introducir el objeto principal de este trabajo. Las opciones barrera son instrumentos derivados más complejos (clasificadas como opciones exóticas) y son ampliamente utilizados en los mercados financieros modernos. Su popularidad se debe principalmente a dos factores, el hecho de que son significativamente más baratas que las opciones vanilla equivalentes y el que permiten a los inversores y empresas cubrir riesgos específicos de manera más eficiente.

A diferencia de las opciones europeas estándar, cuyo valor depende únicamente del precio del activo subyacente al vencimiento, las opciones barrera tienen una característica adicional, su existencia depende de si el precio del activo cruza o no un nivel predeterminado (la **barrera**) durante la vida del contrato. Esta dependencia de la trayectoria completa del precio a lo largo del tiempo, y no solo de su valor final, introduce complejidades significativas en su valoración.

1.2.1. Motivación de las Opciones Barrera

Las opciones barrera se utilizan en diversos contextos financieros:

- **Gestión de riesgos corporativos:** Una empresa exportadora puede usar una opción barrera para protegerse contra movimientos adversos del tipo de cambio, pero solo si estos superan un umbral crítico para su operación.
- **Productos estructurados:** Los bancos de inversión incorporan opciones barrera en productos estructurados para ofrecer perfiles de riesgo-retorno específicos a menor costo.
- **Especulación dirigida:** Los traders pueden expresar visiones de mercado sofisticadas (por ejemplo, “el activo subirá pero no superará cierto nivel”) con menor capital que usando opciones vanilla.
- **Optimización de costos:** Las opciones barrera permiten obtener cobertura a un costo significativamente menor que las opciones estándar, lo que las hace atractivas para empresas con presupuestos limitados.

1.3. El Problema de Valoración

1.3.1. ¿Qué significa “Valorar” una Opción?

En finanzas cuantitativas, “valorar” (del inglés *pricing*) una opción significa determinar su precio teórico justo en el mercado actual, es decir, calcular matemáticamente cuál debería ser la **prima** que el comprador le paga al vendedor el día de hoy.

Dado que el beneficio económico que la opción generará en el futuro depende de cómo fluctúe el precio del activo subyacente (el cual se asume que se comporta de manera aleatoria o estocástica), la valoración consiste en calcular el **valor esperado** de esos beneficios futuros, descontados al valor del dinero de hoy.

Desde la perspectiva de la matemática y la computación, valorar una opción se traduce en resolver un problema riguroso:

- **Matemáticamente**, implica calcular una esperanza matemática sobre un proceso estocástico, lo que frecuentemente equivale a resolver una Ecuación Diferencial Parcial (PDE, por sus siglas en inglés) que modela cómo evoluciona el precio de la opción en relación con el paso del tiempo y el movimiento del activo subyacente.
- **Computacionalmente**, cuando las ecuaciones no tienen una solución analítica exacta, valorar requiere diseñar e implementar algoritmos numéricos eficientes. Esto puede implicar simular millones de posibles caminos aleatorios que el precio podría tomar (simulaciones de Monte Carlo) o discretizar el espacio y el tiempo en mallas de diferencias finitas.

En el caso de las opciones barrera, este problema es significativamente más demandante desde el punto de vista algorítmico. Como el contrato puede desaparecer o activarse si el precio del activo toca la barrera en *cualquier momento* antes de su vencimiento, la computadora no puede limitarse a evaluar el precio al final del período; requiere simular, rastrear y procesar la **trayectoria completa** temporal de los precios.

1.3.2. Fórmulas Analíticas y sus Limitaciones

Bajo el modelo de Black-Scholes con monitoreo continuo de la barrera, existen fórmulas cerradas para valorar opciones barrera europeas, desarrolladas por Reiner y Rubinstein (1991). Estas fórmulas son matemáticamente elegantes y computacionalmente eficientes.

Sin embargo, presentan limitaciones importantes en la práctica:

1. **Monitoreo discreto vs continuo:** En la realidad, las barreras se monitorean en momentos discretos (diariamente, o incluso solo al cierre del mercado), no continuamente. Esto puede generar diferencias significativas en el precio, especialmente para barreras cercanas al precio actual del activo.
2. **Volatilidad constante:** El supuesto de volatilidad constante es particularmente problemático para opciones de largo plazo o en mercados con alta variabilidad de la volatilidad.
3. **Salto en el precio:** El modelo no considera saltos discontinuos en el precio del subyacente, que pueden hacer que el precio “salte” sobre la barrera sin tocarla, afectando significativamente la valoración.
4. **Barreras complejas:** Para barreras dependientes del tiempo, barreras dobles, o barreras parciales (monitoreadas solo en ciertos períodos), no existen fórmulas cerradas.

1.3.3. Desafíos Computacionales

Los métodos numéricos para valorar opciones barrera enfrentan desafíos específicos:

- **Sensibilidad cerca de la barrera:** El valor de la opción y sus derivadas (las “griegas”) cambian drásticamente cuando el precio del subyacente se aproxima a la barrera. Esto requiere una resolución muy fina en esa región.
- **Discontinuidades:** En el momento en que se toca la barrera, el valor de una opción knock-out cae abruptamente a cero (o al valor del rebate). Esta discontinuidad es difícil de capturar numéricamente.
- **Trade-off precisión-velocidad:** Métodos muy precisos pueden ser computacionalmente costosos, mientras que métodos rápidos pueden carecer de la precisión necesaria, especialmente para el cálculo de sensibilidades.

1.4. Objetivos del Trabajo

1.4.1. Objetivo General

Comparar sistemáticamente diferentes métodos numéricos para la valoración de opciones barrera europeas, evaluando su precisión, eficiencia computacional, y aplicabilidad en diferentes escenarios.

1.4.2. Objetivos Específicos

1. **Estudiar el modelo de Black-Scholes:** Analizar las fórmulas cerradas de Reiner y Rubinstein para opciones barrera europeas, comprendiendo su derivación y limitaciones.
2. **Implementar métodos numéricos:** Desarrollar implementaciones de:
 - Mallas adaptativas (Adaptive Mesh Model de Figlewski-Gao)
 - Simulación de Monte Carlo con técnicas de reducción de varianza
3. **Validar las implementaciones:** Comparar los resultados numéricos con las fórmulas analíticas de Reiner-Rubinstein en casos donde estas son aplicables.
4. **Analizar el desempeño:** Evaluar cada método en términos de:
 - Precisión absoluta y relativa
 - Tiempo de cómputo
 - Estabilidad numérica
 - Capacidad para calcular sensibilidades (griegas)
5. **Identificar casos de uso óptimos:** Determinar qué método es más apropiado según:
 - Tipo de opción barrera (knock-in, knock-out, up, down)
 - Posición relativa del precio actual respecto a la barrera
 - Tiempo al vencimiento
 - Volatilidad del subyacente
 - Requerimientos de precisión
6. **Proporcionar recomendaciones prácticas:** Ofrecer guías para la selección del método más apropiado en diferentes contextos de aplicación.

1.5. Contribuciones del Trabajo

Este trabajo contribuye a la literatura y práctica de valoración de opciones barrera en los siguientes aspectos:

1. **Comparación sistemática:** Proporciona una comparación rigurosa y sistemática de múltiples métodos numéricos bajo un marco común de evaluación.
2. **Implementaciones validadas:** Ofrece implementaciones cuidadosamente validadas de métodos avanzados como mallas adaptativas, que pueden servir como referencia para futuros trabajos.
3. **Guías prácticas:** Proporciona recomendaciones concretas sobre qué método usar en diferentes situaciones, útiles tanto para académicos como para profesionales.
4. **Análisis de sensibilidad:** Estudia cómo el desempeño de cada método varía con los parámetros del problema, identificando regiones donde ciertos métodos son superiores.

1.6. Organización del Trabajo

Los capítulos de este trabajo se organizan de la siguiente manera:

En el Capítulo 2 se presentan los fundamentos financieros necesarios para comprender la valoración de opciones. Se introducen los mercados de derivados, los diferentes tipos de opciones (europeas, americanas, exóticas) y en particular las opciones barrera. Se desarrolla el modelo de Black-Scholes estableciendo el marco teórico fundamental.

Los capítulos Capítulo 3, Capítulo 4, Capítulo 5 y Capítulo 6 describen los cuatro métodos de valoración que serán implementados y comparados: las fórmulas analíticas de Reiner y Rubinstein, árboles trinomiales con mallas adaptativas, replicación estática mediante portafolios y simulación de Monte Carlo con el método de Longstaff-Schwartz para opciones americanas. Para cada método se explican sus principios básicos, ventajas y desventajas.

En el Capítulo 8 se presenta una comparación sistemática de todos los métodos implementados. Se diseñan experimentos numéricos con diferentes parámetros (precio del subyacente, strike, barrera, volatilidad, tiempo al vencimiento) y se analizan los resultados en términos de precisión, tiempo de cómputo y estabilidad. Se identifican los casos de uso óptimos para cada método.

Finalmente, las conclusiones generales son presentadas en el Capítulo 9, donde se resumen los resultados principales del trabajo, se presentan las conclusiones sobre qué método es más apropiado en diferentes situaciones, se discuten las limitaciones del estudio y se proponen direcciones para trabajo futuro.

1.7. Repositorio de Código

Todo el material desarrollado para esta tesis, incluyendo las implementaciones de los algoritmos en Python, los scripts utilizados para la generación de figuras y las fuentes originales se encuentra disponible de forma abierta en el siguiente repositorio de GitHub: https://github.com/ChachoPacho/Tesis-Simulation_and_Discretization_Techniques_for_the_Evaluation_of_Barrier_Options.

Capítulo 2

Marco Teórico

Este capítulo presenta los fundamentos teóricos necesarios para comprender la valoración de opciones barrera. Se introducen los conceptos básicos de mercados de derivados, los diferentes tipos de opciones y el modelo de Black-Scholes que constituye la base teórica para los métodos de valoración que se desarrollarán en capítulos posteriores.

2.1. Mercados de Derivados

Los derivados financieros son instrumentos cuyo valor depende (se deriva) del valor de otro activo, llamado activo subyacente. Los subyacentes más comunes incluyen acciones, índices bursátiles, divisas, tasas de interés y commodities.

2.1.1. Características de los Mercados de Derivados

Los mercados de derivados cumplen varias funciones económicas importantes:

- **Gestión de riesgos:** Permiten a empresas e inversores transferir riesgos no deseados a otros participantes dispuestos a asumirlos.
- **Descubrimiento de precios:** Los precios de los derivados reflejan las expectativas del mercado sobre el comportamiento futuro de los activos subyacentes.
- **Apalancamiento:** Permiten tomar posiciones significativas con una inversión inicial relativamente pequeña.
- **Eficiencia de mercado:** Facilitan el arbitraje, contribuyendo a la eficiencia en la formación de precios.

2.1.2. Tipos de Derivados

Como su nombre lo indica, un contrato derivado no tiene un valor propio independiente, sino que su precio “deriva” (es decir, depende matemáticamente) del comportamiento de un elemento de referencia llamado **activo subyacente**. Este subyacente puede ser un activo financiero tradicional (como acciones de

2.2. OPCIONES FINANCIERAS

una empresa, bonos o divisas), un activo físico (materias primas como petróleo, cobre o soja), o incluso variables más abstractas (como tasas de interés).

Dependiendo de la mecánica exacta de cómo se vinculan al activo subyacente, los principales tipos de derivados son:

- **Forwards:** Contratos a medida entre dos partes para comprar o vender un activo en una fecha futura a un precio acordado hoy.
- **Futuros:** Similares a los forwards pero estandarizados y negociados en bolsas organizadas.
- **Swaps:** Acuerdos para intercambiar flujos de efectivo futuros según reglas predeterminadas.
- **Opciones:** Contratos que otorgan el derecho (pero no la obligación) de comprar o vender un activo a un precio determinado.

2.2. Opciones Financieras

Una opción es un contrato que otorga a su tenedor el derecho, pero no la obligación, de comprar (opción call) o vender (opción put) un activo subyacente a un precio predeterminado (precio de ejercicio o *strike*) en o antes de una fecha específica (fecha de vencimiento).

Para ilustrar este concepto con un **ejemplo práctico**: supongamos que las acciones de una empresa tecnológica cotizan hoy en el mercado a \$100. Un inversor cualquiera adquiere una opción de compra (*Call*) que le otorga el derecho a comprar una acción a un precio fijo (*strike*) de \$105 dentro de exactamente un mes. Por acceder a este contrato, el inversor le paga al vendedor un costo inicial o **prima** de \$2.

- Si al cumplirse el mes la acción tuvo mucho éxito y subió a \$120, el inversor decide **ejercer** su derecho: le compra la acción al vendedor a \$105 (el precio acordado) y puede venderla inmediatamente en el mercado a \$120. Obtiene así un beneficio bruto de \$15 (y una ganancia neta de \$13 al descontar la prima original).
- Si, por el contrario, la acción cae a \$90, el inversor simplemente decide **no ejercer** la opción. Carece de sentido matemático obligarse a comprar a \$105 algo que en el mercado cuesta \$90. En este caso, el contrato expira sin valor y su pérdida está estrictamente limitada a los \$2 que pagó inicialmente por la prima.

Este comportamiento asimétrico (ganancias potenciales grandes frente a pérdidas acotadas a la prima) es la propiedad matemática que diferencia a las opciones de otros derivados como los futuros.

2.2.1. Opciones Call y Put

En la jerga financiera, se utiliza el término anglosajón **payoff** para describir la función matemática que determina exactamente cuánto dinero bruto recibe el tenedor de la opción en el instante final en que expira el contrato. En otras

2.3. OPCIONES BARRERA

palabras, es una función que evalúa el valor intrínseco del contrato en el momento de su resolución, basándose únicamente en el precio final del activo y el *strike*, sin tener en cuenta lo que costó inicialmente la prima.

Formalmente, podemos definir estas funciones de *payoff* para cada tipo de opción:

Opción Call: Otorga el derecho de comprar el activo subyacente al precio de ejercicio K . El *payoff* al vencimiento es:

$$\text{Payoff}_{\text{Call}} = \max(S_T - K, 0) \quad (2.1)$$

donde S_T es el precio del subyacente al vencimiento (En el ejemplo anterior $S_T = 120$, $K = 105$, entonces $\text{Payoff}_{\text{Call}} = \max(120 - 105, 0) = 15$). Si $S_T = 90$, entonces $\text{Payoff}_{\text{Call}} = \max(90 - 105, 0) = 0$.

Opción Put: Otorga el derecho de vender el activo subyacente al precio de ejercicio K . El *payoff* al vencimiento es:

$$\text{Payoff}_{\text{Put}} = \max(K - S_T, 0) \quad (2.2)$$

2.2.2. Opciones Europeas vs Americanas

Según el momento en que puede ejercerse la opción, se clasifican en europeas y americanas:

Opciones Europeas: Solo pueden ejercerse en la fecha de vencimiento. Son más simples de valorar analíticamente.

Opciones Americanas: Pueden ejercerse en cualquier momento hasta el vencimiento. Esta flexibilidad adicional las hace más valiosas que sus contrapartes europeas, pero también más difíciles de valorar.

2.2.3. Opciones Exóticas

Las opciones exóticas son aquellas cuyas características difieren de las opciones vanilla (europeas o americanas estándar). Incluyen:

- **Opciones Barrera:** Su existencia depende de si el precio del subyacente cruza un nivel predeterminado durante la validez de la opción.
- **Opciones Asiáticas:** Su *payoff* depende de algún tipo de promedio del precio del subyacente durante todo o algún período.
- **Opciones Lookback:** Su *payoff* depende del máximo o mínimo valor que haya tomado el subyacente.
- **Opciones Digitales:** Pagan una cantidad fija si se cumple cierta condición.

2.3. Opciones Barrera

Las opciones barrera son el foco principal de este trabajo. Su característica distintiva es que, a diferencia de las opciones tradicionales, su existencia depende de si el precio del activo subyacente alcanza o cruza un nivel de precio predeterminado (la barrera H) en algún instante durante la vida de la opción.

2.3. OPCIONES BARRERA

Para asimilar esto más despacio, retomemos el **ejemplo práctico** de la sección anterior. El inversor compraba el derecho a adquirir una acción a un *strike* de \$105 (sabiendo que hoy vale \$100). Ahora imaginemos que, para pagar una prima más barata, el inversor adquiere una **Opción Barrera tipo Call**. El contrato mantiene el *strike* de \$105, pero le agregamos una condición extra: una barrera en \$90. Acuerdan que si el precio de la acción toca o cae por debajo de \$90 en *cualquier momento* durante ese mes, la opción se **cancela automáticamente** (se desactiva).

- Si la acción sube progresivamente a \$120 sin tocar nunca el límite de \$90, el inversor ejerce la opción al final del mes y obtiene su beneficio normalmente.
- Pero si a mitad de mes hay una caída repentina y la acción toca los \$89, su opción deja de existir. Si luego la acción se recupera milagrosamente y termina el mes a \$120, el inversor ya no puede ejercerla, porque el contrato dejó de existir en el momento en que se cruzó la barrera.

Desde una perspectiva matemática y de programación algorítmica, esto significa que el *payoff* ya no es una función simple del precio final S_T , sino que es necesario monitorear y registrar la función del precio S_t en todo momento temporal t para verificar si la condición $S_t \leq 90$ se cumple. Esto es lo que se conoce como un instrumento “dependiente de la trayectoria” (*path-dependent*).

2.3.1. Clasificación de Opciones Barrera

Las opciones barrera se clasifican según dos criterios:

1. Según el efecto de tocar la barrera:

- **Knock-In:** La opción comienza a existir (se activa) solo si se toca o cruza la barrera.
- **Knock-Out:** La opción deja de existir (se extingue) si se toca o cruza la barrera.

2. Según la posición de la barrera:

- **Up:** La barrera H está por encima del precio inicial del subyacente ($H > S_0$).
- **Down:** La barrera H está por debajo del precio inicial del subyacente ($H < S_0$).

Combinando estos criterios para calls y puts obtenemos ocho tipos básicos de opciones barrera:

- Down-and-In Call (DIC)
- Down-and-Out Call (DOC)
- Up-and-In Call (UIC)
- Up-and-Out Call (UOC)
- Down-and-In Put (DIP)

- Down-and-Out Put (DOP)
- Up-and-In Put (UIP)
- Up-and-Out Put (UOP)

A modo de ejemplo, consideremos una **Down-and-In Call (DIC)** con precio inicial del subyacente en \$100, precio de ejercicio (*strike*) de \$105 y barrera en \$90. Esta opción nace inactiva. Solo si el precio de la acción cae en algún momento hasta tocar los \$90, la opción “cobra vida” (se activa). A partir de ese instante, se comporta como una opción de compra tradicional, y el inversor podrá ejercerla si al vencimiento el precio supera los \$105. Si, por el contrario, el precio nunca desciende hasta \$90 durante la vida del contrato, la opción expira sin valor alguno.

2.3.2. Payoffs de Opciones Barrera

El payoff de una opción barrera depende tanto del precio final del subyacente como de si la barrera fue tocada durante la vida de la opción.

Para una **Down-and-Out Call**:

$$\text{Payoff}_{\text{DOC}} = \max(S_T - K, 0) \cdot \mathbb{I}_{\{\min_{0 \leq t \leq T} S_t > H\}} \quad (2.3)$$

Para una **Down-and-In Call**:

$$\text{Payoff}_{\text{DIC}} = \max(S_T - K, 0) \cdot \mathbb{I}_{\{\min_{0 \leq t \leq T} S_t \leq H\}} \quad (2.4)$$

donde $\mathbb{I}_A$ es la función indicadora que vale 1 si se cumple la condición A y 0 en caso contrario.

Es importante notar que, desde una perspectiva matemática, el *payoff* de la opción es una **variable aleatoria**. Su valor final es incierto en el tiempo $t = 0$ y depende enteramente de la trayectoria estocástica que desarrolle el precio del activo subyacente S_t a lo largo del tiempo. Por lo tanto, el desafío de la valoración financiera consistirá en calcular el valor esperado de esta variable aleatoria y descontarlo al valor presente.

2.3.3. Relaciones de Paridad

Existe una relación fundamental entre las primas de las opciones knock-in y knock-out del mismo tipo:

$$\text{Prima Opción Vanilla} = \text{Prima Opción Knock-In} + \text{Prima Opción Knock-Out} \quad (2.5)$$

Por ejemplo, utilizando la notación estándar donde la letra C representa el precio o prima de una opción de compra (*Call*):

$$C_{\text{europea}} = C_{\text{DI}} + C_{\text{DO}} \quad (2.6)$$

donde cada término significa lo siguiente:

- C_{europea} es el costo de una opción Call estándar europea (sin barrera).
- C_{DI} es el costo de una opción *Down-and-In Call* (que solo se activa si toca la barrera baja).

2.4. EL MODELO DE BLACK-SCHOLES

- C_{DO} es el costo de una opción *Down-and-Out Call* (que se anula si toca la barrera baja).

La lógica detrás de esta igualdad es muy intuitiva si imaginamos adquirir ambas opciones simultáneamente. Dado un mismo subyacente, *strike* y vencimiento, si compramos tanto la opción *Knock-In* como la *Knock-Out*, estamos cubriendo todos los escenarios posibles de forma mutuamente excluyente. Si el precio del subyacente toca la barrera en algún momento, la opción *Knock-Out* deja de existir pero la *Knock-In* se activa automáticamente. Si, por el contrario, el precio nunca toca la barrera, la *Knock-In* nunca cobra vida, pero la *Knock-Out* sobrevive intacta hasta el final. En cualquier escenario, al vencimiento terminaremos poseyendo exactamente una opción activa, lo cual equivale a tener en cartera una opción *Vanilla* tradicional sin restricciones de barrera.

Esta relación es útil para validar implementaciones y para valorar opciones knock-in a partir de opciones knock-out (o viceversa).

2.3.4. Rebates

Muchas opciones barrera incluyen un **rebate** (reembolso) R , que es una cantidad fija pagada al tenedor en ciertas circunstancias:

- En opciones **knock-out**: El rebate se paga cuando se toca la barrera (momento en que la opción se extingue).
- En opciones **knock-in**: El rebate se paga al vencimiento si la barrera nunca fue tocada (y por tanto la opción nunca se activó).

2.3.5. Ventajas de las Opciones Barrera

Las opciones barrera son significativamente más baratas que las opciones vanilla equivalentes porque:

- Las opciones knock-out pueden extinguirse antes del vencimiento, reduciendo el riesgo para el vendedor.
- Las opciones knock-in solo comienzan a existir bajo ciertas condiciones, también reduciendo el riesgo.

Esta reducción de costo las hace atractivas para:

- Empresas que buscan cobertura a menor costo
- Inversores con visiones específicas sobre el comportamiento del mercado
- Estructuración de productos financieros complejos

2.4. El Modelo de Black-Scholes

El modelo de Black-Scholes, desarrollado por Fischer Black, Myron Scholes y Robert Merton en 1973, revolucionó la valoración de opciones y sentó las bases de la ingeniería financiera moderna Black y Scholes (1973).

2.4.1. Supuestos del Modelo

El modelo de Black-Scholes se construye sobre una base matemática rigurosa que requiere definir varios conceptos y supuestos clave sobre el comportamiento del mercado:

1. **Dinámica del precio (Movimiento Browniano Geométrico):**

Se asume que el precio del activo subyacente S_t evoluciona siguiendo un Movimiento Browniano Geométrico (MBG). En cálculo estocástico, esto se describe mediante la siguiente Ecuación Diferencial Estocástica:

$$dS_t = \mu S_t dt + \sigma S_t dW_t \quad (2.7)$$

Para comprender esta ecuación, podemos separar el cambio infinitesimal del precio (dS_t) durante un instante temporal (dt) en dos componentes:

- **Componente determinista ($\mu S_t dt$):** Representa la tendencia (o *drift*) del activo. μ es la **tasa de retorno esperada**. Si el mercado fuera totalmente predecible, el precio crecería a esta tasa constantemente.
- **Componente aleatorio ($\sigma S_t dW_t$):** Modela los *shocks* impredecibles del mercado. dW_t es un incremento de un **Proceso de Wiener** (una variable aleatoria normal que representa ruido blanco), y σ es la **volatilidad**, la cual cuantifica la intensidad de dicha aleatoriedad (qué tan bruscos son los movimientos).

2. **Ausencia de Arbitraje y Mercados Completos:**

El modelo asume que no hay oportunidades de **arbitraje** (la posibilidad matemática de obtener ganancias sin riesgo y sin inversión inicial). Imponer la ausencia de arbitraje es lo que permite hallar un único precio justo para la opción. A su vez, se asume un **mercado completo**, lo que significa que es posible crear un portafolio de inversión que replique y cubra perfectamente cualquier riesgo utilizando únicamente el activo subyacente y bonos libres de riesgo.

3. **Tasa Libre de Riesgo (r) constante:**

Se asume la existencia de una tasa de interés libre de riesgo r , que es constante a lo largo del tiempo. A esta tasa, cualquier participante puede pedir prestado o prestar dinero asumiendo un riesgo de impago nulo (usualmente se asimila al rendimiento de los bonos del gobierno).

4. **Volatilidad (σ) constante:**

Se asume que la volatilidad σ del subyacente es conocida y permanece inmutable durante toda la vida de la opción. En la práctica real, la volatilidad suele cambiar, constituyendo una de las mayores limitaciones de este modelo.

5. **Ausencia de Dividendos:**

El activo subyacente no paga dividendos durante la vida de la opción (aunque las matemáticas se pueden extender fácilmente agregando una tasa de dividendos continua).

6. Mercados sin Fricciones en Tiempo Continuo:

Para que la ecuación diferencial parcial se pueda resolver exactamente, se idealizan las condiciones operativas:

- No existen costos de transacción, comisiones financieras ni impuestos.
- Se permite tomar posiciones cortas (*short selling*) de forma ilimitada.
- Los activos son perfectamente divisibles (se pueden operar fracciones infinitesimales).
- No hay oportunidades de arbitraje.

2.4.2. Ecuación Diferencial de Black-Scholes

Bajo estos supuestos, el precio de cualquier derivado $V(S, t)$ que depende del precio del subyacente S y del tiempo t debe satisfacer la ecuación diferencial parcial:

$$\frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0 \quad (2.8)$$

Esta ecuación se resuelve sujeta a condiciones de borde apropiadas que dependen del tipo específico de derivado.

2.4.3. Medida Neutral al Riesgo

Un concepto fundamental del modelo es la **medida neutral al riesgo**. Bajo esta medida de probabilidad:

- El **precio descontado** de cualquier activo es una **martingala**. El “precio descontado” es simplemente el dinero del futuro expresado en su valor del presente (multiplicándolo matemáticamente por el factor de descuento continuo e^{-rt}). Decir que es una *martingala* significa que es un proceso aleatorio sin tendencia, es decir, el valor esperado futuro descontado es exactamente igual al valor presente de hoy.
- El retorno esperado de todos los activos se iguala matemáticamente a la tasa libre de riesgo r . En este universo teórico (bajo la medida $\mathbb{Q}$), se actúa como si los inversores fueran completamente indiferentes al riesgo, por lo que no exigen ganar más por comprar una acción volátil que por comprar un bono seguro.
- Como corolario de lo anterior, el precio justo de un derivado hoy se calcula simplemente sacando el valor promedio esperado de su *payoff* futuro, y descontando (retrotrayendo) ese dinero al día de hoy usando la tasa r .

Bajo la medida neutral al riesgo, el proceso del precio del subyacente se convierte en:

$$dS_t = rS_t dt + \sigma S_t dW_t^{\mathbb{Q}} \quad (2.9)$$

donde $W_t^{\mathbb{Q}}$ es un proceso de Wiener bajo la medida neutral al riesgo $\mathbb{Q}$.

2.4.4. Fórmula de Black-Scholes para Opciones Vanilla

Para una opción call europea con precio de ejercicio K y vencimiento T , la fórmula de Black-Scholes para la prima es:

$$C(S, t) = SN(d_1) - Ke^{-r(T-t)}N(d_2) \quad (2.10)$$

donde:

$$d_1 = \frac{\ln(S/K) + (r + \sigma^2/2)(T - t)}{\sigma\sqrt{T - t}} \quad (2.11)$$

$$d_2 = d_1 - \sigma\sqrt{T - t} \quad (2.12)$$

y $N(\cdot)$ es la función de distribución acumulada de la normal estándar.

Para una opción put europea:

$$P(S, t) = Ke^{-r(T-t)}N(-d_2) - SN(-d_1) \quad (2.13)$$

2.4.5. Las Griegas

Las **griegas** son las derivadas parciales del precio de la opción respecto a sus parámetros. Son fundamentales para la gestión de riesgos:

- **Delta** (Δ): Sensibilidad al precio del subyacente

$$\Delta = \frac{\partial V}{\partial S} \quad (2.14)$$

- **Gamma** (Γ): Tasa de cambio del delta

$$\Gamma = \frac{\partial^2 V}{\partial S^2} \quad (2.15)$$

- **Vega** ($\mathcal{V}$): Sensibilidad a la volatilidad

$$\mathcal{V} = \frac{\partial V}{\partial \sigma} \quad (2.16)$$

- **Theta** (Θ): Sensibilidad al paso del tiempo

$$\Theta = \frac{\partial V}{\partial t} \quad (2.17)$$

- **Rho** (ρ): Sensibilidad a la tasa de interés

$$\rho = \frac{\partial V}{\partial r} \quad (2.18)$$

2.4.6. Limitaciones del Modelo

A pesar de su indudable elegancia matemática y su inmensa utilidad práctica como estándar de la industria, el modelo de Black-Scholes presenta importantes limitaciones teóricas cuando se lo contrasta con el mundo real. Al haber transformado la dinámica del mercado en un sistema idealizado de ecuaciones diferenciales, el modelo se vio obligado a realizar simplificaciones que no siempre se cumplen.

La crítica más fuerte proviene de su tratamiento de la estadística de los precios. El modelo asume que la volatilidad es una constante inmutable y que los retornos se distribuyen de forma estrictamente normal. Sin embargo, la evidencia empírica demuestra que los mercados financieros tienen “colas pesadas” (*fat tails*), es decir, los eventos extremos y las crisis ocurren con mucha mayor frecuencia de lo que predeciría una campana de Gauss. Además, la volatilidad real no es constante, ya que varía dinámicamente y depende del precio de ejercicio, un fenómeno empírico conocido como la “sonrisa de volatilidad” (*volatility smile*).

Otra limitación inherente a la utilización del Movimiento Browniano Geométrico es que asume una trayectoria continua para los precios. Matemáticamente, esto significa que el precio fluye sin interrupciones. En la realidad, los precios sufren saltos abruptos o discontinuidades (por ejemplo, cuando el mercado abre con un precio muy distinto al cierre del día anterior debido a una noticia nocturna importante). El modelo clásico de Black-Scholes es completamente ciego ante estas brechas en la trayectoria.

Finalmente, el modelo ignora la fricción real de operar en el mercado. La premisa de que un algoritmo o inversor puede ajustar sus posiciones de forma continua e ininterrumpida sin pagar costos de transacción es computacional y financieramente imposible. A esto se le suma la idealización de una tasa de interés constante, lo cual resulta ser una aproximación aceptable para opciones que vencen en pocas semanas, pero genera errores sistemáticos considerables al valorar derivados a largo plazo donde el valor del dinero en el tiempo fluctúa.

A pesar de todas estas falencias, el modelo de Black-Scholes sigue siendo el pilar conceptual fundamental de las finanzas cuantitativas. Más que como un oráculo perfecto, se utiliza hoy en día como el punto de referencia base sobre el cual se construyen e iteran modelos matemáticos y algoritmos más sofisticados.

2.5. Extensiones del Modelo Black-Scholes

Para opciones barrera, el modelo de Black-Scholes se extiende incorporando condiciones de borde adicionales que reflejan el comportamiento en la barrera. Estas extensiones permiten obtener fórmulas cerradas para ciertos tipos de opciones barrera europeas, como se verá en el siguiente capítulo.

Otras extensiones importantes del modelo incluyen:

- Modelos de volatilidad estocástica (Heston, SABR)
- Modelos con saltos (Merton, Kou)
- Modelos de volatilidad local (Dupire)
- Modelos de tasas de interés estocásticas

2.5. EXTENSIONES DEL MODELO BLACK-SCHOLES

Sin embargo, estas extensiones quedan fuera del alcance de este trabajo, que se enfoca en métodos de valoración bajo el modelo de Black-Scholes clásico.

A partir del próximo capítulo se presentan los cuatro métodos de valoración bajo este marco que serán implementados y comparados en esta tesis, dedicando un capítulo individual a cada uno. Para opciones barrera europeas se analizan tres métodos: fórmulas analíticas de Reiner y Rubinstein, árboles trinomiales con mallas adaptativas y replicación estática mediante portafolios de opciones *vanilla*. Para opciones barrera americanas se utiliza simulación de Monte Carlo con el método de Longstaff-Schwartz.

Capítulo 3

Método 1: Fórmulas Analíticas de Reiner y Rubinstein

El trabajo seminal de Reiner y Rubinstein (1991) proporciona una metodología sistemática para obtener fórmulas cerradas para los ocho tipos básicos de opciones barrera europeas bajo el modelo de Black-Scholes.

3.1. Intuición Matemática del Método

Antes de sumergirnos en las ecuaciones y densidades de probabilidad, es crucial entender la estrategia teórica subyacente que utilizaron Reiner y Rubinstein para resolver el problema matemáticamente. Su genialidad radicó en dos pilares fundamentales:

1. Estrategia de “Divide y Vencerás”

Calcular analíticamente una opción dependiente de la trayectoria desde cero es una tarea ardua. Los autores resolvieron esto demostrando que cualquier opción barrera se puede descomponer matemáticamente en una suma o resta de piezas más simples y conocidas. En concreto, utilizaron “bloques de construcción” como las opciones estándar (*vanilla*) y pagos fijos condicionales. Al calcular el valor de estos bloques simples y combinarlos linealmente, lograron ensamblar el precio exacto de opciones barreras complejas.

2. El Principio de Reflexión

El mayor desafío algorítmico era estimar la probabilidad de que la trayectoria aleatoria del precio tocara la barrera en *algún momento* durante la vida del contrato. Para evitar integrales estocásticas complejas, se basaron en una propiedad fascinante del Movimiento Browniano con logaritmo, el **Principio de Reflexión**. Este principio geométrico-estadístico establece una simetría perfecta, por cada posible trayectoria del mercado que toca la barrera y termina en un precio final determinado, existe una trayectoria “espejo” matemáticamente idéntica que terminó en un precio simétricamente opuesto más allá de la barrera (*lognormal random walk*). Contar y ponderar estas trayectorias reflejadas

permite calcular probabilidades de cruce utilizando únicamente funciones de distribución normal clásicas.

Comprender estos dos conceptos es la clave para darle sentido al ecosistema de variables y funciones de densidad que se define a continuación.

3.2. Marco Metodológico de Valoración

Reiner y Rubinstein desarrollaron el siguiente método para obtener fórmulas analíticas de valoración de opciones barrera. Para ello, consideraron las diferentes trayectorias del activo: aquellas en que el activo nunca alcanza la barrera y aquellas en las que el activo toca o cruza la barrera.

Consideraremos opciones barrera sobre un activo con precio $S(t)$ en el tiempo t y vencimiento en el tiempo T . Denotaremos como antes:

- r : la tasa libre de riesgo continua
- q : la tasa de dividendos continua del activo
- $e^{-r(T-t)}$: el factor de descuento para el período restante
- σ : la volatilidad del subyacente

Para la opción en sí misma, denotaremos:

- H : el nivel de barrera
- K : el precio de ejercicio (*strike*)
- R : el monto del rebate

Recordemos que la prima de cualquier opción se calcula como el valor esperado del *payoff* descontado desde el tiempo de vencimiento T hasta el presente t :

$$\text{Prima} = e^{-r(T-t)} \mathbb{E}[\text{Payoff}] \quad (3.1)$$

Este *payoff* es una variable aleatoria y el valor esperado se calcula utilizando la función de densidad de la variable subyacente (el logaritmo del retorno) al momento del ejercicio. Para calcular este valor esperado considerando los diferentes tipos de trayectorias (con y sin cruce de barrera), Reiner y Rubinstein proponen tres densidades fundamentales:

- $f(u)$: densidad tradicional del logaritmo natural del activo al vencimiento ($u \in \mathbb{R}$), sin considerar la trayectoria. Se utiliza para modelar las trayectorias donde **no se cruza** la barrera. Matemáticamente:

$$f(u) = \frac{1}{\sigma\sqrt{2\pi(T-t)}} e^{-v^2/2} \quad \text{donde} \quad v = \frac{u - \mu(T-t)}{\sigma\sqrt{T-t}}$$

con $\mu = r - q - \frac{1}{2}\sigma^2$.

- $g(u)$: densidad especial ($u \in \mathbb{R}$) que incorpora información sobre la trayectoria mediante el principio de reflexión. Pondera exclusivamente aquellas

3.3. DESARROLLO PARA UNA OPCIÓN CALL DOWN-AND-IN

trayectorias que **sí cruzaron** la barrera en algún momento pero que terminaron en un nivel particular. Matemáticamente:

$$g(u) = e^{2\eta\alpha\mu\sigma^{-2}} \frac{1}{\sigma\sqrt{2\pi(T-t)}} e^{-v_g^2/2} \quad \text{donde} \quad v_g = \frac{u - 2\eta\alpha - \mu(T-t)}{\sigma\sqrt{T-t}}$$

con $\alpha = \ln(H/S)$ y donde η es un parámetro direccional que toma el valor 1 si la barrera está por debajo del precio inicial (*Down*) y -1 si está por encima (*Up*).

- $h(\tau)$: densidad del tiempo de primer pasaje. Se utiliza para modelar la probabilidad de que la barrera sea tocada exactamente en el instante $\tau > 0$, siendo útil para pagar rebates en el momento del toque/cruce de la barrera. Matemáticamente:

$$h(\tau) = \frac{-\eta\alpha}{\sigma\sqrt{2\pi\tau^3}} e^{-\frac{(-\eta\alpha + \eta\mu\tau)^2}{2\sigma^2\tau}}$$

3.3. Desarrollo para una Opción Call Down-and-In

A fin de simplificar la notación y hacer más comprensible el desarrollo matemático, presentaremos los cálculos explícitos tomando como ejemplo una opción barrera del tipo **Call Down-and-In** (asumiendo por lo tanto que el precio inicial se encuentra por encima de la barrera, $S > H$).

Para calcular el valor esperado descontado del *payoff*, se deben considerar los diferentes tipos de trayectorias y utilizar en cada caso la densidad adecuada.

3.3.1. Trayectorias sin cruce de barrera

En primer lugar, veamos cómo se calcula la prima para el subconjunto de trayectorias donde el precio final del activo termina por encima del strike K (condición para ejercer una opción Call), asumiendo que no hay restricciones de barrera. Para esto se integra el *payoff* de una Call, $(S(T) - K)$, utilizando la densidad tradicional $f(u)$. El resultado de esta integral es equivalente al de una opción *vanilla*:

$$\begin{aligned} term_1 &= e^{-r(T-t)} \int_{\ln(K/S)}^{\infty} (Se^u - K) f(u) du \\ &= Se^{-q(T-t)} N(x) - Ke^{-r(T-t)} N(x - \sigma\sqrt{T-t}) \end{aligned} \quad (3.2)$$

donde:

$$\begin{aligned} x &= \frac{\ln(S/K)}{\sigma\sqrt{T-t}} + \lambda\sigma\sqrt{T-t} \\ \lambda &= \frac{r - q + \sigma^2/2}{\sigma^2} \end{aligned}$$

3.3.2. Términos de Valoración Adicionales para la Call Down-and-In

Al igual que derivamos el $term_1$ integrando sobre la región sin restricciones, necesitamos calcular otras integrales fundamentales limitando los dominios a los valores que superan la barrera H o el strike K y alternando el uso de las densidades $f(u)$ y $g(u)$ para discriminar correctamente las trayectorias reflejadas.

Término 2: Valor esperado incondicional por encima de la barrera

Integramos el *payoff* de una Call utilizando la densidad tradicional $f(u)$, limitando la región de integración a los precios finales que terminan por encima de la barrera H , sin importar si cruzaron o no durante su trayectoria.

$$\begin{aligned} term_2 &= e^{-r(T-t)} \int_{\ln(H/S)}^{\infty} (Se^u - K)f(u)du \\ &= Se^{-q(T-t)}N(x_1) - Ke^{-r(T-t)}N(x_1 - \sigma\sqrt{T-t}) \end{aligned} \quad (3.3)$$

Término 3: Trayectorias con cruce por encima del strike

Aquí utilizamos la densidad de cruce $g(u)$ para calcular el valor esperado considerando únicamente aquellas trayectorias que sí tocaron la barrera y cuyo precio final es superior al strike K .

$$\begin{aligned} term_3 &= e^{-r(T-t)} \int_{\ln(K/S)}^{\infty} (Se^u - K)g(u)du \\ &= Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(y) - Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(y - \sigma\sqrt{T-t}) \end{aligned} \quad (3.4)$$

Término 4: Trayectorias con cruce por encima de la barrera

Análogo al término anterior, pero integrando sobre todos los precios finales que terminan por encima de la barrera H , habiéndola cruzado previamente.

$$\begin{aligned} term_4 &= e^{-r(T-t)} \int_{\ln(H/S)}^{\infty} (Se^u - K)g(u)du \\ &= Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(y_1) - Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(y_1 - \sigma\sqrt{T-t}) \end{aligned} \quad (3.5)$$

Término 5: Valor del Rebate al vencimiento

Si la barrera nunca se toca, el tenedor podría recibir un reembolso R al vencimiento. El valor presente de este reembolso requiere calcular la probabilidad de que el precio termine por encima de H sin haber cruzado nunca la barrera, lo cual se logra integrando la diferencia de densidades $[f(u) - g(u)]$.

$$\begin{aligned} term_5 &= Re^{-r(T-t)} \int_{\ln(H/S)}^{\infty} [f(u) - g(u)]du \\ &= Re^{-r(T-t)} \left[N(x_1 - \sigma\sqrt{T-t}) - \left(\frac{H}{S}\right)^{2\lambda-2} N(y_1 - \sigma\sqrt{T-t}) \right] \end{aligned} \quad (3.6)$$

3.3.3. Ensamblando la Opción Call Down-and-In

Entonces, de acuerdo a la relación entre el valor de la barrera H y el precio de ejercicio K , la prima de una opción barrera Call Down-and-In resulta de componer estos términos:

Si $K > H$:

$$\begin{aligned} C_{DI} &= term_3 + term_5 \\ &= Se^{-q(T-t)} \left(\frac{H}{S} \right)^{2\lambda} N(y) - Ke^{-r(T-t)} \left(\frac{H}{S} \right)^{2\lambda-2} N(y - \sigma\sqrt{T-t}) \\ &\quad + Re^{-r(T-t)} \left[N(x_1 - \sigma\sqrt{T-t}) - \left(\frac{H}{S} \right)^{2\lambda-2} N(y_1 - \sigma\sqrt{T-t}) \right] \end{aligned} \quad (3.7)$$

Si $K < H$:

$$\begin{aligned} C_{DI} &= term_1 - term_2 + term_4 + term_5 \\ &= Se^{-q(T-t)} N(x) - Ke^{-r(T-t)} N(x - \sigma\sqrt{T-t}) \\ &\quad - Se^{-q(T-t)} N(x_1) + Ke^{-r(T-t)} N(x_1 - \sigma\sqrt{T-t}) \\ &\quad + Se^{-q(T-t)} \left(\frac{H}{S} \right)^{2\lambda} N(y_1) - Ke^{-r(T-t)} \left(\frac{H}{S} \right)^{2\lambda-2} N(y_1 - \sigma\sqrt{T-t}) \\ &\quad + Re^{-r(T-t)} \left[N(x_1 - \sigma\sqrt{T-t}) - \left(\frac{H}{S} \right)^{2\lambda-2} N(y_1 - \sigma\sqrt{T-t}) \right] \end{aligned} \quad (3.8)$$

donde definimos las siguientes variables de estandarización:

$$x_1 = \frac{\ln(S/H)}{\sigma\sqrt{T-t}} + \lambda\sigma\sqrt{T-t} \quad (3.9)$$

$$y = \frac{\ln(H^2/(SK))}{\sigma\sqrt{T-t}} + \lambda\sigma\sqrt{T-t} \quad (3.10)$$

$$y_1 = \frac{\ln(H/S)}{\sigma\sqrt{T-t}} + \lambda\sigma\sqrt{T-t} \quad (3.11)$$

3.3.4. El Término Temporal: Rebate al momento de cruce

Para completar el marco de valoración general, en especial para las opciones de salida (*out-options*) donde el contrato se cancela inmediatamente al tocar la barrera, el reembolso R suele pagarse en el instante exacto en el que se produce el cruce. Para valorar este pago, en lugar de integrar sobre el precio al vencimiento, se integra sobre el tiempo de primer pasaje τ utilizando la densidad $h(\tau)$.

Término 6: Valor presente del Rebate instantáneo

La fórmula para este componente integra la densidad temporal de cruce:

$$\begin{aligned} term_6 &= R \int_0^{T-t} e^{-r\tau} h(\tau) d\tau \\ &= R \left[\left(\frac{H}{S} \right)^{a+b} N(z) + \left(\frac{H}{S} \right)^{a-b} N(z - 2b\sigma\sqrt{T-t}) \right] \end{aligned} \quad (3.12)$$

donde las constantes temporales se definen como:

$$a = \frac{r - q}{\sigma^2} - \frac{1}{2} \quad (3.13)$$

$$b = \frac{\sqrt{(r - q - \sigma^2/2)^2 + 2r\sigma^2}}{\sigma^2} \quad (3.14)$$

$$z = \frac{\ln(H/S)}{\sigma\sqrt{T-t}} + b\sigma\sqrt{T-t} \quad (3.15)$$

3.4. Catálogo de Fórmulas Exactas

De una manera análoga, combinando adecuadamente las densidades $f(u)$, $g(u)$ y $h(\tau)$, se desarrollan los términos necesarios para las Call Up-and-Out, Put Down-and-In, etc. A continuación, se detallan las ecuaciones finales explícitas para las primas de las 8 opciones barrera básicas.

3.4.1. Opciones Call

1. Down-and-In Call ($S > H$)

- Si $K > H$:

$$\begin{aligned} C_{DI} = & S e^{-q(T-t)} \left(\frac{H}{S} \right)^{2\lambda} N(y) - K e^{-r(T-t)} \left(\frac{H}{S} \right)^{2\lambda-2} N(y - \sigma\sqrt{T-t}) \\ & + R e^{-r(T-t)} \left[N(x_1 - \sigma\sqrt{T-t}) - \left(\frac{H}{S} \right)^{2\lambda-2} N(y_1 - \sigma\sqrt{T-t}) \right] \end{aligned}$$

- Si $K < H$:

$$\begin{aligned} C_{DI} = & S e^{-q(T-t)} N(x) - K e^{-r(T-t)} N(x - \sigma\sqrt{T-t}) \\ & - S e^{-q(T-t)} N(x_1) + K e^{-r(T-t)} N(x_1 - \sigma\sqrt{T-t}) \\ & + S e^{-q(T-t)} \left(\frac{H}{S} \right)^{2\lambda} N(y_1) - K e^{-r(T-t)} \left(\frac{H}{S} \right)^{2\lambda-2} N(y_1 - \sigma\sqrt{T-t}) \\ & + R e^{-r(T-t)} \left[N(x_1 - \sigma\sqrt{T-t}) - \left(\frac{H}{S} \right)^{2\lambda-2} N(y_1 - \sigma\sqrt{T-t}) \right] \end{aligned}$$

2. Down-and-Out Call ($S > H$)

- Si $K > H$:

$$\begin{aligned} C_{DO} = & S e^{-q(T-t)} N(x) - K e^{-r(T-t)} N(x - \sigma\sqrt{T-t}) \\ & - S e^{-q(T-t)} \left(\frac{H}{S} \right)^{2\lambda} N(y) + K e^{-r(T-t)} \left(\frac{H}{S} \right)^{2\lambda-2} N(y - \sigma\sqrt{T-t}) \\ & + R \left[\left(\frac{H}{S} \right)^{a+b} N(z) + \left(\frac{H}{S} \right)^{a-b} N(z - 2b\sigma\sqrt{T-t}) \right] \end{aligned}$$

- Si $K < H$:

$$\begin{aligned}
 C_{DO} = & Se^{-q(T-t)}N(x_1) - Ke^{-r(T-t)}N(x_1 - \sigma\sqrt{T-t}) \\
 & - Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(y_1) + Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(y_1 - \sigma\sqrt{T-t}) \\
 & + R\left[\left(\frac{H}{S}\right)^{a+b}N(z) + \left(\frac{H}{S}\right)^{a-b}N(z - 2b\sigma\sqrt{T-t})\right]
 \end{aligned}$$

3. Up-and-In Call ($S < H$)

- Si $K > H$:

$$\begin{aligned}
 C_{UI} = & Se^{-q(T-t)}N(x) - Ke^{-r(T-t)}N(x - \sigma\sqrt{T-t}) \\
 & + Re^{-r(T-t)}\left[N(-x_1 + \sigma\sqrt{T-t}) - \left(\frac{H}{S}\right)^{2\lambda-2}N(-y_1 + \sigma\sqrt{T-t})\right]
 \end{aligned}$$

- Si $K < H$:

$$\begin{aligned}
 C_{UI} = & Se^{-q(T-t)}N(x_1) - Ke^{-r(T-t)}N(x_1 - \sigma\sqrt{T-t}) \\
 & - Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(-y) + Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(-y + \sigma\sqrt{T-t}) \\
 & + Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(-y_1) - Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(-y_1 + \sigma\sqrt{T-t}) \\
 & + Re^{-r(T-t)}\left[N(-x_1 + \sigma\sqrt{T-t}) - \left(\frac{H}{S}\right)^{2\lambda-2}N(-y_1 + \sigma\sqrt{T-t})\right]
 \end{aligned}$$

4. Up-and-Out Call ($S < H$)

- Si $K > H$:

$$C_{UO} = R\left[\left(\frac{H}{S}\right)^{a+b}N(-z) + \left(\frac{H}{S}\right)^{a-b}N(-z + 2b\sigma\sqrt{T-t})\right]$$

- Si $K < H$:

$$\begin{aligned}
 C_{UO} = & Se^{-q(T-t)}N(x) - Ke^{-r(T-t)}N(x - \sigma\sqrt{T-t}) \\
 & - Se^{-q(T-t)}N(x_1) + Ke^{-r(T-t)}N(x_1 - \sigma\sqrt{T-t}) \\
 & + Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(-y) - Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(-y + \sigma\sqrt{T-t}) \\
 & - Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(-y_1) + Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(-y_1 + \sigma\sqrt{T-t}) \\
 & + R\left[\left(\frac{H}{S}\right)^{a+b}N(-z) + \left(\frac{H}{S}\right)^{a-b}N(-z + 2b\sigma\sqrt{T-t})\right]
 \end{aligned}$$

3.4.2. Opciones Put

Las fórmulas de las opciones Put se derivan de manera idéntica, alternando las regiones de integración para reflejar precios finales inferiores al strike K . En estas ecuaciones, evaluamos la distribución normal estándar $N(\cdot)$ en los valores negativos de x, y, x_1, y_1 .

5. Down-and-In Put ($S > H$)

- Si $K > H$:

$$\begin{aligned} P_{DI} = & -Se^{-q(T-t)}N(-x_1) + Ke^{-r(T-t)}N(-x_1 + \sigma\sqrt{T-t}) \\ & + Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(y) - Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(y - \sigma\sqrt{T-t}) \\ & - Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(y_1) + Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(y_1 - \sigma\sqrt{T-t}) \\ & + Re^{-r(T-t)}\left[N(x_1 - \sigma\sqrt{T-t}) - \left(\frac{H}{S}\right)^{2\lambda-2}N(y_1 - \sigma\sqrt{T-t})\right] \end{aligned}$$

- Si $K < H$:

$$\begin{aligned} P_{DI} = & -Se^{-q(T-t)}N(-x) + Ke^{-r(T-t)}N(-x + \sigma\sqrt{T-t}) \\ & + Re^{-r(T-t)}\left[N(x_1 - \sigma\sqrt{T-t}) - \left(\frac{H}{S}\right)^{2\lambda-2}N(y_1 - \sigma\sqrt{T-t})\right] \end{aligned}$$

6. Down-and-Out Put ($S > H$)

- Si $K > H$:

$$\begin{aligned} P_{DO} = & -Se^{-q(T-t)}N(-x) + Ke^{-r(T-t)}N(-x + \sigma\sqrt{T-t}) \\ & + Se^{-q(T-t)}N(-x_1) - Ke^{-r(T-t)}N(-x_1 + \sigma\sqrt{T-t}) \\ & - Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(y) + Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(y - \sigma\sqrt{T-t}) \\ & + Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(y_1) - Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(y_1 - \sigma\sqrt{T-t}) \\ & + R\left[\left(\frac{H}{S}\right)^{a+b}N(z) + \left(\frac{H}{S}\right)^{a-b}N(z - 2b\sigma\sqrt{T-t})\right] \end{aligned}$$

- Si $K < H$:

$$P_{DO} = R\left[\left(\frac{H}{S}\right)^{a+b}N(z) + \left(\frac{H}{S}\right)^{a-b}N(z - 2b\sigma\sqrt{T-t})\right]$$

7. Up-and-In Put ($S < H$)

- Si $K > H$:

$$\begin{aligned}
 P_{UI} = & -Se^{-q(T-t)}N(-x) + Ke^{-r(T-t)}N(-x + \sigma\sqrt{T-t}) \\
 & + Se^{-q(T-t)}N(-x_1) - Ke^{-r(T-t)}N(-x_1 + \sigma\sqrt{T-t}) \\
 & - Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(-y_1) + Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(-y_1 + \sigma\sqrt{T-t}) \\
 & + Re^{-r(T-t)}\left[N(-x_1 + \sigma\sqrt{T-t}) - \left(\frac{H}{S}\right)^{2\lambda-2}N(-y_1 + \sigma\sqrt{T-t})\right]
 \end{aligned}$$

- Si $K < H$:

$$\begin{aligned}
 P_{UI} = & -Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(-y) + Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(-y + \sigma\sqrt{T-t}) \\
 & + Re^{-r(T-t)}\left[N(-x_1 + \sigma\sqrt{T-t}) - \left(\frac{H}{S}\right)^{2\lambda-2}N(-y_1 + \sigma\sqrt{T-t})\right]
 \end{aligned}$$

8. Up-and-Out Put ($S < H$)

- Si $K > H$:

$$\begin{aligned}
 P_{UO} = & -Se^{-q(T-t)}N(-x_1) + Ke^{-r(T-t)}N(-x_1 + \sigma\sqrt{T-t}) \\
 & + Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(-y_1) - Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(-y_1 + \sigma\sqrt{T-t}) \\
 & + R\left[\left(\frac{H}{S}\right)^{a+b}N(-z) + \left(\frac{H}{S}\right)^{a-b}N(-z + 2b\sigma\sqrt{T-t})\right]
 \end{aligned}$$

- Si $K < H$:

$$\begin{aligned}
 P_{UO} = & -Se^{-q(T-t)}N(-x) + Ke^{-r(T-t)}N(-x + \sigma\sqrt{T-t}) \\
 & + Se^{-q(T-t)}\left(\frac{H}{S}\right)^{2\lambda}N(-y) - Ke^{-r(T-t)}\left(\frac{H}{S}\right)^{2\lambda-2}N(-y + \sigma\sqrt{T-t}) \\
 & + R\left[\left(\frac{H}{S}\right)^{a+b}N(-z) + \left(\frac{H}{S}\right)^{a-b}N(-z + 2b\sigma\sqrt{T-t})\right]
 \end{aligned}$$

3.5. Generalización del Modelo

Para compactar matemáticamente las 8 opciones y demostrar la elegancia de la formulación original de Reiner y Rubinstein, se pueden introducir dos variables indicadoras binarias:

- ϕ : toma el valor 1 para opciones Call y -1 para opciones Put.
- η : toma el valor 1 para opciones donde la barrera está por debajo del precio inicial (*Down*), y -1 para opciones donde la barrera está por encima (*Up*).

3.5.1. Términos Generalizados

Utilizando estas variables, los seis términos fundamentales presentados anteriormente se pueden reescribir de manera universal para cualquier tipo de opción barrera:

$$term_1 = \phi S e^{-q(T-t)} N(\phi x) - \phi K e^{-r(T-t)} N(\phi x - \phi \sigma \sqrt{T-t}) \quad (3.16)$$

$$term_2 = \phi S e^{-q(T-t)} N(\phi x_1) - \phi K e^{-r(T-t)} N(\phi x_1 - \phi \sigma \sqrt{T-t}) \quad (3.17)$$

$$term_3 = \phi S e^{-q(T-t)} \left(\frac{H}{S}\right)^{2\lambda} N(\eta y) - \phi K e^{-r(T-t)} \left(\frac{H}{S}\right)^{2\lambda-2} N(\eta y - \eta \sigma \sqrt{T-t}) \quad (3.18)$$

$$term_4 = \phi S e^{-q(T-t)} \left(\frac{H}{S}\right)^{2\lambda} N(\eta y_1) - \phi K e^{-r(T-t)} \left(\frac{H}{S}\right)^{2\lambda-2} N(\eta y_1 - \eta \sigma \sqrt{T-t}) \quad (3.19)$$

$$term_5 = R e^{-r(T-t)} \left[N(\eta x_1 - \eta \sigma \sqrt{T-t}) - \left(\frac{H}{S}\right)^{2\lambda-2} N(\eta y_1 - \eta \sigma \sqrt{T-t}) \right] \quad (3.20)$$

$$term_6 = R \left[\left(\frac{H}{S}\right)^{a+b} N(\eta z) + \left(\frac{H}{S}\right)^{a-b} N(\eta z - 2\eta b \sigma \sqrt{T-t}) \right] \quad (3.21)$$

3.5.2. Catálogo Simplificado

Finalmente, la prima de cualquiera de las 8 opciones barrera básicas se puede ensamblar directamente sumando y restando estos términos generales, dependiendo de la relación entre el precio de ejercicio K y la barrera H :

1. Down-and-In Call ($S > H$) $[\phi = 1, \eta = 1]$

- Si $K > H$: $C_{DI} = term_3 + term_5$
- Si $K < H$: $C_{DI} = term_1 - term_2 + term_4 + term_5$

2. Down-and-Out Call ($S > H$) $[\phi = 1, \eta = 1]$

- Si $K > H$: $C_{DO} = term_1 - term_3 + term_6$
- Si $K < H$: $C_{DO} = term_2 - term_4 + term_6$

3. Up-and-In Call ($S < H$) $[\phi = 1, \eta = -1]$

- Si $K > H$: $C_{UI} = term_1 + term_5$
- Si $K < H$: $C_{UI} = term_2 - term_3 + term_4 + term_5$

4. Up-and-Out Call ($S < H$) $[\phi = 1, \eta = -1]$

- Si $K > H$: $C_{UO} = term_6$
- Si $K < H$: $C_{UO} = term_1 - term_2 + term_3 - term_4 + term_6$

5. Down-and-In Put ($S > H$) $[\phi = -1, \eta = 1]$

- Si $K > H$: $P_{DI} = term_2 - term_3 + term_4 + term_5$
- Si $K < H$: $P_{DI} = term_1 + term_5$
- 6. Down-and-Out Put ($S > H$)** $[\phi = -1, \eta = 1]$
 - Si $K > H$: $P_{DO} = term_1 - term_2 + term_3 - term_4 + term_6$
 - Si $K < H$: $P_{DO} = term_6$
- 7. Up-and-In Put ($S < H$)** $[\phi = -1, \eta = -1]$
 - Si $K > H$: $P_{UI} = term_1 - term_2 + term_4 + term_5$
 - Si $K < H$: $P_{UI} = term_3 + term_5$
- 8. Up-and-Out Put ($S < H$)** $[\phi = -1, \eta = -1]$
 - Si $K > H$: $P_{UO} = term_2 - term_4 + term_6$
 - Si $K < H$: $P_{UO} = term_1 - term_3 + term_6$

Capítulo 4

Método 2: Modelo de Malla Adaptativa (AMM)

El Modelo de Malla Adaptativa (Adaptive Mesh Model, AMM), desarrollado por Figlewski y Gao (1999), representa un avance significativo en la valoración numérica de opciones. Este método permite aumentar la precisión en varios órdenes de magnitud sin incrementar sustancialmente el tiempo de ejecución, mediante el injerto de secciones de alta resolución sobre un árbol trinomial base en regiones críticas donde el valor de la opción es altamente no lineal.

En este capítulo explicaremos cómo el AMM resuelve los problemas fundamentales de discretización. Priorizaremos el análisis de las opciones barrera, abordando el comportamiento problemático que ocurre cerca de la barrera en cualquier momento del tiempo. Adicionalmente, mostraremos cómo el método soluciona los problemas al momento del vencimiento (típicos de las opciones vanilla) y los problemas cerca del precio inicial S_0 (críticos para el cálculo de griegas). Si bien algunos problemas históricos fueron identificados en modelos binomiales, el AMM se implementa y opera inherentemente sobre árboles trinomiales, por lo que centraremos toda nuestra exposición matemática en esta estructura para evitar confusiones.

4.1. El Problema de la Discretización en Opciones Barrera

La aplicación directa de modelos trinomiales estándar a la valoración de opciones barrera enfrenta un desafío fundamental que no aparece en opciones vanilla: el problema de la alineación de nodos con la barrera. Este problema fue identificado y abordado sistemáticamente en el trabajo seminal de Boyle y Lau (1994), donde propusieron una solución ingeniosa pero con limitaciones importantes que motivarían desarrollos posteriores.

En un árbol trinomial estándar, los nodos se distribuyen en capas horizontales correspondientes a diferentes niveles de precio del activo subyacente. El espaciamiento vertical entre estas capas está determinado por los factores de movimiento u (hacia arriba) y d (hacia abajo), que a su vez dependen de la volatilidad σ y del número de pasos temporales n . El problema surge porque

la barrera H , que es un parámetro fijo del contrato, raramente coincide exactamente con alguna de estas capas de nodos. En la mayoría de los casos, H cae entre dos capas horizontales, lo que genera una ambigüedad fundamental, ¿en qué momento exactamente se considera que la barrera ha sido tocada? Esta desalineación produce estimaciones sesgadas del valor de la opción y una convergencia notablemente lenta hacia el valor teórico, con errores que persisten incluso cuando se aumenta significativamente el número de pasos.

Boyle y Lau resolvieron este problema mediante una técnica que denominaron “bumping the barrier”. La idea central no es hacer coincidir un nodo exactamente sobre H , sino elegir el número de pasos n de manera que una capa horizontal de nodos quede inmediatamente más allá de la barrera (*just beyond the barrier*) y lo más cerca posible de ella. Para seleccionar n óptimo, los autores proponen evaluar la función:

$$F(m) = \frac{m^2 \sigma^2 T}{(\ln(S_0/H))^2} \quad (4.1)$$

El valor óptimo de n es el mayor entero por debajo de $F(m)$ que satisface las condiciones de alineación para algún entero m . Con esta elección, el nodo más cercano a H queda suficientemente próximo como para minimizar el sesgo sin requerir un número de pasos prohibitivo. Es importante notar que en el **Modelo Trinomial Restringido (RTM)** se fuerza la coincidencia exacta de los nodos sobre la barrera. Esta distinción es relevante porque el RTM hereda directamente las limitaciones que se describen a continuación. Al reducir la distancia nodo-barrera, ambos métodos mejoran dramáticamente la precisión frente al trinomial estándar, eliminando el sesgo sistemático y acelerando la convergencia.

Sin embargo, el método de Boyle y Lau tiene una limitación crítica conocida como el “problema del límite” (boundary problem). Cuando el precio inicial del activo S_0 está muy cerca de la barrera H , la condición de alineación requiere que el tamaño del paso de precio h sea extremadamente pequeño para que al menos un nodo caiga exactamente sobre H . Esto se traduce en la necesidad de un número de pasos n prohibitivamente grande. Por ejemplo, si S_0 está a solo 1/8 de punto de distancia de la barrera, el método puede requerir miles o incluso decenas de miles de pasos temporales para lograr la alineación, haciendo el cálculo computacionalmente inmanejable. Esta limitación es particularmente problemática en la práctica, ya que las opciones barrera son frecuentemente negociadas precisamente en situaciones donde el precio del subyacente está cerca de la barrera, momento en el cual la valoración precisa es más crítica. Es precisamente esta limitación del método de Boyle y Lau la que motivó el desarrollo del Modelo de Malla Adaptativa (AMM) de Figlewski y Gao, que abordaremos en la siguiente sección. El AMM ofrece una solución elegante al problema del límite mediante el uso de mallas de resolución variable, permitiendo valoraciones precisas incluso cuando S_0 y H están arbitrariamente cerca.

4.2. Fundamentos: Árboles Binomiales y Trinomiales

Los modelos de árbol discretizan la evolución del precio del activo subyacente en pasos temporales finitos. En cada nodo del árbol, el precio puede moverse

hacia un número limitado de estados futuros, y la valoración de la opción se obtiene retrocediendo desde el vencimiento hasta el presente. Existen dos variantes principales: el árbol binomial y el árbol trinomial. Si bien el AMM se construye exclusivamente sobre árboles trinomiales, es importante comprender ambas estructuras porque mucha de la literatura fundacional sobre valoración de opciones con barreras (como el trabajo de Boyle y Lau) se desarrolló en el contexto binomial.

4.2.1. Árbol Binomial

En un árbol binomial, desde cada nodo con precio S , el precio en el siguiente paso temporal solo puede tomar dos valores:

- $S \cdot u$ con probabilidad p (movimiento hacia arriba)
- $S \cdot d$ con probabilidad $1 - p$ (movimiento hacia abajo)

donde $u > 1$ y $0 < d < u$ son los factores de movimiento. En el modelo clásico de Cox, Ross y Rubinstein (CRR), estos se calibran como:

$$u = e^{\sigma\sqrt{\Delta t}} \quad (4.2)$$

$$d = e^{-\sigma\sqrt{\Delta t}} = \frac{1}{u} \quad (4.3)$$

y la probabilidad neutral al riesgo es:

$$p = \frac{e^{(r-\delta)\Delta t} - d}{u - d} \quad (4.4)$$

En un árbol binomial, la valoración procede por inducción hacia atrás de forma análoga al trinomial, pero con solo dos ramas. Se parte de los valores terminales en T (el payoff de la opción) y se retrocede nodo a nodo calculando $V(S, t) = e^{-r\Delta t}[p \cdot V(Su, t + \Delta t) + (1 - p) \cdot V(Sd, t + \Delta t)]$. El árbol binomial tiene la ventaja de su simplicidad, pero su resolución más gruesa (dos estados por nodo en lugar de tres) lo hace más susceptible al error de no linealidad, manifestándose en la conocida oscilación “par-impar” de la convergencia.

4.2.2. Árbol Trinomial

En cada nodo del árbol con precio S , el precio en el siguiente paso temporal puede ser:

- $S \cdot u$ con probabilidad p_u (movimiento hacia arriba)
- $S \cdot m$ con probabilidad p_m (movimiento medio, típicamente $m = 1$)
- $S \cdot d$ con probabilidad p_d (movimiento hacia abajo)

4.2. FUNDAMENTOS: ÁRBOLES BINOMIALES Y TRINOMIALES

donde $0 < d < u$ son los factores de movimiento.

A diferencia de las parametrizaciones clásicas (como la de Cox, Ross y Rubinstein), el AMM construye el árbol en el espacio logarítmico $X = \ln(S)$ y define las probabilidades directamente en función del paso espacial h , el paso temporal k , la volatilidad σ y el drift $a = r - q - \sigma^2/2$. Las probabilidades neutrales al riesgo que exige el modelo de (Figlewski y Gao, 1999) son:

$$p_u = \frac{1}{2} \left(\frac{\sigma^2 k}{h^2} + \frac{a^2 k^2}{h^2} + \frac{ak}{h} \right) \quad (4.5)$$

$$p_d = \frac{1}{2} \left(\frac{\sigma^2 k}{h^2} + \frac{a^2 k^2}{h^2} - \frac{ak}{h} \right) \quad (4.6)$$

$$p_m = 1 - p_u - p_d \quad (4.7)$$

El término $\sigma^2 k/h^2$ controla la difusión, mientras que ak/h introduce la componente de drift. El término cuadrático $a^2 k^2/h^2$ es habitualmente pequeño pero garantiza que las probabilidades sean consistentes con el proceso lognormal en los dos primeros momentos.

La valoración procede mediante inducción hacia atrás (backward induction), calculando en cada nodo:

$$V(X, t) = e^{-rk} [p_u V(X+h, t+k) + p_m V(X, t+k) + p_d V(X-h, t+k)] \quad (4.8)$$

donde $V(X, t)$ es el valor de la opción en el tiempo t si el precio del activo es X .

La inducción hacia atrás (backward induction) es el procedimiento algorítmico fundamental para valorar opciones mediante modelos de árbol binomial o trinomial. A diferencia de la simulación de Monte Carlo, que avanza hacia adelante en el tiempo generando trayectorias desde el presente hacia el futuro, los métodos de árbol trabajan en dirección temporal inversa. El proceso comienza en el vencimiento T , donde el valor de la opción es conocido con certeza: es simplemente el payoff terminal, por ejemplo $\max(S_T - K, 0)$ para una opción call europea. Desde este punto de partida, el algoritmo retrocede paso a paso hacia el tiempo inicial, calculando en cada nodo el valor de la opción como el valor esperado descontado de los valores en los nodos hijos (futuros). Matemáticamente, en un árbol trinomial, el valor en un nodo con precio S en el tiempo t se calcula como $V(S, t) = e^{-r\Delta t} [p_u V(Su, t+\Delta t) + p_m V(S, t+\Delta t) + p_d V(Sd, t+\Delta t)]$, donde p_u , p_m y p_d son las probabilidades neutrales al riesgo de movimiento hacia arriba, medio y abajo respectivamente y Δt es el tamaño del paso temporal. Este proceso de retroceso continúa hasta alcanzar el nodo raíz en $t = 0$ con precio S_0 , cuyo valor calculado es precisamente el precio justo de la opción. Para opciones americanas, el algoritmo se modifica ligeramente: en cada nodo se toma el máximo entre el valor de continuación (calculado como antes) y el valor de ejercicio inmediato, reflejando la decisión óptima del tenedor de la opción.




Figura 4.1: Estructura de un árbol trinomial con 3 pasos temporales. Desde cada nodo, el precio puede moverse hacia arriba (multiplicado por $u = 1,15$, verde), mantenerse (multiplicado por $m = 1$, azul), o bajar (multiplicado por $d = 1/u \approx 0,870$, rojo). Las probabilidades neutrales al riesgo son $p_u = 0,25$, $p_m = 0,50$, $p_d = 0,25$. El árbol es recombinante: los nodos que alcanzan el mismo precio se fusionan.

4.3. Análisis de Errores en Árboles Trinomiales

Figlewski y Gao identifican dos fuentes principales de error en los métodos de redes. Aunque el AMM se construye sobre árboles trinomiales para superarlos, es vital comprender su origen.

4.3.1. Error de Distribución

Surge porque el modelo intenta aproximar una distribución lognormal continua con una distribución discreta (trinomial). La calibración del árbol iguala la

media y la varianza del proceso continuo, pero los momentos de orden superior (asimetría, curtosis, etc.) quedan aproximados de forma imperfecta. Esta discrepancia se reduce suavemente a medida que aumenta el número de pasos, ya que el resultado acumulado de muchos pasos trinomiales converge a la distribución lognormal correcta (por el Teorema Central del Límite).

4.3.2. Error de No Linealidad

Este es el error más crítico y ocurre cuando el valor de la opción es altamente no lineal respecto al precio del activo subyacente (es decir, donde la curvatura de $V(S)$ es pronunciada). En estas regiones, una malla estándar es insuficiente. El AMM se enfoca específicamente en minimizar este error, el cual podemos separar en tres categorías principales, ordenadas por su relevancia para este trabajo:

1. Problemas cerca de la barrera en cualquier momento del tiempo

Para las opciones barrera, la no linealidad ocurre durante toda la vida de la opción siempre que el precio se acerca a la barrera H . La probabilidad de tocar la barrera salta discretamente dependiendo de la disposición de los nodos, causando una convergencia “dentada”. Además, cuando S_0 está extremadamente cerca de H , el modelo sufre del “problema del límite”, requiriendo un número intratable de pasos temporales para alinear la red.

2. Problemas al momento del vencimiento (Opciones Vanilla)

Para las opciones estándar (vanilla), la mayor no linealidad ocurre exclusivamente al vencimiento T , alrededor del precio de ejercicio K . El pago de la opción tiene un punto de quiebre brusco. En modelos de redes, esto produce oscilaciones en el error de valoración (históricamente conocido en modelos binomiales como convergencia “par-impar”) porque la alineación de los nodos finales con el strike K cambia drásticamente según la cantidad de pasos elegidos.

3. Problemas cerca de S_0 (Cálculo de Griegas)

Al estimar las griegas como Delta (Δ) y Gamma (Γ), se requieren pequeñas perturbaciones del precio inicial S_0 . En un árbol trinomial estándar, el tamaño del paso h suele ser demasiado grande para calcular derivadas numéricas precisas, lo que introduce un enorme ruido e inestabilidad en la estimación de las sensibilidades.




Figura 4.2: Ejemplo de convergencia inestable causada por el error de no linealidad. Históricamente, el efecto “par-impar” en modelos binomiales demostraba cómo la falta de alineación de los nodos finales generaba oscilaciones. El AMM elimina completamente estos problemas de no linealidad en las estructuras trinomiales.

4.4. Principio del Modelo de Malla Adaptativa

El principio fundamental que sustenta el Modelo de Malla Adaptativa es una observación simple pero poderosa sobre la naturaleza del error numérico en la valoración de opciones: no todas las regiones del espacio precio-tiempo contribuyen igualmente al error total. En un árbol trinomial estándar, se utiliza una resolución uniforme en todo el dominio computacional, dedicando el mismo esfuerzo de cálculo a regiones donde el valor de la opción varía suavemente que a regiones donde presenta alta no linealidad. Este enfoque es ineficiente, desperdiciando poder computacional en áreas donde una red gruesa sería suficiente mientras que proporciona resolución insuficiente en las zonas críticas. El AMM actúa como una técnica de refinamiento selectivo: mantiene una red gruesa con pasos de precio h (en log-espacio, como se detalla a continuación) y pasos de tiempo k para la mayor parte del árbol, pero injerta una red fina con pasos reducidos (típicamente $h/2$ para el precio y $k/4$ para el tiempo) exclusivamente en las regiones de alta no linealidad. Al concentrar la resolución computacional precisamente donde más se necesita, el AMM logra precisión comparable a un

árbol uniforme extremadamente fino pero con una fracción mínima del costo computacional, típicamente menos del 1 % de nodos adicionales.

4.4.1. Arquitectura en el Espacio de Logaritmos

Un aspecto crucial del diseño del AMM es que la malla no se construye utilizando los precios absolutos del activo (S), sino sobre el espacio de los logaritmos de los precios ($X = \ln(S)$). Al transformar la variable subyacente, la geometría del árbol cambia de multiplicativa a aditiva. En el espacio logarítmico, los pasos de precio se vuelven simétricos y constantes: un movimiento hacia arriba equivale a sumar $+h$ y un movimiento hacia abajo equivale a restar $-h$ (siendo $h = \sigma\sqrt{3k}$ en un trinomial estándar).

Esta construcción es la **clave geométrica** que hace posible el injerto de mallas de distinta resolución. Gracias a la simetría aditiva, los nodos de una malla fina (con saltos de $+h/2$ y $-h/2$) coinciden de manera exacta con los nodos de la malla gruesa en todos los puntos de contacto. Cada segundo nodo fino cae precisamente sobre un nodo grueso, permitiendo el acople perfecto de ambas resoluciones sin introducir desalineaciones geométricas ni vacíos en las transiciones de estado. Si el árbol se construyera directamente sobre los precios (S), los pasos serían multiplicativos ($S \cdot u$ y $S \cdot d$) y esta propiedad de encaje perfecto se perdería, ya que el paso absoluto de precio varía según el nivel.

4.4.2. Operación y Valoración sobre la Malla Adaptativa

A nivel operativo, el AMM no es simplemente una superposición gráfica, sino un proceso riguroso de transferencia de información mediante inducción hacia atrás (*backward induction*). Antes de describir los pasos del algoritmo, es necesario comprender un desafío conceptual clave: dado que la malla fina avanza en pasos de tiempo más pequeños ($k/4$) que la malla gruesa (k), existirán **nodos intermedios** o “**nodos colgantes**” (*hanging nodes*) ubicados en los instantes $t + k/4$, $t + 2k/4$ y $t + 3k/4$ que no tienen un nodo correspondiente en la malla gruesa en ese mismo momento temporal. Estos nodos requieren un tratamiento especial en la interfaz entre ambas mallas, como se detalla a continuación.

El procedimiento de valoración se divide en tres fases:

1. **Valoración en la Malla Gruesa:** El proceso inicia calculando los valores de la opción sobre la malla gruesa estándar, ignorando temporalmente la zona refinada. Esto genera una matriz base de valores aproximados con resolución h y k .
2. **Gestión de la Interfaz (Nodos Colgantes):** Los nodos ubicados en los límites de la malla fina (nodos de interfaz) actúan como puentes de información. Para los nodos colgantes, que caen en instantes intermedios donde no existen nodos gruesos, la conexión se logra utilizando un **paso de tiempo efectivo** (Δt_{ef}) que cubre la distancia temporal exacta restante hasta la siguiente columna de nodos de la malla gruesa. Por ejemplo, un nodo colgante en $t + k/4$ se proyecta hacia los nodos gruesos en $t + k$ usando $\Delta t_{\text{ef}} = 3k/4$; uno en $t + 2k/4$ usa $\Delta t_{\text{ef}} = 2k/4$, y así sucesivamente. Las probabilidades de transición se recalculan con este Δt_{ef} , y el valor del nodo se obtiene descontando con $e^{-r \cdot \Delta t_{\text{ef}}}$. Este mecanismo inyecta la información de la malla gruesa hacia el interior del parche fino.

4.4. PRINCIPIO DEL MODELO DE MALLA ADAPTATIVA

3. **Inducción en la Malla Fina:** Con las condiciones de borde establecidas en los nodos de interfaz, el algoritmo ejecuta la inducción hacia atrás exclusivamente por el interior de la malla fina. Utilizando pasos reducidos ($k/4$ y $h/2$), atraviesa la región crítica modelando con alta fidelidad las áreas donde el valor cambia abruptamente (como la cercanía a una barrera o a un strike). El resultado de la valoración se extrae siempre del nodo inicial de la malla fina ($t = 0$).




Figura 4.3: Concepto del Modelo de Malla Adaptativa (AMM). Se muestra un árbol trinomial base (nodos grises) que constituye la malla gruesa. Sobre este se injerta una malla fina (cuadrados verdes) con pasos reducidos en la región crítica. La operación transfiere los valores del árbol grueso hacia los bordes del árbol fino, para luego resolver la valoración internamente.

4.5. AMM para Opciones Barrera

Las opciones barrera presentan un desafío particular: el error de no linealidad ocurre en cada punto del tiempo cuando el precio se acerca a la barrera H , no solo al vencimiento.

4.5.1. El Problema de Convergencia “Dentada”

La convergencia en modelos estándar es “dentada” porque la barrera continua H debe ser reemplazada por una barrera efectiva en el nodo más cercano del árbol. Por ejemplo, si $H = 90$ pero los nodos adyacentes se ubican en $S = 88$ y $S = 93$, el modelo debe elegir uno de ellos como barrera efectiva: si usa 93, la opción recibe “espacio extra” antes del knockout y su valor se sobreestima. Si usa 88, el knockout ocurre prematuramente y el valor se subestima. La magnitud de este error depende de cuán cerca caiga el nodo más cercano de H , lo cual cambia erráticamente al variar n (y por tanto h): para ciertos valores de n un nodo cae casi exactamente sobre H (error pequeño), mientras que para otros la distancia es máxima (error grande). Este comportamiento produce los saltos irregulares característicos de la convergencia “dentada”.

4.5.2. El Problema del Límite

Cuando el precio inicial S_0 está muy cerca de la barrera H , surge un problema adicional. Para que el árbol pueda aplicar correctamente la condición de knockout, necesita al menos un nodo entre S_0 y H que le permita distinguir entre “estar cerca de la barrera” y “haber cruzado la barrera”. En el espacio logarítmico, esto requiere que el paso h sea menor que la distancia entre ambos puntos:

$$h < |\ln(S_0) - \ln(H)| \quad (4.9)$$

Si S_0 está extremadamente cerca de H (por ejemplo, $S_0 = 100$ y $H = 99,90$, donde $|\ln(100) - \ln(99,90)| \approx 0,001$), se necesita un h tan pequeño que obliga a usar miles de pasos de tiempo, haciendo el cálculo inmanejable.

4.5.3. Estructura AMM para Barreras

La solución que propone el AMM consiste en concentrar la resolución numérica precisamente donde el modelo estándar falla: en la vecindad inmediata de la barrera H . Para lograrlo, se injerta una malla fina sobre el árbol grueso base, pero el diseño de esta malla es fundamentalmente diferente al caso de las opciones vanilla.

En las opciones vanilla, la malla fina solo es necesaria en la última columna temporal (cerca del vencimiento T), porque allí es donde ocurre la no linealidad del payoff. En las opciones barrera, en cambio, la condición de knockout puede activarse en *cualquier* instante de la vida de la opción: si el precio cruza H en $t = 0,1T$ o en $t = 0,9T$, el contrato se anula igualmente. Por esta razón, la malla fina debe extenderse a lo largo de **toda la dimensión temporal**, no solo cerca del vencimiento.

En cuanto a la dimensión espacial, la malla fina no se construye simétricamente alrededor de H como si fuera un punto de interés neutral. La barrera es un límite absorbente, es decir, una vez que el precio la cruza, la opción muere

y no tiene sentido modelar la dinámica del precio en esa región. Por tanto, la malla fina se extiende exclusivamente del **lado activo** de la barrera, es decir, del lado donde la opción aún tiene valor. Para una opción down-and-out, ese lado es el que está por encima de H por lo que la malla cubre desde $\ln(H)$ hasta $\ln(H) + h$ en el espacio logarítmico (un paso grueso hacia arriba). Los nodos ubicados exactamente sobre la barrera reciben automáticamente el valor de cero (o del rebate R si lo hubiera), actuando como condición de borde inferior permanente de la malla fina.

Dirección del flujo de información. A diferencia del AMM para opciones vanilla (donde la malla fina es autosuficiente en su región y la información fluye “hacia adentro” del parche), en las opciones barrera la dirección del flujo es descendente: **la malla gruesa actúa como el marco global que “inyecta” las condiciones de borde hacia el parche de alta resolución.** El razonamiento es el siguiente: cuando S_0 está muy cerca de H , la malla gruesa es demasiado tosca para resolver correctamente la probabilidad de cruce en la vecindad de la barrera. Sin embargo, sí captura con suficiente precisión el comportamiento de la opción en nodos alejados de H , donde el valor varía suavemente. Esos valores de la malla gruesa se transfieren a los nodos de interfaz de la malla fina (mediante el mecanismo de nodos colgantes y Δt_{ef} descrito en la Sección 4.4), estableciendo las condiciones de borde que necesita la malla fina para ejecutar su propia inducción hacia atrás con alta resolución. Es en esa inducción interna donde el modelo detecta con precisión quirúrgica los cruces de barrera que la malla gruesa no podía resolver.




Figura 4.4: Estructura del AMM para opciones barrera. Se ilustra el árbol trinomial base con una banda vertical de malla fina a lo largo de toda la dimensión temporal. La malla fina se construye exclusivamente del lado activo de la barrera: para una opción down-and-out, la banda de refinamiento cubre el intervalo $[\ln(H), \ln(H) + h]$ en el espacio logarítmico, es decir, desde la barrera H hasta el primer nodo grueso por encima de ella. Se muestra el precio inicial S_0 cerca de H para evidenciar la solución al problema del límite. Las flechas indican el flujo de información (condiciones de borde) que se transfiere desde la malla gruesa hacia la malla fina para la valoración.

4.5.4. Manejo de la Barrera

Una vez construida la malla fina alrededor de H , el modelo aplica las condiciones del contrato directamente sobre sus nodos. El mecanismo concreto depende del tipo de opción barrera.

Para una **opción knock-out**, el contrato estipula que si el precio del activo toca o cruza la barrera H en algún momento, la opción queda inmediatamente

cancelada. En el árbol, esto se implementa forzando el valor de cualquier nodo ubicado sobre la barrera a ser igual al rebate R (que típicamente es cero, aunque algunos contratos establecen un pago compensatorio). Gracias a la malla fina, este chequeo se realiza en incrementos de precio muy pequeños ($h/2$ en lugar de h), lo que reduce drásticamente la probabilidad de que el árbol “salte” sobre la barrera sin detectarla. En la malla gruesa, un paso de precio de h podía ser tan grande que el precio pasaba de un nodo claramente por encima de H a otro claramente por debajo en un solo salto, sin que ningún nodo intermedio cayera sobre la barrera. La malla fina elimina este problema al ofrecer una resolución suficiente para capturar el cruce.

Para una **opción knock-in**, el contrato funciona al revés: la opción solo se activa si el precio toca la barrera en algún momento; si nunca la toca, el contrato vence sin valor. Valorar directamente las trayectorias que sí tocan la barrera es más complejo, pero existe una relación de paridad entre opciones barrera que simplifica el cálculo. Dado que toda trayectoria o bien toca la barrera (knock-in) o bien no la toca (knock-out), la suma de ambas debe equivaler al valor de una opción vanilla estándar sin restricciones de barrera:

$$V_{\text{vanilla}} = V_{\text{KI}} + V_{\text{KO}} \quad (4.10)$$

Despejando, el precio de la knock-in se obtiene como:

$$V_{\text{KI}} = V_{\text{vanilla}} - V_{\text{KO}} \quad (4.11)$$

Esto permite valorar la knock-in sin modificar el algoritmo del AMM: basta con calcular primero la knock-out mediante el procedimiento descrito y luego restarle su valor al de la vanilla (que se calcula, por ejemplo, analíticamente con las fórmulas de Black-Scholes).

4.5.5. Eficiencia Computacional

El verdadero test de un método numérico no es solo su precisión sino su relación entre precisión y costo computacional. En el contexto de las opciones barrera, el método de referencia natural para comparar es el **Modelo Trinomial Restringido (RTM)**, que es precisamente la técnica de Boyle y Lau descrita al inicio de este capítulo, un árbol trinomial estándar donde se elige el número de pasos n de manera que los nodos queden alineados con la barrera. La palabra “restringido” alude a esa restricción sobre n .

El problema del RTM es que cuando S_0 está muy cerca de H , la condición de alineación fuerza a elegir valores de n prohibitivamente grandes. En ese escenario, el costo computacional del RTM crece de manera desproporcionada (potencialmente en varios órdenes de magnitud) para lograr una precisión aceptable. El AMM resuelve este problema con una arquitectura completamente diferente, en lugar de aumentar la resolución de todo el árbol, concentra los nodos adicionales únicamente en la vecindad de H , manteniendo el árbol grueso para el resto del dominio. El resultado es que el número total de nodos adicionales requeridos es mínimo, y la ventaja computacional frente al RTM es especialmente pronunciada precisamente cuando $S_0 \approx H$, que es la situación de mayor interés práctico. Esta mejora en eficiencia fue documentada por Figlewski y Gao (1999) en el artículo original del método.

4.6. AMM para Opciones Vanilla

Aunque el enfoque principal de este trabajo recae sobre las opciones barrera, las siguientes secciones (4.6 y 4.7) ilustran el Modelo de Malla Adaptativa utilizando opciones estándar (vanilla) como caso de estudio. Esta separación temporal del problema de la barrera se realiza con un fin didáctico, para explicar de forma aislada las arquitecturas específicas desarrolladas para resolver la no linealidad alrededor del precio de ejercicio al vencimiento y el cálculo numérico de las griegas en el instante inicial $t = 0$. No obstante, es fundamental destacar que la arquitectura del AMM es inherentemente modular y flexible. Las técnicas que se exponen a continuación, como el refinamiento focalizado en el strike y la ramificación cuadrinomial, son totalmente complementarias y pueden superponerse de forma natural a la estructura de banda continua desarrollada para opciones barrera en la Sección 4.5. Esta modularidad permite combinar distintas mallas en un mismo árbol para obtener, por ejemplo, griegas de alta precisión en opciones barrera sin arrastrar errores de discretización en el precio.

Para opciones europeas o americanas estándar, la mayor no linealidad ocurre alrededor del precio de ejercicio K al vencimiento T .

4.6.1. Estructura

Se añade una malla fina con pasos de precio $h/2$ y tiempo $k/4$ solo en la región:

- **Temporal:** El último paso del árbol grueso, entre $T - k$ y T .
- **Espacial:** La banda alrededor del strike K , anclada a los dos nodos de la malla gruesa que encierran a K (es decir, $X_K^- \leq \ln(K) < X_K^+$), más cuatro pasos finos adicionales hacia cada lado ($4 \times h/2 = 2h$). En notación aproximada esto corresponde al intervalo $[K - 2h, K + 2h]$, garantizando que toda la región de no linealidad quede cubierta independientemente de dónde caiga K respecto a la grilla.




Figura 4.5: Estructura del AMM para opciones vanilla. Se muestra un árbol trinomial (nodos grises con conexiones grises) que constituye la malla gruesa. Sobre este árbol se injerta una malla fina (cuadrados verdes pequeños) con pasos $h/2$ y $k/4$ únicamente en la región crítica (rectángulo amarillo): temporal $[T-k, T]$ y espacial $[K-2h, K+2h]$. La línea azul punteada marca el strike K donde ocurre la mayor no linealidad al vencimiento. Esta estrategia concentra la resolución donde más se necesita: alrededor del precio de ejercicio al vencimiento.

4.6.2. Eficiencia

En un árbol trinomial de 100 pasos, añadir un nivel de AMM aumenta los cálculos en menos del 0,4%. Un segundo nivel de refinamiento (AMM-2, con pasos $h/4$ y $k/16$) añade menos del 0,4% adicional.

4.6.3. Rendimiento

Según Figlewski y Gao, un modelo AMM-2 con solo 25 pasos de tiempo es más preciso que:

4.7. AMM PARA EL CÁLCULO DE GRIEGAS

- Un modelo trinomial estándar de 250 pasos
- Un modelo binomial de 1000 pasos (que requiere 250 veces más tiempo de ejecución)

La Tabla 4.1 resume los resultados del análisis de Figlewski y Gao para un conjunto de prueba de 27 opciones put europeas, comparando la Raíz del Error Cuadrático Medio (RMSE) en precio y griegas:

Modelo	Pasos (N)	Nodos	Tiempo (s)	RMSE		
				Precio	Delta	Gamma
Binomial	25	351	0.0060	0.020841	0.005805	0.001594
Trinomial	25	676	0.0090	0.012025	0.003337	0.000428
AMM-1	25	716	0.0117	0.002812	0.003345	0.000539
AMM-2	25	756	0.0121	0.000615	0.003359	0.000548
Binomial	100	5,151	0.0451	0.004929	0.001470	0.000197
Trinomial	100	10,201	0.0941	0.002770	0.000846	0.000144
AMM-1	100	10,241	0.0961	0.000600	0.000845	0.000140
AMM-2	100	10,281	0.0982	0.000151	0.000854	0.000138
Binomial	250	31,626	0.2163	0.002214	0.000534	0.000073
Trinomial	250	63,001	0.5407	0.001360	0.000346	0.000061
AMM-1	250	63,041	0.5418	0.000245	0.000334	0.000056
AMM-2	250	63,081	0.5428	0.000057	0.000342	0.000056
Binomial	1000	501,501	3.0674	0.000448	0.000145	0.000020
Trinomial	1000	1,002,001	8.5623	0.000244	0.000079	0.000015
AMM-1	1000	1,002,041	8.5954	0.000056	0.000086	0.000014
AMM-2	1000	1,002,081	8.5854	0.000016	0.000085	0.000014

Tabla 4.1: Comparación detallada de rendimiento y precisión para valoración de opciones y cálculo de griegas. El AMM logra errores significativamente menores en precio, Delta y Gamma con un incremento mínimo en tiempo de ejecución (¡3 % vs trinomial estándar) y número de nodos (¡0.1 % adicional). Datos de Figlewski y Gao (1999).

4.7. AMM para el Cálculo de Griegas

Las griegas Delta (Δ) y Gamma (Γ) miden la sensibilidad del precio de la opción ante cambios en el precio del activo subyacente. Numéricamente, se calculan como derivadas aproximadas: se evalúa el modelo en dos (o tres) precios iniciales levemente distintos y se estima la pendiente (o curvatura) de la función de valor. A este procedimiento se lo llama **perturbación** y por lo general se “perturba” el precio inicial S_0 en una cantidad pequeña ϵ hacia arriba y hacia abajo, se obtiene el valor de la opción en cada caso, y luego se aplica la fórmula de diferencias finitas.

El problema es que en un árbol trinomial estándar la perturbación más chica posible es $\epsilon = h$ (un paso completo de precio), porque los únicos nodos disponibles en $t = 0$ son S_0 , $S_0 \cdot u$ y $S_0 \cdot d$. En el espacio logarítmico, eso equivale a $\epsilon = h = \sigma\sqrt{3k}$, que para parámetros típicos puede ser del orden del 5 % o más del precio. Una perturbación tan grande introduce un error enorme

en la estimación de la derivada, especialmente en regiones de alta curvatura (Gamma elevada).

4.7.1. Extensión del Árbol

Una técnica estándar para obtener tres puntos de valoración consiste en extender el árbol un paso temporal hacia atrás desde $t = 0$, añadiendo un nodo “raíz” en $t = -k$ del cual brotan los nodos $S_0 \cdot u$, S_0 y $S_0 \cdot d$ en $t = 0$. Esto provee tres valores de opción con una perturbación de tamaño h , pero como se señaló, ese tamaño suele ser demasiado grande para estimar derivadas con precisión.

4.7.2. Ramificación Cuadrinomial

Para calcular las griegas con mayor precisión, el AMM permite usar perturbaciones más pequeñas que h . La idea es añadir en $t = 0$ dos nodos auxiliares ubicados en $X_0 \pm \epsilon$, donde $X_0 = \ln(S_0)$ es el log-precio inicial y $\epsilon < h$ es la perturbación (por ejemplo, $\epsilon = h/2$ o $\epsilon = h/4$). En el espacio de precios, esos nodos corresponden a $S_0 e^{+\epsilon}$ y $S_0 e^{-\epsilon}$: valores apenas por encima y por debajo de S_0 .

El desafío de añadir estos nodos en posiciones no estándar es que no forman parte de la malla del árbol, por lo que sus vecinos no coinciden exactamente con los nodos ya existentes. Para resolverlo sin generar probabilidades de transición negativas, el AMM emplea una **ramificación cuadrinomial**: desde cada nodo perturbado en $t = 0$, el precio puede moverse a **cuatro** nodos en lugar de los tres habituales del trinomial. El destino temporal depende del nivel de refinamiento aplicado:

- **Primer nivel AMM** ($\epsilon = h/2$): los nodos perturbados en $X_0 \pm h/2$ ramifican directamente hacia los nodos de la malla gruesa en $t = k$. La cuarta rama permite alcanzar nodos que caen fuera de las tres posiciones trinomiales estándar.
- **Segundo nivel AMM** ($\epsilon = h/4$): los nodos perturbados en $X_0 \pm h/4$ ramifican hacia los nodos de la malla fina en $t = k/4$, aprovechando la resolución adicional del primer nivel de refinamiento.

En ambos casos, los destinos están espaciados de modo que se solapan exactamente con la malla existente, garantizando probabilidades válidas y no negativas.

Con los valores de la opción en $X_0 + \epsilon$ y $X_0 - \epsilon$ obtenidos de esta manera, se calculan las diferencias finitas en log-espacio. Como el árbol vive en el espacio logarítmico, al convertir estas diferencias a sensibilidades respecto al precio S se debe aplicar la regla de la cadena. Definiendo:

$$V'_X = \frac{V(X_0 + \epsilon) - V(X_0 - \epsilon)}{2\epsilon} \quad (4.12)$$

$$V''_X = \frac{V(X_0 + \epsilon) - 2V(X_0) + V(X_0 - \epsilon)}{\epsilon^2} \quad (4.13)$$

las griegas respecto a S se obtienen como:

4.7. AMM PARA EL CÁLCULO DE GRIEGAS

$$\Delta = \frac{\partial V}{\partial S} = \frac{1}{S_0} V'_X \quad (4.14)$$

$$\Gamma = \frac{\partial^2 V}{\partial S^2} = \frac{1}{S_0^2} (V''_X - V'_X) \quad (4.15)$$

con $\epsilon = h/2$ o incluso $\epsilon = h/4$. Es fundamental no confundir ϵ (un incremento en log-espacio) con un incremento directo en el precio, ya que mezclar ambas escalas introduciría errores graves de escalado en la estimación.




Figura 4.6: Ramificación cuadrinomial para el cálculo de griegas mediante diferencias finitas. Se muestra un árbol trinomial base (nodos grises, conexiones negras gruesas) con nodos adicionales en $t = 0$ ubicados en $S_0 + \epsilon$ (verde) y $S_0 - \epsilon$ (rojo), donde $\epsilon = h/4$ es una perturbación pequeña. Las líneas sólidas grises representan ramificación cuadrinomial (4 ramas) desde los nodos perturbados y los nodos extremos en $t = k/4$, permitiendo calcular simultáneamente Delta y Gamma con alta precisión.

4.7.3. Precisión

El método natural de calcular las griegas en un árbol trinomial sin AMM es extender el árbol un paso hacia atrás y usar la perturbación mínima disponible: $\epsilon = h$ (un paso de precio completo). Esa es la línea de base con la que se compara el AMM.

Al sustituir esa perturbación gruesa por la ramificación cuadrinomial, el AMM reduce el RMSE (Error Cuadrático Medio respecto al valor teórico de Black-Scholes) de las griegas de manera sustancial. Sin embargo, el grado de mejora depende críticamente de cuántos niveles de refinamiento se apliquen y en qué extremos del árbol. Según Figlewski y Gao (1999), una configuración AMM con refinamiento únicamente en $t = 0$ (por ejemplo, AMM(1,0) o AMM(2,0)) produce un RMSE en Delta de ~ 0.001087 , que es **peor** que el 0.000079 de un trinomial de 1000 pasos. Solo la configuración **AMM(3,3)** (tres niveles de refinamiento tanto al inicio $t = 0$ como al vencimiento $t = T$) logra reducir el error a ~ 0.000053 y superar al trinomial de 1000 pasos, con un tiempo de ejecución que es del orden de 500 veces menor. Por ello, la afirmación correcta sería que un AMM de 25 pasos con **tres niveles de refinamiento en ambos extremos** es más preciso que un trinomial estándar de 1000 pasos.

Precisión en el Cálculo de Delta: Trinomial vs AMM con Ramificación Cuadrinomial




Figura 4.7: Precisión en el cálculo de Delta mediante ramificación cuadrinomial. Se compara el RMSE en Delta para diferentes configuraciones AMM $(0, T)$, donde 0 es el inicio de la opción y T es el final de la misma. La ramificación cuadrinomial permite calcular Delta mediante diferencias finitas. AMM (3,3) logra una mejora de 60x vs Trinomial en $N=100$, con un incremento de tiempo $< 3\%$. Notablemente, AMM (1,0) mejora Delta sin costo adicional al refinar solo la región crítica.




Figura 4.8: Precisión en el cálculo de Gamma mediante ramificación cuadrinomial. Se compara el RMSE en Gamma para diferentes configuraciones AMM. La ramificación cuadrinomial permite calcular Gamma mediante diferencias finitas de segundo orden. AMM (1,1) logra una mejora de 7.2x vs Trinomial en $N=100$. A diferencia de Delta, Gamma no mejora significativamente con niveles superiores a (2,2), lo que sugiere que AMM (1,1) es óptimo para este cálculo. El incremento en tiempo es $< 3\%$.

4.8. Ventajas del AMM

- **Eficiencia extrema:** Aumenta la precisión en órdenes de magnitud con incremento mínimo en tiempo de ejecución
- **Escalabilidad:** Permite abordar problemas que son computacionalmente prohibitivos con métodos estándar
- **Flexibilidad:** Aplicable a opciones vanilla, barrera y cálculo de griegas con estructuras específicas para cada caso
- **Convergencia mejorada:** Elimina el comportamiento “par-impar” y la convergencia “dentada” de los modelos estándar

- **Aplicaciones prácticas:** Especialmente valioso para cálculo de volatilidad implícita (que requiere múltiples valoraciones repetitivas) y opciones exóticas complejas

4.9. Consistencia Matemática

Figlewski y Gao proporcionan una prueba formal de convergencia, demostrando que a medida que el tamaño de los pasos de tiempo y precio tiende a cero, el valor de la opción obtenido por el AMM converge al valor teórico de tiempo continuo. Esta consistencia garantiza que el método no solo es eficiente, sino también matemáticamente riguroso.

Capítulo 5

Método 3: Replicación Estática

La replicación estática es un método desarrollado para cubrir o replicar el valor de una opción objetivo (frecuentemente una opción exótica) mediante la construcción de un portafolio compuesto por otras opciones, generalmente opciones estándar o “vanilla”. A diferencia de la cobertura dinámica, que requiere ajustes continuos en la posición del activo subyacente, este enfoque busca establecer un portafolio de cobertura con pesos fijos que no requiera ajustes posteriores durante la vida de la opción o dentro de un rango específico de precios y tiempos.

Esta técnica se fundamenta en los supuestos estándar de la teoría de valoración de opciones (como el modelo Black-Scholes), permitiendo descomponer teóricamente una opción exótica en un portafolio de opciones estándar, cuyos precios de mercado y bid-ask spreads suelen ser más transparentes y líquidos. Aunque una replicación perfecta teórica podría requerir un número infinito de opciones estándar, en la práctica es posible lograr una aproximación adecuada utilizando un número limitado de instrumentos.

5.1. Concepto de Replicación Estática

El concepto central de la replicación estática radica en igualar los flujos de caja y los valores de frontera de la opción objetivo utilizando un portafolio de instrumentos más simples. Cabe definir que, en el contexto de los derivados financieros, los “flujos de caja” (*cash flows*) representan cualquier entrada o salida de dinero asociada al contrato (como el cobro o pago de primas iniciales, reembolsos intermedios o el pago final al vencimiento o *payoff*). Por otro lado, en este contexto se denomina “frontera” a los límites espaciales y temporales que definen el contrato de la opción, típicamente, esto incluye el nivel de precio del activo subyacente que actúa como barrera (donde la opción se activa o desactiva) y la fecha de vencimiento.

La idea: replicación con un portafolio de opciones vanilla

La estrategia consiste en construir un portafolio de opciones estándar (calls y puts europeas con diferentes precios de ejercicio y vencimientos) que replique el valor de la opción exótica en sus fronteras. Por ejemplo, para una opción barrera up-and-out (que deja de existir si el precio del subyacente toca un nivel superior), el objetivo es crear un portafolio que tenga el mismo pago que la opción estándar al vencimiento (si no toca la barrera), pero cuyo valor neto sea cero si el precio del activo alcanza la barrera antes del vencimiento.

Esto se logra “anulando” el valor de la opción original en la barrera mediante la venta en corto de otras opciones que tengan valor positivo en ese mismo punto. Es importante aclarar que la “venta en corto” (*short selling*) consiste en tomar una posición vendedora sobre un instrumento que no se posee, en el caso de las opciones, implica emitir el contrato asumiendo sus obligaciones a cambio de recibir una prima inicial. De esta manera, el portafolio estático imita el comportamiento de “desaparición” de la opción barrera sin necesidad de vender la opción exótica en sí misma.

Fundamento teórico: ¿Por qué funciona?

La validez del método descansa en el Principio de Replicación Estática. Este principio establece que si dos portafolios tienen los mismos valores en todas las fronteras de una región determinada (precio del activo y tiempo) y satisfacen la misma ecuación diferencial (la ecuación de Black-Scholes) dentro de dicha región, entonces deben tener el mismo valor en cualquier punto interior de esa región.

Por lo tanto, no es necesario igualar el valor de la opción en cada punto posible del futuro; basta con construir un portafolio que coincida con el valor de la opción objetivo en sus fronteras naturales (al vencimiento y sobre la barrera de precio). Una vez que los valores en la frontera están alineados, la teoría de valoración por inducción hacia atrás (backward induction) garantiza que el valor actual y la sensibilidad del portafolio replicante serán iguales a los de la opción objetivo.

Ventajas frente a la cobertura dinámica

La principal ventaja de este método es que elimina la necesidad de rebalanceo continuo. Cabe definir previamente que una “cobertura” (*hedge*) es una estrategia financiera diseñada para reducir o mitigar el riesgo de mercado, y una “posición” es la cantidad de un activo o derivado que un inversor posee (si está comprado) o debe (si está vendido). La cobertura dinámica tradicional (como el *Delta hedging*) requiere ajustar estas posiciones constantemente a medida que pasa el tiempo o cambia el precio del activo, lo cual presenta dos dificultades mayores:

1. El ajuste continuo es imposible en la práctica y el rebalanceo discreto genera errores de cobertura.
2. Los costos de transacción asociados al ajuste frecuente pueden erosionar el margen de beneficio de la opción.

La replicación estática utiliza pesos fijos determinados al inicio, evitando estos costos y dificultades operativas. Además, es particularmente útil para opciones exóticas con un valor Γ alto (como las opciones barrera cerca de su nivel de activación/desactivación), donde la cobertura dinámica se vuelve costosa e imprecisa debido a la necesidad de realizar grandes ajustes ante pequeños movimientos del mercado.

5.2. Metodología de Derman-Ergener-Kani

La metodología propuesta por Derman, Ergener, y Kani (1994) se basa en la construcción sistemática de un portafolio de cobertura que iguala el valor de la opción objetivo en una serie de puntos discretos sobre su frontera (espacio y tiempo). El enfoque fundamental es recursivo: comienza igualando el pago al vencimiento y retrocede en el tiempo para ajustar los valores en la barrera, aprovechando que el valor de la opción exótica es conocido en dichas fronteras (por ejemplo, cero en una opción knock-out o un valor de reembolso específico).

5.2.1. Construcción del Portafolio y Selección de Strikes

La construcción del portafolio replicante se realiza paso a paso, asegurando que la adición de nuevas opciones para corregir el valor en un punto de la frontera no altere la replicación ya lograda en puntos anteriores o regiones interiores. Para lograr esto, la selección de los precios de ejercicio (strikes) es crítica y sigue reglas estrictas dependiendo de la ubicación de la frontera respecto al precio actual del activo:

- **Frontera de Vencimiento:** Se inicia replicando el pago final de la opción objetivo (t_{exp}) utilizando una combinación de opciones vanilla (calls o puts) con diferentes strikes que vencen en esa fecha. Esto constituye el portafolio inicial.
- **Fronteras Superiores (por encima del precio actual):** Para ajustar el valor del portafolio en una barrera superior en tiempos anteriores al vencimiento ($t < t_{exp}$), se deben utilizar opciones de compra (*calls*) con strikes iguales o superiores al nivel de la barrera ($K \geq B$). Esto garantiza que dichas opciones expiren *out-of-the-money* si el precio del activo se mantiene por debajo de la barrera, evitando así generar flujos de caja no deseados dentro de la región de replicación.
- **Fronteras Inferiores (por debajo del precio actual):** De manera análoga, para ajustar el valor en una barrera inferior, se deben utilizar opciones de venta (*puts*) con strikes iguales o inferiores al nivel de la barrera ($K \leq B$). Al igual que en el caso anterior, estas opciones no tendrán valor al vencimiento si el precio se mantiene por encima de la frontera inferior, preservando la integridad de la replicación interior.

5.2.2. Cálculo de Pesos y Procedimiento Recursivo

Una vez seleccionados los instrumentos adecuados, los pesos (cantidad de opciones a comprar o vender) se calculan mediante un proceso iterativo hacia

5.3. CONSTRUCCIÓN DEL PORTAFOLIO

atrás en el tiempo. Si dividimos el tiempo hasta el vencimiento en intervalos discretos $t_1, t_2, \dots, t_{exp}$, el procedimiento es el siguiente:

1. **Ajuste al Vencimiento (t_{exp}):** Se seleccionan opciones estándar que igualen el pago de la opción objetivo al vencimiento. Por ejemplo, para una opción up-and-out call que no ha tocado la barrera, esto equivale simplemente a una call estándar con el mismo strike que la opción exótica.
2. **Retroceso al paso anterior (t_{n-1}):** Se calcula el valor teórico del portafolio replicante existente en el punto de la frontera correspondiente al tiempo t_{n-1} (por ejemplo, en la barrera B). Generalmente, este valor no coincidirá con el valor de la opción objetivo (que suele ser cero en el caso de opciones *knock-out*).
3. **Cálculo del Peso de Corrección:** Para eliminar esta discrepancia, se añade una nueva posición en una opción estándar que venza en t_{exp} (o en el tiempo correspondiente a la frontera, dependiendo de la implementación exacta). El peso (w) de esta nueva opción se calcula para que su valor compense exactamente el error del portafolio en ese punto:

$$w = \frac{V_{portafolio}(B, t_{n-1}) - V_{objetivo}(B, t_{n-1})}{V_{nueva_opcion}(B, t_{n-1})} \quad (5.1)$$

Donde $V_{portafolio}$ es el valor acumulado de las opciones añadidas en pasos previos y V_{nueva_opcion} es el valor de la opción utilizada para el ajuste.

4. **Iteración:** Este proceso se repite para $t_{n-2}, t_{n-3}, \dots, t_1$, añadiendo en cada paso opciones adicionales que corrijan el valor en la frontera sin afectar los puntos ya ajustados en el futuro (gracias a la selección de strikes descrita anteriormente).

Teóricamente, si se utilizara un número infinito de opciones para cubrir todos los puntos de la frontera, la replicación sería exacta. En la práctica, se utiliza un número finito de opciones para igualar el valor en puntos discretos, lo que proporciona una aproximación robusta cuyo error disminuye al aumentar la cantidad de instrumentos de cobertura.

5.3. Construcción del Portafolio

La construcción práctica del portafolio replicante sigue un proceso sistemático que transforma la frontera continua de la opción exótica en un conjunto discreto de puntos de control. Este proceso requiere una selección cuidadosa de los instrumentos vanilla para garantizar que la corrección del valor en un punto de la frontera no introduzca flujos de caja no deseados en regiones ya cubiertas.

5.3.1. Selección de Opciones Vanilla

La regla fundamental para elegir los instrumentos de cobertura es asegurar que estos no tengan valor intrínseco dentro de la región válida de la opción objetivo (es decir, antes de que se toque la barrera). Según Derman, Ergener y Kani, la selección se realiza en función de la ubicación de la frontera respecto al precio actual del activo:

5.3. CONSTRUCCIÓN DEL PORTAFOLIO

- **Frontera de Vencimiento** (t_{exp}): Para replicar el pago final de la opción, se pueden utilizar tanto opciones call como put de cualquier precio de ejercicio (K) conveniente, combinándolas para igualar el perfil de pago de la opción objetivo al vencimiento.
- **Fronteras Superiores** ($S > S_{actual}$): Para ajustar el valor en una barrera superior (como en una opción *up-and-out*), se deben utilizar exclusivamente opciones de compra (**calls**) con precios de ejercicio iguales o superiores al nivel de la barrera ($K \geq B$). Esto asegura que, si el precio del activo se mantiene por debajo de la barrera, estas opciones expiren *out-of-the-money* (sin valor), preservando así la replicación lograda en el interior de la región.
- **Fronteras Inferiores** ($S < S_{actual}$): De manera análoga, para replicar condiciones en una frontera inferior (como en una opción *down-and-out*), se deben emplear opciones de venta (**puts**) con precios de ejercicio iguales o inferiores al nivel de la barrera ($K \leq B$). Estas opciones no generarán flujos de caja si el precio del activo se mantiene por encima de la frontera inferior.

5.3.2. Determinación de los Pesos

Una vez seleccionados los instrumentos, los pesos (cantidad de opciones a comprar o vender) se determinan mediante un proceso recursivo hacia atrás en el tiempo. El objetivo es “anular” la discrepancia entre el valor del portafolio acumulado y el valor de la opción objetivo en puntos discretos de la frontera. El cálculo matemático para el peso α_i de una nueva opción que se añade en el paso i para corregir el valor en el tiempo t_i y precio B_i se define formalmente como:

$$\alpha_i = \frac{\xi_{i-1} - V_{portafolio}(B_{i-1}, t_{i-1})}{C(B_{i-1}, t_{i-1})} \quad (5.2)$$

Donde:

- ξ_{i-1} es el valor conocido de la opción objetivo en la frontera (usualmente cero para opciones knock-out o un valor de reembolso específico).
- $V_{portafolio}$ es el valor teórico acumulado de todas las opciones estándar añadidas en pasos anteriores (vencimientos futuros ya cubiertos).
- $C(B_{i-1}, t_{i-1})$ es el valor de la nueva opción estándar utilizada para el ajuste en ese punto de la frontera

En términos prácticos, si el portafolio actual tiene un valor positivo en una barrera donde la opción objetivo vale cero, el peso α_i será negativo, indicando que se debe tomar una posición short en la nueva opción para cancelar dicho valor.

5.3.3. Aproximación de la Barrera

Dado que en el mundo real los precios de las acciones son continuos, una replicación estática perfecta requeriría un número infinito de opciones estándar para cubrir cada punto posible de la frontera. Sin embargo, la metodología permite una aproximación robusta mediante la discretización de la frontera:

1. **Puntos de anclaje:** Se selecciona un conjunto limitado de puntos de tiempo y precio sobre la barrera (por ejemplo, cada mes o cada semana) donde se forzará la igualdad de valores.
2. **Convergencia:** A medida que se aumenta el número de opciones utilizadas en el portafolio replicante (disminuyendo el intervalo de tiempo entre los puntos de ajuste), el “error de replicación” o mismatch en los puntos intermedios disminuye significativamente.

Por ejemplo, los autores demuestran que al pasar de un portafolio de 6 opciones (ajuste bimestral) a uno de 24 opciones (ajuste quincenal) para replicar una opción up-and-out a un año, el error de valor teórico se reduce drásticamente, logrando que el comportamiento del portafolio replicante sea casi indistinguible del de la opción exótica objetivo.

Capítulo 6

Método 4: Monte Carlo para Opciones Americanas

La simulación de Monte Carlo es una técnica fundamental en finanzas computacionales que permite valorar derivados complejos mediante la generación de trayectorias aleatorias del precio del activo subyacente. Aunque es naturalmente adecuada para opciones europeas, su aplicación a opciones americanas presenta desafíos significativos debido a la posibilidad de ejercicio anticipado.

6.1. Desafío de las Opciones Americanas

6.1.1. El Problema del Ejercicio Óptimo

Las opciones americanas otorgan a su tenedor el derecho de ejercer en cualquier momento hasta el vencimiento T . Esta flexibilidad adicional implica que el valor de la opción en cualquier instante t es:

$$V(S_t, t) = \max \{ \text{Payoff inmediato}, \mathbb{E}^{\mathbb{Q}}[e^{-r\Delta t} V(S_{t+\Delta t}, t + \Delta t) | S_t] \} \quad (6.1)$$

donde el primer término representa el valor de ejercicio inmediato y el segundo el valor de continuación (mantener la opción viva).

La decisión óptima de ejercicio requiere comparar en cada instante:

- **Valor intrínseco:** $\max(S_t - K, 0)$ para calls o $\max(K - S_t, 0)$ para puts
- **Valor de continuación:** El valor esperado descontado de mantener la opción

6.2. Simulación de Monte Carlo

6.2.1. Generación de Trayectorias

Bajo el modelo de Black-Scholes, el precio del activo subyacente bajo la medida neutral al riesgo sigue:

$$dS_t = (r - \delta)S_t dt + \sigma S_t dW_t^{\mathbb{Q}} \quad (6.2)$$

donde r es la tasa libre de riesgo, δ es la tasa de dividendos, σ es la volatilidad y $W_t^{\mathbb{Q}}$ es un proceso de Wiener bajo la medida neutral al riesgo.

La solución analítica de esta ecuación diferencial estocástica es:

$$S_{t+\Delta t} = S_t \exp \left[\left(r - \delta - \frac{\sigma^2}{2} \right) \Delta t + \sigma \sqrt{\Delta t} Z \right] \quad (6.3)$$

donde $Z \sim N(0, 1)$ es una variable aleatoria normal estándar.

6.2.2. Algoritmo Básico para Opciones Europeas

Para una opción europea, el algoritmo de Monte Carlo es directo:

1. Generar M trayectorias del precio del subyacente desde $t = 0$ hasta $t = T$
2. Para cada trayectoria i , calcular el payoff al vencimiento: $\text{Payoff}_i = \max(S_T^{(i)} - K, 0)$ para calls
3. Estimar el valor de la opción como:

$$V(S_0, 0) \approx e^{-rT} \frac{1}{M} \sum_{i=1}^M \text{Payoff}_i \quad (6.4)$$

El error estándar de esta estimación decrece como $O(1/\sqrt{M})$, independientemente de la dimensionalidad del problema.

6.2.3. Monitoreo de Barreras

Para opciones con barreras, es necesario monitorear si el precio cruza el nivel H durante la vida de la opción. Esto requiere discretizar cada trayectoria en N pasos temporales:

$$S_{t_j} = S_{t_{j-1}} \exp \left[\left(r - \delta - \frac{\sigma^2}{2} \right) \Delta t + \sigma \sqrt{\Delta t} Z_j \right] \quad (6.5)$$

para $j = 1, 2, \dots, N$, donde $\Delta t = T/N$ y $Z_j \sim N(0, 1)$ son independientes.

En cada paso se verifica si S_{t_j} ha cruzado la barrera H :

- Para opciones **knock-out**: Si se cruza H , la trayectoria se marca como extinguida
- Para opciones **knock-in**: Si se cruza H , la trayectoria se marca como activada

Sesgo de Discretización: El monitoreo discreto puede no detectar cruces que ocurren entre puntos de observación. Este sesgo se reduce aumentando N , pero a costa de mayor tiempo computacional.

6.2.4. El Problema Fundamental: ¿Cuándo Ejercer?

Para opciones americanas, el desafío es determinar la estrategia de ejercicio óptima. En cada punto de decisión t_j , necesitamos saber si es óptimo ejercer o continuar.

El problema es que en Monte Carlo avanzamos hacia adelante en el tiempo, pero la decisión de ejercicio requiere conocer el valor de continuación, que depende del futuro. Esto crea una paradoja circular: para decidir si ejercer en el momento t_j , necesitamos calcular el valor esperado de continuación $\mathbb{E}[V(S_{t_{j+1}}, t_{j+1}) | S_{t_j}]$. Sin embargo, el valor de la opción en el siguiente paso, $V(S_{t_{j+1}}, t_{j+1})$, depende inherentemente de las decisiones de ejercicio futuras, las cuales a su vez dependen de valores de continuación en períodos posteriores. Por lo tanto, esta interdependencia hace que la decisión óptima no pueda abordarse directamente mediante una simulación estándar hacia adelante, requiriendo un enfoque metodológico más sofisticado.

6.3. Método de Longstaff-Schwartz (LSM)

La simulación de Monte Carlo para opciones americanas enfrenta el desafío de la direccionalidad del tiempo. Como vimos en la sección anterior, la decisión de ejercer anticipadamente requiere comparar el valor intrínseco inmediato con el valor de continuación esperado, el cual, a su vez, depende de decisiones de ejercicio en períodos subsiguientes, generando una dependencia circular que es imposible de resolver de manera secuencial hacia el futuro.

El método propuesto por Longstaff y Schwartz (2001), conocido como *Least Squares Monte Carlo* (LSM), resuelve este problema mediante un enfoque estadístico basado en la regresión de mínimos cuadrados. En lugar de avanzar hacia adelante para evaluar la estrategia óptima, el algoritmo genera primero todas las trayectorias de precios completas hasta el vencimiento y luego retrocede en el tiempo (*backward induction*).

En cada punto de decisión t_j , el modelo estima el valor de continuación condicional aproximándolo como una función del precio actual del activo mediante regresión transversal (es decir, evaluando simultáneamente el corte transversal de todas las trayectorias simuladas en ese instante exacto, utilizando típicamente polinomios de Laguerre como funciones base). Para las trayectorias que están *in-the-money*, se efectúa una regresión del valor descontado realizado en t_{j+1} sobre el precio actual S_{t_j} . Esto permite comparar empíricamente el beneficio de ejercer la opción inmediatamente frente al de mantenerla viva, convirtiendo un complejo problema de optimización dinámica en una secuencia manejable de problemas de regresión.

6.3.1. Idea Central

La intuición del método es:

1. Generar todas las trayectorias completas desde $t = 0$ hasta $t = T$
2. Trabajar hacia atrás en el tiempo (*backward induction*)
3. En cada punto de decisión t_j , usar regresión para estimar el valor de continuación como función del precio actual

4. Comparar el valor de continuación estimado con el valor de ejercicio inmediato
5. Ejercer si el valor inmediato excede el valor de continuación

6.3.2. Estimación del Valor de Continuación

En el tiempo t_j , para todas las trayectorias que están “in-the-money” (donde el ejercicio inmediato tiene valor positivo) se estima el valor de continuación mediante regresión de mínimos cuadrados **sobre los flujos de caja reales obtenidos ex-post** (y no sobre el valor esperado de la opción, lo cual generaría un sesgo alcista):

$$\mathbb{E}\left[\sum_{i=j+1}^N e^{-r(t_i-t_j)} CF_i | S_{t_j}\right] \approx \sum_{k=0}^K a_k L_k(S_{t_j}) \quad (6.6)$$

donde CF_i representa el flujo de caja real que ocurre en el tiempo t_i a lo largo de la trayectoria condicionado a que la opción no se ejerció antes, L_k son funciones base (típicamente polinomios de Laguerre) y a_k son coeficientes determinados por regresión.

¿Por qué Polinomios de Laguerre?

Los polinomios de Laguerre ponderados $L_k(x)e^{-x/2}$ forman una base ortogonal en $[0, \infty)$, que es el dominio natural de los precios de activos. Por simplicidad se utilizan polinomios de Laguerre simples (no ponderados) ya que la elección exacta de las funciones base (ya sean ponderadas, no ponderadas, de Hermite, etc.) no afecta significativamente la convergencia del algoritmo siempre que se usen los términos suficientes. Los primeros polinomios son:

$$L_0(x) = 1 \quad (6.7)$$

$$L_1(x) = 1 - x \quad (6.8)$$

$$L_2(x) = 1 - 2x + \frac{x^2}{2} \quad (6.9)$$

$$L_3(x) = 1 - 3x + \frac{3x^2}{2} - \frac{x^3}{6} \quad (6.10)$$

En la práctica, se usan típicamente los primeros 3-5 polinomios.

6.3.3. Algoritmo de Longstaff-Schwartz

El algoritmo LSM procede en cuatro pasos principales:

Paso 1: Generación de Trayectorias

Se generan M trayectorias completas del precio del subyacente desde $t = 0$ hasta $t = T$, discretizadas en N pasos temporales.

Paso 2: Inicialización al Vencimiento

Para cada trayectoria, el valor al vencimiento es simplemente el payoff de la opción.

Paso 3: Inducción Hacia Atrás

Este es el núcleo del algoritmo. Para cada tiempo t_j desde t_{N-1} hasta t_1 :

6.3. MÉTODO DE LONGSTAFF-SCHWARTZ (LSM)

1. Se identifican las trayectorias in-the-money (donde el ejercicio inmediato tiene valor positivo)
2. Para estas trayectorias, se realiza una regresión de mínimos cuadrados usando funciones base (típicamente polinomios de Laguerre) para estimar el valor de continuación:

$$\mathbb{E}[e^{-r\Delta t}V(S_{t_{j+1}}, t_{j+1})|S_{t_j}] \approx \sum_{k=0}^K a_k L_k(S_{t_j}) \quad (6.11)$$

3. Se compara el valor de ejercicio inmediato con el valor de continuación estimado
4. Se toma la decisión de ejercicio óptima: ejercer si el valor inmediato excede el valor de continuación

Paso 4: Valoración

El valor de la opción es el promedio descontado de los payoffs en los tiempos de ejercicio óptimos determinados en el paso anterior.

6.3.4. Extensión a Opciones Barrera Americanas

Para opciones americanas con barreras, el algoritmo LSM se modifica para incorporar el monitoreo de la barrera:

- **Knock-out:** Si una trayectoria cruza la barrera en t_j , se establece su valor en el rebote R y no se consideran decisiones de ejercicio futuras para esa trayectoria.
- **Knock-in:** La trayectoria solo puede ejercerse después de que se haya cruzado la barrera. Antes del cruce, solo se considera el valor de continuación.

6.3.5. Ventajas y Limitaciones del Método LSM

Ventajas:

- **Flexibilidad:** Aplicable a opciones con payoffs complejos, múltiples subyacentes y barreras
- **Escalabilidad:** No sufre de la maldición de la dimensionalidad como árboles y diferencias finitas
- **Implementación:** Relativamente simple de programar
- **Griegas:** Pueden estimarse mediante diferencias finitas o métodos de sensibilidad

Limitaciones:

- **Convergencia lenta:** Error $O(1/\sqrt{M})$ requiere muchas simulaciones para alta precisión
- **Sesgo bajo:** El método tiende a subestimar ligeramente el valor verdadero (sesgo bajo)

- **Elección de funciones base:** El rendimiento depende de la elección apropiada de funciones base
- **Costo computacional:** Para alta precisión, puede ser más lento que métodos de árbol para problemas de baja dimensionalidad

6.3.6. Comparación con Otros Métodos

El método LSM es particularmente valioso cuando:

- El problema es de alta dimensionalidad (opciones sobre múltiples activos)
- El payoff es complejo o path-dependent
- Se requiere flexibilidad para incorporar características exóticas

Para opciones americanas simples de baja dimensionalidad, los árboles adaptativos (como el AMM) pueden ser más eficientes. Sin embargo, para opciones barrera americanas con múltiples características exóticas, el LSM es frecuentemente el método de elección en la práctica.

Capítulo 7

Implementaciones

7.1. Fórmulas de Reiner y Rubinstein

7.1.1. Descripción de la Implementación

A diferencia de las opciones americanas estándar, las opciones barrera permiten soluciones de valoración en “forma cerrada” debido a que la frontera crítica del precio del activo está determinada de antemano y especificada en el contrato. El marco teórico propuesto por Reiner y Rubinstein descompone el valor de cualquier opción barrera europea en una combinación lineal de hasta seis términos analíticos de valoración. Desde el punto de vista de la Ingeniería de Software, implementar directamente ocho ecuaciones monolíticas distintas (para las combinaciones de Up/Down, In/Out, Call/Put) resulta ineficiente, propenso a errores y difícil de mantener. Por lo tanto, la descripción algorítmica de este método se diseñó bajo un paradigma modular. El algoritmo base se encarga de calcular de forma independiente los componentes de las distribuciones normales y los términos de valoración. Posteriormente, la lógica de negocio ensambla estos términos dependiendo del tipo de opción requerida, apoyándose en el uso de variables binarias matemáticas definidas por los autores: η y ϕ .

- La variable η toma el valor de 1 si la barrera es aproximada desde arriba (Down-options) y -1 si es aproximada desde abajo (Up-options).
- La variable ϕ actúa como un interruptor para la función de pago, tomando el valor de 1 para opciones Call y -1 para opciones Put.

Esta abstracción matemática permite que el código sea altamente reutilizable, ya que las mismas funciones base evalúan los seis términos principales y las reglas de paridad y construcción simplemente suman o restan los bloques correspondientes.

7.1.2. Detalles de Implementación

La implementación computacional de estas fórmulas cerradas se desarrolló priorizando la precisión numérica y la velocidad de ejecución. Al ser este método el “oráculo” o valor de referencia exacto (ground truth) contra el cual se evaluarán los métodos numéricos posteriores (como el AMM y Monte Carlo), su rendimiento es crítico.

Cálculo de Variables Auxiliares

El cálculo de los términos analíticos implica evaluar múltiples variables auxiliares (x, x_1, y, y_1, z y los escalares λ, a, b) que dependen directamente del precio del activo S , el precio de ejercicio K , la barrera H y el tiempo t . Para soportar el diseño de experimentos del Capítulo 8, donde se requiere evaluar el precio de la opción bajo miles de trayectorias o en densas mallas de precios, el código se implementó utilizando operaciones vectorizadas (por ejemplo, mediante la librería NumPy en Python). Esto permite calcular arreglos enteros de precios simultáneamente sin incurrir en la penalización de rendimiento de los bucles iterativos.

Evaluación de la Distribución Normal

El núcleo computacional de las ecuaciones de Reiner y Rubinstein reside en la Función de Distribución Acumulada de la Normal Estándar, denotada como $N(\cdot)$. Dado que esta función no tiene una representación algebraica elemental, en la implementación se utilizan aproximaciones numéricas altamente optimizadas provistas por las librerías científicas estándar (como `scipy.stats.norm.cdf`).

Manejo de Casos Límite y Rebates

El algoritmo incluye el manejo explícito del rebate R , un flujo de caja fijo que se paga al tenedor si la opción es cancelada (knock-out) o si expira sin ser activada (knock-in). El valor presente de este rebate, correspondiente al término para opciones Out y al término para opciones In, incorpora el descuento por la tasa de interés ponderada por el tiempo de primer paso (first passage time). La implementación aísla este cálculo para permitir que el usuario defina $R = 0$ sin causar inestabilidades numéricas en el resto de los términos.

Código Relevante

Listing 7.1: Términos de RR

```
def calcular_terminos_rr(S, K, H, t, r_rate, d_rate, \
                        sigma, phi, eta, R=0):
    # Asumimos tasas continuas estandar
    r, d = exp(r_rate), exp(d_rate)

    # Variables auxiliares
    mu = log(r/d) - 0.5 * sigma^2
    lambda_ = 1 + (mu / sigma^2)
    a = mu / sigma^2 # Derivado del paper original de RR
    b = sqrt(mu^2 + 2 * log(r) * sigma^2) / sigma^2

    denom = sigma * sqrt(t)
    x = (log(S/K) / denom) + lambda_ * denom
    x1 = (log(S/H) / denom) + lambda_ * denom
    y = (log(H^2 / (S*K)) / denom) + lambda_ * denom
    y1 = (log(H/S) / denom) + lambda_ * denom
    z = (log(H/S) / denom) + b * denom
```

```

# Factores de descuento
S_d_t = S * (d^(-t))
K_r_t = K * (r^(-t))
R_r_t = R * (r^(-t))
H_S = H / S

term1 = phi * S_d_t * N(phi * x) \
        - phi * K_r_t * N(phi * x - phi * denom)
term2 = phi * S_d_t * N(phi * x1) \
        - phi * K_r_t * N(phi * x1 - phi * denom)
term3 = phi * S_d_t * (H_S^(2 * lambda_)) * N(eta * y) \
        - phi * K_r_t * (H_S^(2 * lambda_ - 2)) \
        * N(eta * y - eta * denom)
term4 = phi * S_d_t * (H_S^(2 * lambda_)) * N(eta * y1) \
        - phi * K_r_t * (H_S^(2 * lambda_ - 2)) \
        * N(eta * y1 - eta * denom)
term5 = R_r_t * (N(eta * x1 - eta * denom) \
        - (H_S^(2 * lambda_ - 2)) \
        * N(eta * y1 - eta * denom))
term6 = R * ((H_S^(a + b)) * N(eta * z) \
        + (H_S^(a - b)) * N(eta * z - 2 * eta * b * denom))

return term1, term2, term3, term4, term5, term6

```

7.1.3. Cálculo de Griegas

En el contexto de la gestión de riesgos financieros, el cálculo de las “Griegas” (sensibilidades del precio de la opción ante cambios en los parámetros del mercado) es tan importante como la valoración misma. En los métodos basados en redes discretas, como los árboles trinomiales estándar, estimar la Delta (Δ) y la Gamma (Γ) mediante la perturbación del precio inicial introduce un severo ruido numérico debido al error de no linealidad inherente a la malla. Dividir por un valor de perturbación ϵ muy pequeño magnifica dramáticamente este error. Sin embargo, la implementación de las fórmulas cerradas de Reiner y Rubinstein proporciona una ventaja computacional inmensa: la función de valoración es analítica y continua en todo su dominio (excepto exactamente en la barrera). Esto permite dos enfoques algorítmicos para el cálculo de las Griegas:

- **Derivación Analítica Exacta:** Consiste en calcular las derivadas parciales exactas de los seis términos de valoración respecto a S (para Delta y Gamma), respecto a σ (para Vega), etc. Aunque matemáticamente es el enfoque más riguroso, su implementación en código es extensa y propensa a errores tipográficos en la transcripción de las fórmulas derivadas.
- **Diferencias Finitas Centrales:** Dado que la evaluación de la función vectorizada es computacionalmente instantánea y carece del ruido de discretización espacial de los árboles, es posible aplicar diferencias finitas centrales utilizando un ϵ infinitesimal (por ejemplo, $\epsilon = 10^{-4}$ o menor) con extrema estabilidad numérica.

7.1. FÓRMULAS DE REINER Y RUBINSTEIN

Para esta implementación, las sensibilidades se computan mediante el segundo enfoque:

$$\Delta \approx \frac{V(S + \epsilon) - V(S - \epsilon)}{2\epsilon}$$
$$\Gamma \approx \frac{V(S + \epsilon) - 2V(S) + V(S - \epsilon)}{\epsilon^2}$$

Los resultados obtenidos mediante este método poseen una alta precisión y se establecen en este trabajo como el valor de referencia exacto (ground truth) contra el cual se evaluará el rendimiento de la ramificación cuadrinomial del Modelo de Malla Adaptativa (AMM) detallado en el Capítulo 7.2.1.

7.1.4. Validación

Para garantizar la correctitud de la implementación algorítmica de las fórmulas de Reiner y Rubinstein, se diseñó una batería de pruebas computacionales (unit tests) basadas en las propiedades matemáticas y financieras descritas por los autores originales. La validación consta de tres pruebas de estrés fundamentales:

Verificación de Relaciones de Paridad

Una propiedad teórica fundamental en la estructuración de opciones exóticas es que un portafolio compuesto por una opción knock-in y una opción knock-out idénticas (mismo strike, vencimiento y barrera) equivale exactamente a una opción europea estándar (vanilla). A nivel de código, se validó sistemáticamente que para cualquier vector de precios de entrada, la suma de las rutinas computacionales cumpla con la identidad:

$$\text{Precio_Call_Vanilla}(S, K, T, r, \sigma) = \text{Precio_Down_In_Call}(\dots) + \text{Precio_Down_Out_Call}(\dots)$$

Esta prueba garantiza que el manejo de los interruptores binarios η y ϕ , así como la combinación de los términos de valoración, no omiten ningún flujo de caja.

Verificación de Límites Asintóticos

Se comprobó la robustez de la implementación analizando el comportamiento de las opciones cuando la barrera es empujada hacia los límites del dominio.

- Para una opción Down-and-Out, si se configura el parámetro de la barrera $H \rightarrow 0$, el impacto de la barrera se vuelve matemáticamente irrelevante. Se verificó que el algoritmo converge suave y exactamente al valor de la fórmula de Black-Scholes clásica.
- De manera análoga, si para una opción Down-and-In (donde $S > H$) la barrera se eleva de manera que $H \rightarrow S$, la opción se activa inmediatamente por definición, comprobándose que su valor computado iguala al de una opción vanilla.

Aislamiento del Término de Reembolso (Rebate)

Los autores destacan un caso particular contraintuitivo: el valor de una opción Up-and-Out Call cuando el precio de ejercicio es mayor que la barrera ($K > H$). Puesto que para que el activo subyacente alcance el strike primero debe cruzar la barrera (lo cual extingue la opción), esta configuración nunca puede generar un pago (payoff) ordinario. Por lo tanto, su valor reside única y exclusivamente en el pago del rebate al momento del impacto. Se incluyeron pruebas que verifican este caso de frontera, al ejecutar la función correspondiente con $K > H$, el algoritmo aísla y retorna correctamente solo la evaluación del Término 6 de la ecuación, confirmando el correcto manejo de la densidad del tiempo de primer paso (first passage time) y el factor de descuento condicional.

7.2. Árboles Trinomiales con Mallas Adaptativas

7.2.1. Descripción del Algoritmo

La implementación del Modelo de Malla Adaptativa (AMM) para opciones de barrera difiere fundamentalmente de los árboles trinomiales estándar en su fase de inicialización. Mientras que en un árbol estándar se define arbitrariamente el número de pasos de tiempo (N) y se derivan los parámetros espaciales, en el AMM la geometría de la malla está dictada por las condiciones de contorno (la barrera) y la profundidad de refinamiento deseada. El algoritmo comienza con una fase de calibración estricta para asegurar que los nodos de la malla fina coincidan exactamente con la barrera del precio, evitando así el “problema del límite”.

Calibración de la Geometría (Malla Gruesa)

La construcción de la malla base (denotada como conjunto de nodos A o malla gruesa) requiere resolver un sistema de restricciones acopladas para determinar el paso de precio (h) y el paso de tiempo (k).

Restricción Espacial: Alineación con la Barrera Para valorar con precisión una opción barrera, es imperativo que la barrera física H coincida con una capa horizontal de nodos en el árbol. En el AMM, definimos la resolución en función de la distancia entre el precio inicial del activo (S_0) y la barrera (H).

Sea M el número de niveles de refinamiento de la malla fina (donde $M = 0$ implica un árbol trinomial estándar restringido). El algoritmo debe calcular el paso de precio de la malla gruesa, h , de tal manera que, al dividirlo por $2M$, el paso más fino cubra exactamente la distancia a la barrera.

La fórmula de inicialización para h es:

$$h = 2^M \times |\ln(S_0) - \ln(H)| \quad (7.1)$$

Esta ecuación garantiza que el nodo $B_{1,0}$ (en la malla fina) coincida con el precio inicial S_0 y que el nodo inferior de la malla fina coincida con H .

Nota de Implementación: El árbol se construye en el espacio logarítmico $X = \ln(S)$. Por tanto, la barrera se convierte en una constante $\ln(H)$ para todos los pasos de tiempo, simplificando la verificación de knock-out.

Restricción Temporal: El Parámetro de Estiramiento Una vez fijado h por la restricción espacial, el paso de tiempo k no puede ser elegido libremente. Debe cumplir dos condiciones simultáneas:

1. Mantener la estabilidad numérica y la convergencia de la varianza (típicamente gobernado por un parámetro libre $\lambda \approx 3$).
2. Resultar en un número entero de pasos de tiempo N hasta el vencimiento T .

Dado que calcular k directamente a partir de h y la volatilidad σ raramente produce un entero para T , se implementa el “Parámetro de Estiramiento”

(*Stretch Parameter*). El algoritmo calcula un k provisional y luego lo “estira” ligeramente para ajustar N al entero más cercano. La fórmula implementada, derivada de la Ecuación 17 de Figlewski y Gao (1999), es:

$$k = \frac{T}{\text{int}\left(\frac{j\sigma^2 T}{h^2}\right)} \quad (7.2)$$

Donde:

- j : Parámetro de estabilidad (generalmente se establece $j = 3$ para minimizar el error de distribución).
- $\text{int}(\cdot)$: Función que toma la parte entera.

El denominador representa el número total de pasos de tiempo (N) de la malla gruesa. Este ajuste asegura que el árbol termine exactamente en T sin necesidad de truncar o interpolar el último paso.

Cálculo de Probabilidades de la Malla Base Con h y k calibrados, se calculan las probabilidades de transición para los nodos de la malla gruesa. A diferencia de los árboles centrados en la media, acá el árbol está anclado en la barrera, por lo que incluimos el término *drift* en las probabilidades. Definimos el *drift* α como:

$$\alpha = r - q - \frac{\sigma^2}{2} \quad (7.3)$$

Donde r es la tasa libre de riesgo y q la tasa de dividendos.

Las probabilidades de movimiento hacia arriba (p_u), al medio (p_m) y hacia abajo (p_d) para la malla gruesa se implementan como:

$$p_u = \frac{1}{2} \left(\frac{\sigma^2 k}{h^2} + \frac{\alpha^2 k^2}{h^2} + \frac{\alpha k}{h} \right) \quad (7.4)$$

$$p_d = \frac{1}{2} \left(\frac{\sigma^2 k}{h^2} + \frac{\alpha^2 k^2}{h^2} - \frac{\alpha k}{h} \right) \quad (7.5)$$

$$p_m = 1 - p_u - p_d \quad (7.6)$$

Validación: El código debe incluir una aserción (*assert*) inmediatamente después de este cálculo para verificar que $p_u, p_m, p_d \geq 0$. Si el parámetro de estiramiento j es cercano a 3, las probabilidades serán positivas y estables.

Gestión de la Interfaz entre Mallas

Una vez calibrada y calculada la malla gruesa (Nodos del conjunto A), el siguiente paso es construir la malla fina (Nodos del conjunto B) en la región crítica cercana a la barrera.

Para una opción barrera, el flujo de información es descendente (Malla Gruesa $\rightarrow$ Malla Fina). Esto significa que utilizaremos los valores ya calculados en los nodos A para interpolar los valores de los nodos frontera de B .

El desafío de implementación radica en los “Nodos Intermedios” (o nodos colgantes). Dado que la malla fina tiene una resolución temporal 4 veces mayor que la gruesa, existen nodos B en los tiempos $t + k/4$, $t + 2k/4$ y $t + 3k/4$ que no tienen un nodo A correspondiente en el mismo instante temporal. Para valorarlos, debemos proyectarlos hacia los nodos A del siguiente paso de tiempo completo ($t + k$).

Cálculo de Probabilidades Ajustadas (Ecuación de Transición) Consideremos los nodos $B_{2,j}$ (ubicados un paso de precio grueso por encima de la barrera). Estos nodos sirven como el “techo” de la malla fina y deben conectarse a los nodos de la malla gruesa A .

Para conectar un nodo intermedio ubicado en el instante $t + \tau$ con los nodos A en el instante $t + k$, debemos calcular probabilidades trinomiales usando un paso de tiempo efectivo (Δt_{eff}) que cubra la distancia restante hasta la columna de nodos A .

Las probabilidades ajustadas para un nodo con paso de tiempo efectivo Δt_{eff} se implementan según las siguientes fórmulas (derivadas de la Ec. 12 de Figlewski y Gao):

$$p_u(\Delta t_{eff}) = \frac{1}{2} \left(\frac{\sigma^2 \Delta t_{eff}}{h^2} + \frac{\alpha^2 (\Delta t_{eff})^2}{h^2} + \frac{\alpha \Delta t_{eff}}{h} \right) \quad (7.7)$$

$$p_d(\Delta t_{eff}) = \frac{1}{2} \left(\frac{\sigma^2 \Delta t_{eff}}{h^2} + \frac{\alpha^2 (\Delta t_{eff})^2}{h^2} - \frac{\alpha \Delta t_{eff}}{h} \right) \quad (7.8)$$

$$p_m(\Delta t_{eff}) = 1 - p_u - p_d \quad (7.9)$$

Lógica de Bucle: En el código, para cada intervalo grueso entre t y $t + k$, se deben calcular tres sets de probabilidades distintos para los nodos frontera:

- **Para nodos en $t+k/4$:** Usar $\Delta t_{eff} = 3k/4$.
- **Para nodos en $t+2k/4$:** Usar $\Delta t_{eff} = 2k/4$.
- **Para nodos en $t+3k/4$:** Usar $\Delta t_{eff} = k/4$.

Valoración de los Nodos Frontera Con las probabilidades ajustadas, calculamos el valor de la opción en estos nodos intermedios descontando desde los nodos A del futuro.

Sea $V(B_{2,j})$ el valor de un nodo en la frontera superior de la malla fina. Su valor se obtiene de los nodos de la malla gruesa A_u (arriba), A_m (medio) y A_d (abajo) correspondientes al tiempo $t + k$:

$$V(B_{2,j}) = e^{-r\Delta t_{eff}} [p_u(\Delta t_{eff})V(A_u) + p_m(\Delta t_{eff})V(A_m) + p_d(\Delta t_{eff})V(A_d)] \quad (7.10)$$

Nota crítica de implementación: Observe que el factor de descuento es dinámico y debe ser $e^{-r\Delta t_{eff}}$. Dado que las probabilidades de transición se calculan proyectando el nodo intermedio directamente hacia los nodos de la malla gruesa (A), el descuento debe aplicarse sobre toda la distancia temporal efectiva (Δt_{eff}) que los separa, y no por un único micro-paso de $k/4$.

Relleno de la Malla Fina Una vez calculados los valores en el “techo” de la malla fina ($B_{2,j}$) y sabiendo que el “piso” de la malla es la barrera ($B_{0,j} = 0$ o valor de Rebate), procedemos a calcular los nodos internos ($B_{1,j}$) que se encuentran a $h/2$ de la barrera.

Estos nodos no requieren conexión con la malla gruesa ya que se valoran mediante inducción hacia atrás estándar dentro de la propia malla fina.

1. **Geometría Fina:** Usar paso de precio $h_{fine} = h/2$ y paso de tiempo $k_{fine} = k/4$.
2. **Probabilidades Finas:** Calcular p'_u, p'_m, p'_d usando las fórmulas estándar trinómicas con h_{fine} y k_{fine} .
3. **Recursión:**

$$V(B_{1,j}) = e^{-r(k/4)} [p'_u V(B_2, j+1) + p'_m V(B_1, j+1) + p'_d V(B_0, j+1)] \quad (7.11)$$

Este proceso se repite retrocediendo desde el vencimiento T (o desde el final del bloque injertado) hasta llegar a $t = 0$, obteniendo finalmente el valor en el nodo $B_{1,0}$, que corresponde al precio exacto de la opción con alta precisión.

Valoración Backward y Recursividad

Una vez establecidas las probabilidades de transición y las reglas de interfaz, el proceso de valoración se ejecuta mediante un algoritmo secuencial estricto. A diferencia de un árbol estándar que se resuelve en un solo barrido desde T hasta 0, el AMM requiere una valoración por etapas jerárquicas.

Fase 1: Resolución de la Malla Gruesa (Conjunto A) El algoritmo comienza resolviendo completamente la malla base, ignorando temporalmente la existencia de la malla fina.

1. Se inicializan los valores terminales en $t = T$ para todos los nodos $A_{i,N}$ basándose en el payoff de la opción: $\max(S - K, 0)$ o $\max(K - S, 0)$.
2. Se ejecuta la inducción hacia atrás (*backward induction*) estándar hasta $t = 0$, aplicando la condición de barrera en cada paso: si un nodo $A_{i,j}$ cae por debajo de la barrera (en el caso de down-and-out), su valor se fuerza a 0 (o al valor del Rebate).
3. Resultado: Al finalizar esta fase, tenemos una matriz de valores $V(A_{i,j})$ que servirá como fuente de datos (“oráculo”) para los niveles inferiores.

Fase 2: Inyección de Valores en la Frontera Fina Antes de resolver la malla fina, debemos poblar sus bordes utilizando los datos de la Fase 1. El código debe iterar sobre cada paso de tiempo grueso j y calcular los valores de los nodos de interfaz $B_{2,*}$ (el “techo” de la malla fina).

El bucle debe manejar la interpolación temporal descrita en la sección anterior:

- Para los nodos B que coinciden con tiempos $A(t, t+k, \dots)$, se copia el valor directamente desde la malla gruesa. La calibración de la Ec. 7.1 garantiza que los nodos espaciales estén perfectamente alineados, por lo que no se requiere ningún tipo de interpolación espacial.
- Para los nodos intermedios $(t + k/4, t + 2k/4, \dots)$, se ejecuta la función de proyección usando la Ecuación 7.10.

Fase 3: Resolución de la Malla Fina (Conjunto B) Con las condiciones de frontera superior ($B_{2,j}$ calculados en Fase 2) e inferior ($B_{0,j} = 0$ por la barrera), se resuelve el interior de la malla fina.

1. Se comienza en el vencimiento T (o en el punto donde la malla fina se une a la gruesa).
2. Se retrocede paso a paso con $\Delta t = k/4$.
3. En cada paso, se calcula el valor de los nodos internos $B_{1,j}$ utilizando las probabilidades trinomiales estándar de la malla fina y los valores de los tres nodos conectados en el paso $j + 1$.

Generalización Recursiva (Para $M > 1$) Si el modelo utiliza múltiples niveles de refinamiento ($M > 1$), este proceso se vuelve recursivo. La propiedad de isomorfismo del AMM permite que, una vez resuelta la malla de Nivel 1 (Nodos B), esta actúe como la “Malla Gruesa” para el Nivel 2 (Nodos C).

7.2.2. Detalles de Implementación

Estructuras de Datos y Memoria

Uno de los errores más comunes al implementar métodos de refinamiento de malla es instanciar una matriz global de alta resolución y dejar la mayoría de sus entradas vacías o inutilizadas. La eficiencia del AMM radica en que la malla fina es un “parche” local y no una estructura global. Por tanto, la gestión de memoria debe tratar las mallas como entidades separadas pero vinculadas.

Arquitectura de Almacenamiento Disperso En lugar de crear una matriz de tamaño $(4N \times 4N)$ que consumiría memoria cuadrática, la implementación debe utilizar dos estructuras distintas:

1. Matriz Base (A): Un array bidimensional de tamaño $(N + 1) \times (2N + 1)$ para almacenar los valores de la malla gruesa.
2. Matriz de Banda (B): Una estructura optimizada que almacena solo los nodos necesarios a lo largo de la barrera.

Para un modelo de barrera con un nivel de refinamiento ($M = 1$), la malla fina no cubre todo el espacio de precios, sino solo una franja estrecha adyacente a H . Según el análisis de complejidad, la cantidad de nodos adicionales es lineal respecto al tiempo:

$$Nodos_{adicionales} = 10 \times N \quad (7.12)$$

Donde N es el número de pasos de tiempo de la malla gruesa.

Recomendación de Implementación: Representar la malla fina B como una matriz de dimensiones $(3 \times 4N)$.

- La dimensión vertical es 3 porque solo necesitamos calcular los nodos en los niveles $h/2$ (interno), h (frontera superior) y 0 (barrera/frontera inferior).

- La dimensión horizontal es $4N$ porque la resolución temporal es cuatro veces mayor.

Esto reduce el consumo de memoria drásticamente en comparación con refinar todo el árbol.

Complejidad Computacional y Escalabilidad La ventaja crítica del AMM debe documentarse en esta sección. Al añadir niveles de profundidad, el número de nodos crece, pero de manera controlada.

Para un nivel de profundidad m , el número de nodos nuevos añadidos por cada paso de tiempo grueso es:

$$\Delta \text{Nodos}(m) = 10 \times 4^{m-1} \quad (7.13)$$

Esto implica que para un árbol estándar de $N = 100$ pasos (aprox. 10,000 nodos totales):

- **AMM Nivel 1:** Añade solo 1,000 nodos (incremento del 10%). *Total $\approx 11,200$ nodos.*
- **Equivalente Estándar (Refinado Global):** Para obtener la misma resolución espacial cerca de la barrera sin AMM, se requeriría cuadruplicar N a 400. Esto generaría aprox. 160,000 nodos.

El código debe reflejar esta eficiencia: el tiempo de ejecución para el AMM debe ser comparable al del árbol trinomial base, mientras que el error de convergencia se reduce cuadráticamente.

Código Relevante

La implementación del AMM requiere traducir las ecuaciones de probabilidad ajustada y la lógica recursiva en estructuras de control eficientes. A continuación se presentan los tres componentes críticos que permiten la convergencia estable del modelo.

1. Calibración Geométrica y Parámetro de Estiramiento Para garantizar la estabilidad numérica descrita por Figlewski y Gao (1999), el paso de tiempo k no puede ser arbitrario; debe derivarse del paso de precio h para mantener el parámetro de estiramiento $j \approx 3$. El siguiente snippet muestra cómo se fuerza esta restricción para obtener un número entero de pasos N .

Listing 7.2: Cálculo de pasos de tiempo enteros (Eq. 17)

```
def calibrar_geometria(S0, H, T, sigma, M):
    distancia = |log(S0) - log(H)|

    # Eq. 18: El paso de precio crece exponencialmente con M
    h_coarse = (2**M) * distancia

    # Eq. 11 y 17: Ajuste del paso de tiempo para j=3
    # Se redondea N al entero mas cercano para evitar pasos fraccionarios
    N_ideal = (T * 3 * sigma**2) / (h_coarse**2)
```

```

N_steps = int(N_ideal)

k_coarse = T / N_steps
return h_coarse, k_coarse, N_steps

```

2. Probabilidades de Transición en la Interfaz La mayor complejidad del AMM reside en los nodos “colgantes” de la interfaz (Fila 2 de la malla fina). A diferencia de los nodos estándar, estos requieren probabilidades que varían según su distancia temporal al siguiente nodo grueso, tal como se define en la Ecuación (12).

Listing 7.3: Cálculo dinámico de probabilidades para nodos de interfaz

```

def calcular_probs(dt_eff, dx, r, q, sigma):
    """
    Calcula probabilidades para sub-pasos  $k/4$ ,  $2k/4$ ,  $3k/4$ .  $dt\_eff$ :
    Tiempo restante hasta el proximo nodo grueso ( $T$ ,  $T-k/4\dots$ )
    """
    drift = r - q - 0.5 * sigma**2

    # Terminos de la Ecuacion (12)
    term1 = (sigma**2 * dt_eff) / (dx**2)
    term2 = (drift**2 * dt_eff**2) / (dx**2)
    term3 = (drift * dt_eff) / dx

    pu = 0.5 * (term1 + term2 + term3)
    pd = 0.5 * (term1 + term2 - term3)
    pm = 1.0 - pu - pd

    return pu, pm, pd

```

3. El Bucle de Refinamiento Recursivo Este bucle es la implementación práctica de la propiedad de isomorfismo del AMM. Como el modelo es isomorfo, se pueden añadir niveles sucesivos de refinamiento aplicando exactamente el mismo procedimiento matemático. En el código, esto se refleja en cómo el bucle toma la malla fina recién generada y la convierte en la “malla gruesa” de la siguiente iteración (`current_grid = fine_grid`).

Listing 7.4: Generalización recursiva y bucle de refinamiento

```

def Resolver_AMM(S0, K, T, r, q, sigma, H, M):
    # 1. CALIBRACION GLOBAL (Para la malla mas profunda)
    h_coarse_base, k_base, N_base = calibrar_geometria(
        S0, H, T, sigma, M)

    # 2. CONSTRUIR MALLA BASE (NIVEL 0)
    A_grid = build_coarse_mesh(S0, K, T, r, q, sigma, H,
        h_coarse_base, k_base, N_base)

    # 3. BUCLE DE REFINAMIENTO (NIVEL 1 hasta M)
    current_grid = A_grid

```

7.2. ÁRBOLES TRINOMIALES CON MALLAS ADAPTATIVAS

```
current_h, current_k, current_N = h_coarse_base, k_base, N_base

for level in range(1, M + 1):
    # La nueva malla fina se "injerta" en la actual
    fine_grid = build_fine_mesh(current_grid, current_h,
                                current_k, current_N, r,
                                q, sigma, H, K)

    current_grid = fine_grid # La fina de hoy es la gruesa de mañana
    current_h, current_k, current_N = actualizar_parametros(...)

return current_grid[1, 0] # Retornar el valor actual (t=0) del nodo central

def build_coarse_mesh(S0, K, T, r, q, sigma, H, h, k, N):
    # Eq. 9 para malla gruesa
    pu_A, pm_A, pd_A = calcular_probs(k, h, r, q, sigma)

    A_grid = initialize_coarse_mesh()
    A_grid[max_price_nodes, N] = actualizar_payoff_terminal(...)
    A_grid[:, 0:N-1] = Standard_Backward_Induction(...)
    return A_grid

def build_fine_mesh(coarse_grid, h_coarse, k_coarse,
                    N_coarse, r, q, sigma, H, K):
    total_fine_steps = N_coarse * 4
    B_grid = initialize_fine_mesh()

    # 1. INYECCION DE NODOS (Eq. 11)
    for j in range(N_coarse): # Logica de interpolacion (Eq. 12 y 13)
        t_start = j * 4

        # El source siempre es la malla previa
        B_grid[2, t_start] = coarse_grid[1, j]

        # Nodos intermedios (Interpolacion)
        V_Ad, V_Am, V_Au = coarse_grid[:, j+1]

        for sub_step in range(1, 4):
            # Distancia efectiva a proximo A
            dt_eff = (4 - sub_step) * (k_coarse / 4)
            pu_adj, pm_adj, pd_adj = calcular_probs(dt_eff, h_coarse, r, q, sigma)

            # Valorar usando los nodos A del FUTURO
            B_grid[2, t_start + sub_step] = (pu_adj * V_Au +
                                                pm_adj * V_Am +
                                                pd_adj * V_Ad) * np.exp(-r * dt_eff)

    # 2. RELLENO INTERNO (Backward Induction)
    h_fine, k_fine = h_coarse / 2, k_coarse / 4
    pu, pm, pd = calcular_probs(k_fine, h_fine, r, q, sigma)
```

```

B_grid[2, total_fine_steps] = coarse_grid[1, N_coarse]
B_grid[:, total_fine_steps] = actualizar_payoff_terminal(...)
B_grid[:, 0:total_fine_steps-1] = Standard_Backward_Induction(...)
return B_grid

```

Esta estructura garantiza que la información fluya correctamente desde la resolución más baja hacia la más alta (flujo *downward* para barreras), permitiendo obtener el precio de alta precisión en $t = 0$.

7.2.3. Validación

Para verificar la corrección de la implementación y demostrar la superioridad del AMM sobre los árboles estándar, se realizaron pruebas de convergencia comparando los resultados del modelo contra la solución analítica cerrada para opciones de barrera continua.

Metodología de Validación (Benchmark)

Es crucial notar que el AMM converge a la solución de tiempo continuo, no a la discreta. Por lo tanto, el benchmark correcto no es un árbol binomial de pasos altos, sino la fórmula de Merton (1973) para opciones down-and-out call:

$$C_{teo} = C_{BS}(S_0, K) - \left(\frac{H}{S_0}\right)^{2\lambda} C_{BS}(H^2/S_0, K) \quad (7.14)$$

Donde $\lambda = \frac{r-q-\sigma^2/2}{\sigma^2}$ y C_{BS} es la fórmula estándar de Black-Scholes.

Prueba de Estrés: El Problema del Límite

Se evaluó el desempeño del modelo en el escenario crítico donde el precio inicial S_0 está extremadamente cerca de la barrera, una situación donde los métodos tradicionales fallan por falta de resolución o inestabilidad numérica.

Configuración del Experimento:

- Barrera $H = 90$, Strike $K = 100$, $T = 1$, $\sigma = 0,25$, $r = 0,1$.
- Precio Inicial Crítico: $S_0 = 90,125$ (Distancia de 0,14 % a la barrera).

Resultados Comparativos:

Análisis: Como se observa en la Tabla 7.1, el árbol estándar es incapaz de valorar la opción con una malla razonable porque el paso de precio mínimo es mayor que la distancia $S_0 - H$. El AMM con $M = 4$ logra una precisión de 4 decimales manteniendo el costo computacional bajo ($N = 100$ pasos base), resolviendo efectivamente el problema del límite mediante la inserción local de nodos.

Análisis de Eficiencia

Las pruebas de tiempo de ejecución confirman que el costo computacional del AMM escala linealmente. Añadir un nivel de refinamiento incrementa el tiempo de cálculo en aproximadamente un factor constante pequeño (correspondiente a

7.2. ÁRBOLES TRINOMIALES CON MALLAS ADAPTATIVAS

Tabla 7.1: Comparación de convergencia cerca de la barrera ($S_0 = 90,125$).

Método	Timesteps (N)	Valor Calculado	Err. Relativo
Solución Exacta (Merton)	-	$\approx 0,161648$	-
Árbol Trinomial ($M = 0$)	N/A	<i>Fallo (Oscilación)</i>	$> 100 \%$
AMM Nivel 2 ($M = 2$)	6083	0,161312	0,21 %
AMM Nivel 4 ($M = 4$)	380	0,161532	0,07 %

valorar la franja de 3 filas), en contraste con el factor de $\times 16$ (4^2) que requeriría refinar todo el árbol globalmente. Esto valida la eficiencia del método para aplicaciones en tiempo real.

7.3. Replicación Estática

En esta sección se detalla el procedimiento computacional utilizado para implementar la metodología de replicación estática descrita teóricamente en el capítulo 3. El objetivo es construir un portafolio de opciones estándar cuyos valores en la frontera coincidan con los de una opción barrera objetivo.

7.3.1. Descripción del Algoritmo

El algoritmo implementado se basa en un proceso recursivo de “inducción hacia atrás” (backward induction), discretizando el tiempo de vida de la opción en N intervalos.

Selección de Strikes

Para garantizar que los instrumentos de cobertura no generen flujos de caja no deseados dentro de la región de validación, la selección de los precios de ejercicio (K) se automatiza siguiendo las reglas de frontera de Derman-Ergener-Kani:

- Para la frontera de vencimiento ($t = T$): Se utilizan opciones con el mismo strike que la opción original para replicar el payoff estándar.
- Para barreras superiores ($B > S_0$): Se seleccionan opciones Call con $K = B$. Esto asegura que si $S < B$, la opción expira out-of-the-money y no altera el valor del portafolio.
- Para barreras inferiores ($B < S_0$): Se seleccionan opciones Put con $K = B$.

Cálculo de Pesos

El algoritmo calcula los pesos (w_i o α_i) iterando desde el vencimiento hacia el presente. Sea t_i los puntos discretos en el tiempo donde se ajusta la frontera:

1. Inicialización ($t_N = T$): Se establece el portafolio inicial igualando el pago de la opción al vencimiento. 2. Bucle Recursivo ($i = N - 1, \dots, 1$):

- Se calcula el valor del portafolio acumulado (V_{port}) en el punto de la barrera (B, t_i).
- Se calcula el valor teórico de la opción objetivo (V_{target}) en ese mismo punto (generalmente 0 para knock-out o el valor del rebate).
- Se determina el peso de la nueva opción de ajuste (C_{ajuste}) mediante la fórmula discreta derivada del principio de replicación:

$$\alpha_i = \frac{V_{target}(B, t_i) - V_{port}(B, t_i)}{C_{ajuste}(B, t_i)} \quad (7.15)$$

Esta ecuación asegura que el error de valor en la frontera sea cero en el tiempo t_i .

7.3.2. Detalles de Implementación

Para la ejecución del modelo se asumen las condiciones estándar de Black-Scholes (volatilidad constante σ , tasa libre de riesgo r y dividendos d). La implementación requiere definir la granularidad de la discretización temporal, la cual afecta directamente la precisión de la réplica.

La frontera continua se aproxima mediante un conjunto finito de puntos de control (B, t_k) . En la práctica, esto implica que el portafolio solo garantiza la igualdad de valor exactamente en estos puntos. Si el activo subyacente toca la barrera entre dos puntos de control, existe un error de discretización teórico. Asimismo, el modelo asume que, al tocarse la barrera, el portafolio estático se liquida para cubrir la obligación o eliminar la posición, un proceso teóricamente libre de costos si la replicación es perfecta.

7.3.3. Validación del Portafolio Replicante

Para validar la eficacia del algoritmo, se compara el valor del portafolio estático resultante contra el valor teórico analítico de la opción objetivo (calculado mediante fórmulas cerradas estándar, como Rubinstein-Reiner para opciones barrera).

Comparación y Análisis de Convergencia

El análisis demuestra que la calidad de la replicación depende críticamente del número de instrumentos de cobertura utilizados (frecuencia de ajuste en la frontera).

Basado en los resultados de Derman y cols. (1994), se observa que:

- Replicación de baja frecuencia (6 opciones): Al ajustar la frontera cada 2 meses (6 puntos de contacto), el desajuste (mismatch) entre el portafolio y la opción objetivo puede ser significativo, alcanzando errores cercanos al 19 % del valor de la opción en regiones próximas a la barrera y cercanas al vencimiento.
- Replicación de alta frecuencia (24 opciones): Al aumentar la discretización a ajustes quincenales (24 puntos), el error de valor disminuye drásticamente. El perfil de valor del portafolio replicante converge hacia el de la opción barrera teórica, reduciendo el desajuste a niveles marginales (aprox. 0.10 en valor monetario frente a un valor objetivo de 2.00).

Esto confirma que, aunque una réplica perfecta requeriría infinitas opciones, una aproximación con un número finito (ej. 24) logra una convergencia robusta para fines prácticos.

Ejemplos Numéricos

Consideremos una opción Up-and-Out Call con los siguientes parámetros: $S_0 = 100$, Strike $K = 100$, Barrera $B = 120$, Vencimiento $T = 1$ año, Volatilidad $\sigma = 15\%$, $r = 5\%$.

1. Valor Objetivo: El valor teórico de esta opción es 1.913.

7.3. REPLICACIÓN ESTÁTICA

2. Portafolio (6 ajustes): Construido con 1 Call estándar ($K = 100$) y 6 Calls ($K = 120$) con vencimientos bimestrales.
 - El valor resultante del portafolio es 2,284.
 - Error: 0,37 (aprox. 19%). El error se concentra principalmente cerca de la barrera cuando falta poco tiempo para el vencimiento.
3. Portafolio (24 ajustes): Construido con ajustes cada 0.5 meses.
 - El valor resultante del portafolio es 2,01.
 - Error: 0,10 (aprox. 5%). La superficie de valor del portafolio es casi indistinguible de la opción objetivo.

Estos resultados validan que el método de replicación estática permite descomponer una opción exótica compleja en una suma lineal de opciones vanilla, facilitando su valoración y cobertura sin necesidad de rebalanceo dinámico continuo.

7.4. Monte Carlo para Opciones Americanas

Este capítulo documenta la implementación del método de Longstaff-Schwartz (LSM) para la valoración de opciones americanas con barreras mediante simulación de Monte Carlo.

7.4.1. Descripción del Algoritmo Implementado

Generación de Trayectorias

La generación de trayectorias del precio del activo subyacente se implementa usando la fórmula exacta del Movimiento Browniano Geométrico:

$$S_{t+\Delta t} = S_t \exp \left[\left(r - \delta - \frac{\sigma^2}{2} \right) \Delta t + \sigma \sqrt{\Delta t} Z \right] \quad (7.16)$$

donde $Z \sim N(0, 1)$ es una variable aleatoria normal estándar.

Parámetros de Discretización:

- **Número de simulaciones** M : Típicamente entre 10,000 y 100,000 trayectorias
- **Número de pasos temporales** N : Entre 50 y 252 pasos (días de trading anuales)
- **Paso temporal**: $\Delta t = T/N$

La implementación genera todas las trayectorias de forma vectorizada para eficiencia computacional:

```
dt = T / steps
z = np.random.standard_normal((iterations, steps))
log_returns = (r - delta - 0.5 * sigma**2) * dt + \
              sigma * np.sqrt(dt) * z
cumulative_log_returns = np.cumsum(log_returns, axis=1)
s_path = S0 * np.exp(np.hstack([np.zeros((iterations, 1)),
                                cumulative_log_returns]))
```

Monitoreo de Barrera

Para opciones con barreras, se monitorea en cada paso temporal si el precio ha cruzado el nivel de barrera H .

Knock-Out (Down-and-Out):

```
hit_barrier = np.any(s_path <= H, axis=1)
```

Knock-Out (Up-and-Out):

```
hit_barrier = np.any(s_path >= H, axis=1)
```

Knock-In: Se utiliza la lógica inversa, marcando las trayectorias que han activado la opción.

Sesgo de Discretización: El monitoreo discreto puede no detectar cruces que ocurren entre puntos de observación. Este sesgo se reduce aumentando N , aunque esto incrementa el costo computacional. Para aplicaciones que requieren alta precisión, se pueden usar técnicas de corrección de continuidad o métodos de Brownian bridge.

Método de Longstaff-Schwartz

El núcleo del algoritmo LSM implementa la inducción hacia atrás con regresión para estimar valores de continuación.

Paso 1: Inicialización al Vencimiento. Para cada trayectoria i , el valor al vencimiento es el payoff:

$$V_{t_N}^{(i)} = \max(K - S_{t_N}^{(i)}, 0) \quad (\text{para puts}) \quad (7.17)$$

```
cash_flow = np.maximum(K - s_path[:, -1], 0) # Put payoff
```

Paso 2: Inducción Hacia Atrás. Para cada tiempo t_j desde t_{N-1} hasta t_1 :

1. Descontar cash flows futuros:

```
cash_flow = cash_flow * np.exp(-r * dt)
```

2. Identificar trayectorias in-the-money:

$$\mathcal{I}_j = \{i : K - S_{t_j}^{(i)} > 0\} \quad (7.18)$$

```
intrinsic = np.maximum(K - s_path[:, t], 0)
itm = intrinsic > 0
```

3. Verificar estado de barrera:

```
hit_barrier = np.any(s_path[:, :t+1] <= H, axis=1)
active = itm & ~hit_barrier # ITM y no tocó barrera
```

4. Regresión de mínimos cuadrados:

Se realiza regresión solo sobre trayectorias activas para estimar el valor de continuación:

$$\min_{a_0, \dots, a_K} \sum_{i \in \mathcal{I}_j} \left[Y^{(i)} - \sum_{k=0}^K a_k L_k(S_{t_j}^{(i)}) \right]^2 \quad (7.19)$$

```
if np.sum(active) > 0:
```

```
    X = s_path[active, t]
    Y = cash_flow[active]
```

```
    # Regresión con polinomios (simples)
    regression = np.polyfit(X, Y, deg=2)
    continuation_value = np.polyval(regression, X)
```

```
    # Regresión con polinomios (Laguerre)
    # basis = laguerre_basis(X, degree=3) # Construye L_0, L_1, L_2, L_3
    # coeffs = np.linalg.lstsq(basis, Y, rcond=None)[0]
    # continuation = basis @ coeffs
```

5. Decisión de ejercicio óptimo:

$$V_{t_j}^{(i)} = \begin{cases} K - S_{t_j}^{(i)} & \text{si } K - S_{t_j}^{(i)} > C_{t_j}^{(i)} \\ e^{-r\Delta t} V_{t_{j+1}}^{(i)} & \text{en caso contrario} \end{cases} \quad (7.20)$$

```
exercise = intrinsic[active] > continuation_value
cash_flow[active][exercise] = intrinsic[active][exercise]
```

6. Anular trayectorias que tocaron barrera:

```
cash_flow[hit_barrier] = 0 # o rebate R si aplica
```

Paso 3: Valoración Final. El valor de la opción es el promedio descontado:

$$V(S_0, 0) \approx e^{-r\Delta t} \frac{1}{M} \sum_{i=1}^M \text{CashFlow}_i \quad (7.21)$$

```
option_value = np.exp(-r * dt) * np.mean(cash_flow)
```

7.4.2. Detalles de Implementación

La implementación se realiza en Python 3.8+ utilizando NumPy para operaciones vectorizadas. La arquitectura del código prioriza la eficiencia mediante operaciones matriciales que evitan bucles explícitos.

Lenguaje y Librerías**Dependencias principales:**

- **NumPy** (v2.4.1): Generación de números aleatorios, operaciones vectorizadas
- **scikit-learn** (opcional): Regresión lineal alternativa para LSM

Generador de números aleatorios:

```
rng = np.random.default_rng(seed=42) # Para reproducibilidad
z = rng.standard_normal((iterations, steps))
```

Funciones Base para Regresión

Se implementan dos tipos de funciones base para la regresión en el método LSM:

1. Polinomios Simples (más rápidos):

```
coeffs = np.polyfit(X, Y, deg=2)
continuation = np.polyval(coeffs, X)
```

2. Polinomios de Laguerre (más precisos):

```
def laguerre_basis(x, degree=3):
    L = np.ones((len(x), degree + 1))
    if degree >= 1:
        L[:, 1] = 1 - x
    for n in range(1, degree):
        L[:, n+1] = ((2*n+1-x)*L[:, n] - n*L[:, n-1]) / (n+1)
    return L

basis = laguerre_basis(X, degree=3)
coeffs = np.linalg.lstsq(basis, Y, rcond=None)[0]
continuation = basis @ coeffs
```

Optimizaciones Implementadas

Vectorización: Todas las operaciones sobre trayectorias usan broadcasting de NumPy, evitando bucles que degradarían el rendimiento 10-100x.

Regresión selectiva: Solo se ejecuta sobre trayectorias in-the-money activas, reduciendo el costo computacional típicamente en 30-50 %.

Gestión de memoria: Para $M = 100,000$ con $N = 252$, la matriz ocupa ~200 MB en float64. Si es necesario, usar float32 (100 MB) con pérdida mínima de precisión.

Tiempos de Ejecución

Tiempos típicos (CPU Intel i7, single-thread):

Tabla 7.2: Tiempos de ejecución para opciones americanas con barrera

Simulaciones (M)	Pasos (N)	Tiempo
10,000	50	22 ms
50,000	100	193 ms
100,000	252	728 ms

7.4.3. Validación de Monte Carlo

Análisis de Convergencia

Se analiza la convergencia del método respecto a dos parámetros clave usando una American Down-and-Out Put con parámetros: $S_0 = 44$, $K = 40$, $H = 39,6$, $T = 1$, $r = 0,06$, $\sigma = 0,2$.

1. Convergencia respecto al número de simulaciones M :

El error estándar teórico es $SE = \sigma/\sqrt{M}$, donde σ es la desviación estándar de los payoffs. Los resultados empíricos con $N = 50$ pasos temporales son:

Tabla 7.3: Convergencia del error estándar respecto al número de simulaciones

Simulaciones (M)	Error Estándar
1,000	0.003069
5,000	0.001363
10,000	0.000952
50,000	0.000420
100,000	0.000298

Se verifica que el error decrece aproximadamente como $O(1/\sqrt{M})$: al multiplicar M por 4, el error se reduce a la mitad, confirmando la teoría.

2. Convergencia respecto al número de pasos temporales N :

Para opciones con barreras, aumentar N reduce el sesgo de discretización en el monitoreo de la barrera. Se recomienda usar al menos $N = 50$ para barreras cercanas al precio inicial y $N = 100 - 252$ para aplicaciones que requieren alta precisión.

Intervalos de Confianza

El intervalo de confianza al 95 % se calcula como:

$$IC_{95\%} = \bar{V} \pm 1,96 \cdot \frac{\hat{\sigma}}{\sqrt{M}} \quad (7.22)$$

donde $\bar{V}$ es el precio estimado y $\hat{\sigma}$ es la desviación estándar muestral de los payoffs descontados.

Ejemplos Numéricos

Se presentan dos casos de prueba para validar la implementación y demostrar el cálculo de intervalos de confianza.

Caso 1: American Down-and-Out Put

Parámetros: $S_0 = 100$, $K = 100$, $H = 80$, $T = 1$ año, $r = 0,05$, $\sigma = 0,25$, $M = 50,000$, $N = 100$.

```
price , std = monte_carlo_lsm_barrier(  
    S0=100, K=100, H=80, T=1, r=0.05, sigma=0.25,  
    iterations=50000, steps=100,  
    isCall=False, isUp=False, isIn=False  
)
```

Resultados obtenidos:

- Precio estimado: $V = 7,5064$
- Error estándar: $SE = 0,0304$
- Intervalo de confianza 95 %: $[7,4469, 7,5660]$
- Ancho del intervalo: $0,1191$

Caso 2: American Up-and-In Call

Parámetros: $S_0 = 100$, $K = 100$, $H = 120$, $T = 1$ año, $r = 0,05$, $\sigma = 0,30$, $M = 50,000$, $N = 100$.

```
price, std = monte_carlo_lsm_barrier(  
    S0=100, K=100, H=120, T=1, r=0.05, sigma=0.30,  
    iterations=50000, steps=100,  
    isCall=True, isUp=True, isIn=True  
)
```

Resultados obtenidos:

- Precio estimado: $V = 13,8092$
- Error estándar: $SE = 0,1025$
- Intervalo de confianza 95 %: $[13,6083, 14,0101]$
- Ancho del intervalo: 0,4018

Interpretación de los Resultados:

- El IC 95 % indica que hay 95 % de probabilidad de que el valor verdadero esté dentro del intervalo calculado
- El Caso 2 tiene un IC más ancho (0,4018 vs 0,1191) debido a mayor varianza en los payoffs (mayor $\sigma = 0,30$ y naturaleza knock-in)
- Para reducir el ancho del IC a la mitad, se necesitan 4 veces más simulaciones (debido a la convergencia $O(1/\sqrt{M})$)
- El precio del Up-and-In Call (13,81) es mayor que el Down-and-Out Put (7,51), reflejando la mayor volatilidad y el drift positivo de la tasa libre de riesgo

Verificación de Límites:

Para validar la implementación, se verifica que cuando la barrera está muy lejos del precio inicial, el precio de una opción con barrera converge al de una opción americana vanilla (sin barrera). Se utiliza una American Put con parámetros: $S_0 = 100$, $K = 100$, $T = 1$, $r = 0,05$, $\sigma = 0,25$, $M = 50,000$, $N = 100$.

Tabla 7.4: Convergencia al límite vanilla cuando la barrera se aleja

Tipo de Opción	Precio	Diferencia vs Vanilla
Vanilla ($H=0.01$, imposible)	7.8819	—
Down-and-Out ($H=50$)	7.8815	0.0005
Down-and-Out ($H=10$)	7.8819	0.0000

Los resultados confirman que:

- Con $H = 10$ (muy por debajo de $S_0 = 100$), la diferencia es prácticamente nula (0.0000)
- Con $H = 50$ (lejana pero no extrema), la diferencia es mínima (0.0005)
- Esto valida que la implementación maneja correctamente los casos límite
- La opción vanilla se simula usando $H = 0,01$ con knock-out, garantizando que la barrera nunca se toca

Capítulo 8

Resultados y Comparación

8.1. Diseño de Experimentos

Para evaluar de manera rigurosa las metodologías implementadas en este trabajo, el diseño experimental se ha estructurado en torno a los desafíos matemáticos específicos que presenta cada tipo de opción. En lugar de utilizar un único conjunto de parámetros arbitrario, los experimentos se basan en los escenarios propuestos por la literatura fundacional de cada modelo. Esto permite no solo validar la correctitud de nuestras implementaciones, sino también aislar y medir el impacto del “problema del límite”, el error de discretización temporal y la convergencia estadística de manera independiente.

8.1.1. Casos de Prueba para Opciones Europeas

La evaluación de las opciones de estilo europeo se divide en dos grandes escenarios, diseñados para contrastar los métodos numéricos frente a las fórmulas exactas de Reiner y Rubinstein.

El primer escenario está diseñado para llevar al extremo el error de no linealidad y el problema geométrico de las redes discretas. Para ello, evaluamos una opción Down-and-Out Call con un precio de ejercicio $K = 100$, una barrera inferior $H = 90$, vencimiento a un año ($T = 1$), tasa libre de riesgo del 10 % y volatilidad del 25 %. El experimento consiste en calcular el valor de la opción acercando progresivamente el precio inicial del activo (S_0) hacia la barrera (desde $S_0 = 92$ hasta $S_0 = 90,125$). Este diseño nos permitirá observar cómo el árbol trinomial estándar colapsa computacionalmente al intentar alinear sus nodos con la barrera y cómo el Modelo de Malla Adaptativa (AMM) resuelve esta crisis.

El segundo escenario se enfoca en el problema de la cobertura en el mercado real, evaluando el algoritmo de Replicación Estática. Utilizaremos una opción Up-and-Out Call con $S_0 = 100$, $K = 100$, una barrera superior $H = 120$, vencimiento $T = 1$, tasa de interés del 5 %, rendimiento por dividendos del 3 % y volatilidad del 15 %. En este caso, el objetivo no es variar el precio inicial, sino alterar la frecuencia temporal con la que construimos el portafolio de opciones vanilla de cobertura (comparando ajustes bimestrales frente a quincenales) para medir cómo la discretización del tiempo afecta el costo real de replicar la opción exótica.

8.1.2. Casos de Prueba para Opciones Americanas

Dado que la valoración de opciones americanas introduce el problema del ejercicio anticipado, el diseño experimental para la simulación de Monte Carlo requiere un enfoque distinto. Para aislar el efecto de la regresión transversal introducida por el método de Longstaff-Schwartz (LSM), el caso de prueba se basará en una opción Put americana estándar, evitando temporalmente la interferencia de una barrera.

Los parámetros base establecen un precio de ejercicio $K = 40$, una tasa libre de riesgo del 6 % y una volatilidad del 20 %. Evaluaremos la opción para dos horizontes temporales distintos ($T = 1$ y $T = 2$ años) y bajo tres condiciones de moneyness inicial: in-the-money ($S_0 = 36$), at-the-money ($S_0 = 40$) y out-of-the-money ($S_0 = 44$). Este abanico de escenarios garantiza que el algoritmo de regresión del LSM, basado en polinomios de Laguerre, sea puesto a prueba en trayectorias donde la decisión de ejercicio temprano es trivial frente a aquellas donde el valor de continuación y el valor intrínseco son casi idénticos.

8.1.3. Métricas de Evaluación

Para garantizar una comparación objetiva entre los distintos métodos, definimos un conjunto estandarizado de métricas que capturan tanto la precisión matemática como la viabilidad computacional. La exactitud de los métodos para opciones europeas (AMM y Replicación Estática) se cuantifica mediante el error absoluto y el error relativo tomando como “oráculo” o valor real el resultado arrojado por las ecuaciones analíticas de Reiner y Rubinstein. En el caso de la simulación de Monte Carlo para opciones americanas, al no existir una fórmula cerrada, la convergencia se evalúa analizando el error estándar estadístico de la simulación a medida que se aumenta el número de trayectorias (desde 1,000 hasta 100,000 caminos). Finalmente, la eficiencia algorítmica se evalúa de forma dual. Por un lado, se registra el tiempo de ejecución (CPU time) necesario para alcanzar un nivel de precisión aceptable. Por otro lado, y de manera más fundamental, se analiza la complejidad espacial, medida a través del número total de nodos instanciados en el caso de los árboles (donde contrastamos el crecimiento lineal del AMM frente al crecimiento cuadrático del trinomial global) y el número de opciones de ajuste necesarias en el caso del portafolio estático.

8.2. Resultados para Opciones Europeas

8.2.1. Superando el “Problema del Límite”: AMM vs. Trinomial Estándar

La valoración de opciones barrera mediante redes discretas enfrenta un desafío geométrico crítico cuando el precio inicial del activo subyacente se encuentra muy cerca del nivel de la barrera. Como se explicó en capítulos anteriores, para evitar errores severos de estimación, los modelos de árbol requieren que una capa horizontal de nodos coincida exactamente con la barrera. Sin embargo, forzar esta alineación implica que el tamaño del paso de precio (h) no puede ser mayor que la distancia entre el precio inicial y la barrera. Dado que el paso de tiempo (k) debe ser proporcional al cuadrado del paso de precio para mantener la estabilidad probabilística, reducir h provoca que el número total de pasos

8.2. RESULTADOS PARA OPCIONES EUROPEAS

de tiempo (N) crezca de manera cuadrática. Este fenómeno, conocido como el “problema del límite”, puede volver al método estándar computacionalmente inmanejable.

Para ilustrar este comportamiento y evaluar la solución propuesta por el Modelo de Malla Adaptativa (AMM), calculamos el valor de una opción Down-and-Out Call (con strike $K = 100$, barrera $H = 90$, volatilidad $\sigma = 25\%$, tasa $r = 10\%$ y vencimiento $T = 1$ año) acercando progresivamente el precio inicial (S_0) hacia la barrera. La Tabla 8.1 contrasta el valor arrojado por las fórmulas analíticas de Reiner y Rubinstein (como valor exacto de referencia) frente a los resultados y requerimientos computacionales del árbol trinomial estándar y del AMM.

Tabla 8.1: Comparación de métodos numéricos para valoración de Down-and-Out Call cerca de la barrera. Los parámetros son: $K = 100$, $H = 90$, $T = 1$ año, $r = 0,10$, $d = 0,05$, $\sigma = 0,25$.

Precio Inicial (S_0)	Valor Analítico (R&R)	Trinomial Estándar (Valor / Pasos N)	AMM (Valor / Nivel M)
92.000	2.506	2.507 (N=388)	2.507 (M=0)
91.000	1.274	1.274 (N=1,535)	1.274 (M=1)
90.500	0.642	0.642 (N=6,108)	0.643 (M=2)
90.250	0.323	0.323 (N=24,367)	0.323 (M=3)
90.125	0.162	Falla / Inmanejable	0.162 (M=4)

El análisis de estos resultados expone claramente la vulnerabilidad del enfoque tradicional. Cuando el precio del activo se encuentra a una distancia segura de la barrera ($S_0 = 92$), ambos métodos logran converger al valor teórico de 2,506 con un costo computacional bajo. No obstante, a medida que S_0 se acerca a 90, el árbol trinomial estándar sufre una explosión combinatoria. Al llegar a $S_0 = 90,125$ (apenas a un octavo de punto de la barrera), forzar un nodo sobre $H = 90$ exige un paso de precio minúsculo, disparando la cantidad de pasos de tiempo teóricos a casi 100,000 iteraciones. En este punto, la creación de la matriz global del árbol colapsa la memoria o requiere tiempos de ejecución inaceptables, provocando el fallo práctico del método. En marcado contraste, el comportamiento del AMM demuestra una eficiencia notable. Al mantener una red base gruesa (por ejemplo, $N = 100$) y resolver el requerimiento de distancia injertando niveles sucesivos de malla fina (M) únicamente en la franja adyacente a la barrera, el AMM desvincula la resolución espacial de la complejidad global del árbol. Para el caso extremo de $S_0 = 90,125$, al aplicar 4 niveles de refinamiento ($M = 4$), el AMM es capaz de capturar la no linealidad y calcular el precio exacto de 0,162 en fracciones de segundo. En conclusión, este experimento demuestra que el AMM actúa como una solución quirúrgica: no desperdicia poder de cómputo en regiones donde el precio del activo se comporta de forma lineal. Al concentrar la resolución exclusivamente donde la geometría de la barrera lo exige, el modelo supera el “problema del límite” y garantiza tasaciones precisas incluso en los escenarios más críticos.

8.2.2. Convergencia y Costo de la Replicación Estática

A diferencia del Modelo de Malla Adaptativa, que busca resolver numéricamente la ecuación diferencial subyacente con la mayor exactitud posible, la metodología de Replicación Estática de Derman, Ergener y Kani aborda el problema desde la perspectiva de la cobertura en el mercado (hedging). En este contexto, el valor calculado no es simplemente una aproximación matemática, sino el costo real de construir un portafolio compuesto por opciones vanilla que imite el comportamiento de la opción exótica. Por lo tanto, el error numérico en este método representa el “desajuste” o mismatch financiero al que se expone el emisor por discretizar la frontera de la barrera en intervalos de tiempo finitos. Para evaluar este comportamiento, consideramos una opción Up-and-Out Call con un precio inicial $S_0 = 100$, un precio de ejercicio $K = 100$ y una barrera superior $H = 120$, con vencimiento a un año ($T = 1$), tasa libre de riesgo del 5 % y volatilidad del 15 %. De acuerdo con las fórmulas analíticas de Reiner y Rubinstein, el valor teórico exacto de esta opción es 1,913. El experimento consiste en construir el portafolio replicante variando la frecuencia con la que se añaden opciones estándar para forzar que el valor del portafolio sea cero sobre la barrera. La Tabla 8.2 muestra el costo de estos portafolios y su error respecto al valor teórico.

Tabla 8.2: Convergencia de la Replicación Estática: efecto del número de opciones de ajuste

Método de Valoración / Cobertura	Valor Calculado	Error Absoluto	Error Relativo
Valor Teórico Objetivo (R&R)	1.913	—	—
Portafolio (6 ajustes / frec. bimestral)	2.284	+0.371	$\approx 19.4\%$
Portafolio (24 ajustes / frec. quincenal)	2.010	+0.097	$\approx 5.0\%$

El análisis de estos resultados revela el impacto directo de la discretización temporal en la gestión de riesgos. Si el emisor de la opción decide cubrirse realizando ajustes estáticos en la frontera solo cada dos meses (requiriendo un portafolio de 6 opciones), el costo de armar dicha cobertura es de 2,284, lo que sobreestima el valor real de la opción en casi un 20 %. Este sobre costo ocurre porque el portafolio garantiza que su valor será cero únicamente en las fechas de ajuste. Si el precio del activo cruza la barrera de 120 en un día intermedio entre dos ajustes, el portafolio no se anulará perfectamente, dejando al emisor con un riesgo residual. El mercado cobra una prima por asumir la imprecisión de esta cobertura discreta. Sin embargo, a medida que aumentamos la densidad del portafolio utilizando 24 opciones con vencimientos quincenales, la frontera discreta se aproxima mucho más a la barrera continua real. Como resultado, el valor del portafolio cae a 2,010, reduciendo el error relativo a un marginal 5 %. Esto demuestra empíricamente que la Replicación Estática converge de manera robusta y predecible hacia el valor teórico a medida que aumenta la granularidad de la discretización, permitiendo a los operadores equilibrar el costo de transacción (comprar más opciones) frente al riesgo de desajuste.

8.2.3. Comparación Unificada: Precisión Numérica frente a Viabilidad de Mercado

Para consolidar el análisis de las opciones de estilo europeo, resulta sumamente ilustrativo contrastar el desempeño de los tres métodos estudiados (Reiner-Rubinstein, AMM y Replicación Estática) bajo un mismo escenario base. Esta comparación unificada, presentada en la Tabla 8.3 utilizando los parámetros del experimento anterior, pone en evidencia las diferencias fundamentales en la naturaleza y propósito de cada algoritmo.

Tabla 8.3: Comparación Unificada de Métodos para Opciones Europeas

Método de Valoración	Enfoque Principal	Valor Calculado	Err. Abs. vs R&R
R&R	Teórico Exacto (Oráculo)	1.913	—
AMM	Precisión Numérica (Nivel M=2)	1.913	<0.001
Replicación Estática	Cobertura de Mercado (24 ajustes)	2.010	+0.097

La tabla ilustra que no existe un método de valoración que sea superior en el vacío; su utilidad depende del problema que el analista intente resolver. Las fórmulas de Reiner y Rubinstein actúan como el valor teórico fundamental, asumiendo condiciones perfectas y continuas. Cuando el objetivo es la tasación algorítmica pura, el Modelo de Malla Adaptativa demuestra ser una herramienta de una precisión y eficiencia extraordinarias: al injertar la red de alta resolución únicamente cerca de la barrera de 120, el modelo logra colapsar el error geométrico casi por completo, replicando el valor analítico de 1,913 al tercer decimal en fracciones de segundo. Por el contrario, el valor de 2,010 arrojado por la Replicación Estática no debe ser interpretado simplemente como un “cálculo inexacto”. Representa el límite de viabilidad del mercado: es la respuesta concreta a cuánto cuesta replicar esa opción exótica utilizando instrumentos financieros reales y discretos, asumiendo que el monitoreo continuo es fácticamente imposible.

8.3. Resultados para Opciones Americanas

8.3.1. Estimación del Valor de Continuación (LSM)

Para aislar el efecto estadístico de la regresión y evaluar la precisión del algoritmo LSM al capturar la prima por ejercicio anticipado, el experimento se enfoca en una opción Put americana estándar. Se compara el valor obtenido por la simulación frente a un método riguroso de Diferencias Finitas implícitas (utilizado como valor de referencia exacto). Los parámetros base establecen un precio de ejercicio $K = 40$, tasa libre de riesgo del 6 %, volatilidad del 20 % y un esquema de simulación LSM con 100,000 trayectorias (50,000 antitéticas) con 50 pasos temporales por año, utilizando los primeros tres polinomios de Laguerre como funciones base. La Tabla 8.4 muestra los resultados para horizontes de uno y dos años bajo diferentes condiciones de moneyness inicial.

8.3. RESULTADOS PARA OPCIONES AMERICANAS

Tabla 8.4: Comparación de Valoración para Put Americana (Diferencias Finitas vs. LSM). Parámetros: $K = 40$, $r = 0,06$, $\sigma = 0,20$. Simulación LSM con 100,000 trayectorias, 50 pasos temporales por año, 3 polinomios de Laguerre.

Vencimiento	Precio Inicial (S_0)	Dif. Finitas (Referencia)	LSM (Simulación)	SE	Diferencia Absoluta
$T = 1$	36 (ITM)	4.478	4.472	0.010	-0,006
$T = 1$	40 (ATM)	2.314	2.313	0.009	-0,001
$T = 1$	44 (OTM)	1.110	1.118	0.007	+0,008
$T = 2$	36 (ITM)	4.840	4.821	0.012	-0,019
$T = 2$	40 (ATM)	2.885	2.879	0.010	-0,006
$T = 2$	44 (OTM)	1.690	1.675	0.009	-0,015

El análisis de esta tabla confirma la extraordinaria capacidad del algoritmo LSM para estimar el valor de continuación utilizando información transversal de trayectorias aleatorias. Para opciones a un año ($T = 1$), las estimaciones por simulación difieren del valor de diferencias finitas en menos de un centavo, lo cual cae holgadamente dentro de los márgenes del spread bid-ask (oferta-demanda) de los mercados reales. Además, se observa que las diferencias son tanto positivas como negativas, lo que sugiere que la aproximación no sufre de un sesgo sistemático severo que subestime la opción de manera inaceptable. El algoritmo demuestra ser igualmente robusto independientemente de si la opción inicia in-the-money o out-of-the-money, lo que valida la elección de los polinomios de Laguerre para modelar la frontera de ejercicio temprano

8.3.2. Análisis de Convergencia Estadística

Mientras que los modelos de redes (como el AMM) convergen determinísticamente a medida que se reduce el paso espacial, la simulación de Monte Carlo exhibe una convergencia estocástica. La precisión del método no se mide por un error geométrico, sino por el error estándar (SE) de los payoffs descontados en la muestra. Para evaluar esta dinámica en un entorno exótico, se analizó el comportamiento del error estándar frente al incremento en el número de trayectorias (M) utilizando una opción Put Americana Down-and-Out. Los parámetros del experimento establecen un precio inicial $S_0 = 44$, precio de ejercicio $K = 40$ y una barrera inferior fijada en $H = 39,6$, con vencimiento a un año ($T = 1$), una tasa libre de riesgo del 6 % ($r = 0,06$) y una volatilidad del 20 % ($\sigma = 0,2$) y discretizada en $N = 50$ pasos temporales.

La introducción de esta barrera somete al algoritmo LSM a un doble esfuerzo computacional.

En cada uno de los 50 pasos temporales, no solo debe ejecutar la regresión para estimar el valor de continuación, sino que previamente debe monitorear la trayectoria del precio. Si el activo subyacente cae al nivel de 39,6 o por debajo, la trayectoria sufre un knock-out, su valor se anula (asumiendo un rebate de cero) y queda excluida de las decisiones de ejercicio futuras. La Tabla 8.5 resume el impacto del tamaño muestral sobre la precisión de este cálculo.

8.4. COMPARACIÓN GLOBAL DE MÉTODOS

Tabla 8.5: Convergencia del Error Estándar y Tiempos de Ejecución en Monte Carlo LSM. Opción Put Americana: $S_0 = 44$, $K = 40$, $T = 1$, $r = 0,06$, $\sigma = 0,20$.

Simulaciones (M)	Err. Estándar (SE)	Int. de Confianza (95 %)	Tiempo (milisegundos)
1,000	0.003069	± 0.127	< 5
5,000	0.001363	± 0.055	≈ 12
10,000	0.000952	± 0.039	≈ 22
50,000	0.000420	± 0.017	≈ 62
100,000	0.000375	± 0.012	≈ 728 (con 252 pasos)

Estos resultados empíricos ilustran vívidamente la naturaleza asintótica dictada por el Teorema del Límite Central. El error decrece a una tasa proporcional a $O(1/M)$. Por ejemplo, al pasar de 10,000 a 50,000 simulaciones, el error se reduce a la mitad (de 0,000952 a 0,000420), lo que concuerda con la teoría matemática que establece que para dividir el error por dos, el costo computacional debe multiplicarse por cuatro.

Esta característica revela el principal compromiso (trade-off) de la simulación de Monte Carlo frente a los métodos presentados en la sección anterior. Si bien el modelo es lo suficientemente flexible para acomodar barreras complejas y decisiones americanas vectorizando el código de manera eficiente, lograr intervalos de confianza extremadamente estrechos exige un incremento exponencial en los recursos de cómputo. Además, para barreras continuas, el monitoreo discreto en $N = 50$ o $N = 252$ pasos introduce un sesgo de discretización intrínseco, ya que el precio podría cruzar la barrera entre dos fechas de observación sin ser detectado. En consecuencia, el método LSM se justifica plenamente por su escalabilidad dimensional, aunque para opciones de un único activo subyacente con geometrías estrictas de barrera, los modelos de redes adaptativas resulten más precisos en tiempo de CPU.

8.4. Comparación Global de Métodos

Tras haber analizado el rendimiento individual de cada algoritmo frente a sus desafíos intrínsecos, resulta fundamental establecer una comparación cruzada que consolide los hallazgos de esta investigación. Esta evaluación global no busca declarar un único método como superior de manera absoluta, sino mapear las fortalezas y debilidades de cada enfoque frente a las distintas dimensiones del problema de valoración de opciones barrera.

8.4.1. Resumen de Desempeño

Para sintetizar las propiedades observadas a lo largo de los experimentos numéricos, la Tabla 5.6 presenta un resumen conceptual del perfil de desempeño de las cuatro metodologías estudiadas.

8.4. COMPARACIÓN GLOBAL DE MÉTODOS

Tabla 8.6: Resumen del Perfil de Desempeño de los Métodos de Valoración

Método	Naturaleza	Precisión Numérica	Costo Comp.	Flexibilidad / Extensibilidad
R&R	Analítica / Continua	Exacta (Teórica)	Instantáneo (Bajo)	Muy Baja - Solo Europeas
AMM	Red Discreta (Determinista)	Muy Alta	Muy Bajo $O(N)$	Moderada - Opciones 1D
Replicación Estática	Portafolio de Mercado	Moderada / Alta	Bajo	Alta (Depende del mercado)
LSM	Simulación (Estocástica)	Moderada (SE)	Alto $O(1/\sqrt{M})$	Muy Alta - Americanas - Multi-activo

El análisis conjunto revela un claro compromiso (trade-off) entre eficiencia computacional y flexibilidad. Por un lado, las fórmulas cerradas de Reiner y Rubinstein ofrecen respuestas exactas de forma instantánea, pero exigen que el contrato cumpla estrictamente con los supuestos teóricos de Black-Scholes (monitoreo continuo, volatilidad constante y ausencia de ejercicio anticipado). Cuando se requiere relajar estos supuestos sin perder la eficiencia, el Modelo de Malla Adaptativa (AMM) se posiciona como la herramienta numérica más potente. Al injertar alta resolución espacial únicamente donde es estrictamente necesario, el AMM logra replicar la precisión teórica evadiendo la explosión combinatoria que sufren los árboles estándar.

En el otro extremo del espectro, la simulación de Monte Carlo con el método de Longstaff-Schwartz (LSM) sacrifica la convergencia determinista y el bajo tiempo de CPU a cambio de una extensibilidad casi ilimitada. Al no sufrir la maldición de la dimensionalidad, el LSM es capaz de incorporar monitoreo discreto de la barrera y decisiones de ejercicio americano sin que la estructura del algoritmo colapse. Finalmente, la Replicación Estática ocupa un lugar único en esta comparativa: más que un modelo de tasación puramente matemática, es una estrategia de ingeniería financiera. Su precisión no se mide en decimales matemáticos, sino en la capacidad empírica de anular el riesgo de la barrera utilizando instrumentos líquidos y reales.

8.4.2. Casos de Uso Óptimos

La elección del método adecuado en la práctica profesional no obedece a una jerarquía estricta de superioridad, sino a la naturaleza específica del problema financiero a resolver.

Las **fórmulas de Reiner y Rubinstein** son el estándar de oro para la validación y el benchmarking académico. Su uso es óptimo como “oráculo” en el desarrollo de software financiero, permitiendo a los programadores calibrar el error de sus motores numéricos antes de aplicarlos a casos donde no existe una solución cerrada.

El **Modelo de Malla Adaptativa (AMM)** es la opción indiscutible cuando el problema requiere tasaciones intensivas y repetitivas sobre opciones de un solo activo subyacente. Un caso de uso óptimo para el AMM es el cálculo de volatilidades implícitas. Puesto que los algoritmos de búsqueda de raíces requieren valorar la misma opción decenas de veces ajustando el parámetro de volatilidad, un método estocástico como Monte Carlo introduciría ruido y un árbol estándar

tomaría demasiado tiempo si el precio está cerca de la barrera. El AMM, con su convergencia suave y tiempos de respuesta de fracciones de segundo, resuelve este problema de manera ideal.

La **Replicación Estática** encuentra su caso de uso óptimo en las mesas de trading institucional y en la gestión directa de riesgos. Cuando un banco emite una opción exótica fuertemente no lineal (alta gamma cerca de la barrera), la cobertura dinámica (Delta hedging) se vuelve imprecisa y prohibitivamente costosa debido a los costos de transacción. En estos escenarios, construir un portafolio estático con opciones estándar es la estrategia preferida, ya que permite “inmunizar” el libro de operaciones frente a los saltos bruscos del mercado sin necesidad de rebalanceo continuo.

Por último, el método **LSM de Monte Carlo** es la herramienta esencial para derivados de alta complejidad que escapan a los modelos de redes. Su uso es óptimo cuando la opción barrera es de estilo americano, cuando la barrera se monitorea discretamente (por ejemplo, observando el precio solo al cierre de cada día, lo cual invalida las fórmulas continuas), o cuando el derivado depende de múltiples factores de riesgo interrelacionados (como opciones exóticas sobre cestas de acciones).

8.4.3. Recomendaciones Prácticas

A partir de este análisis, se derivan tres recomendaciones fundamentales para la implementación de sistemas de valoración de opciones barrera:

- En primer lugar, los sistemas modernos no deben depender de un único motor de cálculo, sino de una arquitectura híbrida. Se recomienda utilizar el AMM para la tasación en tiempo real y el cálculo de sensibilidades (las “Griegas”) de opciones europeas y americanas unidimensionales, limitando el uso intensivo de Monte Carlo exclusivamente a los contratos que involucren trayectorias complejas o múltiples variables de estado.
- En segundo lugar, en lo que respecta a la gestión de riesgos, es vital no confundir el “valor teórico matemático” con el “costo real de cobertura”. Se recomienda a los operadores utilizar la Replicación Estática para establecer un límite superior al precio de la opción exótica. Si el portafolio replicante discreto (construido con opciones vanilla de mercado) resulta más costoso que el valor teórico arrojado por el AMM o LSM, esa diferencia debe ser considerada como una prima de riesgo operativo y de liquidez que el modelo matemático puro es incapaz de capturar.
- Finalmente, si la decisión recae en implementar Monte Carlo mediante el algoritmo LSM, es altamente recomendable aprovechar su capacidad inherente de paralelización. Dado que la evaluación transversal de las trayectorias es su principal cuello de botella de rendimiento, distribuir la simulación y la regresión de mínimos cuadrados en múltiples procesadores es una práctica obligatoria para reducir el error estadístico a niveles tolerables sin comprometer la viabilidad comercial del modelo.

8.5. Discusión

8.5.1. Ventajas y Desventajas Observadas

A lo largo de los experimentos numéricos desarrollados en este capítulo, se evidenció que la valoración de opciones barrera impone exigencias matemáticas que ningún método individual puede resolver de manera óptima en todas sus dimensiones. El contraste de los resultados nos permite destilar las fortalezas y debilidades intrínsecas de cada enfoque.

Por el lado de los métodos determinísticos, las fórmulas analíticas de Reiner y Rubinstein confirmaron su estatus de estándar de oro para la validación de algoritmos, ofreciendo una precisión absoluta con un costo computacional nulo. Sin embargo, su extrema rigidez metodológica las vuelve ineficaces para contratos que se desvían de los supuestos continuos ideales. Como respuesta a esto, el Modelo de Malla Adaptativa (AMM) demostró ser la solución numérica más sofisticada para opciones de un único activo subyacente. Su principal ventaja observada fue la capacidad de neutralizar el error de no linealidad y resolver el “problema del límite” sin incurrir en la explosión combinatoria de los árboles estándar. La desventaja del AMM, no obstante, radica en su vulnerabilidad a la maldición de la dimensionalidad; su arquitectura espacial lo vuelve ineficiente si se intentara modelar derivados dependientes de múltiples activos correlacionados al mismo tiempo.

Desde la perspectiva de la gestión de riesgos, la Replicación Estática de Derman, Ergener y Kani demostró la ventaja incomparable de inmunizar un portafolio contra movimientos bruscos sin la necesidad de rebalanceo dinámico continuo. Esto reduce drásticamente la exposición operativa. Su desventaja principal es la dependencia empírica en la liquidez del mercado: el método asume que siempre existirán opciones vanilla disponibles con los precios de ejercicio y vencimientos exactos requeridos para cubrir la frontera, lo cual rara vez ocurre en la realidad sin incurrir en costos de interpolación.

Finalmente, la simulación de Monte Carlo equipada con el método de Longstaff-Schwartz (LSM) exhibió como gran ventaja su universalidad y flexibilidad. Fue el único método capaz de manejar simultáneamente el monitoreo discreto de trayectorias y el ejercicio anticipado americano de forma natural. Sin embargo, la gran desventaja observada fue su lenta convergencia estocástica. Alcanzar el nivel de precisión geométrica de cuatro decimales que el AMM logra en fracciones de segundo requeriría un esfuerzo computacional inmanejable en Monte Carlo, confirmando que este último debe reservarse para problemas donde los métodos de red colapsan.

8.5.2. Limitaciones del Estudio

A pesar de la exhaustividad del análisis comparativo, es importante enmarcar los resultados obtenidos dentro de las limitaciones teóricas y prácticas de este trabajo. En primer lugar, todos los modelos numéricos implementados fueron contruidos y calibrados bajo el entorno del modelo de Black-Scholes. Esto implica que los experimentos asumieron una volatilidad constante y tasas de interés deterministas a lo largo de toda la vida de la opción. En los mercados financieros reales, la volatilidad exhibe comportamientos estocásticos, asimetrías y sonrisas (smiles). Si bien métodos como Monte Carlo pueden adaptarse fácilmente

a procesos más complejos (como modelos de difusión con saltos o volatilidad estocástica), el impacto de estos fenómenos en el error de discretización de los árboles adaptativos y en el costo del portafolio replicante no fue medido en este estudio.

En segundo lugar, el análisis de la Replicación Estática se realizó bajo el supuesto de mercados sin fricciones. La estimación del costo del portafolio replicante (por ejemplo, el uso de 24 opciones de ajuste) se basó en precios teóricos puros, ignorando el spread oferta-demanda y los costos de transacción reales. En la práctica de una mesa de dinero, comprar y vender docenas de opciones quincenales para cubrir una barrera podría erosionar significativamente el margen de ganancia de la operación, un factor de riesgo de liquidez que nuestras métricas de error absoluto no capturan.

Por último, en lo que respecta a la validación de Monte Carlo, el monitoreo del evento de knock-out o knock-in se evaluó de forma estrictamente discreta en los pasos temporales simulados (por ejemplo, 50 o 252 pasos por año). Esto introduce un sesgo intínseco conocido, ya que el precio real del activo podría haber cruzado la barrera continua entre dos fechas de observación sin que el algoritmo lo detecte. La aplicación de técnicas avanzadas de interpolación estocástica, como los puentes brownianos (Brownian bridges), para corregir este sesgo de monitoreo continuo en simulaciones discretas, queda fuera del alcance de esta investigación.

Capítulo 9

Conclusiones y Trabajo Futuro

9.1. Resumen de Resultados

El presente trabajo de investigación evaluó y comparó sistemáticamente cuatro metodologías fundamentales para la valoración de opciones barrera, abarcando desde soluciones analíticas hasta técnicas numéricas avanzadas. Los resultados obtenidos demostraron que las ecuaciones de Reiner y Rubinstein proveen un valor teórico exacto bajo supuestos continuos, consolidándose como el estándar de oro para la validación algorítmica. Al trasladar el problema de tasación a redes discretas, se comprobó empíricamente que los árboles trinomiales estándar colapsan a nivel computacional cuando el precio del activo se encuentra críticamente cerca de la barrera. Sin embargo, la implementación del Modelo de Malla Adaptativa (AMM) superó este obstáculo con notable éxito, logrando aislar el error de no linealidad y alcanzando una precisión de hasta cuatro decimales en fracciones de segundo.

Desde la perspectiva de la cobertura en el mercado, los experimentos con la técnica de Replicación Estática evidenciaron que la convergencia teórica tiene un correlato práctico directo: el aumento en la frecuencia de ajuste del portafolio replicante (utilizando opciones vanilla) reduce el costo y el riesgo del desajuste a niveles marginales, validando el método como una alternativa superior a la cobertura dinámica continua. Finalmente, para el entorno de las opciones de estilo americano, la simulación de Monte Carlo equipada con el algoritmo de Longstaff-Schwartz demostró ser robusta frente al desafío del ejercicio anticipado, aunque puso en evidencia que su flexibilidad estructural conlleva un alto costo computacional dictado por su lenta convergencia estocástica (un trade-off fundamental).

9.2. Conclusiones Principales

9.2.1. Sobre los Métodos para Opciones Europeas

El análisis del “problema del límite” y del error de discretización espacial arroja una conclusión clara para el desarrollo de software financiero: la fuerza

bruta no es una solución viable. Incrementar masivamente el número de pasos en un árbol estándar para alinear los nodos con la barrera resulta computacionalmente ineficiente. El AMM demuestra que una distribución inteligente de los recursos de hardware, injertando mallas de alta resolución única y exclusivamente en las regiones críticas de la opción, es la estrategia numérica óptima para derivados dependientes de la trayectoria sobre un único activo. A su vez, los resultados de la Replicación Estática permiten concluir que el valor de una opción exótica no debe interpretarse únicamente como el resultado de una ecuación diferencial, sino como el costo real de ensamblar un rompecabezas de instrumentos estándar en el mercado, donde la granularidad temporal de los contratos determina el riesgo residual que asume el emisor.

9.2.2. Sobre Monte Carlo para Opciones Americanas

La implementación de la metodología de Longstaff-Schwartz permite concluir que la estimación del valor de continuación mediante una regresión de mínimos cuadrados de corte transversal (utilizando, por ejemplo, polinomios de Laguerre) resuelve de manera elegante y eficiente la paradoja de la inducción hacia atrás en trayectorias simuladas. No obstante, la naturaleza de su convergencia impone un límite práctico ineludible. Dado que el error decrece a una tasa proporcional a la raíz cuadrada del tamaño muestral, alcanzar los niveles de precisión extremos que los métodos de red logran instantáneamente requiere un esfuerzo computacional exponencial. Por consiguiente, se concluye que el método de Monte Carlo debe reservarse no como la primera línea de defensa, sino como la herramienta definitiva frente a problemas intratables por otros medios.

9.2.3. Comparación Global

La conclusión fundamental que se desprende de esta investigación es que no existe una jerarquía absoluta entre los modelos de valoración estudiados; su supremacía está dictada enteramente por el contexto y las dimensiones del problema. Mientras que el AMM domina en eficiencia y precisión determinista para contratos unidimensionales, la simulación de Monte Carlo es la elección insustituible para evitar la maldición de la dimensionalidad en opciones complejas o de múltiples activos. La Replicación Estática, por su parte, actúa como el puente indispensable entre la teoría matemática y la práctica real de las mesas de dinero. En definitiva, la ingeniería financiera moderna exige una arquitectura algorítmica híbrida, requiriendo que el analista comprenda las mecánicas internas de cada método para seleccionar la herramienta que mejor equilibre el rigor matemático con la viabilidad operativa.

9.3. Trabajo Futuro

El análisis comparativo desarrollado en esta investigación establece una base sólida para la valoración de opciones barrera, pero al mismo tiempo abre múltiples vías para futuras expansiones, tanto desde la perspectiva teórica como en su aplicación algorítmica.

9.3.1. Extensiones del Modelo

La primera y más natural extensión de este trabajo consistiría en relajar los supuestos del modelo clásico de Black-Scholes. Dado que se ha comprobado que la volatilidad en los mercados reales no es constante, sino que exhibe sonrisas y asimetrías (smiles y skews), un paso fundamental sería adaptar las metodologías numéricas a modelos de volatilidad estocástica o modelos de difusión con saltos (como el propuesto por Merton (1976)). Mientras que la simulación de Monte Carlo puede acomodar estas dinámicas estocásticas con relativa facilidad modificando la ecuación diferencial de las trayectorias, adaptar el Modelo de Malla Adaptativa (AMM) a entornos donde la volatilidad cambia con el precio del activo sería un desafío matemático y de programación considerable, pero de gran valor académico.

9.3.2. Extensiones de los Métodos

A nivel algorítmico, existen mejoras puntuales que podrían incrementar la exactitud de los métodos estudiados. Para el enfoque de simulación de Monte Carlo, el principal problema detectado fue el sesgo de discretización al monitorear la barrera en pasos de tiempo finitos (por ejemplo, diariamente). Un trabajo futuro podría implementar la técnica de Puentes Brownianos (Brownian Bridges) dentro del algoritmo de Longstaff-Schwartz. Esta técnica probabilística permite calcular la probabilidad exacta de que el activo haya cruzado la barrera entre dos fechas de observación discretas, eliminando el sesgo de monitoreo sin necesidad de multiplicar el esfuerzo computacional generando pasos de tiempo diminutos.

Por el lado del Modelo de Malla Adaptativa, si bien demostró ser inmensamente superior para opciones unidimensionales, un área de investigación abierta es el desarrollo de mallas adaptativas multidimensionales. Lograr injertar alta resolución tridimensional para evaluar opciones exóticas sobre cestas de activos correlacionados expandiría drásticamente la utilidad de los métodos de redes discretas frente al monopolio actual de Monte Carlo en esos escenarios.

9.3.3. Aplicaciones Prácticas y Validación Empírica

Finalmente, el salto definitivo de esta investigación sería llevar los algoritmos desde un entorno de simulación pura hacia una validación empírica con datos reales de mercado. En particular, la metodología de Replicación Estática ganaría enorme profundidad si se la pusiera a prueba utilizando superficies de volatilidad reales y spreads oferta-demanda extraídos de una bolsa de derivados (como Matba ROFEX o ByMA) o del mercado interbancario (como MAE). Construir el portafolio replicante midiendo los costos de transacción reales, la liquidez de los instrumentos estándar disponibles para el ajuste y el riesgo de gap (saltos de precio nocturnos) permitiría evaluar empíricamente si la inmunización estática prometida por la teoría matemática sobrevive a la fricción física del mercado financiero.

Referencias

- Black, F., y Scholes, M. (1973). The pricing of options and corporate liabilities. *Journal of political economy*, 81(3), 637–654.
- Boyle, P. P., y Lau, S. H. (1994). Bumping up against the barrier with the binomial method. *The Journal of Derivatives*, 1(4), 6–14.
- Derman, E., Ergener, D., y Kani, I. (1994). Static replication of barrier options. *The Journal of Derivatives*, 2(2), 78–95.
- Figlewski, S., y Gao, B. (1999). The adaptive mesh model: a new approach to efficient option pricing. *The Journal of Financial Engineering*, 8, 211–241.
- Longstaff, F. A., y Schwartz, E. S. (2001). Valuing american options by simulation: A simple least-squares approach. *The Review of Financial studies*, 14(1), 113–147.
- Merton, R. C. (1976). Option pricing when underlying stock returns are discontinuous. *Journal of Financial Economics*, 3(1), 125–144. Descargado de <https://www.sciencedirect.com/science/article/pii/0304405X76900222> doi: [https://doi.org/10.1016/0304-405X\(76\)90022-2](https://doi.org/10.1016/0304-405X(76)90022-2)
- Reiner, E., y Rubinstein, M. (1991). Breaking down barrier options. *Risk*, 4(8), 28–35.